



Penerbit
Gita Lentera

PENGANTAR PEMBELAJARAN MACHINE LEARNING

Januardi Nasir, S.Kom., M.Kom.
Yonky Fernando, S.Kom., M.Kom.
Masna Wati, S.Si., M.T.
Dr. Yodhi Yuniarthe, M.Kom.
Oktavia, S.Si., M.Si.
Siti Nurhayati, S.Kom., M.Kom.

Dr. Sri Lestari, S.Kom., M.Cs.
Pradita Eko Prasetyo Utomo, M.Cs.
Sharfina Faza, S. Kom., M. Kom.
Yuliana, M.Cs.
Rezza Anugrah Mutiarawan, S.Kom, M.Kom.
Santi Prayudani, S.Kom., M.Kom.
Zulfan, S.T., M.T.

PENGANTAR MACHINE LEARNING

Penulis:

Januardi Nasir, S.Kom., M.Kom.

Yonky Pernando, S.Kom., M.Kom.

Masna Wati, S.Si., M.T.

Dr. Yodhi Yuniarthe, M.Kom.

Oktavia, S.Si., M.Si.

Siti Nurhayati, S.Kom., M.Kom.

Dr. Sri Lestari, S.Kom., M.Cs.

Pradita Eko Prasetyo Utomo., M.Cs.

Sharfina Faza, S.Kom., M.Kom.

Yuliana, M.Cs.

Rezza Anugrah Mutiarawan, S.Kom, M.Kom.

Santi Prayudani, S.Kom., M.Kom.

Zulfan, S.T., M.T.



Penerbit:

CV. Gita Lentera

One Step to Publish your Ideas

Pengantar Machine Learning

Penulis:

Januardi Nasir, S.Kom., M.Kom.
Yonky Pernando, S.Kom., M.Kom.
Masna Wati, S.Si., M.T.
Dr. Yodhi Yuniarthe, M.Kom.
Oktavia, S.Si., M.Si.
Siti Nurhayati, S.Kom., M.Kom.
Dr. Sri Lestari, S.Kom., M.Cs.
Pradita Eko Prasetyo Utomo., M.Cs.
Sharfina Faza, S.Kom., M.Kom.
Yuliana, M.Cs.
Rezza Anugrah Mutiarawan, S.Kom, M.Kom.
Santi Prayudani, S.Kom., M.Kom.
Zulfan, S.T., M.T.

Editor:

Yasha Langitta Setiawan, S.I.Kom., M.I.Kom.

ISBN: 978-634-7072-69-6

CV. Gita Lentera

Redaksi:

Perm. Permata hijau regency blok F/1 kelurahan Pisang kecamatan Pauh kota
Padang, Sumatera Barat

<https://gitalentera.com> / git4lenter4@gmail.com

Anggota IKAPI

All right reserved

Cetakan Pertama: 2025

Hak Cipta dilindungi oleh Undang-undang. Dilarang memperbanyak karya tulis ini dalam bentuk apapun tanpa izin penerbit.

SINOPSIS

Buku ini berisi pemahaman menyeluruh tentang konsep pembelajaran mesin. Tidak hanya mahasiswa, tetapi juga profesional perangkat lunak akan menemukan berbagai teknik dengan pembahasan yang memadai dalam buku ini yang memenuhi kebutuhan lingkungan profesional. Manajer teknis akan memperoleh wawasan tentang penerapan pembelajaran mesin ke dalam keseluruhan proses rekayasa perangkat lunak. Mahasiswa, pengembang, dan manajer teknis dengan latar belakang dasar ilmu komputer akan merasa materi dalam buku ini mudah dibaca. Setiap bab dimulai dengan paragraf pengantar, yang memberikan gambaran umum bab tersebut beserta tabel cakupan bab yang mencantumkan topik-topik yang dibahas dalam bab tersebut. Contoh pertanyaan di akhir bab membantu siswa mempersiapkan diri untuk ujian. Poin-poin pembahasan dan Poin-poin untuk direnungkan yang diberikan di dalam bab-bab membantu memperjelas dan memahami bab-bab tersebut dengan mudah dan juga mengeksplorasi kemampuan berpikir siswa dan profesional. Ringkasan diberikan di akhir setiap bab untuk tinjauan singkat topik-topik tersebut. Di seluruh buku ini, Anda akan melihat banyak latihan dan pertanyaan diskusi. Jangan lewatkan latihan-latihan ini – latihan-latihan ini penting untuk memahami konsep-konsep machine learning secara menyeluruh. Buku ini dimulai dengan pengantar tentang Pembelajaran Mesin yang menjadi landasan teori untuk bab-bab selanjutnya. Pemodelan, Rekayasa fitur, dan probabilitas dasar dibahas sebagai bab-bab sebelum memasuki dunia pembelajaran mesin yang membantu memahami konsep pembelajaran mesin dengan mudah di lain waktu.

KATA PENGANTAR

Permintaan berulang dari mahasiswa Ilmu Komputer dan teknik TI yang merupakan pembaca buku-buku kami sebelumnya mendorong kami untuk menulis buku ini tentang pembelajaran mesin. Konsep pembelajaran mesin dan potensi besar penerapannya masih merupakan pengetahuan khusus dan belum tersebar luas di kalangan komunitas mahasiswa. Jadi, kami berpikir untuk menulis buku ini khusus untuk para teknisi, mahasiswa, dan manajer junior sehingga mereka memahami konsep pembelajaran mesin dengan mudah. Mereka seharusnya tidak hanya menggunakan paket perangkat lunak pembelajaran mesin, tetapi juga memahami konsep di balik paket tersebut. Penerapan pembelajaran mesin semakin meningkat dari hari ke hari. Dari merekomendasikan produk kepada pembeli, hingga memprediksi pasar real estat masa depan, hingga membantu praktisi medis dalam diagnosis, hingga mengoptimalkan konsumsi energi, sehingga membantu tujuan Bumi Hijau, pembelajaran mesin menemukan kegunaannya di setiap bidang kehidupan.

Padang, 06 Maret 2025

Tim Penulis

KATA SAMBUTAN

Buku dalam bidang Teknologi Informasi dengan tema: Pengantar Pembelajaran Machine Learning adalah buku Publikasi Ilmiah yang bekerjasama dengan beberapa dosen dalam bidang informati dan bidang keteknikan lainnya. Buku ini merupakan kumpulan artikel yang ditulis oleh para peneliti/dosen sejumlah perguruan tinggi, baik yang berasal dari dalam dalam negeri. Sebagian besar penulisnya adalah dengan latar belakang informatika dan ditambah pula dengan sejumlah penulis yang bidang keilmuannya juga terkait erat dengan bidang informatika. Didalamnya terdapat sejumlah khazanah pemikiran intelektual serta hasil riset dalam bidang ilmu informatika yang sangat relevan dengan kondisi kekinian. Kompetensi keilmuan dan pengalaman masing masing penulis dalam menyusun artikel yang terdapat dalam buku ini, tentu saja sangat memperkaya khazanah pemikiran intelektual yang dimiliki oleh bangsa ini, khususnya di kalangan ilmuwan dengan kualifikasi doktor yang tentu saja memiliki tanggungjawab moral dan tanggungjawab intelektual yang sangat berat yaitu harus terlibat secara aktif dalam mencerdaskan kehidupan bangsa.

Padang, 06 Maret 2025

Tim Penulis

DAFTAR ISI

Sinopsis	iii
Kata Pengantar	iv
Kata Sambutan	v
Bab 1 Pengantar Machine Learning	1
1.1 PENDAHULUAN	1
1.2 APA ITU PEMBELAJARAN MANUSIA?	5
1.3 JENIS PEMBELAJARAN MANUSIA	5
1.3.1 Pembelajaran di bawah bimbingan ahli	6
1.3.2 Pembelajaran dipandu oleh pengetahuan yang diperoleh dari para ahli	7
1.3.3 Belajar secara mandiri	8
1.4 APA ITU PEMBELAJARAN MESIN?	8
1.4.1 Bagaimana mesin belajar?	10
1.4.2 Masalah pembelajaran yang dirumuskan dengan baik	15
1.5 JENIS PEMBELAJARAN MESIN	17
1.5.1 Pembelajaran terbimbing	18
1.5.2 Pembelajaran tanpa pengawasan	24
1.5.3 Pembelajaran penguatan	27
1.5.4 Perbandingan – pembelajaran terbimbing, tanpa bimbingan, dan penguatan	28
1.6 MASALAH YANG TIDAK DAPAT DISELESAIKAN DENGAN MENGGUNAKAN MACHINE LEARNING	29
1.7 APLIKASI PEMBELAJARAN MESIN	29

1.7.1 Perbankan dan keuangan	30
1.7.2 Asuransi	31
1.7.3 Pelayanan Kesehatan	31
1.8 BAHASA/ALAT TERKINI DALAM PEMBELAJARAN MESIN.....	32
1.8.1 Python	32
1.8.2 R.....	33
1.8.3 Bahasa Pemrograman Matlab	33
1.8.4 SAS ('Statistical Analysis System')	34
1.8.5 Bahasa/alat lainnya.....	34
1.9 MASALAH DALAM PEMBELAJARAN MESIN.....	35
1.10 RINGKASAN	37
Bab 2 Persiapan untuk Membuat Model.....	43
2.1 PENDAHULUAN	43
2.2 AKTIVITAS PEMBELAJARAN MESIN	46
2.3 JENIS DATA DASAR DALAM PEMBELAJARAN MESIN	48
2.4 MENJELAJAHI STRUKTUR DATA	54
2.4.1 Menjelajahi data numerik	56
2.4.2 Plotting dan eksplorasi data numerik	63
2.4.3 Menjelajahi data kategorikal	73
2.4.4 Menjelajahi hubungan antar variable	76
2.5 KUALITAS DATA DAN REMEDIASI	81
2.5.1 Kualitas data	81
2.5.2 Remediasi data	82
2.6 PRA-PEMROSESAN DATA.....	86

2.6.1 Pengurangan dimensi	86
2.6.2 Pemilihan subset fitur	88
2.7 RINGKASAN	89
Bab 3 Pemodelan dan Evaluasi	95
3.1 PENDAHULUAN	95
3.2 MEMILIH MODEL	99
3.2.1 Model prediktif	102
3.2.2 Model deskriptif	103
3.3 PELATIHAN MODEL (UNTUK PEMBELAJARAN TERAWASI)	104
3.3.1 Metode Holdout	104
3.3.2 Metode Validasi Silang K-fold	106
3.3.3 Pengambilan sampel bootstrap	109
3.3.4 Pembelajar yang malas vs. Pembelajar yang bersemangat	110
3.4 REPRESENTASI DAN INTERPRETABILITAS MODEL	112
3.4.1 Pemasangan yang kurang pas	112
3.4.2 Penyesuaian berlebihan	113
3.4.3 Bias – trade-off varians.	114
3.5 EVALUASI KINERJA MODEL	117
3.5.1 Pembelajaran terbimbing – klasifikasi	117
3.5.2 Pembelajaran terbimbing – regresi	127
3.5.3 Pembelajaran tanpa pengawasan - pengelompokan	129
3.6 MENINGKATKAN KINERJA MODEL	133
3.7 RINGKASAN	137

Bab 4 Dasar-dasar Rekayasa Fitur.....	145
4.1 PENDAHULUAN	145
4.1.1 Apa itu fitur?	146
4.1.2 Apa itu rekayasa fitur?	147
4.2 TRANSFORMASI FITUR	149
4.2.1 Konstruksi fitur	150
4.2.2 Ekstraksi fitur	156
4.3 PEMILIHAN SUBSET FITUR	163
4.3.1 Masalah dalam data berdimensi tinggi	164
4.3.2 Penggerak utama pemilihan fitur – relevansi dan redundansi fitur	165
4.3.3 Ukuran relevansi dan redundansi fitur	167
4.3.4 Proses pemilihan fitur secara keseluruhan.....	174
4.3.5 Pendekatan pemilihan fitur	176
4.4 RINGKASAN	178
Bab 5 Tinjauan Singkat tentang Probabilitas	186
5.1 PENDAHULUAN	186
5.2 PENTINGNYA ALAT STATISTIK DALAM PEMBELAJARAN MESIN ..	187
5.3 KONSEP PROBABILITAS – INTERPRETASI FREKUENTIS DAN BAYESIAN.....	189
5.3.1 Tinjauan singkat tentang teori probabilitas.....	190
5.4 VARIABEL ACAK	196
5.4.1 Variabel acak diskrit.....	197
5.4.2 Variabel acak kontinyu.....	199

5.5 BEBERAPA DISTRIBUSI DISKRET YANG UMUM.....	202
5.5.1 Distribusi Bernoulli	202
5.5.2 Distribusi Binomial.....	202
5.5.3 Distribusi multinomial dan multinoulli	204
5.5.4 Distribusi Poisson.....	205
5.6 BEBERAPA DISTRIBUSI BERKESINAMBUNGAN YANG UMUM	206
5.6.1 Distribusi seragam	206
5.6.2 Distribusi Gaussian (normal)	208
5.6.3 Distribusi Laplace.....	211
5.7 BEBERAPA VARIABEL ACAK	212
5.7.1 Variabel acak bivariat.....	212
5.7.2 Fungsi distribusi bersama	213
5.7.3 Fungsi massa probabilitas gabungan	214
5.7.5 Distribusi bersyarat.....	215
5.7.6 Kovariansi dan korelasi	216
5.8 TEOREMA BATAS PUSAT	218
5.9 DISTRIBUSI SAMPEL	219
5.9.1 Pengambilan sampel dengan penggantian.....	220
5.9.2 Pengambilan sampel tanpa penggantian	221
5.9.3 Rata-rata dan varians sampel	221
5.10 PENGUJIAN HIPOTESIS	223
5.11. PERKIRAAN MONTE CARLO.....	226
5.12 RINGKASAN	227
SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI)	232

Bab 6 Pembelajaran Konsep Bayesian	237
6.1 PENDAHULUAN	237
6.2 MENGAPA METODE BAYESIAN PENTING?	238
6.3 TEOREMA BAYES	240
6.3.1 Sebelumnya	242
6.3.2 Belakang	243
6.3.3 Kemungkinan	244
6.4 TEOREMA BAYES DAN KONSEP PEMBELAJARAN	247
6.4.1 Algoritma Bayesian dengan metode brute force.....	247
6.4.2 Konsep pembelajar yang konsisten	251
6.4.3 Klasifikasi optimal Bayes	251
6.4.4 Pengklasifikasi Naïve Bayes	253
6.4.5 Aplikasi Klasifikasi Naïve Bayes	262
6.4.6 Penanganan Fitur Numerik Kontinu dalam Naïve Bayes Classifier.....	264
6.5 JARINGAN KEYAKINAN BAYESIAN	265
6.5.1 Independensi dan independensi bersyarat	267
6.5.2 Penggunaan jaringan Keyakinan Bayesian dalam pembelajaran mesin	272
6.6 RINGKASAN	273
Bab 7 Pembelajaran Terbimbing: Klasifikasi	282
7.1 PENDAHULUAN	282
7.2 CONTOH PEMBELAJARAN TERAWASI.....	283
7.3 MODEL KLASIFIKASI.....	285

7.4 LANGKAH PEMBELAJARAN KLASIFIKASI.....	287
7.5 ALGORITMA KLASIFIKASI UMUM	290
7.6 RINGKASAN	336
Bab 8 Pembelajaran Terbimbing: Regresi	347
8.1 PENDAHULUAN	347
8.2 CONTOH REGRESI.....	348
8.3 ALGORITMA REGRESI UMUM	349
8.3.1 Regresi Linier Sederhana	350
8.3.3 Asumsi dalam Analisis Regresi.....	364
8.3.5 Meningkatkan Akurasi Regresi Linier.....	366
8.4 RINGKASAN	377
SOAL PILIHAN GANDA	380
SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI)	383
Bab 9 Pembelajaran Tanpa Pengawasan	386
9.1 PENDAHULUAN	386
9.2 PEMBELAJARAN TANPA PENGAWASAN VS PEMBELAJARAN DENGAN PENGAWASAN.....	387
9.3 PENERAPAN PEMBELAJARAN TANPA PENGAWASAN	388
9.4 PENGELOMPOKAN	389
9.4.2 Berbagai jenis teknik pengelompokan	395
9.5 MENEMUKAN POLA DENGAN MENGGUNAKAN ATURAN ASOSIASI	414
9.5.1 Definisi istilah umum	415
9.5.2 Aturan asosiasi.....	417

9.5.3 Algoritma apriori untuk pembelajaran aturan asosiasi	419
9.5.4 Membangun aturan prinsip apriori	421
9.6 RINGKASAN	426
SOAL PILIHAN GANDA (MASING-MASING 1 NILAI)	428
Bab 10 Dasar-dasar Jaringan Syaraf Tiruan	433
10.1 PENDAHULUAN	433
10.2 MEMAHAMI NEURON BIOLOGIS.....	435
10.3 MENJELAJAHI NEURON BUATAN	436
10.4 JENIS FUNGSI AKTIVASI	438
10.4.1 Fungsi identitas.....	438
10.4.2 Fungsi ambang batas/langkah	438
10.4.3 Fungsi ReLU (Rectified Linear Unit)	439
10.4.4 Fungsi sigmoid	440
10.4.5 Fungsi tangen hiperbolik	441
10.5 IMPLEMENTASI AWAL ANN	442
10.5.1 Model neuron McCulloch–Pitts	442
10.5.2 Perseptron Rosenblatt	444
10.5.3 Model jaringan ADALINE	450
10.6 ARSITEKTUR JARINGAN SYARAF	451
10.6.1 Jaringan umpan maju satu lapis	452
10.6.2 Jaringan ANN umpan maju multi-lapis	453
10.6.3 Jaringan kompetitif	454
10.6.4 Jaringan berulang	455
10.7 PROSES PEMBELAJARAN DI ANN	456

10.7.1 Jumlah lapisan	457
10.7.2 Arah aliran sinyal	457
10.7.3 Jumlah node dalam lapisan	457
10.7.4 Bobot interkoneksi antar neuron.....	458
10.8 PROPAGASI KEMBALI.....	459
10.9 PEMBELAJARAN MENDALAM	464
10.10 RINGKASAN	465
SOAL PILIHAN GANDA.....	467
SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI).....	470
Bab 11 PEMBELAJARAN REPRESENTASI	473
11.1 PENDAHULUAN	473
11.2 PEMBELAJARAN REPRESENTASI	473
11.2.1 Jaringan saraf terbimbing dan multilayer perceptron	476
11.2.2 Analisis komponen independen (Tanpa pengawasan)	476
11.2.3 Pengode Otomatis	477
11.3 PEMBELAJARAN AKTIF	479
11.3.1 Heuristik untuk pembelajaran aktif	479
11.3.2 Strategi kueri pembelajaran aktif	480
11.4 PEMBELAJARAN BERBASIS INSTANCE (PEMBALASAN BERBASIS MEMORI).....	481
11.4.1 Fungsi basis radial.....	482
11.4.2 Pro dan kontra metode pembelajaran berbasis instans..	484
11.5 RINGKASAN	484
C SOAL PILIHAN GANDA (SOAL 1 NILAI)	486

BAB 12 ALGORITMA PEMBELAJARAN ATURAN ASOSIASI	488
12.1 Algoritma Apriori.....	488
12.2 Algoritma Eclat.....	489
12.3 ALGORITMA PEMBELAJARAN ENSEMBLE	489
12.3.1 Agregasi bootstrap (Bagging).....	490
12.3.2 Meningkatkan.....	491
12.3.3 Mesin penguat gradien (GBM)	492
12.4.7 ALGORITMA REGULASI	492
12.5 RINGKASAN	493
DAFTAR PUSTAKA.....	496

Bab 1 Pengantar Machine Learning

Januardi Nasir, S.Kom., M.Kom.

A. Tujuan Pembelajaran

Tujuan dari bab ini adalah untuk menjelajah ke dalam arena pembelajaran mesin. Para pendatang baru berjuang keras untuk memahami filosofi pembelajaran mesin. Selain itu, mereka tidak tahu harus mulai dari mana dan masalah mana yang dapat dan harus dipecahkan menggunakan alat dan teknik pembelajaran mesin. Bab ini dimaksudkan untuk memberikan para pendatang baru titik awal untuk perjalanan dalam pembelajaran mesin. Bab ini dimulai dari perjalanan historis di bidang ini dan membawanya maju untuk memberikan gambaran sekilas tentang aplikasi masa kini.

1.1 PENDAHULUAN

Sudah lebih dari 20 tahun sejak sebuah program komputer mengalahkan juara dunia dalam sebuah permainan yang dianggap membutuhkan banyak kecerdasan untuk memainkannya. Program komputer tersebut adalah Deep Blue milik IBM dan berhasil mengalahkan juara catur dunia, Gary Kasparov. Saat itu, mungkin, sebagian besar orang menaruh perhatian serius pada bidang ilmu komputer yang berkembang pesat atau lebih khusus lagi kecerdasan buatan – yaitu pembelajaran mesin (ML).

Sampai saat ini, pembelajaran mesin adalah bidang teknologi yang matang yang menemukan penerapannya di hampir setiap bidang kehidupan. Ia dapat merekomendasikan mainan untuk balita dengan cara yang sama seperti ia dapat menyarankan buku teknologi untuk seorang

geek atau judul yang kaya dalam literatur untuk seorang penulis. Ia memprediksi pasar masa depan untuk membantu pedagang amatir bersaing dengan pedagang saham berpengalaman. Ia membantu seorang onkolog menemukan apakah tumor ganas atau jinak. Ia membantu dalam mengoptimalkan konsumsi energi sehingga membantu tujuan Bumi Hijau. Google telah menjadi salah satu pelopor yang memfokuskan banyak penelitiannya pada pembelajaran mesin dan kecerdasan buatan – mobil self-driving Google dan Google Brain menjadi dua proyek Google yang paling ambisius dalam perjalanannya berinovasi di bidang pembelajaran mesin. Singkatnya, pembelajaran mesin telah menjadi cara hidup, tidak peduli bidang kehidupan mana yang kita perhatikan dengan saksama. Tetapi dari mana semuanya dimulai?

Dasar pembelajaran mesin dimulai pada abad ke-18 dan ke-19. Karya terkait pertama muncul pada tahun 1763. Pada tahun itu, karya Thomas Bayes 'An Essay towards solving a Problem in the Doctrine of Chances' diterbitkan dua tahun setelah kematiannya. Karya ini merupakan dasar dari Teorema Bayes, karya fundamental yang menjadi dasar sejumlah algoritma pembelajaran mesin. Pada tahun 1812, Teorema Bayes diformalkan oleh matematikawan Prancis Pierre-Simon Laplace. Metode kuadrat terkecil, yang merupakan konsep dasar untuk memecahkan masalah regresi, diformalkan pada tahun 1805. Pada tahun 1913, Andrey Markov menemukan konsep rantai Markov.

Namun, awal mula kerja yang terfokus di bidang pembelajaran mesin dianggap sebagai karya penting Alan Turing pada tahun 1950. Dalam makalahnya 'Computing Machinery and Intelligence' (Mind, New Series, Vol. 59, No. 236, Okt., 1950, hlm. 433–460), Turing mengajukan pertanyaan 'Bisakah mesin berpikir?' atau dengan kata lain, 'Apakah mesin memiliki kecerdasan?'. Dia adalah orang pertama yang mengusulkan bahwa mesin dapat 'belajar' dan menjadi cerdas secara artifisial. Pada tahun 1952, Arthur Samuel dari laboratorium IBM mulai mengerjakan

program pembelajaran mesin, dan pertama kali mengembangkan program yang dapat memainkan Catur. Pada tahun 1957, Frank Rosenblatt merancang program jaringan saraf pertama yang mensimulasikan otak manusia. Sejak saat itu, selama 50 tahun berikutnya, perjalanan pembelajaran mesin menjadi sangat menarik. Sejumlah algoritma pembelajaran mesin diformulasikan oleh berbagai peneliti, misalnya algoritma tetangga terdekat pada tahun 1969, jaringan saraf berulang pada tahun 1982, mesin vektor pendukung, dan algoritma hutan acak pada tahun 1995. Prestasi terbaru dalam pengembangan pembelajaran mesin adalah program AlphaGo milik Google, yang telah mengalahkan pemain Go manusia profesional dengan menggunakan teknik pembelajaran mesin.


Hal-hal yang Perlu Dipertimbangkan

- Sementara Deep Blue mencari sekitar 200 juta posisi per detik, Kasparov mungkin hanya mencari tidak lebih dari 5–10 posisi per detik. Namun, ia bermain pada level yang hampir sama. Ini jelas menunjukkan bahwa manusia memiliki beberapa trik yang belum dapat dikuasai komputer.
- Go adalah permainan papan yang dapat dimainkan oleh dua orang pemain. Permainan ini ditemukan di Cina hampir 2500 tahun yang lalu dan dianggap sebagai permainan papan tertua. Meskipun memiliki aturan yang relatif sederhana, Go adalah permainan yang sangat rumit (lebih rumit daripada catur) karena ukuran papannya yang lebih besar dan lebih banyak kemungkinan langkah.

Evolusi pembelajaran mesin sejak tahun 1950 digambarkan dalam Gambar 1.1.

Perkembangan pesat di bidang pembelajaran mesin telah memicu pertanyaan di benak setiap orang – dapatkah mesin belajar lebih baik daripada manusia? Untuk menemukan jawabannya, langkah pertama

adalah memahami apa itu pembelajaran dari sudut pandang manusia. Dengan begitu, kita dapat lebih memahami apa itu pembelajaran mesin. Pada akhirnya, kita perlu mengetahui apakah pembelajaran mesin telah melampaui atau berpotensi melampaui pembelajaran manusia dalam setiap aspek kehidupan.



GAMBAR 1.1Evolusi pembelajaran mesin

1.2 APA ITU PEMBELAJARAN MANUSIA?

Dalam ilmu kognitif, belajar biasanya disebut sebagai proses memperoleh informasi melalui observasi. Dan mengapa kita perlu belajar? Dalam kehidupan sehari-hari, kita perlu melakukan banyak aktivitas. Mungkin itu tugas sederhana seperti berjalan di jalan atau mengerjakan pekerjaan rumah. Atau mungkin beberapa tugas kompleks seperti memutuskan sudut peluncuran roket agar dapat memiliki lintasan tertentu. Untuk melakukan tugas dengan cara yang tepat, kita perlu memiliki informasi sebelumnya tentang satu atau lebih hal yang terkait dengan tugas tersebut (Zein et al., 2023). Selain itu, saat kita terus belajar lebih banyak atau dengan kata lain memperoleh lebih banyak informasi, efisiensi dalam mengerjakan tugas terus meningkat. Misalnya, dengan lebih banyak pengetahuan, kemampuan mengerjakan pekerjaan rumah dengan lebih sedikit kesalahan meningkat. Dengan cara yang sama, informasi dari peluncuran roket sebelumnya membantu dalam mengambil tindakan pencegahan yang tepat dan membuat peluncuran roket lebih sukses. Jadi, dengan lebih banyak pembelajaran, tugas dapat dilakukan dengan lebih efisien (Wang et al., 2021).

1.3 JENIS PEMBELAJARAN MANUSIA

Berpikir secara intuitif, pembelajaran manusia terjadi dalam satu dari tiga cara – (1) seseorang yang ahli dalam subjek tersebut secara langsung mengajari kita, (2) kita membangun gagasan kita sendiri secara tidak langsung berdasarkan apa yang telah kita pelajari dari ahli tersebut di masa lalu, atau (3) kita melakukannya sendiri, mungkin setelah beberapa kali mencoba, beberapa di antaranya tidak berhasil. Jenis pembelajaran pertama, dapat kita sebut, termasuk dalam kategori pembelajaran langsung di bawah bimbingan ahli, jenis kedua termasuk dalam

pembelajaran yang dipandu oleh pengetahuan yang diperoleh dari para ahli dan jenis ketiga adalah pembelajaran sendiri atau belajar mandiri. Mari kita lihat masing-masing jenis ini secara mendalam menggunakan contoh kehidupan nyata dan mencoba memahami apa artinya(Eni, 1967).

1.3.1 Pembelajaran di bawah bimbingan ahli

Seorang bayi dapat menanamkan sifat dan karakteristik tertentu, belajar langsung dari walinya. Ia menyebut tangannya sebagai 'tangan', karena itulah informasi yang ia peroleh dari orang tuanya. Langit berwarna 'biru' baginya karena itulah yang diajarkan orang tuanya. Kita mengatakan bahwa bayi 'belajar' hal-hal dari orang tuanya.

Tahap kehidupan berikutnya adalah saat bayi mulai bersekolah. Di sekolah, ia mulai dengan pengenalan dasar huruf dan angka. Kemudian bayi belajar cara membentuk kata dari huruf dan angka dari angka. Secara perlahan pembelajaran yang lebih kompleks terjadi dalam bentuk kalimat, paragraf, matematika kompleks, sains, dll. Bayi dapat mempelajari semua hal ini dari gurunya yang sudah memiliki pengetahuan di bidang ini.

Kemudian, dimulailah jenjang pendidikan yang lebih tinggi, di mana seseorang mempelajari keterampilan yang lebih kompleks dan berorientasi pada aplikasi. Mahasiswa teknik memperoleh keterampilan dalam salah satu disiplin ilmu seperti sipil, ilmu komputer, listrik, mekanik, dll. Mahasiswa kedokteran mempelajari anatomi, fisiologi, farmakologi, dll. Ada beberapa pakar, umumnya guru, di bidang masing-masing yang memiliki pengetahuan mendalam tentang materi pelajaran, yang membantu mahasiswa dalam mempelajari keterampilan ini.

Kemudian orang tersebut mulai bekerja sebagai seorang profesional di suatu bidang. Meskipun ia mungkin telah melalui pembelajaran teoritis yang cukup di bidang masing-masing, ia masih perlu belajar lebih banyak tentang penerapan langsung dari pengetahuan yang telah diperolehnya.

Para mentor profesional, berdasarkan pengetahuan yang telah mereka peroleh melalui pengalaman langsung selama bertahun-tahun, membantu semua pendatang baru di bidang tersebut untuk belajar di tempat kerja. Dalam semua fase kehidupan manusia, terdapat unsur pembelajaran terbimbing. Pembelajaran ini diberikan oleh seseorang semata-mata karena ia telah mengumpulkan pengetahuan berdasarkan pengalamannya di bidang tersebut. Jadi, pembelajaran terbimbing adalah proses memperoleh informasi dari seseorang yang memiliki pengetahuan yang cukup karena pengalaman masa lalunya.

1.3.2 Pembelajaran dipandu oleh pengetahuan yang diperoleh dari para ahli

Bagian penting dari pembelajaran juga terjadi dengan pengetahuan yang telah diberikan oleh guru atau mentor pada suatu saat dalam beberapa bentuk/konteks lain. Misalnya, seorang bayi dapat mengelompokkan semua objek dengan warna yang sama meskipun orang tuanya tidak secara khusus mengajarkannya untuk melakukannya. Ia mampu melakukannya karena pada suatu saat orang tuanya telah memberitahunya warna mana yang biru, mana yang merah, mana yang hijau, dst. Seorang anak yang sudah dewasa dapat memilih satu kata ganjil dari sekumpulan kata karena kata tersebut adalah kata kerja dan kata-kata lainnya adalah kata benda. Ia dapat melakukan ini karena kemampuannya untuk memberi label kata-kata tersebut sebagai kata kerja atau kata benda, yang diajarkan oleh guru bahasa Inggrisnya dahulu kala. Dalam peran profesional, seseorang dapat mengetahui kepada pelanggan mana ia harus memasarkan suatu kampanye dari pengetahuan tentang preferensi yang diberikan oleh atasannya dahulu kala.

Dalam semua situasi ini, tidak ada pembelajaran langsung. Yang ada hanyalah informasi masa lalu yang dibagikan pada konteks yang berbeda, yang digunakan sebagai pembelajaran untuk membuat keputusan.

1.3.3 Belajar secara mandiri

Dalam banyak situasi, manusia dibiarkan belajar sendiri. Contoh klasiknya adalah bayi yang belajar berjalan melewati rintangan. Ia menabrak rintangan dan jatuh berkali-kali hingga ia belajar bahwa setiap kali ada rintangan, ia harus melewatinya. Ia menghadapi tantangan yang sama saat belajar mengendarai sepeda saat masih kecil atau mengendarai mobil saat dewasa. Tidak semua hal diajarkan oleh orang lain. Banyak hal yang perlu dipelajari hanya dari kesalahan yang dibuat di masa lalu. Kita cenderung membuat daftar periksa tentang hal-hal yang harus kita lakukan, dan hal-hal yang tidak boleh kita lakukan, berdasarkan pengalaman kita.

1.4 APA ITU PEMBELAJARAN MESIN?

Sebelum menjawab pertanyaan 'Apa itu pembelajaran mesin?' pertanyaan yang lebih mendasar yang muncul di benak seseorang adalah

- Apakah mesin benar-benar belajar?
- Jika ya, bagaimana mereka belajar?
- Masalah apa yang dapat kita anggap sebagai masalah pembelajaran yang terdefinisi dengan baik? Apa saja fitur penting yang diperlukan untuk mendefinisikan masalah pembelajaran dengan baik?

Pada awalnya, penting untuk memformalkan definisi pembelajaran mesin. Ini akan menjawab pertanyaan pertama, yaitu apakah mesin benar-benar belajar. Ada banyak cara untuk mendefinisikan pembelajaran

mesin. Namun, yang mungkin paling relevan, ringkas, dan diterima secara universal adalah yang dinyatakan oleh Tom M. Mitchell, Profesor Departemen Pembelajaran Mesin, Sekolah Ilmu Komputer, Universitas Carnegie Mellon. Tom M. Mitchell telah mendefinisikan pembelajaran mesin sebagai

'Suatu program komputer dikatakan belajar dari pengalaman E berkenaan dengan beberapa kelas tugas T dan ukuran kinerja P, jika kinerjanya pada tugas-tugas di T, sebagaimana diukur dengan P, meningkat seiring dengan pengalaman E.'

Artinya, sebuah mesin dapat dianggap belajar jika ia mampu mengumpulkan pengalaman dengan melakukan tugas tertentu dan meningkatkan kinerjanya dalam melakukan tugas serupa di masa mendatang. Ketika kita berbicara tentang pengalaman masa lalu, yang dimaksud adalah data masa lalu yang terkait dengan tugas tersebut. Data ini merupakan masukan ke mesin dari suatu sumber(Eni, 1967).

Dalam konteks pembelajaran bermain catur, E merepresentasikan pengalaman bermain, T merepresentasikan tugas bermain catur dan P adalah ukuran kinerja yang ditunjukkan oleh persentase permainan yang dimenangkan oleh pemain. Pemetaan yang sama dapat diterapkan untuk masalah pembelajaran mesin lainnya, misalnya, masalah klasifikasi gambar. Dalam konteks klasifikasi gambar, E merepresentasikan data masa lalu dengan gambar yang memiliki label atau kelas yang ditetapkan (misalnya apakah gambar tersebut adalah kelas kucing atau kelas anjing atau kelas gajah, dll.), T adalah tugas menetapkan kelas ke gambar baru yang tidak berlabel dan P adalah ukuran kinerja yang ditunjukkan oleh persentase gambar yang diklasifikasikan dengan benar.

Langkah pertama dalam setiap proyek adalah mendefinisikan masalah Anda. Bahkan jika algoritma yang paling canggih digunakan, hasilnya tidak akan berarti apa-apa jika masalah yang dipecahkan salah.

1.4.1 Bagaimana mesin belajar?

Proses pembelajaran mesin dasar dapat dibagi menjadi tiga bagian.

1. **Masukan Data:**Data atau informasi masa lalu digunakan sebagai dasar pengambilan keputusan di masa depan
2. **Abstraksi:**Data masukan direpresentasikan secara lebih luas melalui algoritma yang mendasarinya
3. **Generalisasi:**Representasi yang abstrak digeneralisasikan untuk membentuk kerangka kerja dalam pengambilan keputusan

Gambar 1.2 adalah representasi skematis dari proses pembelajaran mesin.



GAMBAR 1.2Proses pembelajaran mesin

Mari kita bahas hal-hal tersebut dalam perspektif proses pembelajaran manusia dan mencoba memahami proses pembelajaran mesin dengan lebih jelas. Alasannya, dalam beberapa hal, proses pembelajaran mesin mencoba meniru proses pembelajaran manusia dalam skala besar(Bhaumik, 2018).

Mari kita pertimbangkan situasi proses belajar yang umum dari kelas dan buku serta persiapan untuk ujian. Banyak siswa cenderung mencoba menghafal (sering kita sebut 'belajar dengan hafalan') sebanyak mungkin hal. Ini mungkin berhasil jika cakupan pembelajaran tidak begitu luas.

Selain itu, jenis pertanyaan yang diajukan dalam ujian cukup sederhana dan lugas. Pertanyaan dapat dijawab hanya dengan menuliskan hal-hal yang telah dihafal. Namun, karena cakupannya semakin luas dan pertanyaan yang diajukan dalam ujian menjadi lebih kompleks, strategi menghafal tidak berjalan dengan baik. Jumlah topik mungkin menjadi terlalu banyak untuk dihafal siswa. Selain itu, kemampuan menghafal bervariasi dari siswa ke siswa. Bersamaan dengan itu, karena pertanyaan menjadi lebih kompleks, reproduksi langsung dari hal-hal yang dihafal mungkin tidak membantu. Situasi terus memburuk saat siswa naik ke kelas yang lebih tinggi (Nasir, 2024).

Jadi, apa yang kita lihat dalam kasus pembelajaran manusia adalah bahwa hanya dengan menghafal dengan baik dan mengingat dengan sempurna, yaitu hanya berdasarkan masukan pengetahuan, siswa dapat berhasil dalam ujian hanya sampai tahap tertentu. Di luar itu, strategi pembelajaran yang lebih baik perlu diadopsi:

1. mampu menangani luasnya materi pelajaran dan permasalahan terkait dalam menghafalnya
2. mampu menjawab pertanyaan yang belum diketahui jawabannya secara langsung

Pilihan yang baik adalah mencari tahu poin-poin atau ide-ide kunci di antara kumpulan pengetahuan yang luas. Ini membantu dalam membuat garis besar topik dan pemetaan konseptual dari topik-topik yang digariskan tersebut dengan seluruh Kumpulan pengetahuan (Wijayakusuma & Emik Sapitri, 2020).

Misalnya, kumpulan pengetahuan yang luas dapat terdiri dari semua hewan hidup dan karakteristiknya seperti apakah mereka hidup di darat atau air, apakah mereka bertelur, apakah mereka memiliki sisik atau bulu atau tidak, dll. Merupakan tugas yang sulit bagi setiap siswa untuk menghafal karakteristik semua hewan hidup – tidak peduli seberapa banyak memori fotografis yang mungkin dimilikinya. Lebih baik untuk

menggambar gagasan tentang kelompok dasar yang dimiliki semua hewan hidup dan karakteristik yang menentukan masing-masing kelompok dasar. Kelompok dasar hewan adalah invertebrata dan vertebrata. Vertebrata selanjutnya dikelompokkan sebagai mamalia, reptil, amfibi, ikan, dan burung. Di sini, kami telah memetakan kelompok hewan dan karakteristik menonjolnya ;

1. Invertebrata: Tidak memiliki tulang belakang dan rangka
2. Bertulang belakang;
 1. Ikan: Selalu hidup di air dan bertelur
 2. Amfibi: Semi-akuatik yaitu dapat hidup di air atau darat; kulit halus; bertelur
 3. Reptil: Amfibi semi-akuatik; kulit bersisik; bertelur; berdarah dingin
 4. Burung: Bisa terbang; bertelur; berdarah panas
 5. Mamalia: Memiliki rambut atau bulu; memiliki susu untuk memberi makan anaknya; berdarah panas

Hal ini memudahkan untuk mengingat karena cakupannya kini terbatas untuk mengetahui kelompok hewan tempat hewan tersebut berada. Sisa jawaban tentang karakteristik hewan dapat diperoleh dari konsep pemetaan kelompok hewan dan karakteristiknya.

Beralih ke paradigma pembelajaran mesin, kumpulan pengetahuan yang luas tersedia dari masukan data. Namun, alih-alih menggunakannya secara keseluruhan, peta konsep, yang sangat sejalan dengan pemetaan kelompok hewan terhadap karakteristik yang dijelaskan di atas, diambil dari data masukan (Suahati et al., 2022). Ini tidak lain hanyalah abstraksi pengetahuan sebagaimana dilakukan oleh mesin. Pada akhirnya, pemetaan yang diabstraksikan dari data masukan dapat diterapkan untuk membuat kesimpulan kritis. Misalnya, jika kelompok hewan diberikan pemahaman tentang karakteristik dapat dibuat secara otomatis. Sebaliknya, jika karakteristik hewan yang tidak diketahui diberikan,

kesimpulan pasti dapat dibuat tentang kelompok hewan tempat hewan itu berada. Ini adalah generalisasi dalam konteks pembelajaran mesin.

1.4.1.1 Abstraksi

Selama proses pembelajaran mesin, pengetahuan dimasukkan dalam bentuk data masukan. Akan tetapi, data tersebut tidak dapat digunakan dalam bentuk dan rupa aslinya. Seperti yang kita lihat pada contoh di atas, abstraksi membantu dalam memperoleh peta konseptual berdasarkan data masukan (Badieah et al., 2016). Peta ini, atau model sebagaimana dikenal dalam paradigma pembelajaran mesin, merupakan representasi pengetahuan yang diringkaskan dari data mentah. Model tersebut dapat berupa salah satu dari berikut ini

formulir

- Blok komputasi seperti aturan if/else
- Persamaan matematika
- Struktur data spesifik seperti pohon atau grafik
- Pengelompokan logis dari pengamatan serupa

Pemilihan model yang digunakan untuk memecahkan masalah pembelajaran tertentu merupakan tugas manusia. Keputusan terkait pemilihan model diambil berdasarkan beberapa aspek, beberapa di antaranya tercantum di bawah ini:

- Jenis masalah yang akan dipecahkan: Apakah masalahnya terkait dengan perkiraan atau prediksi, analisis tren, pemahaman berbagai segmen atau kelompok objek, dll.
- Sifat data masukan: Seberapa lengkap data masukan, apakah data tidak memiliki nilai untuk banyak bidang, tipe data, dll.
- Domain masalah: Jika masalahnya berada pada domain bisnis kritis dengan tingkat input data tinggi dan butuh inferensi segera, misalnya masalah deteksi penipuan di domain perbankan.

Setelah model dipilih, tugas selanjutnya adalah menyesuaikan model berdasarkan data masukan. Mari kita pahami ini dengan sebuah contoh. Dalam kasus di mana model direpresentasikan oleh persamaan matematika, katakanlah ' $y = c_1 + c_2x$ ' (model ini dikenal sebagai regresi linier sederhana yang akan kita pelajari di bab berikutnya), berdasarkan data masukan, kita harus mencari nilai c_1 dan c_2 . Jika tidak, persamaan (atau model) tidak berguna. Jadi, menyesuaikan model, dalam hal ini, berarti menemukan nilai koefisien atau konstanta yang tidak diketahui dari persamaan atau model. Proses menyesuaikan model berdasarkan data masukan ini dikenal sebagai pelatihan. Selain itu, data masukan yang menjadi dasar penyelesaian model dikenal sebagai data pelatihan.

1.4.1.2 Generalisasi

Bagian pertama dari proses pembelajaran mesin adalah abstraksi, yaitu mengabstraksikan pengetahuan yang datang sebagai data masukan dalam bentuk model. Namun, proses abstraksi ini, atau yang lebih populer, melatih model, hanyalah satu bagian dari pembelajaran mesin. Bagian penting lainnya adalah menyempurnakan pengetahuan yang diabstraksikan ke dalam bentuk yang dapat digunakan untuk mengambil keputusan di masa mendatang (Rahmadani & Pardede, 2021). Hal ini dicapai sebagai bagian dari generalisasi. Bagian ini cukup sulit dicapai. Hal ini karena model dilatih berdasarkan kumpulan data terbatas, yang mungkin memiliki kumpulan karakteristik terbatas. Namun, ketika kita ingin menerapkan model untuk mengambil keputusan pada kumpulan data yang tidak diketahui, yang biasanya disebut sebagai data uji, kita mungkin menghadapi dua masalah:

1. Model yang dilatih terlalu selaras dengan data pelatihan, sehingga mungkin tidak menggambarkan tren sesungguhnya.

2. Data uji memiliki karakteristik tertentu yang tampaknya tidak diketahui oleh data pelatihan.

Oleh karena itu, pendekatan pengambilan keputusan yang tepat tidak akan berhasil. Pendekatan perkiraan atau heuristik, seperti halnya pengambilan keputusan berdasarkan intuisi pada manusia, harus diadopsi. Pendekatan ini berisiko tidak membuat keputusan yang tepat – cukup jelas karena asumsi tertentu yang dibuat mungkin tidak benar dalam kenyataan. Namun, seperti halnya mesin, kesalahan yang sama dapat dilakukan oleh manusia juga ketika keputusan dibuat berdasarkan intuisi atau firasat – dalam situasi di mana pengambilan keputusan berdasarkan alasan yang tepat tidak memungkinkan.

1.4.2 Masalah pembelajaran yang dirumuskan dengan baik

Untuk mendefinisikan masalah baru, yang dapat dipecahkan menggunakan pembelajaran mesin, kerangka kerja sederhana, yang disorot di bawah ini, dapat digunakan. Kerangka kerja ini juga membantu dalam memutuskan apakah masalah tersebut merupakan kandidat yang tepat untuk dipecahkan menggunakan pembelajaran mesin. Kerangka kerja ini melibatkan jawaban atas tiga pertanyaan:

1. Apa masalahnya?
2. Mengapa masalah tersebut perlu dipecahkan?
3. Bagaimana cara mengatasi masalahnya?

Langkah 1: Apa Masalahnya?

Sejumlah informasi harus dikumpulkan untuk mengetahui apa masalahnya.

Deskripsi informal tentang masalah tersebut, misalnya saya memerlukan program yang akan memunculkan kata berikutnya saat saya mengetik sebuah kata.

Formalisme

Gunakan formalisme pembelajaran mesin Tom Mitchell yang disebutkan di atas untuk mendefinisikan T, P, dan E untuk masalah tersebut.

Misalnya:

- Tugas (T): Meminta kata berikutnya saat saya mengetik suatu kata.
- Pengalaman (E): Kumpulan kata-kata dan frasa bahasa Inggris yang umum digunakan.
- Kinerja (P): Jumlah kata yang benar yang diminta dianggap sebagai persentase (yang dalam paradigma pembelajaran mesin dikenal sebagai akurasi pembelajaran).

Asumsi -Buatlah daftar asumsi tentang masalah tersebut.

Masalah serupa

Masalah apa lagi yang pernah Anda lihat atau dapat Anda pikirkan yang serupa dengan masalah yang tengah Anda coba pecahkan?

Langkah 2: Mengapa masalah tersebut perlu dipecahkan?

Motivasi

Apa motivasi untuk memecahkan masalah tersebut? Persyaratan apa yang akan dipenuhi?

Misalnya, apakah masalah ini menyelesaikan masalah bisnis yang sudah berlangsung lama seperti menemukan transaksi yang berpotensi curang? Atau tujuannya lebih sepele seperti mencoba menyarankan beberapa film untuk ditonton akhir pekan mendatang.

Manfaat solusi

Pertimbangkan manfaat dari penyelesaian masalah. Kemampuan apa saja yang dimungkinkan?

Penting untuk memahami dengan jelas manfaat dari penyelesaian masalah. Manfaat ini dapat diartikulasikan untuk menjual proyek.

Penggunaan solusi

Bagaimana solusi permasalahan tersebut akan digunakan dan berapa lama solusi tersebut diharapkan dapat bertahan?

Langkah 3: Bagaimana saya menyelesaikan masalahnya?

Cobalah mencari cara untuk menyelesaikan masalah tersebut secara manual.

Uraikan secara rinci pengumpulan data, persiapan data, dan desain program langkah demi langkah untuk memecahkan masalah. Kumpulkan semua rincian ini dan perbarui bagian sebelumnya dari definisi masalah, terutama asumsinya.

Ringkasan


- **Langkah 1: Apa masalahnya?**Jelaskan masalah secara informal dan formal dan daftarkan asumsi dan masalah serupa.
- **Langkah2: Mengapa masalah tersebut perlu dipecahkan?**Cantumkan motivasi di balik penyelesaian masalah tersebut, manfaat yang akan diperoleh dari penyelesaian tersebut, dan bagaimana penyelesaian tersebut akan digunakan.
- **Langkah 3: Bagaimana saya menyelesaikan masalahnya?**Jelaskan bagaimana masalah tersebut akan dipecahkan secara manual untuk membuang pengetahuan domain.

1.5 JENIS PEMBELAJARAN MESIN

Seperti yang disorot di Gambar 1.3 Pembelajaran mesin dapat diklasifikasikan menjadi tiga kategori besar:

1. Pembelajaran terbimbing – Disebut juga pembelajaran prediktif. Mesin memprediksi kelas objek yang tidak diketahui berdasarkan informasi terkait kelas sebelumnya dari objek serupa.
2. Pembelajaran tanpa pengawasan – Disebut juga pembelajaran deskriptif. Mesin menemukan pola pada objek yang tidak diketahui dengan mengelompokkan objek yang serupa.

3. Pembelajaran penguatan – Mesin belajar bertindak sendiri untuk mencapai tujuan yang diberikan.



GAMBAR 1.3Jenis-jenis pembelajaran mesin


1.5.1 Pembelajaran terbimbing

Motivasi utama pembelajaran terbimbing adalah untuk belajar dari informasi masa lalu. Jadi, informasi masa lalu seperti apa yang dibutuhkan mesin untuk pembelajaran terbimbing? Informasi tersebut adalah informasi tentang tugas yang harus dijalankan mesin. Dalam konteks definisi pembelajaran mesin, informasi masa lalu ini adalah pengalaman. Mari kita coba memahaminya dengan sebuah contoh.

Misalkan sebuah mesin menerima gambar dari berbagai objek sebagai input dan tugasnya adalah memisahkan gambar berdasarkan bentuk atau warna objek. Jika berdasarkan bentuk, gambar yang berbentuk bulat perlu dipisahkan dari gambar objek berbentuk segitiga, dst. Jika pemisahan perlu dilakukan berdasarkan warna, gambar objek biru perlu dipisahkan dari gambar objek hijau. Namun, bagaimana mesin dapat mengetahui bentuk bulat atau segitiga? Dengan cara yang sama, bagaimana mesin dapat membedakan gambar objek berdasarkan warna biru atau hijau? Mesin sangat mirip dengan anak kecil yang orang tuanya atau orang dewasa perlu membimbingnya dengan informasi dasar tentang bentuk dan warna sebelum ia dapat mulai mengerjakan tugas.

Mesin memerlukan informasi dasar yang diberikan kepadanya. Input dasar ini, atau pengalaman dalam paradigma pembelajaran mesin, diberikan dalam bentuk data pelatihan. Data pelatihan adalah informasi masa lalu tentang tugas tertentu. Dalam konteks masalah segregasi gambar, data pelatihan akan memiliki data masa lalu tentang berbagai aspek atau fitur pada sejumlah gambar, beserta tag tentang apakah gambar tersebut berbentuk bulat atau segitiga, atau berwarna biru atau hijau. Tag tersebut disebut 'label' dan kami katakan bahwa data pelatihan diberi label dalam kasus pembelajaran terbimbing.

Gambar 1.4 adalah gambaran sederhana dari proses pembelajaran terbimbing. Data pelatihan berlabel yang berisi informasi masa lalu muncul sebagai input. Berdasarkan data pelatihan, mesin membangun model prediktif yang dapat digunakan pada data uji untuk menetapkan label untuk setiap rekaman dalam data uji.



GAMBAR 1.4 Pembelajaran yang diawasi

Beberapa contoh pembelajaran terbimbing adalah

- Memprediksi hasil suatu permainan

- Memprediksi apakah suatu tumor ganas atau jinak.
- Memprediksi harga domain seperti real estat, saham, dll.
- Mengklasifikasikan teks seperti mengklasifikasikan sekumpulan email sebagai spam atau non-spam.

Sekarang, mari kita pertimbangkan dua contoh di atas, katakanlah 'memprediksi apakah tumor ganas atau jinak' dan 'memprediksi harga domain seperti real estat'. Apakah kedua masalah ini sama sifatnya? Jawabannya adalah 'tidak'. Meskipun keduanya adalah masalah prediksi, dalam satu kasus kita mencoba memprediksi kategori atau kelas mana data yang tidak diketahui berada sedangkan dalam kasus lain kita mencoba memprediksi nilai absolut dan bukan kelas. Ketika kita mencoba memprediksi variabel kategoris atau nominal, masalah tersebut dikenal sebagai masalah klasifikasi. Sedangkan ketika kita mencoba memprediksi variabel bernilai riil, masalah tersebut termasuk dalam kategori regresi.


Mari kita coba memahami kedua area pembelajaran terawasi, yaitu klasifikasi dan regresi secara lebih rinci.

1.5.1.1 Klasifikasi

Mari kita bahas cara memisahkan gambar objek berdasarkan bentuknya. Jika gambarnya adalah objek bulat, gambar tersebut dimasukkan ke dalam satu kategori, sedangkan jika gambarnya adalah objek segitiga, gambar tersebut dimasukkan ke dalam kategori lain (Mubarak et al., 2020). Dalam kategori mana mesin harus meletakkan gambar dengan kategori yang tidak diketahui, yang juga disebut data uji dalam istilah pembelajaran mesin, bergantung pada informasi yang didapatnya dari data sebelumnya, yang kita sebut sebagai data latih. Karena data latih memiliki label atau kategori yang ditentukan untuk setiap gambar, mesin harus memetakan gambar atau data uji baru

ke sekumpulan gambar yang mirip dengannya dan menetapkan label atau kategori yang sama ke data uji.

Jadi kita mengamati bahwa seluruh masalah berkisar pada pemberian label atau kategori atau kelas pada data uji berdasarkan informasi label atau kategori atau kelas yang diberikan oleh data pelatihan. Karena sasarannya adalah untuk memberikan label kelas, jenis masalah ini disebut masalah klasifikasi. Gambar 1.5 menggambarkan proses klasifikasi yang umum.



GAMBAR 1.5Klasifikasi

Ada sejumlah algoritma pembelajaran mesin populer yang membantu dalam memecahkan masalah klasifikasi. Untuk menyebutkan beberapa, algoritma Naïve Bayes, Decision tree, dan k-Nearest Neighbor diadopsi oleh banyak pembelajaran mesin.

Masalah klasifikasi yang kritis dalam konteks perbankan adalah mengidentifikasi potensi transaksi penipuan. Karena ada jutaan transaksi yang harus diteliti dan dipastikan apakah itu transaksi penipuan, tidak mungkin bagi manusia untuk melakukan tugas ini. Pembelajaran mesin

secara efektif dimanfaatkan untuk melakukan tugas ini dan ini adalah kasus klasifikasi klasik. Berdasarkan data transaksi sebelumnya, khususnya yang diberi label penipuan, semua transaksi masuk baru ditandai atau diberi label sebagai normal atau mencurigakan. Transaksi mencurigakan selanjutnya dipisahkan untuk ditinjau lebih dekat.

Singkatnya, klasifikasi adalah jenis pembelajaran terbimbing di mana fitur target, yang berjenis kategorikal, diprediksi untuk data uji berdasarkan informasi yang diberikan oleh data pelatihan. Fitur kategorikal target dikenal sebagai kelas.

Beberapa masalah klasifikasi yang umum meliputi:

- Klasifikasi gambar
- Prediksi Penyakit
- Prediksi menang-kalah pertandingan
- Prediksi bencana alam seperti gempa bumi, banjir, dll.
- Pengenalan tulisan tangan

1.5.1.2. Regresi

Dalam regresi linier, tujuannya adalah untuk memprediksi fitur numerik seperti harga real estat atau saham, suhu, nilai ujian, pendapatan penjualan, dll. Variabel prediktor yang mendasari dan variabel target bersifat kontinu. Dalam kasus regresi linier, hubungan garis lurus 'dipasang' antara variabel prediktor dan variabel target, menggunakan konsep statistik metode kuadrat terkecil. Seperti dalam kasus metode kuadrat terkecil, jumlah kuadrat galat antara nilai aktual dan nilai prediksi dari variabel target dicoba untuk diminimalkan (Shidiq, 2021). Dalam kasus regresi linier sederhana, hanya ada satu variabel prediktor sedangkan dalam kasus regresi linier berganda, beberapa variabel prediktor dapat dimasukkan dalam model.

Mari kita ambil contoh latihan penganggaran tahunan para manajer penjualan. Mereka harus memberikan prediksi penjualan untuk tahun berikutnya berdasarkan angka penjualan tahun-tahun sebelumnya dibandingkan dengan investasi yang dilakukan. Jelas, data yang terkait dengan masa lalu serta data yang akan diprediksi bersifat berkelanjutan. Dalam pendekatan dasar, model regresi linier sederhana dapat diterapkan dengan investasi sebagai variabel prediktor dan pendapatan penjualan sebagai variabel target.


Gambar 1.6 menunjukkan model regresi sederhana yang khas, di mana garis regresi disesuaikan berdasarkan nilai variabel target terhadap nilai variabel prediktor yang berbeda. Model regresi linier yang khas dapat direpresentasikan dalam bentuk –

$$y = \alpha + \beta x$$

di mana 'x' merupakan variabel prediktor dan 'y' merupakan variabel target.

Data masukan berasal dari kumpulan data multivariat terkenal bernama Iris yang diperkenalkan oleh ahli statistik dan biologi Inggris Ronald Fisher. Kumpulan data tersebut terdiri dari 50 sampel dari masing-masing tiga spesies Iris – Iris setosa, Iris virginica, dan Iris versicolor. Empat fitur diukur untuk setiap sampel – panjang sepal, lebar sepal, panjang petal, dan lebar petal. Fitur-fitur ini dapat membedakan spesies bunga yang berbeda secara unik.

Kumpulan data Iris biasanya digunakan sebagai data pelatihan untuk memecahkan masalah klasifikasi prediksi spesies bunga berdasarkan nilai fitur. Namun, kita juga dapat menunjukkan regresi menggunakan kumpulan data ini, dengan memprediksi nilai satu fitur menggunakan fitur lain sebagai prediktor. Gambar 1.6, panjang kelopak merupakan variabel prediktor yang jika dimasukkan ke dalam model regresi linier sederhana, membantu dalam memprediksi nilai variabel target panjang kelopak.



GAMBAR 1.6Regresi


Aplikasi regresi yang umum dapat dilihat pada

- Perkiraan permintaan dalam ritel
- Prediksi penjualan untuk manajer
- Prediksi harga di bidang real estate
- Ramalan cuaca
- Prakiraan permintaan keterampilan di pasar kerja

1.5.2 Pembelajaran tanpa pengawasan

Tidak seperti pembelajaran terbimbing, dalam pembelajaran tak terbimbing, tidak ada data pelatihan berlabel untuk dipelajari dan tidak ada prediksi yang harus dibuat. Dalam pembelajaran tak terbimbing, tujuannya adalah mengambil kumpulan data sebagai input dan mencoba menemukan pengelompokan atau pola alami dalam elemen atau rekaman data. Oleh karena itu, pembelajaran tak terbimbing sering disebut sebagai model deskriptif dan proses pembelajaran tak terbimbing disebut sebagai penemuan pola atau penemuan pengetahuan. Salah satu aplikasi penting dari pembelajaran tak terbimbing adalah segmentasi pelanggan.


Pengelompokan merupakan jenis utama pembelajaran tanpa pengawasan. Pengelompokan bertujuan untuk mengelompokkan atau mengatur objek-objek yang serupa. Oleh karena itu, objek-objek yang termasuk dalam kluster yang sama cukup mirip satu sama lain sementara objek-objek yang termasuk dalam kluster yang berbeda cukup berbeda. Oleh karena itu, tujuan pengelompokan adalah untuk menemukan pengelompokan intrinsik data yang tidak berlabel dan membentuk kluster, seperti yang digambarkan dalam Gambar 1.7. Berbagai ukuran kesamaan dapat diterapkan untuk pengelompokan. Salah satu ukuran kesamaan yang paling umum diadopsi adalah jarak. Dua item data dianggap sebagai bagian dari kluster yang sama jika jarak di antara keduanya lebih kecil. Dengan cara yang sama, jika jarak antara item data tinggi, item tersebut umumnya tidak termasuk dalam kluster yang sama. Ini juga dikenal sebagai pengelompokan berbasis jarak. Gambar 1.8 menggambarkan proses pengelompokan pada tingkat tinggi.



GAMBAR 1.7 Pengelompokan berbasis jarak

Selain pengelompokan data dan memperoleh pandangan yang diringkas darinya, satu lagi varian pembelajaran tanpa pengawasan adalah analisis asosiasi. Sebagai bagian dari analisis asosiasi, asosiasi antara elemen data diidentifikasi. Mari kita coba memahami pendekatan analisis asosiasi dalam konteks salah satu contoh yang paling umum, yaitu analisis

keranjang belanja seperti yang ditunjukkan pada Gambar 1.9 Dari data transaksi masa lalu di toko kelontong, dapat diamati bahwa sebagian besar pelanggan yang telah membeli barang A, juga telah membeli barang B dan barang C atau setidaknya salah satunya. Ini berarti bahwa ada hubungan yang kuat antara peristiwa 'pembelian barang A' dengan peristiwa 'pembelian barang B', atau 'pembelian barang C'. Mengidentifikasi jenis-jenis hubungan ini adalah tujuan dari analisis hubungan. Hal ini membantu dalam meningkatkan jalur penjualan, karenanya menjadi masukan penting bagi kelompok penjualan. Aplikasi penting dari analisis hubungan meliputi analisis keranjang belanja dan sistem rekomendasi.



GAMBAR 1.8 Pembelajaran tanpa pengawasan

TransID	Items Bought
1	{Butter, Bread}
2	{Diaper, Bread, Milk, Beer}
3	{Milk, Chicken, Beer, Diaper}
4	{Bread, Diaper, Chicken, Beer}
5	{Diaper, Beer, Cookies, Ice cream}
...	...

Market Basket transactions
Frequent itemsets → (Diaper, Beer)
Possible association: Diaper → Beer


GAMBAR 1.9 Analisis keranjang pasar

1.5.3 Pembelajaran penguatan

Kita telah melihat bayi belajar berjalan tanpa pengetahuan sebelumnya tentang cara melakukannya. Sering kali kita bertanya-tanya bagaimana mereka melakukannya. Mereka melakukannya dengan cara yang relatif sederhana.

Pertama, mereka melihat orang lain berjalan di sekitar, misalnya orang tua atau siapa pun yang tinggal di sekitar. Mereka memahami bahwa kaki harus digunakan, satu per satu, untuk melangkah. Saat berjalan, terkadang mereka jatuh saat menabrak rintangan, sedangkan di waktu lain mereka dapat berjalan dengan lancar saat menghindari rintangan yang bergelombang. Saat mereka dapat berjalan melewati rintangan, orang tua mereka gembira dan menghargai bayi tersebut dengan tepukan keras atau mungkin cokelat. Saat mereka jatuh saat menghindari rintangan, tentu saja orang tua mereka tidak bertepuk tangan atau memberi cokelat. Lambat laun, tibalah saatnya bayi belajar dari kesalahan dan dapat berjalan dengan lebih mudah.

Dengan cara yang sama, mesin sering belajar untuk melakukan tugas secara mandiri. Mari kita coba memahami dalam konteks contoh anak yang belajar berjalan. Tindakan yang ingin dicapai adalah berjalan, anak adalah pelakunya dan tempat dengan rintangan yang coba dilalui anak menyerupai lingkungannya. Ia mencoba meningkatkan kinerjanya dalam melakukan tugas. Ketika subtugas berhasil diselesaikan, hadiah diberikan. Ketika subtugas tidak dijalankan dengan benar, jelas tidak ada hadiah yang diberikan. Ini berlanjut hingga mesin mampu menyelesaikan seluruh tugas. Proses pembelajaran ini dikenal sebagai pembelajaran penguatan. Gambar 1.10 menangkap proses pembelajaran penguatan tingkat tinggi.



GAMBAR 1.10Pembelajaran penguatan

Salah satu contoh pembelajaran penguatan kontemporer adalah mobil tanpa pengemudi. Informasi penting yang perlu diperhatikan adalah kecepatan dan batas kecepatan di berbagai ruas jalan, kondisi lalu lintas, kondisi jalan, kondisi cuaca, dll. Tugas yang harus diperhatikan adalah memulai/menghentikan, mempercepat/memperlambat, berbelok ke kiri/kanan, dll.

1.5.4 Perbandingan – pembelajaran terbimbing, tanpa bimbingan, dan penguatan

SUPERVISED	UNSUPERVISED	REINFORCEMENT
This type of learning is used when you know how to classify a given data, or in other words classes or labels are available.	This type of learning is used when there is no idea about the class or label of a particular data. The model has to find pattern in the data.	This type of learning is used when there is no idea about the class or label of a particular data. The model has to do the classification – it will get rewarded if the classification is correct, else get punished.
Labelled training data is needed. Model is built based on training data.	Any unknown and unlabelled data set is given to the model as input and records are grouped.	The model learns and updates itself through reward/ punishment.
The model performance can be evaluated based on how many misclassifications have been done based on a comparison between predicted and actual values.	Difficult to measure whether the model did something useful or interesting. Homogeneity of records grouped together is the only measure.	Model is evaluated by means of the reward function after it had some time to learn.
There are two types of supervised learning problems – classification and regression.	There are two types of unsupervised learning problems – clustering and association.	No such types.
Simplest one to understand.	More difficult to understand and implement than supervised learning.	Most complex to understand and apply.
Standard algorithms include • Naive Bayes • k-nearest neighbour (kNN) • Decision tree • Linear regression • Logistic regression • Support Vector Machine (SVM), etc.	Standard algorithms are • k-means • Principal Component Analysis (PCA) • Self-organizing map (SOM) • Apriori algorithm • DBSCAN etc.	Standard algorithms are • Q-learning • Sarsa
Practical applications include • Handwriting recognition • Stock market prediction • Disease prediction • Fraud detection, etc.	Practical applications include • Market basket analysis • Recommender systems • Customer segmentation, etc.	Practical applications include • Self-driving cars • Intelligent robots • AlphaGo Zero (the latest version of DeepMind's AI system playing Go)

1.6 MASALAH YANG TIDAK DAPAT DISELESAIKAN DENGAN MENGGUNAKAN MACHINE LEARNING

Pembelajaran mesin tidak boleh diterapkan pada tugas-tugas yang memerlukan manusia yang sangat efektif atau sering kali memerlukan campur tangan manusia. Misalnya, pengaturan lalu lintas udara merupakan tugas yang sangat rumit yang membutuhkan keterlibatan manusia yang intens. Pada saat yang sama, untuk tugas-tugas yang sangat sederhana yang dapat diimplementasikan menggunakan paradigma pemrograman tradisional, tidak ada gunanya menggunakan pembelajaran mesin. Misalnya, aplikasi sederhana yang digerakkan oleh aturan atau berbasis rumus seperti mesin kalkulator harga, aplikasi pelacakan sengketa, dll. tidak memerlukan teknik pembelajaran mesin.

Pembelajaran mesin hanya boleh digunakan jika proses bisnis memiliki beberapa kelemahan. Jika tugas sudah dioptimalkan, penerapan pembelajaran mesin tidak akan cukup untuk membenarkan laba atas investasi.

Untuk situasi di mana data pelatihan tidak mencukupi, pembelajaran mesin tidak dapat digunakan secara efektif. Hal ini karena, dengan set data pelatihan yang kecil, dampak data yang buruk akan jauh lebih buruk. Agar kualitas prediksi atau rekomendasi menjadi baik, data pelatihan harus cukup besar.

1.7 APLIKASI PEMBELAJARAN MESIN

Di mana pun terdapat sejumlah besar data masa lalu, pembelajaran mesin dapat digunakan untuk menghasilkan wawasan yang dapat ditindaklanjuti dari data tersebut. Meskipun pembelajaran mesin diadopsi dalam berbagai bentuk di setiap domain bisnis, kami telah membahas tiga

domain utama di bawah ini hanya untuk memberikan gambaran tentang jenis tindakan apa yang dapat dilakukan menggunakan pembelajaran mesin.

1.7.1 Perbankan dan keuangan

Dalam industri perbankan, transaksi penipuan, terutama yang terkait dengan kartu kredit, sangat lazim terjadi. Karena volume dan kecepatan transaksi sangat tinggi, solusi pembelajaran mesin berkinerja tinggi diterapkan oleh hampir semua bank terkemuka di seluruh dunia. Model tersebut bekerja secara real-time, yaitu transaksi penipuan terdeteksi dan dicegah tepat pada saat terjadinya. Hal ini membantu menghindari banyak kerepotan operasional dalam menyelesaikan sengketa yang mungkin timbul akibat transaksi penipuan tersebut.

Nasabah bank sering kali ditawarkan proposal yang menggiurkan oleh bank pesaing lainnya. Proposal seperti bunga bank yang lebih tinggi, biaya pemrosesan pinjaman yang lebih rendah, rekening tabungan dengan saldo nol, tanpa penalti cerukan, dll. ditawarkan kepada nasabah, dengan maksud agar nasabah beralih ke bank pesaing. Selain itu, terkadang nasabah menjadi tidak bersemangat karena buruknya kualitas layanan bank dan beralih ke bank pesaing. Pembelajaran mesin membantu mencegah atau setidaknya mengurangi perputaran nasabah. Pembelajaran deskriptif dan prediktif dapat diterapkan untuk mengurangi perputaran nasabah. Dengan menggunakan pembelajaran deskriptif, kantong masalah tertentu, yaitu bank tertentu atau zona tertentu atau jenis penawaran tertentu seperti pinjaman mobil, dapat ditemukan di mana perputaran maksimum terjadi. Jelas sekali, ini adalah area bermasalah yang memerlukan penyelidikan lebih lanjut untuk menemukan dan memperbaiki akar penyebabnya. Dengan menggunakan pembelajaran prediktif, sekumpulan nasabah yang rentan yang mungkin

akan segera meninggalkan bank, dapat diidentifikasi. Tindakan yang tepat dapat diambil untuk memastikan bahwa nasabah tetap kembali.

1.7.2 Asuransi

Industri asuransi sangat padat data. Karena alasan itu, pembelajaran mesin digunakan secara luas dalam industri asuransi. Dua area utama dalam industri asuransi tempat pembelajaran mesin digunakan adalah prediksi risiko selama pendaftaran nasabah baru dan manajemen klaim. Selama pendaftaran nasabah, berdasarkan informasi masa lalu, profil risiko nasabah baru perlu diprediksi. Berdasarkan kuantum risiko yang diprediksi, kuota dibuat untuk calon nasabah. Ketika klaim nasabah datang untuk penyelesaian, informasi masa lalu yang terkait dengan klaim historis bersama dengan catatan adjuster dipertimbangkan untuk memprediksi apakah ada kemungkinan klaim tersebut penipuan. Selain informasi masa lalu yang terkait dengan nasabah tertentu, informasi yang terkait dengan nasabah serupa, yaitu nasabah yang termasuk dalam lokasi geografis, kelompok usia, kelompok etnis, dll. yang sama, juga dipertimbangkan untuk merumuskan model.

1.7.3 Pelayanan Kesehatan

Data perangkat yang dapat dikenakan membentuk sumber yang kaya untuk menerapkan pembelajaran mesin dan memprediksi kondisi kesehatan orang tersebut secara real time. Jika ada beberapa masalah kesehatan yang diprediksi oleh model pembelajaran, orang tersebut segera diperingatkan untuk mengambil tindakan pencegahan. Jika terjadi beberapa masalah ekstrem, dokter atau penyedia layanan kesehatan di sekitar orang tersebut dapat diperingatkan. Misalkan seorang lansia berjalan-jalan pagi di taman dekat rumahnya. Tiba-tiba, saat berjalan,

tekanan darahnya melonjak melampaui batas tertentu, yang dilacak oleh perangkat yang dapat dikenakan. Data yang dapat dikenakan dikirim ke server jarak jauh dan algoritma pembelajaran mesin terus-menerus menganalisis data streaming. Ia juga memiliki riwayat orang lanjut usia dan orang-orang dari kelompok usia yang sama. Model tersebut memprediksi beberapa kematian kecuali tindakan segera diambil. Peringatan dapat dikirim ke orang tersebut untuk segera berhenti berjalan dan beristirahat. Selain itu, dokter dan penyedia layanan kesehatan dapat diperingatkan untuk bersiaga.

Pembelajaran mesin bersama dengan visi komputer juga memainkan peran penting dalam diagnosis penyakit dari pencitraan medis.

1.8 BAHASA/ALAT TERKINI DALAM PEMBELAJARAN MESIN

Algoritme yang terkait dengan berbagai tugas pembelajaran mesin diketahui semua orang dan dapat diimplementasikan menggunakan bahasa/platform apa pun. Algoritme ini dapat diimplementasikan menggunakan platform Java atau bahasa C/C++ atau dalam .NET. Namun, ada beberapa bahasa dan alat yang telah dikembangkan dengan fokus untuk mengimplementasikan pembelajaran mesin. Beberapa di antaranya, yang paling banyak digunakan, dibahas di bawah ini.

1.8.1 Python

Python adalah salah satu bahasa pemrograman sumber terbuka terpopuler yang banyak diadopsi oleh komunitas pembelajaran mesin. Bahasa ini dirancang oleh Guido van Rossum dan pertama kali dirilis pada tahun 1991. Implementasi referensi Python, yaitu CPython, dikelola oleh Python Software Foundation, yang merupakan organisasi nirlaba.

Python memiliki pustaka yang sangat kuat untuk fungsi matematika tingkat lanjut (NumPy), algoritme dan alat matematika (SciPy) serta plot numerik (matplotlib). Berdasarkan pustaka ini, terdapat pustaka pembelajaran mesin bernama scikitlearn, yang memiliki berbagai algoritme klasifikasi, regresi, dan pengelompokan yang tertanam di dalamnya.

1.8.2 R

R adalah bahasa pemrograman untuk komputasi statistik dan analisis data. Bahasa pemrograman ini merupakan bahasa sumber terbuka yang sangat populer di kalangan akademisi, terutama di kalangan ahli statistik dan penambang data. R dianggap sebagai varian dari S, proyek GNU yang dikembangkan di Bell Laboratories. Saat ini, bahasa pemrograman ini didukung oleh R Foundation untuk komputasi statistik.

R adalah bahasa pemrograman yang sangat sederhana dengan sekumpulan besar pustaka yang tersedia untuk berbagai tahap pembelajaran mesin. Beberapa pustaka yang menonjol dalam hal popularitas adalah plyr/dplyr (untuk transformasi data), caret ('Classification and Regression Training' untuk klasifikasi), RJava (untuk memfasilitasi integrasi dengan Java), tm (untuk text mining), ggplot2 (untuk visualisasi data). Selain pustaka tersebut, paket tertentu seperti Shiny dan R Markdown telah dikembangkan di sekitar R untuk mengembangkan aplikasi web interaktif, dokumen, dan dasbor di R tanpa banyak usaha.

1.8.3 Bahasa Pemrograman Matlab

MATLAB (matrix laboratory) adalah perangkat lunak komersial berlisensi dengan dukungan kuat untuk berbagai komputasi numerik.

MATLAB memiliki basis pengguna yang besar di seluruh industri dan akademisi. MATLAB dikembangkan oleh MathWorks, sebuah perusahaan yang didirikan pada tahun 1984. Sebagai perangkat lunak berpemilik, MATLAB dikembangkan jauh lebih profesional, diuji secara ketat, dan memiliki dokumentasi yang komprehensif.

MATLAB juga menyediakan dukungan fungsi statistik yang luas dan memiliki sejumlah besar algoritma pembelajaran mesin bawaan. Ia juga memiliki kemampuan untuk meningkatkan skala himpunan data besar melalui pemrosesan paralel pada kluster dan cloud.

1.8.4 SAS ('Statistical Analysis System')

SAS (sebelumnya dikenal sebagai 'Statistical Analysis System') adalah perangkat lunak komersial berlisensi lainnya yang menyediakan dukungan kuat untuk fungsi pembelajaran mesin. Dikembangkan dalam bahasa C oleh SAS Institute, SAS pertama kali dirilis pada tahun 1976.

SAS adalah perangkat lunak yang terdiri dari berbagai komponen. Fungsionalitas manajemen data dasar tertanam dalam komponen Base SAS sedangkan komponen lain seperti SAS/INSIGHT, Enterprise Miner, SAS/STAT, dll. membantu dalam fungsi khusus yang terkait dengan penambahan data dan analisis statistik.

1.8.5 Bahasa/alat lainnya

Ada banyak bahasa dan alat lain yang juga mendukung fungsi pembelajaran mesin. Dimiliki oleh IBM, SPSS (awalnya bernama Statistical Package for the Social Sciences) adalah paket populer yang mendukung penambahan data khusus dan analisis statistik. Awalnya populer untuk analisis statistik dalam ilmu sosial (sebagaimana tercermin dari namanya), SPSS sekarang juga populer di bidang lain.

Dirilis pada tahun 2012, Julia adalah bahasa pemrograman sumber terbuka berlisensi liberal untuk analisis numerik dan ilmu komputasi. Bahasa ini telah menggabungkan semua hal baik dari MATLAB, Python, R, dan bahasa pemrograman lain yang digunakan untuk pembelajaran mesin yang membuatnya terus mendapat perhatian dari komunitas pengembangan pembelajaran mesin. Poin penting lainnya yang mendukung Julia adalah kemampuannya untuk mengimplementasikan algoritma pembelajaran mesin berkinerja tinggi.

1.9 MASALAH DALAM PEMBELAJARAN MESIN

Pembelajaran mesin merupakan bidang yang relatif baru dan masih berkembang. Selain itu, tingkat penelitian dan jenis penggunaan alat dan teknologi pembelajaran mesin sangat bervariasi dari satu negara ke negara lain. Hukum dan peraturan, latar belakang budaya, kematangan emosional orang berbeda secara drastis di berbagai negara. Semua faktor ini membuat penggunaan pembelajaran mesin dan masalah yang muncul akibat penggunaan pembelajaran mesin menjadi sangat berbeda.

Ketakutan dan masalah terbesar yang muncul dari pembelajaran mesin terkait dengan privasi dan pelanggaran privasi. Fokus utama pembelajaran adalah menganalisis data, baik yang lalu maupun yang sekarang, dan menghasilkan wawasan dari data tersebut. Wawasan ini mungkin terkait dengan orang-orang dan fakta-fakta yang diungkapkan mungkin cukup pribadi untuk dirahasiakan. Selain itu, orang yang berbeda memiliki preferensi yang berbeda dalam hal berbagi informasi. Sementara beberapa orang mungkin terbuka untuk berbagi beberapa tingkat informasi secara publik, beberapa orang lain mungkin tidak ingin membagikannya bahkan kepada semua teman dan membatasinya hanya untuk anggota keluarga. Contoh klasiknya adalah tanggal lahir (bukan hari, tetapi tanggal secara keseluruhan), foto-foto kencan makan malam

dengan keluarga, latar belakang pendidikan, dll. Beberapa orang membagikannya dengan semua orang di platform sosial seperti Facebook sementara yang lain tidak, atau jika mereka melakukannya, mereka mungkin membatasinya hanya untuk teman-teman. Ketika algoritma pembelajaran mesin diimplementasikan menggunakan informasi tersebut, secara tidak sengaja orang mungkin menjadi kesal. Misalnya, jika ada algoritma pembelajaran untuk melakukan segmentasi pelanggan berdasarkan preferensi dan hasil analisis digunakan untuk mengirim kampanye pemasaran yang ditargetkan, hal itu akan melukai emosi orang dan malah lebih banyak menimbulkan kerugian daripada manfaat. Di negara tertentu, kejadian seperti itu dapat mengakibatkan tindakan hukum yang harus diambil oleh orang yang terkena dampak.

Bahkan jika tidak ada pelanggaran privasi, mungkin ada situasi di mana tindakan yang diambil berdasarkan pembelajaran mesin dapat menimbulkan reaksi yang merugikan. Mari kita ambil contoh latihan penemuan pengetahuan yang dilakukan sebelum memulai kampanye pemilihan. Jika suatu daerah tertentu menunjukkan mayoritas etnis atau ketidakseimbangan faktor demografi tertentu, dan promosi kampanye menyampaikan pesan dengan mempertimbangkan hal itu, hal itu sebenarnya dapat membuat para pemilih kesal dan menyebabkan hasil yang merugikan.

Jadi pertimbangan yang sangat penting sebelum menerapkan pembelajaran mesin adalah bahwa penilaian manusia yang tepat harus dilakukan sebelum menggunakan hasil apa pun dari pembelajaran mesin. Hanya dengan demikian keputusan yang diambil akan bermanfaat dan juga tidak mengakibatkan dampak buruk apa pun.

1.10 RINGKASAN

Pembelajaran mesin menyerap filosofi pembelajaran manusia, yaitu belajar dari bimbingan ahli dan dari pengalaman.

- Abstraksi: Data masukan direpresentasikan dengan cara yang diringkas. Generalisasi: Representasi yang diabstraksikan
- digeneralisasi untuk membentuk kerangka kerja dalam pengambilan keputusan. Sebelum mulai memecahkan masalah apa pun menggunakan pembelajaran mesin, harus diputuskan apakah masalah tersebut merupakan masalah yang tepat untuk dipecahkan menggunakan pembelajaran mesin. Pembelajaran mesin dapat diklasifikasikan ke dalam tiga kategori besar: Pembelajaran terbimbing: Disebut juga pembelajaran prediktif. Tujuan pembelajaran ini adalah untuk memprediksi kelas/nilai objek yang tidak diketahui berdasarkan informasi sebelumnya tentang objek serupa. Contoh: memprediksi apakah tumor ganas atau jinak, prediksi harga dalam domain seperti real estat, saham, dll.
- Pembelajaran tanpa pengawasan: Disebut juga pembelajaran deskriptif, membantu menemukan kelompok atau pola pada objek yang tidak diketahui dengan mengelompokkan objek yang serupa. Contoh: segmentasi pelanggan, sistem rekomendasi, dll.
- Pembelajaran penguatan: Mesin belajar bertindak sendiri untuk mencapai tujuan yang diberikan. Contoh: mobil tanpa pengemudi, robot cerdas, dll.

Pembelajaran mesin telah diadopsi oleh berbagai domain industri seperti Perbankan dan Layanan Keuangan, Asuransi, Kesehatan, Ilmu Hayati, dll. untuk memecahkan masalah.

- Beberapa platform yang paling banyak diadopsi untuk mengimplementasikan pembelajaran mesin termasuk Python, R,
- MATLAB, SAS, SPSS, dll.

Untuk menghindari masalah etika, pertimbangan kritis diperlukan sebelum menerapkan pembelajaran mesin dan menggunakan hasil apa pun dari pembelajaran mesin.

SOAL PILIHAN GANDA (MASING-MASING 1 NILAI):

1. Pembelajaran mesin adalah bidang _____.
 1. Interdisipliner
 2. Lajang
 3. Multidisiplin
 4. Semua hal di atas
2. Suatu program komputer dikatakan belajar dari _____ E berkenaan dengan beberapa kelas tugas T dan ukuran kinerja P, jika kinerjanya pada tugas-tugas di T, sebagaimana diukur dengan P, meningkat dengan E.
 1. Pelatihan
 2. Pengalaman
 3. Basis Data
 4. Algoritma
3. _____ telah digunakan untuk melatih kendaraan agar dapat mengemudi dengan benar dan mandiri di jalan raya.
 1. Pembelajaran mesin
 2. Penambangan data
 3. Jaringan saraf
 4. Robotika

4. Hipotesis apa pun yang menemukan perkiraan fungsi target pada sekumpulan contoh pelatihan yang cukup besar juga akan memperkirakan fungsi target dengan baik pada contoh lain yang tidak teramati. Ini disebut _____.
 1. Hipotesa
 2. Hipotesis induktif
 3. Sedang belajar
 4. Pembelajaran konsep
5. Faktor-faktor yang mempengaruhi kinerja sistem pembelajar tidak termasuk
 1. Skema representasi yang digunakan
 2. Skenario pelatihan
 3. Jenis umpan balik
 4. Struktur data yang baik
6. Metode pembelajaran yang berbeda tidak termasuk
 1. Menghafal
 2. Analogi
 3. Deduksi
 4. Perkenalan
7. Model bahasa terdiri dari kategori-kategori yang tidak termasuk
 1. Unit bahasa
 2. Struktur peran unit
 3. Batasan sistem
 4. Unit struktural
8. Ada berapa jenis yang tersedia dalam pembelajaran mesin?
 1. 1
 2. 2
 3. 3
 4. 4
9. Algoritma k-means adalah

1. Algoritma pembelajaran yang diawasi
 2. Algoritma pembelajaran tanpa pengawasan
 3. Algoritma pembelajaran semi-supervised
 4. Algoritma pembelajaran dengan pengawasan lemah
10. Algoritma Q-learning adalah
1. Algoritma pembelajaran yang diawasi
 2. Algoritma pembelajaran tanpa pengawasan
 3. Algoritma pembelajaran semi-supervised
 4. Algoritma pembelajaran penguatan
11. Jenis pembelajaran ini digunakan ketika tidak ada ide tentang kelas atau label data tertentu
1. Algoritma pembelajaran yang diawasi
 2. Algoritma pembelajaran tanpa pengawasan
 3. Algoritma pembelajaran semi-supervised
 4. Algoritma pembelajaran penguatan
12. Model belajar dan memperbarui dirinya melalui penghargaan/hukuman jika terjadi
1. Algoritma pembelajaran yang diawasi
 2. Algoritma pembelajaran tanpa pengawasan
 3. Algoritma pembelajaran semi-supervised
 4. Algoritma pembelajaran penguatan

SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI):

1. Apa itu pembelajaran manusia? Berikan dua contoh.
2. Apa saja jenis pembelajaran manusia? Apakah ada bentuk pembelajaran mesin yang setara?
3. Apa itu machine learning? Apa saja tugas utama machine learning?

4. Jelaskan konsep hukuman dan penghargaan dalam pembelajaran penguatan.
5. Apa konsep pembelajaran sebagai pencarian?
6. Apa saja tujuan pembelajaran mesin? Bagaimana kaitannya dengan pembelajaran manusia?
7. Definisikan pembelajaran mesin dan jelaskan berbagai elemennya dengan contoh nyata.
8. Jelaskan proses abstraksi dengan sebuah contoh.
9. Apa itu generalisasi? Apa perannya dalam proses pembelajaran mesin?
10. Apa itu klasifikasi? Jelaskan perbedaan utama antara klasifikasi dan regresi.
11. Apa itu regresi? Berikan contoh beberapa masalah praktis yang dipecahkan menggunakan regresi.
12. Jelaskan proses pengelompokan secara rinci.
13. Tulis catatan singkat tentang dua hal berikut:
 1. Penerapan algoritma pembelajaran mesin
 2. Pembelajaran yang diawasi
 3. Pembelajaran tanpa pengawasan
 4. Pembelajaran penguatan

PERTANYAAN JAWABAN PANJANG (PERTANYAAN 10 NILAI):

1. Apa itu machine learning? Jelaskan dua aplikasi bisnis machine learning. Apa saja kemungkinan masalah etika dari aplikasi machine learning?
2. Jelaskan bagaimana pembelajaran manusia terjadi:
 1. Di bawah bimbingan langsung para ahli
 2. Di bawah bimbingan tidak langsung dari para ahli
 3. Belajar mandiri

3. Jelaskan berbagai bentuk pembelajaran mesin dengan beberapa contoh.
4. Bandingkan berbagai jenis pembelajaran mesin.
5. Apa yang Anda maksud dengan masalah pembelajaran yang dirumuskan dengan baik? Jelaskan fitur-fitur penting yang dibutuhkan untuk mendefinisikan masalah pembelajaran dengan baik.
6. Bisakah semua masalah dipecahkan menggunakan pembelajaran mesin? Jelaskan jawaban Anda secara terperinci.
7. Apa saja alat dan teknologi yang tersedia untuk memecahkan masalah dalam pembelajaran mesin? Berikan detail tentang dua di antaranya.
8. Apa saja jenis-jenis pembelajaran terbimbing? Jelaskan dengan contoh penerapan di setiap bidang.
9. Apa saja jenis pembelajaran tanpa pengawasan? Jelaskan perbedaannya dengan contoh penerapan di setiap area.
10. Jelaskan secara rinci proses pembelajaran mesin.
 1. Tulis catatan singkat tentang dua hal berikut:
 1. Bahasa Indonesia: MATLAB
 2. Penerapan pembelajaran mesin dalam bidang kesehatan
 3. Analisis keranjang pasar
 4. Regresi linier sederhana
 2. Tuliskan perbedaan antara (dua hal):
 1. Abstraksi dan generalisasi
 2. Pembelajaran dengan pengawasan dan tanpa pengawasan
 3. Klasifikasi dan regresi

Bab 2 Persiapan untuk Membuat Model

Yonky Pernando,S.Kom,M.Kom,

A.Tujuan Pembelajaran

Bab ini memberikan gambaran terperinci tentang cara memahami data yang masuk dan menciptakan pemahaman dasar tentang sifat dan kualitas data. Informasi ini, pada gilirannya, membantu memilih dan kemudian menerapkan model. Jadi, pengetahuan yang diberikan dalam bab ini membantu seorang pemula mengambil langkah pertama menuju pemodelan yang efektif dan memecahkan masalah pembelajaran mesin.

2.1 PENDAHULUAN

Pada bab terakhir, kita diperkenalkan dengan pembelajaran mesin. Pada awalnya, kita melihat sekilas perjalanan pembelajaran mesin sebagai teknologi yang terus berkembang. Semuanya berawal dari usulan ilmuwan komputer terkenal Alan Turing – mesin dapat 'belajar' dan menjadi cerdas secara artifisial. Secara bertahap, selama beberapa dekade berikutnya, inovasi-inovasi yang inovatif muncul dari Arthur Samuel, Frank Rosenblatt, John Hopfield, Christopher Watkins, Geoffrey Hinton, dan banyak ilmuwan komputer lainnya. Mereka membentuk konsep Jaringan Syaraf Tiruan, Jaringan Syaraf Tiruan Berulang, Pembelajaran Penguatan, Pembelajaran Mendalam, dll. yang membawa pembelajaran mesin ke tingkat yang lebih

tinggi. Secara paralel, aplikasi pembelajaran mesin yang menarik terus terjadi, dengan organisasi-organisasi seperti IBM dan Google yang memimpin. Apa yang dimulai dengan kemenangan Deep Blue IBM atas juara catur dunia Gary Kasparov, berlanjut dengan kemenangan Watson IBM atas dua juara manusia dalam kompetisi Jeopardy. Google juga memulai dengan serangkaian inovasi yang menerapkan pembelajaran mesin. Program Google Brain, Sibyl, Waymo, AlphaGo – semuanya merupakan aplikasi pembelajaran mesin yang sangat canggih yang telah membawa teknologi ini ke tingkat yang lebih tinggi. Sekarang kita dapat melihat kehadiran teknologi pembelajaran mesin yang sangat luas di semua lapisan masyarakat.

Kita juga telah melihat jenis pembelajaran manusia dan bagaimana hal itu, dalam beberapa hal, dapat dikaitkan dengan jenis pembelajaran mesin – diawasi, tidak diawasi, dan penguatan. Pembelajaran yang diawasi, seperti yang kita lihat, menyiratkan pembelajaran dari data masa lalu, juga disebut data pelatihan, yang memiliki nilai atau kelas yang diketahui. Mesin dapat 'belajar' atau 'dilatih' dari data masa lalu dan menetapkan kelas atau nilai ke data yang tidak diketahui, disebut sebagai data uji. Ini membantu dalam memecahkan masalah yang terkait dengan prediksi. Ini sangat mirip dengan pembelajaran manusia melalui bimbingan ahli seperti yang terjadi pada bayi dari orang tua atau siswa melalui guru. Jadi, pembelajaran yang diawasi dalam kasus mesin dapat dianggap sebagai pembelajaran yang dipandu dari masukan manusia.

Pembelajaran mesin tanpa pengawasan tidak memiliki data berlabel untuk dipelajari. Ia mencoba menemukan pola dalam data yang tidak berlabel. Ini sangat mirip dengan manusia yang mencoba mengelompokkan objek dengan bentuk yang sama. Pembelajaran ini tidak

dipandu oleh masukan berlabel tetapi menggunakan pengetahuan yang diperoleh dari label itu sendiri. Yang terakhir namun tidak kalah pentingnya adalah pembelajaran penguatan di mana mesin mencoba belajar sendiri melalui mekanisme penalti/hadiah – sekali lagi, caranya hampir sama dengan cara manusia belajar sendiri.

Terakhir, kita melihat beberapa penerapan pembelajaran mesin dalam berbagai domain seperti perbankan dan keuangan, asuransi, dan perawatan kesehatan. Deteksi penipuan merupakan kasus bisnis penting yang diterapkan di hampir semua bank di seluruh dunia dan sebagian besar menggunakan pembelajaran mesin. Prediksi risiko untuk nasabah baru merupakan kasus penting serupa dalam industri asuransi yang menerapkan pembelajaran mesin. Di sektor perawatan kesehatan, prediksi penyakit memanfaatkan pembelajaran mesin secara luas, terutama di negara-negara maju.

Meskipun pengembangan teknologi pembelajaran mesin telah meluas dan implementasinya telah meluas, untuk memulai sebagai praktisi, kita perlu memperoleh beberapa pemahaman dasar. Kita perlu memahami cara menerapkan serangkaian alat dan teknologi yang tersedia dalam pembelajaran mesin untuk memecahkan masalah. Faktanya, hal itu akan sangat spesifik untuk jenis masalah yang ingin kita pecahkan. Jika itu adalah masalah prediksi, jenis aktivitas yang akan terlibat akan sangat berbeda jika itu adalah masalah di mana kita mencoba mengungkap pola dalam data tanpa pengetahuan sebelumnya tentang data tersebut. Jadi seperti apa proyek pembelajaran mesin atau apa saja aktivitas menonjol yang membentuk inti dari proyek pembelajaran mesin akan bergantung pada apakah proyek itu berada di area pembelajaran terbimbing atau tidak terbimbing atau area pembelajaran penguatan. Namun, terlepas

dari variasinya, beberapa pengetahuan dasar perlu dibangun sebelum kita mulai dengan konsep pembelajaran mesin inti dan algoritme utama. Di bagian ini, kita akan melihat sekilas beberapa aktivitas pembelajaran mesin yang umum dan berfokus pada beberapa konsep mendasar yang perlu diperoleh semua praktisi sebagai prasyarat sebelum memulai perjalanan mereka di bidang pembelajaran mesin.

2.2 AKTIVITAS PEMBELAJARAN MESIN

Langkah pertama dalam aktivitas pembelajaran mesin dimulai dengan data. Dalam kasus pembelajaran terbimbing, data pelatihan berlabel diikuti oleh data uji yang tidak berlabel. Dalam kasus pembelajaran tak terbimbing, tidak ada pertanyaan tentang data berlabel tetapi tugasnya adalah menemukan pola dalam data masukan. Tinjauan dan eksplorasi data yang menyeluruh diperlukan untuk memahami jenis data, kualitas data, dan hubungan antara berbagai elemen data. Berdasarkan hal itu, beberapa aktivitas pra-pemrosesan mungkin perlu dilakukan pada data masukan sebelum kita dapat melanjutkan dengan aktivitas pembelajaran mesin inti. Berikut ini adalah aktivitas persiapan umum yang dilakukan setelah data masukan masuk ke sistem pembelajaran mesin:

- Pahami jenis data dalam set data masukan yang diberikan.
- Jelajahi data untuk memahami sifat dan kualitasnya.
- Jelajahi hubungan antar elemen data, misalnya hubungan antar fitur.
- Temukan potensi masalah dalam data.


- Lakukan perbaikan yang diperlukan, misalnya imputasi nilai data yang hilang, dsb., jika diperlukan. Terapkan langkah pra-pemrosesan, seperlunya.

Setelah data disiapkan untuk pemodelan, tugas pembelajaran pun dimulai. Sebagai bagian dari tugas tersebut, lakukan aktivitas berikut:

- Data input pertama-tama dibagi menjadi beberapa bagian – data pelatihan dan data pengujian (disebut holdout). Langkah ini hanya berlaku untuk pembelajaran terbimbing.
- Pertimbangkan berbagai model atau algoritma pembelajaran untuk dipilih. Latih model berdasarkan data pelatihan untuk masalah pembelajaran terbimbing dan terapkan pada data yang tidak diketahui. Terapkan langsung model tanpa pengawasan yang dipilih pada data masukan untuk masalah pembelajaran tanpa pengawasan.

Setelah model dipilih, dilatih (untuk pembelajaran terbimbing), dan diterapkan pada data masukan, kinerja model dievaluasi. Berdasarkan pilihan yang tersedia, tindakan khusus dapat diambil untuk meningkatkan kinerja model, jika memungkinkan.

Gambar 2.1 menggambarkan proses empat langkah pembelajaran mesin.



GAMBAR 2.1Proses rinci pembelajaran mesin

Tabel 2.1 berisi ringkasan langkah-langkah dan aktivitas yang terlibat:

Tabel 2.1 Aktivitas dalam Pembelajaran Mesin

Step #	Step Name	Activities Involved
Step 1	Preparing to Model	• Understand the type of data in the given input data set • Explore the data to understand data quality • Explore the relationships amongst the data elements, e.g. inter-feature relationship • Find potential issues in data • Remediate data, if needed • Apply following pre-processing steps, as necessary: ✓ Dimensionality reduction ✓ Feature subset selection
Step 2	Learning	• Data partitioning/holdout • Model selection • Cross-validation
Step 3	Performance evaluation	• Examine the model performance, e.g. confusion matrix in case of classification • Visualize performance trade-offs using ROC curves
Step 4	Performance improvement	• Tuning the model • Ensembling • Bagging • Boosting

Pada bab ini, kita akan membahas bagian pertama, yaitu persiapan untuk membuat model. Bagian yang tersisa, yaitu pembelajaran, evaluasi kinerja, dan peningkatan kinerja akan dibahas di Bab 3.

2.3 JENIS DATA DASAR DALAM PEMBELAJARAN MESIN

Sebelum memulai dengan jenis data, mari kita pahami terlebih dahulu apa itu kumpulan data dan apa saja elemen dari kumpulan data. Kumpulan data adalah kumpulan informasi atau catatan yang saling terkait. Informasi tersebut mungkin mengenai suatu entitas atau bidang

subjek tertentu. Misalnya (Gambar 2.2), kita mungkin memiliki kumpulan data tentang siswa yang setiap rekamannya berisi informasi tentang siswa tertentu. Sekali lagi, kita dapat memiliki kumpulan data tentang kinerja siswa yang memiliki rekaman yang memberikan kinerja, yaitu nilai pada setiap mata pelajaran.

Setiap baris dari kumpulan data disebut rekaman. Setiap kumpulan data juga memiliki beberapa atribut, yang masing-masing memberikan informasi tentang karakteristik tertentu. Misalnya, dalam kumpulan data tentang siswa, ada empat atribut yaitu Nomor Induk, Nama, Jenis Kelamin, dan Usia, yang masing-masing dapat dipahami sebagai karakteristik khusus tentang entitas siswa. Atribut juga dapat disebut sebagai fitur, variabel, dimensi atau bidang. Kedua kumpulan data, Siswa dan Prestasi Siswa, memiliki empat fitur atau dimensi; oleh karena itu mereka dikatakan memiliki ruang data empat dimensi. Baris atau rekaman mewakili titik dalam ruang data empat dimensi karena setiap baris memiliki nilai tertentu untuk masing-masing dari empat atribut atau fitur. Nilai atribut, cukup dapat dipahami, dapat bervariasi dari rekaman ke rekaman. Misalnya, jika kita merujuk ke dua rekaman pertama dalam kumpulan data Siswa, nilai atribut Nama, Jenis Kelamin, dan Usia berbeda (Gambar 2.3).

Student data set:

Roll Number	Name	Gender	Age
129/011	Mihir Karmarkar	M	14
129/012	Geeta Iyer	F	15
129/013	Chanda Bose	F	14
129/014	Sreenu Subramanian	M	14
129/015	Pallav Gupta	M	16
129/016	Gajanan Sharma	M	15

Student performance data set:

Roll Number	Maths	Science	Percentage
129/011	89	45	89.33%
129/012	89	47	90.67%
129/013	68	29	64.67%
129/014	83	38	80.67%
129/015	57	23	53.33%
129/016	78	35	75.33%

GAMBAR 2.2Contoh kumpulan data

Roll Number	Name	Gender	Age
129/011	Mihir Karmarkar	M	14
129/012	Geeta Iyer	F	15

GAMBAR 2.3Catatan dan atribut kumpulan data

Setelah konteks kumpulan data diberikan, mari kita coba memahami berbagai jenis data yang umumnya kita temukan dalam masalah pembelajaran mesin. Data secara umum dapat dibagi menjadi dua jenis berikut:

1. Data kualitatif
2. Data kuantitatif

Data kualitatif memberikan informasi tentang kualitas suatu objek atau informasi yang tidak dapat diukur. Misalnya, jika kita

mempertimbangkan kualitas kinerja siswa dalam hal 'Baik', 'Rata-rata', dan 'Buruk', maka data tersebut termasuk dalam kategori data kualitatif. Selain itu, nama atau nomor induk siswa merupakan informasi yang tidak dapat diukur menggunakan skala pengukuran tertentu. Jadi, data tersebut termasuk dalam data kualitatif. Data kualitatif juga disebut data kategoris. Data kualitatif dapat dibagi lagi menjadi dua jenis sebagai berikut:

1. Data nominal
2. Data ordinal

Data nominal adalah data yang tidak memiliki nilai numerik, tetapi memiliki nilai bernama. Data ini digunakan untuk menetapkan nilai bernama pada atribut. Nilai nominal tidak dapat dikuantifikasi. Contoh data nominal adalah

1. Golongan darah: A, B, O, AB, dll.
2. Kebangsaan: India, Amerika, Inggris, dll.
3. Jenis Kelamin: Pria, Wanita, Lainnya

Jelaslah, operasi matematika seperti penjumlahan, pengurangan, perkalian, dsb. tidak dapat dilakukan pada data nominal. Oleh karena itu, fungsi statistik seperti mean, variance, dsb. juga tidak dapat diterapkan pada data nominal.

Namun, hitungan dasar dimungkinkan. Jadi modus, yaitu nilai yang paling sering muncul, dapat diidentifikasi untuk data nominal.

Data ordinal, selain memiliki sifat-sifat data nominal, juga dapat diurutkan secara alami. Ini berarti data ordinal juga menetapkan nilai bernama pada atribut tetapi tidak seperti data nominal, data ordinal dapat disusun dalam urutan nilai yang meningkat atau menurun sehingga kita dapat mengatakan apakah suatu nilai lebih baik atau lebih besar dari nilai lainnya. Contoh data ordinal adalah

1. Kepuasan pelanggan: 'Sangat Senang', 'Senang', 'Tidak Senang', dll.
2. Nilai: A, B, C, dst.
3. Kekerasan Logam: 'Sangat Keras', 'Keras', 'Lembut', dll.

Seperti data nominal, penghitungan dasar dimungkinkan untuk data ordinal. Oleh karena itu, modus dapat diidentifikasi. Karena pengurutan dimungkinkan dalam kasus data ordinal, median, dan kuartil dapat diidentifikasi sebagai tambahan. Rata-rata masih belum dapat dihitung.

Data kuantitatif berkaitan dengan informasi tentang kuantitas suatu objek – karenanya dapat diukur. Misalnya, jika kita mempertimbangkan atribut 'tanda', maka dapat diukur menggunakan skala pengukuran. Data kuantitatif juga disebut sebagai data numerik. Ada dua jenis data kuantitatif:

1. Data interval
2. Data rasio

Data interval adalah data numerik yang tidak hanya urutannya diketahui, tetapi juga perbedaan pasti antara nilai-nilainya. Contoh ideal data interval adalah suhu Celsius. Perbedaan antara setiap nilai tetap sama dalam suhu Celsius. Misalnya, perbedaan antara 12°C dan 18°C derajat dapat diukur dan adalah 6°C seperti dalam kasus perbedaan antara $15,5^{\circ}\text{C}$ dan $21,5^{\circ}\text{C}$. Contoh lain termasuk tanggal, waktu, dll.


Untuk data interval, operasi matematika seperti penjumlahan dan pengurangan dapat dilakukan. Oleh karena itu, untuk data interval, kecenderungan sentral dapat diukur dengan rata-rata, median, atau modus. Simpangan baku juga dapat dihitung.

Namun, data interval tidak memiliki sesuatu yang disebut nilai 'nol sejati'. Misalnya, tidak ada yang disebut 'suhu 0' atau 'tidak ada suhu'.

Oleh karena itu, hanya penjumlahan dan pengurangan yang berlaku untuk data interval. Rasio tidak dapat diterapkan. Ini berarti, kita dapat mengatakan suhu 40°C sama dengan suhu $20^{\circ}\text{C} + \text{suhu } 20^{\circ}\text{C}$. Namun, kita tidak dapat mengatakan suhu 40°C berarti dua kali lebih panas daripada suhu 20°C .

Data rasio mewakili data numerik yang nilai pastinya dapat diukur. Nol absolut tersedia untuk data rasio. Selain itu, variabel-variabel ini dapat ditambahkan, dikurangi, dikalikan, atau dibagi. Kecenderungan sentral dapat diukur dengan mean, median, atau modus dan metode penyebaran seperti simpangan baku. Contoh data rasio meliputi tinggi badan, berat badan, usia, gaji, dll.

Gambar 2.4 memberikan gambaran ringkas tentang berbagai jenis data yang mungkin kita temukan dalam masalah pembelajaran mesin umum.



GAMBAR 2.4Jenis data

Selain pendekatan yang dijelaskan di atas, atribut juga dapat dikategorikan ke dalam beberapa jenis berdasarkan sejumlah nilai yang dapat ditetapkan. Atribut dapat bersifat diskrit atau kontinu berdasarkan faktor ini.

Atribut diskret dapat memiliki jumlah nilai yang terbatas atau tak terbatas. Atribut nominal seperti nomor urut, nomor jalan, kode pin, dll. dapat memiliki jumlah nilai yang terbatas sedangkan atribut numerik seperti jumlah, peringkat siswa, dll. dapat memiliki nilai tak terbatas. Jenis khusus atribut diskret yang hanya dapat memiliki dua nilai disebut atribut biner. Contoh atribut biner meliputi pria/wanita, positif/negatif, ya/tidak, dll.

Atribut berkelanjutan dapat mengasumsikan nilai apa pun yang merupakan bilangan riil. Contoh atribut berkelanjutan meliputi panjang, tinggi, berat, harga, dll.

kecuali beberapa pengecualian, misalnya atribut 'jumlah'.

2.4 MENJELAJAHI STRUKTUR DATA

Sekarang, kita memahami bahwa dalam pembelajaran mesin, kita menemukan dua tipe data dasar – numerik dan kategorikal. Dengan konteks ini dalam pikiran, kita dapat mempelajari lebih dalam untuk memahami kumpulan data. Kita perlu memahami bahwa dalam kumpulan data, atribut mana yang bersifat numerik dan mana yang bersifat kategorikal. Ini karena, pendekatan untuk mengeksplorasi data numerik berbeda dari pendekatan untuk mengeksplorasi data kategorikal. Dalam kasus kumpulan data standar, kita mungkin memiliki kamus data yang tersedia untuk referensi. Kamus data adalah repositori metadata, yaitu repositori semua informasi yang terkait dengan struktur setiap elemen data yang terkandung dalam kumpulan data. Kamus data memberikan informasi terperinci tentang setiap atribut – deskripsi serta tipe data dan detail relevan lainnya. Jika kamus data tidak tersedia, kita perlu menggunakan fungsi pustaka standar dari alat pembelajaran mesin yang

kita gunakan dan mendapatkan detailnya. Untuk saat ini, mari kita lanjutkan dengan kumpulan data standar dari repositori pembelajaran mesin UCI.

Kumpulan data yang kami ambil sebagai referensi adalah kumpulan data Auto MPG yang tersedia di repositori UCI. Gambar 2.5 adalah cuplikan beberapa baris pertama kumpulan data.

mpg	cylinder	displacement	horsepower	weight	acceleration	model year	origin	car name
18	8	307	130	3504	12	70	1	Chevrolet chevelle malibu
15	8	350	165	3693	11.5	70	1	Buick skylark 320
18	8	318	150	3436	11	70	1	Plymouth satellite
16	8	304	150	3433	12	70	1	Amc rebel sst
17	8	302	140	3449	10.5	70	1	Ford torino
15	8	429	198	4341	10	70	1	Ford galaxie 500
14	8	454	220	4354	9	70	1	Chevrolet impala
14	8	440	215	4312	8.5	70	1	Plymouth fury iii
14	8	455	225	4425	10	70	1	Pontiac catalina
15	8	390	190	3850	8.5	70	1	Amc acbassador dpl
15	8	383	170	3563	10	70	1	Dodge challenger se
14	8	340	160	3609	8	70	1	Plymouth ' cuda 340
15	8	400	150	3761	9.5	70	1	Chevrolet monte carlo
14	8	455	225	3086	10	70	1	Buick estate wagon (sw)
24	4	113	95	2372	15	70	3	Toyota corona mark ii
22	6	198	95	2933	15.5	70	1	Plymouth duster
18	6	199	97	2774	15.5	70	1	Amc hornet

GAMBAR 2.5Set data MPG otomatis

Seperti yang terlihat jelas dari data, atribut seperti 'mpg', 'cylinders', 'displacement', 'horsepower', 'weight', 'acceleration', 'model year', dan 'origin' semuanya berupa angka. Dari semua atribut ini, 'cylinders', 'model year', dan 'origin' bersifat diskrit karena hanya sejumlah nilai terbatas yang dapat diasumsikan oleh atribut-atribut ini. Atribut angka lainnya, yaitu 'mpg', 'displacement', 'horsepower', 'weight', dan 'acceleration' dapat mengasumsikan nilai riil apa pun.

Oleh karena itu, atribut-atribut ini sifatnya berkesinambungan. Satu-satunya atribut yang tersisa 'nama mobil' adalah bertipe kategoris, atau

lebih tepatnya nominal. Kumpulan data ini mengenai prediksi konsumsi bahan bakar dalam mil per galon, yaitu atribut numerik 'mpg' adalah atribut target.

Dengan pemahaman tentang atribut kumpulan data ini, kita dapat mulai mengeksplorasi atribut numerik dan kategoris secara terpisah.

2.4.1 Menjelajahi data numerik

Ada dua plot matematika yang paling efektif untuk mengeksplorasi data numerik – box plot dan histogram. Kita akan mengeksplorasi semua plot ini satu per satu, dimulai dengan yang paling penting, yaitu box plot.

2.4.1.1 Memahami kecenderungan sentral

Untuk memahami sifat variabel numerik, kita dapat menerapkan ukuran kecenderungan sentral data, yaitu mean dan median. Dalam statistik, ukuran kecenderungan sentral membantu kita memahami titik sentral dari sekumpulan data. Mean, menurut definisi, adalah jumlah semua nilai data dibagi dengan jumlah elemen data. Misalnya, mean dari sekumpulan observasi – 21, 89, 34, 67, dan 96 dihitung seperti di bawah ini.

$$\text{Mean} = \frac{21 + 89 + 34 + 67 + 96}{5} = 61.4$$

Jika rangkaian angka di atas mewakili nilai 5 siswa dalam satu kelas, nilai rata-ratanya, atau yang berada di tengah rentang tersebut adalah 61,4.

Median, sebaliknya, adalah nilai elemen yang muncul di tengah daftar elemen data yang diurutkan. Jika kita mempertimbangkan 5

elemen data di atas, daftar yang diurutkan akan menjadi – 21, 34, 67, 89, dan 96. Karena ada 5 elemen data, elemen ke-3 dalam daftar yang diurutkan dianggap sebagai median. Oleh karena itu, nilai median dari kumpulan data ini adalah 67.

Mungkin ada rasa ingin tahu alami untuk memahami mengapa dua ukuran kecenderungan sentral ditinjau. Alasannya adalah mean dan median dipengaruhi secara berbeda oleh nilai data yang muncul di awal atau di akhir rentang. Mean yang dihitung dari jumlah kumulatif nilai data, dipengaruhi jika terlalu banyak elemen data yang memiliki nilai lebih dekat ke ujung rentang, yaitu dekat dengan nilai maksimum atau minimum. Ini sangat sensitif terhadap outlier, yaitu nilai yang luar biasa tinggi atau rendah, dibandingkan dengan nilai lainnya. Mean cenderung bergeser secara drastis bahkan karena adanya sejumlah kecil outlier. Jika kita mengamati bahwa untuk atribut tertentu deviasi antara nilai mean dan median cukup tinggi, kita harus menyelidiki atribut tersebut lebih lanjut dan mencoba mencari tahu akar penyebabnya bersama dengan kebutuhan untuk remediasi.

Jadi, dalam konteks kumpulan data Auto MPG, mari kita coba mencari tahu nilai mean dan median untuk setiap atribut numerik. Kita juga dapat mencari tahu apakah deviasi antara nilai-nilai ini besar. Gambar 2.6, perbandingan antara mean dan median untuk semua atribut telah ditunjukkan. Kita dapat melihat bahwa untuk atribut seperti 'mpg', 'weight', 'acceleration', dan 'model.year' deviasi antara mean dan median tidak signifikan yang berarti peluang atribut-atribut ini memiliki terlalu banyak nilai outlier lebih kecil. Namun, deviasi tersebut signifikan untuk atribut 'cylinders', 'displacement' dan 'origin'. Jadi, kita perlu menelusuri lebih jauh dan melihat beberapa statistik lagi untuk atribut-atribut ini.

Selain itu, ada beberapa masalah dalam nilai atribut 'horsepower' yang menyebabkan perhitungan mean dan median tidak memungkinkan.

	mpg	cylinders	displacement	horsepower	weight	acceleration	model year	origin
Median	23	4	148.5	?	2804	15.5	76	1
Mean	23.51	5.455	193.4	?	2970	15.57	76.01	1.573
Deviation	2.17	26.67%	23.22%		5.59%	0.45%	0.01%	36.43%
	Low	High	High		Low	Low	Low	High

GAMBAR 2.6Rata-rata vs. Median untuk MPG Mobil

Dengan sedikit penyelidikan, kita dapat mengetahui bahwa masalah tersebut terjadi karena 6 elemen data, seperti yang ditunjukkan padaGambar 2.7, tidak memiliki nilai untuk atribut 'tenaga kuda'.

mpg	cylinders	displacement	horsepower	weight	acceleration	model year	origin	car name
25	4	98	?	2046	19	71	1	Ford pinto
21	6	200	?	2875	17	74	1	Ford maverick
40.9	4	85	?	1835	17.3	80	2	Renault lecar deluxe
23.6	4	140	?	2905	14.3	80	1	Ford mustang cobra
34.5	4	100	?	2320	15.8	81	2	Renault 18i
23	4	151	?	3035	20.5	82	1	Ame concord di

GAMBAR 2.7Nilai atribut 'horsepower' yang hilang di Auto MPG

Oleh karena itu, atribut 'horsepower' tidak diperlakukan sebagai angka. Itulah sebabnya operasi yang berlaku pada variabel angka, seperti mean atau median, gagal. Jadi, pertama-tama kita harus memperbaiki

nilai atribut 'horsepower' yang hilang sebelum dapat melakukan eksplorasi apa pun. Namun, kita akan membahas pendekatan perbaikan nilai yang hilang nanti.

2.4.1.2 Memahami penyebaran data

Sekarang setelah kita menjelajahi kecenderungan utama dari berbagai atribut numerik, kita memiliki gagasan yang jelas tentang atribut mana yang memiliki deviasi besar antara mean dan median. Mari kita cermati atribut-atribut tersebut. Untuk menelusuri lebih dalam, kita perlu melihat seluruh rentang nilai atribut, meskipun tidak pada tingkat elemen data karena mungkin terlalu luas untuk ditinjau secara manual. Jadi, kita akan mengambil pandangan terperinci tentang penyebaran data dalam bentuk

1. Penyebaran data
2. Posisi nilai data yang berbeda

2.4.1.2.1 Mengukur dispersi data

Pertimbangkan nilai data dari dua atribut

1. Nilai atribut 1 : 44, 46, 48, 45, dan 47
2. Nilai atribut 2 : 34, 46, 59, 39, dan 52

Kedua set nilai tersebut memiliki nilai rata-rata dan median sebesar 46. Akan tetapi, set nilai pertama yang memiliki atribut 1 lebih terkonsentrasi atau berkelompok di sekitar nilai rata-rata/median sedangkan set nilai kedua dari atribut 2 cukup menyebar atau terpecah. Untuk mengukur tingkat penyebaran suatu data, atau untuk mengetahui seberapa jauh nilai-nilai yang berbeda dari suatu data tersebar, varians

data diukur. Varians suatu data diukur menggunakan rumus yang diberikan di bawah ini:

Perbedaan $(x) = \frac{\sum_{i=1}^n x_i^2}{n} - \left(\frac{\sum_{i=1}^n x_i}{n} \right)^2$, dimana x adalah variabel atau atribut yang variansnya akan diukur dan n adalah jumlah observasi atau nilai variabel x. Simpangan baku suatu data diukur sebagai berikut:

$$\text{Standard deviation } (x) = \sqrt{\text{Variance } (x)}$$

Nilai varians atau deviasi standar yang lebih besar menunjukkan dispersi yang lebih besar dalam data dan sebaliknya. Dalam contoh di atas, mari kita hitung varians atribut 1 dan atribut 2. Untuk atribut 1,

$$\begin{aligned} \text{Variance} &= \frac{\sum_{i=1}^n x_i^2}{n} - \left(\frac{\sum_{i=1}^n x_i}{n} \right)^2 \\ &= \frac{44^2 + 46^2 + 48^2 + 45^2 + 47^2}{5} - \left(\frac{44 + 46 + 48 + 45 + 47}{5} \right)^2 \\ &= \frac{1936 + 2116 + 2304 + 2025 + 2209}{5} - \left(\frac{230}{5} \right)^2 = \frac{10590}{5} - (46)^2 = 2 \end{aligned}$$

Untuk atribut 2,

$$\begin{aligned}
 \text{Variance} &= \frac{\sum_{i=1}^n x_i^2}{n} - \left(\frac{\sum_{i=1}^n x_i}{n} \right)^2 \\
 &= \frac{34^2 + 46^2 + 59^2 + 39^2 + 52^2}{5} - \left(\frac{34 + 46 + 59 + 39 + 52}{5} \right)^2 \\
 &= \frac{1156 + 2116 + 3481 + 1521 + 2704}{5} - \left(\frac{230}{5} \right)^2 = \frac{10978}{5} - (46)^2 = 79.6
 \end{aligned}$$

Jadi, dari pengukuran tersebut, cukup jelas bahwa nilai atribut 1 cukup terkonsentrasi di sekitar rata-rata, sementara nilai atribut 2 sangat menyebar. Karena data ini kecil, pemeriksaan visual dan pemahaman dapat dilakukan dan hasilnya sesuai dengan nilai yang diukur.

2.4.1.2.2 Mengukur posisi nilai data

Ketika nilai data atribut disusun dalam urutan menaik, kita telah melihat sebelumnya bahwa median memberikan nilai data sentral, yang membagi seluruh set data menjadi dua bagian. Demikian pula, jika bagian pertama data dibagi menjadi dua bagian sehingga setiap bagian terdiri dari seperempat set data, maka median dari bagian pertama tersebut dikenal sebagai kuartil pertama atau Q1. Dengan cara yang sama, jika bagian kedua data dibagi menjadi dua bagian, maka median dari bagian kedua tersebut dikenal sebagai kuartil ketiga atau Q3. Median keseluruhan juga dikenal sebagai kuartil kedua atau Q2. Jadi, setiap set data memiliki lima nilai minimum, kuartil pertama (Q1), median (Q2), kuartil ketiga (Q3), dan maksimum.

Mari kita tinjau nilai-nilai ini untuk atribut 'silinder', 'perpindahan', dan 'asal'. Gambar 2.8 menangkap ringkasan rentang statistik untuk atribut. Jika kita mengambil contoh atribut 'perpindahan', kita dapat

melihat bahwa perbedaan antara nilai minimum dan Q1 adalah 36,2 dan perbedaan antara Q1 dan median adalah 44,3. Sebaliknya, perbedaan antara median dan Q3 adalah 113,5 dan Q3 dan nilai maksimum adalah 193. Dengan kata lain, nilai yang lebih besar lebih menyebar daripada yang lebih kecil. Ini membantu dalam memahami mengapa nilai rata-rata jauh lebih tinggi daripada median untuk atribut 'perpindahan'. Demikian pula, dalam kasus atribut 'silinder', kita dapat mengamati bahwa perbedaan antara nilai minimum dan median adalah 1 sedangkan perbedaan antara median dan nilai maksimum adalah 4. Untuk atribut 'asal', perbedaan antara nilai minimum dan median adalah 0 sedangkan perbedaan antara median dan nilai maksimum adalah 2.

	cylinders	displacement	origin
Minimum	3	68	1
Q1	4	104.2	1
Median	4	148.5	1
Q3	8	262	2
Maximum	8	455	3

GAMBAR 2.8Analisis nilai atribut untuk MPG Otomatis

Akan tetapi, kita masih belum dapat memastikan apakah ada outlier yang ada dalam data. Untuk itu, kita dapat menggunakan beberapa cara untuk memvisualisasikan data. Box plot merupakan media visualisasi yang sangat baik untuk data numerik.

2.4.2 Plotting dan eksplorasi data numerik

2.4.2.1 *Diagram kotak*


Sekarang setelah kita memiliki pemahaman yang cukup jelas tentang atribut kumpulan data dalam hal penyebaran dan kecenderungan sentral, mari kita coba untuk memvisualisasikan semuanya sebagai diagram kotak. Diagram kotak adalah mekanisme yang sangat efektif untuk mendapatkan tampilan satu kali dan memahami sifat data. Namun sebelum kita meninjau diagram kotak untuk berbagai atribut kumpulan data Auto MPG, mari kita coba memahami diagram kotak secara umum dan interpretasi berbagai aspek dalam diagram kotak. Seperti yang dapat kita lihat di [Gambar 2.9](#), diagram kotak (juga disebut diagram kotak dan kumis) memberikan visualisasi standar dari statistik ringkasan lima angka dari suatu data, yaitu minimum, kuartil pertama (Q1), median (Q2), kuartil ketiga (Q3), dan maksimum. Berikut adalah interpretasi terperinci dari diagram kotak;

- Persegi panjang atau kotak pusat membentang dari kuartil pertama hingga ketiga (yaitu Q1 hingga Q3), sehingga memberikan rentang interkuartil (IQR).
- Median diberikan oleh garis atau pita di dalam kotak.

Kumis bawah memanjang hingga 1,5 kali rentang interkuartil (atau IQR) dari bagian bawah kotak, yaitu kuartil pertama atau Q1. Namun, panjang kumis bawah yang sebenarnya bergantung pada nilai data


terendah yang termasuk dalam ($Q1 - 1,5 \text{ kali IQR}$). Mari kita coba memahami ini dengan sebuah contoh. Katakanlah untuk sekumpulan data tertentu, $Q1 = 73$, median = 76 dan $Q3 = 79$. Oleh karena itu, IQR akan menjadi 6 (yaitu $Q3 - Q1$). Jadi, kumis bawah dapat mencapai maksimum hingga ($Q1 - 1,5 \times \text{IQR}$) = $73 - 1,5 \times 6 = 64$. Namun, katakanlah ada nilai data rentang lebih rendah seperti 70, 63, dan 60. Jadi, kumis bawah akan berada pada angka 70 karena ini adalah nilai data terendah yang lebih besar dari 64.

- Kumis atas memanjang hingga 1,5 sebagai kali rentang interkuartil (atau IQR) dari atas kotak, yaitu kuartil ketiga atau $Q3$. Mirip dengan kumis bawah, panjang sebenarnya kumis atas juga akan bergantung pada nilai data tertinggi yang termasuk dalam ($Q3 + 1,5 \text{ kali IQR}$). Mari kita coba memahami ini dengan sebuah contoh. Untuk kumpulan data yang sama yang disebutkan pada poin di atas, kumis atas dapat memanjang maksimum hingga ($Q3 + 1,5 \times \text{IQR}$) = $79 + 1,5 \times 6 = 88$. Jika ada rentang nilai data yang lebih tinggi seperti 82, 84, dan 89. Jadi, kumis atas akan muncul pada 84 karena ini adalah nilai data tertinggi yang lebih rendah dari 88.
- Nilai data yang muncul di luar batas bawah atau atas adalah nilai yang masing-masing luar biasa rendah atau tinggi. Nilai-nilai ini adalah outlier, yang mungkin perlu mendapat pertimbangan khusus.



GAMBAR 2.9Kotak plot

Mari kita visualisasikan diagram kotak untuk tiga atribut 'silinder', 'perpindahan', dan 'asal'. Kita juga akan meninjau diagram kotak atribut lain yang deviasi antara rata-rata dan mediannya sangat kecil dan melihat perbedaan dasar pada diagram kotak masing-masing. Gambar 2.10 menyajikan diagram kotak masing-masing.



GAMBAR 2.10Kotak diagram atribut MPG Otomatis

2.4.2.1.1 Menganalisis diagram kotak untuk 'silinder'

Kotak diagram untuk atribut 'silinder' terlihat bentuknya agak aneh. Kumis bagian atas hilang, pita untuk median jatuh di bagian bawah kotak, bahkan kumis bagian bawah cukup kecil dibandingkan dengan panjang kotak! Apakah semuanya benar?

Jawabannya adalah YA, dan Anda dapat mengetahuinya jika Anda menyelidiki lebih dalam nilai data aktual dari atribut tersebut. Atribut 'silinder' bersifat diskrit dan memiliki nilai dari 3 hingga 8. Tabel 2.2 menangkap frekuensi dan frekuensi kumulatifnya.

Tabel 2.2Frekuensi Atribut “Silinder”

Cylinders	Frequency	Cumulative Frequency
3	4	4
4	204	208 (= 4 + 204)
5	3	211 (= 208 + 3)
6	84	295 (= 211 + 84)
7	0	295 (= 295 + 0)
8	103	398 (= 295 + 103)

Seperti yang dapat diamati dalam tabel, frekuensi sangat tinggi untuk nilai data 4. Dua nilai data lain yang frekuensinya cukup tinggi adalah 6 dan 8. Jadi sekarang jika kita mencoba menemukan kuartil, karena frekuensi totalnya adalah 398, kuartil pertama (Q1), median (Q2), dan kuartil ketiga (Q3) akan berada pada frekuensi kumulatif 99,5 (yaitu rata-rata observasi ke-99 dan ke-100), 199 dan 298,5 (yaitu rata-rata observasi ke-298 dan ke-299), masing-masing. Dengan cara ini $Q1 = 4$, median = 4 dan $Q3 = 8$. Karena tidak ada nilai data di atas 8, tidak ada batas atas. Juga, karena Q1 dan median adalah 4, pita untuk median jatuh di bagian bawah kotak. Dengan cara yang sama, meskipun kumis bawah dapat diperpanjang hingga -2 ($Q1 - 1,5 \times IQR = 4 - 1,5 \times 4 = -2$), pada kenyataannya, tidak ada nilai data yang lebih rendah dari 3. Oleh karena itu, kumis bawah juga pendek. Bagaimanapun, nilai silinder kurang dari 1 tidak mungkin.

2.4.2.1.2 Menganalisis diagram kotak untuk 'asal'

Seperti diagram kotak untuk atribut 'silinder', diagram kotak untuk atribut 'silinder' juga terlihat cukup aneh bentuknya. Di sini, kumis bagian

bawah hilang dan pita untuk median berada di bagian bawah kotak! Mari kita verifikasi apakah semuanya benar?

Sama seperti atribut 'cylinders', atribut 'origin' sifatnya diskret dan memiliki nilai dari 1 hingga 3. **Tabel 2.3** menangkap frekuensi dan frekuensi kumulatif (yaitu penjumlahan frekuensi semua interval sebelumnya) darinya.

Tabel 2.3 Frekuensi Atribut “Asal”

origin	Frequency	Cumulative Frequency
1	249	249
2	70	319 (= 249 + 70)
3	79	398 (= 319 + 79)

Seperti yang dapat diamati dalam tabel, frekuensi sangat tinggi untuk nilai data 1. Karena frekuensi totalnya adalah 398, kuartil pertama (Q1), median (Q2), dan kuartil ketiga (Q3) akan berada pada frekuensi kumulatif 99,5 (yaitu rata-rata pengamatan ke-99 dan ke-100), 199 dan 298,5 (yaitu rata-rata pengamatan ke-298 dan ke-299), masing-masing. Dengan cara ini $Q1 = 1$, median = 1, dan $Q3 = 2$. Karena Q1 dan median memiliki nilai yang sama, pita untuk median berada di bagian bawah kotak. Tidak ada nilai data yang lebih rendah dari Q1. Oleh karena itu, kumis bawah tidak ada.

2.4.2.1.3 Menganalisis diagram kotak untuk 'perpindahan'

Kotak diagram untuk atribut 'perpindahan' terlihat lebih baik daripada kotak diagram sebelumnya. Akan tetapi, masih ada beberapa kelainan kecil, yang penyebabnya perlu ditinjau ulang. Pertama, kumis

bawah jauh lebih kecil daripada kumis atas. Selain itu, pita untuk median lebih dekat ke bagian bawah kotak.

Mari kita lihat lebih dekat data ringkasan atribut 'perpindahan'. Nilai kuartil pertama, $Q1 = 104,2$, median $= 148,5$, dan kuartil ketiga, $Q3 = 262$. Karena $(\text{median} - Q1) = 44,3$ lebih besar dari $(Q3 - \text{median}) = 113,5$, pita untuk median lebih dekat ke bagian bawah kotak (yang mewakili $Q1$). Nilai IQR, dalam kasus ini, adalah $157,8$. Jadi, kumis bawah bisa $1,5$ kali $157,8$ lebih kecil dari $Q1$. Namun, nilai data minimum untuk atribut 'perpindahan' adalah 68 . Jadi, kumis bawah pada $15\% [(Q1 - \text{minimum}) / (1,5 \times \text{IQR}) = (104,2 - 68) / (1,5 \times 157,8) = 15\%]$ dari panjang yang diizinkan. Di sisi lain, nilai data maksimum adalah 455 . Jadi kumis atas adalah $81\% [(\text{maksimum} - Q3) / (1,5 \times \text{IQR}) = (455 - 262) / (1,5 \times 157,8) = 81\%]$ dari panjang yang diizinkan. Inilah sebabnya mengapa kumis atas jauh lebih panjang daripada kumis bawah.

2.4.2.1.4 Menganalisis diagram kotak untuk 'Tahun Model'

Kotak diagram untuk atribut 'model.tahun' tampak sempurna. Mari kita validasi apakah memang sesuai dengan yang diharapkan.

Untuk atribut 'model.year':

Kuartil pertama, $Q1 = 73$

Rata-rata, $Q2 = 76$

Kuartil ketiga, $Q3 = 79$

Jadi, selisih antara median dan $Q1$ sama persis dengan $Q3$ dan median (keduanya 3). Itulah sebabnya pita untuk median berjarak sama persis dari bagian bawah dan atas kotak.

Saya $QR = Q3 - Q1 = 79 - 73 = 6$


Selisih antara Q1 dan nilai data minimum (yaitu 70) juga sama dengan nilai data maksimum (yaitu 82) dan Q3 (keduanya 3). Jadi kumis bawah dan atas diharapkan berukuran sama yaitu 33% [$3 / (1,5 \times 6)$] dari panjang yang diizinkan.

2.4.2.2 Histogram

Histogram adalah plot lain yang membantu dalam visualisasi atribut numerik yang efektif. Histogram membantu dalam memahami distribusi data numerik ke dalam serangkaian interval, yang juga disebut sebagai 'bin'. Perbedaan penting antara histogram dan box plot adalah

- Fokus histogram adalah untuk memetakan rentang nilai data (bertindak sebagai 'kotak'), jumlah elemen data dalam setiap rentang akan bergantung pada distribusi data. Berdasarkan hal itu, ukuran setiap batang yang sesuai dengan rentang yang berbeda akan bervariasi.
- Fokus diagram kotak adalah membagi elemen data dalam satu set data menjadi empat bagian yang sama, sehingga setiap bagian berisi jumlah elemen data yang sama.

Histogram mungkin memiliki bentuk yang berbeda-beda, tergantung pada sifat data, misalnya kemiringan. Gambar 2.11 menyediakan gambaran berbagai bentuk histogram yang umumnya dibuat. Pola-pola ini memberi kita pemahaman cepat tentang data dan dengan demikian bertindak sebagai alat eksplorasi data yang hebat.




GAMBAR 2.11Bentuk Histogram Umum

Sekarang mari kita periksa histogram untuk atribut berbeda dari set data MPG Otomatis yang disajikan dalam [Gambar 2.12](#) Histogram untuk 'mpg' dan 'weight' miring ke kanan. Histogram untuk 'acceleration' simetris dan unimodal, sedangkan histogram untuk 'model.year' simetris dan seragam. Untuk atribut yang tersisa, histogram bersifat multimodal.

Sekarang mari kita gali lebih dalam salah satu histogram, katakanlah histogram untuk atribut 'akselerasi'. Histogram terdiri dari sejumlah batang, satu batang muncul untuk setiap 'kotak'. Tinggi batang mencerminkan jumlah total elemen data yang nilainya berada dalam nilai kotak tertentu, atau frekuensi. Berbicara dalam konteks histogram untuk akselerasi, setiap 'kotak' mewakili interval nilai akselerasi 2 unit. Jadi kotak kedua, misalnya, mencerminkan nilai akselerasi 10 hingga 12 unit. Tinggi diagram batang yang sesuai mencerminkan jumlah semua elemen data yang nilainya berada di antara 10 dan 12 unit. Juga, terlihat dari histogram bahwa ia membentang di atas nilai akselerasi 8 hingga 26 unit. Frekuensi elemen data yang sesuai dengan kotak pertama terus meningkat, hingga mencapai kotak rentang 14 hingga 16 unit. Pada rentang ini, batang

berukuran paling tinggi. Jadi kita dapat menyimpulkan bahwa jumlah maksimum elemen data berada dalam rentang ini. Setelah rentang ini, ukuran batang mulai menurun hingga akhir seluruh rentang pada nilai percepatan 26 satuan.

Harap perhatikan bahwa ketika histogram seragam, seperti dalam kasus atribut 'model. tahun', ini memberikan petunjuk bahwa semua nilai memiliki kemungkinan yang sama untuk muncul.



GAMBAR 2.12Atribut Histogram MPG Otomatis

2.4.3 Menjelajahi data kategorikal

Kita telah melihat ada beberapa cara untuk menjelajahi data numerik. Akan tetapi, tidak banyak pilihan untuk menjelajahi data kategoris. Dalam set data MPG Otomatis, atribut 'car.name' bersifat kategoris. Selain itu, seperti yang telah kita bahas sebelumnya, kita dapat mempertimbangkan 'silinder' sebagai variabel kategoris, bukan variabel numerik.

Ringkasan pertama yang mungkin menarik untuk dicatat adalah berapa banyak nama unik yang ada untuk atribut 'nama mobil' atau berapa banyak nilai unik yang ada untuk atribut 'silinder'. Kita bisa mendapatkannya sebagai berikut:

Untuk atribut 'nama mobil'

1. Chevrolet chevrolet malibu
2. Mobil Buick Skylark 320
3. Satelit Plymouth
4. Pemberontak amc sst
5. Ford tronton
6. Ford galaksi 500
7. Mobil Chevrolet Impala
8. Plymouth Fury III (Kemarahan Plymouth III)
9. Pontiac Catalina
10. Duta Amc dpl

Untuk atribut 'silinder'

8 4 6 3 5

Kita juga dapat mencari sedikit lebih detail dan ingin mendapatkan tabel yang berisi kategori atribut dan jumlah elemen data yang termasuk dalam kategori tersebut. **Tabel 2.4** Dan **2.5** berisi rincian ini.

Untuk atribut 'nama mobil'

Tabel 2.4Jumlah Kategori untuk Atribut 'nama mobil'

Attribute Value	amc ambas-sador brougham	amc ambas-sador dpl	amc ambassa-dor sst	amc concord	amc concord d/l	amc con-cord dl 6	amc gremlin	...
Count	1	1	1	1	2	2	4	...

Untuk atribut “silinder”

Tabel 2.5Jumlah Kategori untuk Atribut 'Silinder'

Attribute Value	3	4	5	6	8
Count	4	204	3	84	103

Dengan cara yang sama, kita mungkin juga tertarik untuk mengetahui proporsi (atau persentase) jumlah elemen data yang termasuk dalam suatu kategori. Misalnya, untuk atribut 'silinder', proporsi elemen data yang termasuk dalam kategori 4 adalah $204 \div 398 = 0,513$, yaitu 51,3%. **Tabel 2.6** Dan **2.7** berisi ringkasan atribut kategoris berdasarkan proporsi elemen data.

Untuk atribut 'nama mobil'

Tabel 2.6Proporsi Kategori untuk Atribut "'Silinder'

Attribute Value	Amc ambas-sador brougham	Amc ambassa-dor dpl	Amc ambassa-dor sst	Amc concord	Amc concord d/l	Amc concord dl 6	Amc gremlin	...
Count	0.003	0.003	0.003	0.003	0.005	0.005	0.01	...

Untuk atribut 'silinder'

Tabel 2.7Proporsi Kategori untuk Atribut “Silinder”

Attribute Value	3	4	5	6	8
Count	0.01	0.513	0.008	0.211	0.259

Terakhir, seperti yang telah kita baca di bagian sebelumnya tentang jenis data, ukuran statistik “modus” berlaku pada atribut kategoris. Seperti yang kita ketahui, seperti mean dan median, modus juga merupakan ukuran statistik untuk kecenderungan sentral suatu data. Modus suatu data adalah nilai data yang paling sering muncul. Dalam konteks atribut kategoris, modus adalah kategori yang memiliki jumlah nilai data terbanyak. Karena mean dan median tidak dapat diterapkan untuk variabel kategoris, modus adalah satu-satunya ukuran kecenderungan sentral.

Mari kita coba cari tahu modus untuk atribut 'nama mobil' dan 'silinder'. Untuk silinder, karena jumlah kategori lebih sedikit dan kita memiliki seluruh tabel yang tercantum di atas, kita dapat melihat bahwa modusnya adalah 4, karena itulah nilai data yang frekuensinya paling tinggi. Lebih dari 50% elemen data termasuk dalam kategori 4. Namun, hal itu tidak begitu jelas untuk atribut 'nama mobil' dari informasi yang diberikan di atas. Ketika kita menyelidiki dan mencoba mencari modusnya, ditemukan bahwa itu adalah kategori 'ford pinto' yang frekuensinya memiliki nilai tertinggi 6.

Suatu atribut dapat memiliki satu atau lebih modus. Distribusi frekuensi suatu atribut yang memiliki modus tunggal disebut 'unimodal', dua modus disebut 'bimodal' dan beberapa modus disebut 'multimodal'.

2.4.4 Menjelajahi hubungan antar variable


Hingga saat ini, kita telah menjelajahi atribut tunggal secara terpisah. Satu sudut pandang penting lainnya dalam eksplorasi data adalah menjelajahi hubungan antara atribut. Ada beberapa plot yang memungkinkan kita menjelajahi hubungan antara variabel. Plot dasar dan yang paling umum digunakan adalah plot sebar.

2.4.4.1 *Diagram sebar*

Plot sebar membantu dalam memvisualisasikan hubungan bivariat, yaitu hubungan antara dua variabel. Ini adalah plot dua dimensi di mana titik atau titik digambar pada koordinat yang disediakan oleh nilai atribut. Misalnya, dalam satu set data ada dua atribut – `attr_1` dan `attr_2`. Kita ingin memahami hubungan antara dua atribut, yaitu dengan perubahan nilai satu atribut, katakanlah `attr_1`, bagaimana nilai atribut lainnya, katakanlah `attr_2`, berubah. Kita dapat menggambar plot sebar, dengan `attr_1` dipetakan ke sumbu x dan `attr_2` dipetakan dalam sumbu y. Jadi, setiap titik dalam plot akan memiliki nilai `attr_1` dalam koordinat x dan nilai `attr_2` dalam koordinat y. Seperti dalam plot dua dimensi, `attr_1` dikatakan sebagai variabel independen dan `attr_2` sebagai variabel dependen.


Mari kita ambil contoh nyata dalam konteks ini. Dalam kumpulan data Auto MPG, diharapkan ada beberapa hubungan antara atribut 'displacement' dan 'mpg'. Mari kita coba verifikasi intuisi kita menggunakan diagram sebar 'displacement' dan 'mpg'. Mari kita petakan 'displacement' sebagai koordinat x dan 'mpg' sebagai koordinat y. Diagram sebar muncul seperti pada Gambar 2.13.

Seperti yang terlihat pada diagram sebar, terdapat hubungan yang pasti antara kedua variabel. Nilai 'mpg' tampaknya terus menurun seiring dengan peningkatan nilai 'perpindahan'. Mungkin terlintas dalam pikiran kita, seberapa jauh hubungannya? Nah, hal itu dapat ditinjau dengan menghitung korelasi antara variabel. Lihat [Bab 5](#) jika Anda ingin mengetahui lebih lanjut tentang korelasi dan cara menghitungnya. Satu fakta menarik lainnya yang perlu diperhatikan adalah bahwa ada nilai data tertentu yang menonjol dari yang lain. Misalnya, ada satu elemen data yang memiliki mpg 37 untuk perpindahan 250. Catatan ini sama sekali berbeda dari elemen data lain yang memiliki nilai perpindahan serupa tetapi nilai mpg dalam kisaran 15 hingga 25. Ini memberikan indikasi adanya nilai data outlier.



GAMBAR 2.13Diagram sebar 'perpindahan' dan 'mpg'

Di dalam **Gambar 2.14**, hubungan berpasangan di antara fitur-fitur – 'mpg', 'displacement', 'horsepower', 'weight', dan 'acceleration' telah tertangkap. Seperti yang dapat Anda lihat, dalam sebagian besar kasus, terdapat hubungan yang signifikan antara pasangan atribut. Namun, dalam beberapa kasus, misalnya antara atribut 'weight' dan 'acceleration', hubungannya tampaknya tidak terlalu kuat.



GAMBAR 2.14 Plot sebaran berpasangan antara berbagai atribut MPG Otomatis

2.4.4.2 Tabulasi silang dua arah

Tabulasi silang dua arah (juga disebut tab silang atau tabel kontingensi) digunakan untuk memahami hubungan dua atribut kategoris secara ringkas. Tabulasi silang memiliki format matriks yang menyajikan tampilan ringkasan distribusi frekuensi bivariat. Tab silang, sangat mirip dengan diagram sebar, membantu memahami seberapa besar nilai data dari satu atribut berubah seiring dengan perubahan nilai data atribut lainnya. Mari kita coba lihat dengan contoh, dalam konteks kumpulan data Auto MPG.

Mari kita asumsikan atribut 'cylinders', 'model.year', dan 'origin' sebagai kategoris dan mencoba memeriksa variasi salah satunya terhadap yang lain. Seperti yang kita pahami, atribut 'cylinders' mencerminkan jumlah silinder dalam mobil dan mengasumsikan nilai 3, 4, 5, 6, dan 8. Atribut 'model.year' menangkap tahun model setiap mobil dan 'origin' memberikan wilayah mobil, nilai untuk origin 1, 2, dan 3 sesuai dengan Amerika Utara, Eropa, dan Asia. Berikut adalah tabel silang. Mari kita coba memahami informasi apa yang sebenarnya mereka berikan.

Tabel silang pertama, yaitu yang menunjukkan hubungan antara atribut 'model, tahun' dan 'asal' membantu kita memahami jumlah kendaraan per tahun di setiap kawasan Amerika Utara, Eropa, dan Asia. Jika dilihat dari sudut pandang lain, kita bisa mendapatkan jumlah kendaraan per kawasan selama beberapa tahun. Semua ini berada dalam konteks data sampel yang diberikan dalam set data Auto MPG.

Beralih ke tabel silang kedua, tabel tersebut memberikan jumlah mobil 3, 4, 5, 6, atau 8 silinder di setiap wilayah yang ada dalam kumpulan data sampel. Tabel silang terakhir menyajikan jumlah mobil 3, 4, 5, 6, atau 8 silinder setiap tahun.

Kita mungkin juga ingin membuat tabel silang dengan tampilan yang lebih ringkas, seperti tabel silang yang memberikan jumlah mobil dengan 4 silinder atau kurang dan lebih dari 4 silinder di setiap wilayah atau menurut tahun. Ini dapat dilakukan dengan menggabungkan nilai data menurut atribut 'silinder'. **Tabel 2.8–2.10** menyajikan tabel silang untuk berbagai kombinasi atribut.

'Tahun model' vs. 'asal'

Tabel 2.8 Tab silang untuk 'Tahun model' vs. 'Asal'

Origin \ Model Year	70	71	72	73	74	75	76	77	78	79	80	81	82
1	22	20	18	29	15	20	22	18	22	23	7	13	20
2	5	4	5	7	6	6	8	4	6	4	9	4	2
3	2	4	5	4	6	4	4	6	8	2	13	12	9

"Silinder" vs. "Asal Usul"

Tabel 2.9 Tab silang untuk 'Silinder' vs. 'Asal'

Cylinders \ Origin	1	2	3
3	0	0	4
4	72	63	69
5	0	3	0
6	74	4	6
8	103	0	0

"Silinder" vs. "Tahun model"

Tabel 2.10 Tab silang untuk 'Silinder' vs. 'Tahun model'

Cylinders \ Model Year	70	71	72	73	74	75	76	77	78	79	80	81	82
3	0	0	1	1	0	0	0	1	0	0	1	0	0
4	7	13	14	11	15	12	15	14	17	12	25	21	28
5	0	0	0	0	0	0	0	0	1	1	1	0	0
6	4	8	0	8	7	12	10	5	12	6	2	7	3
8	18	7	13	20	5	6	9	8	6	10	0	1	0

2.5 KUALITAS DATA DAN REMEDIASI

2.5.1 Kualitas data

Keberhasilan pembelajaran mesin sangat bergantung pada kualitas data. Data yang memiliki kualitas yang tepat membantu mencapai akurasi prediksi yang lebih baik, dalam kasus pembelajaran terbimbing. Namun, tidak realistis untuk mengharapkan bahwa data akan sempurna. Kami telah menemukan setidaknya dua jenis masalah:

1. Elemen data tertentu tanpa nilai atau data dengan nilai yang hilang.
2. Elemen data yang memiliki nilai yang sangat berbeda dari elemen lainnya, yang kami sebut sebagai outlier.

Ada beberapa faktor yang menyebabkan masalah kualitas data ini. Berikut ini beberapa di antaranya:

- **Pemilihan set sampel salah:** Data mungkin tidak mencerminkan kualitas normal atau reguler karena pemilihan set sampel yang salah. Misalnya, jika kita memilih set sampel transaksi penjualan dari periode perayaan dan mencoba menggunakan data tersebut untuk memprediksi penjualan di masa mendatang. Dalam kasus ini, prediksi akan jauh dari skenario sebenarnya, hanya karena set sampel telah dipilih pada waktu yang salah. Demikian pula, jika kita mencoba memprediksi hasil jajak pendapat menggunakan data pelatihan yang tidak terdiri dari campuran pemilih yang tepat dari berbagai segmen seperti usia, jenis kelamin, keragaman etnis, dll., prediksi pasti akan gagal. Itu mungkin juga terjadi karena ukuran sampel yang salah. Misalnya, sampel berukuran kecil mungkin tidak dapat menangkap semua aspek atau informasi yang diperlukan untuk pembelajaran model yang tepat.

- **Kesalahan dalam pengumpulan data:** menghasilkan outlier dan nilai yang hilang Dalam banyak kasus, seseorang atau sekelompok orang bertanggung jawab atas pengumpulan data yang akan digunakan dalam kegiatan pembelajaran. Dalam proses manual ini, ada kemungkinan terjadi pencatatan data yang salah baik dalam hal nilai (misalnya 20,67 salah dicatat sebagai 206,7 atau 2,067) atau dalam hal unit pengukuran (misalnya cm. salah dicatat sebagai m. atau mm.). Hal ini dapat mengakibatkan elemen data yang memiliki nilai yang sangat tinggi atau rendah dari elemen lainnya. Catatan tersebut disebut sebagai outlier.
- Bisa juga terjadi bahwa data tidak terekam sama sekali. Dalam kasus survei yang dilakukan untuk mengumpulkan data, hal ini lebih mungkin terjadi karena responden survei mungkin memilih untuk tidak menanggapi pertanyaan tertentu. Jadi nilai data untuk elemen data tersebut dalam catatan responden tersebut hilang.

2.5.2 Remediasi data

Masalah kualitas data, seperti yang disebutkan di atas, perlu diperbaiki, jika jumlah efisiensi yang tepat harus dicapai dalam kegiatan pembelajaran. Dari dua area utama yang disebutkan di atas, yang pertama dapat diperbaiki dengan teknik pengambilan sampel yang tepat. Ini adalah area yang sama sekali berbeda – dicakup sebagai area subjek khusus dalam statistik. Kami tidak akan membahasnya dalam buku ini. Namun, kesalahan manusia pasti terjadi, tidak peduli apa pun pemeriksaan dan penyeimbangan yang kami lakukan. Oleh karena itu, langkah-langkah perbaikan yang tepat perlu diambil untuk area kedua yang disebutkan di atas. Kami akan membahas cara menangani outlier dan nilai yang hilang.

2.5.2.1 Penanganan outlier

Nilai outlier adalah elemen data dengan nilai yang sangat tinggi yang dapat memengaruhi akurasi prediksi, terutama dalam model regresi. Setelah nilai outlier diidentifikasi dan keputusan telah diambil untuk mengubah nilai tersebut, Anda dapat mempertimbangkan salah satu pendekatan berikut. Namun, jika nilai outlier bersifat alami, yaitu nilai elemen data secara mengejutkan tinggi atau rendah karena alasan yang valid, maka kita tidak boleh mengubahnya.

- **Hapus outlier:**Jika jumlah rekaman yang merupakan outlier tidak banyak, pendekatan yang sederhana adalah menghapusnya.
- **Tuduhan:**Cara lain adalah dengan mengimputasikan nilai dengan mean atau median atau modus. Nilai elemen data yang paling mirip juga dapat digunakan untuk imputasi.
- **Pembatasan:**Untuk nilai yang berada di luar batasan IQR $1,5|x|$, kita dapat membatasinya dengan mengganti observasi di bawah batas bawah dengan nilai persentil ke-5 dan observasi yang berada di atas batas atas, dengan nilai persentil ke-95.

Jika terdapat sejumlah besar outlier, outlier tersebut harus diperlakukan secara terpisah dalam model statistik. Dalam kasus tersebut, kelompok harus diperlakukan sebagai dua kelompok yang berbeda, model harus dibuat untuk kedua kelompok tersebut, lalu hasilnya dapat digabungkan.

2.5.2.2 Penanganan nilai yang hilang

Dalam satu set data, satu atau beberapa elemen data mungkin memiliki nilai yang hilang dalam beberapa rekaman. Seperti yang dibahas

di atas, hal ini dapat disebabkan oleh kelalaian dari pihak surveyor atau orang yang mengumpulkan data sampel atau oleh responden, terutama karena keenggannya untuk menanggapi atau kurangnya pemahaman yang diperlukan untuk memberikan tanggapan. Mungkin saja pertanyaan tertentu (yang menjadi dasar asal nilai elemen data) tidak berlaku untuk orang atau objek yang datanya dikumpulkan. Ada beberapa strategi untuk menangani nilai elemen data yang hilang. Beberapa strategi tersebut telah dibahas di bawah ini.

2.5.2.2.1 Menghilangkan catatan yang memiliki nilai elemen data yang hilang

Jika proporsi elemen data yang memiliki nilai yang hilang berada dalam batas yang dapat ditoleransi, pendekatan yang sederhana namun efektif adalah menghapus catatan yang memiliki elemen data tersebut. Hal ini dimungkinkan jika kuantum data yang tersisa setelah menghapus elemen data yang memiliki nilai yang hilang cukup besar.

Dalam kasus kumpulan data Auto MPG, hanya dalam 6 dari 398 catatan, nilai atribut 'horsepower' tidak ada. Jika kita menyingkirkan 6 catatan tersebut, kita akan tetap memiliki 392 catatan, yang tentunya merupakan jumlah yang besar. Jadi, kita dapat dengan mudah menghilangkan catatan tersebut dan terus bekerja dengan kumpulan data yang tersisa.

Namun, hal ini tidak akan mungkin dilakukan jika proporsi rekaman yang memiliki elemen data dengan nilai yang hilang sangat tinggi karena hal itu akan mengurangi kekuatan model karena pengurangan dalam ukuran data pelatihan.

2.5.2.2.2 Mengimputasi nilai yang hilang

Imputasi adalah metode untuk menetapkan nilai pada elemen data yang memiliki nilai yang hilang. Nilai yang paling sering ditetapkan adalah mean/modus/median. Untuk atribut kuantitatif, semua nilai yang hilang diimputasikan dengan mean, median, atau modus dari nilai yang tersisa di bawah atribut yang sama. Untuk atribut kualitatif, semua nilai yang hilang diimputasikan oleh modus dari semua nilai yang tersisa dari atribut yang sama. Namun, strategi lain dapat mengidentifikasi jenis pengamatan serupa yang nilainya diketahui dan menggunakan mean/median/modus dari nilai-nilai yang diketahui tersebut.

Misalnya, dalam konteks atribut 'tenaga kuda' dari kumpulan data Auto MPG, karena atributnya kuantitatif, kami mengambil rata-rata atau median dari nilai elemen data yang tersisa dan menetapkan ke semua elemen data yang memiliki nilai yang hilang. Jadi, kami dapat menetapkan rata-rata, yaitu 104,47 dan menetapkan ke semua enam elemen data. Pendekatan lainnya adalah kami dapat mengambil rata-rata atau median berdasarkan kesamaan. Jika kami merujuk ke enam pengamatan dengan nilai yang hilang untuk atribut 'tenaga kuda' seperti yang digambarkan dalam [Tabel 2.11](#), 'silinder' adalah atribut yang secara logis paling terhubung dengan 'tenaga kuda' karena dengan peningkatan jumlah silinder mobil, tenaga kuda mobil diharapkan meningkat. Jadi, untuk lima pengamatan, kita dapat menggunakan rata-rata elemen data atribut 'tenaga kuda' yang memiliki silinder = 4; yaitu 78,28 dan untuk satu pengamatan yang memiliki silinder = 6, kita dapat menggunakan rata-rata

elemen data yang sama dengan silinder = 6, yaitu 101,5, untuk mengimputasikan nilai pada elemen data yang hilang.

Tabel 2.11 Nilai yang Hilang untuk Atribut 'Tenaga Kuda'

mpg	cylinders	dis- place- ment	horse- power	weight	accel- eration	model year	origin	car name
25	4	98	?	2046	19	71	1	Ford pinto
21	6	200	?	2875	17	74	1	Ford maverick
40.9	4	85	?	1835	17.3	80	2	Renault lecar deluxe
23.6	4	140	?	2905	14.3	80	1	Ford mustang cobra
34.5	4	100	?	2320	15.8	81	2	Renault 18i
23	4	151	?	3035	20.5	82	1	Ame concord dl

2.5.2.2.3 Memperkirakan nilai yang hilang

Jika terdapat titik data yang mirip dengan titik data yang memiliki nilai atribut yang hilang, maka nilai atribut dari titik data yang mirip tersebut dapat ditempatkan sebagai pengganti nilai yang hilang. Untuk menemukan titik data atau pengamatan yang mirip, fungsi jarak dapat digunakan.

Misalnya, mari kita asumsikan bahwa berat badan seorang siswa Rusia yang berusia 12 tahun dan tinggi badan 5 kaki tidak diketahui. Maka berat badan siswa Rusia lainnya yang berusia mendekati 12 tahun dan tinggi badan mendekati 5 kaki dapat dimasukkan.

2.6 PRA-PEMROSESAN DATA

2.6.1 Pengurangan dimensi

Hingga akhir tahun 1990-an, sangat sedikit domain yang dieksplorasi yang mencakup kumpulan data dengan sejumlah besar atribut atau fitur. Secara umum, kumpulan data yang digunakan dalam pembelajaran mesin biasanya berjumlah beberapa puluh. Namun, dalam dua dekade terakhir, telah terjadi perkembangan pesat dalam biologi komputasional seperti proyek genom. Proyek-proyek ini telah menghasilkan kumpulan data berdimensi sangat tinggi dengan 20.000 atau lebih fitur yang sangat umum. Selain itu, telah terjadi adopsi jaringan sosial yang meluas yang mengarah pada kebutuhan akan klasifikasi teks untuk analisis perilaku pelanggan.

Kumpulan data berdimensi tinggi memerlukan ruang dan waktu komputasi yang besar. Pada saat yang sama, tidak semua fitur berguna – fitur-fitur tersebut menurunkan kinerja algoritma pembelajaran mesin. Sebagian besar algoritma pembelajaran mesin berkinerja lebih baik jika dimensionalitas kumpulan data, yaitu jumlah fitur dalam kumpulan data, dikurangi. Pengurangan dimensionalitas membantu mengurangi ketidakrelevanan dan redundansi dalam fitur. Selain itu, lebih mudah untuk memahami model jika jumlah fitur yang terlibat dalam aktivitas pembelajaran lebih sedikit.

Reduksi dimensionalitas mengacu pada teknik-teknik pengurangan dimensionalitas suatu set data dengan menciptakan atribut-atribut baru dengan menggabungkan atribut-atribut asli. Pendekatan yang paling umum untuk reduksi dimensionalitas dikenal sebagai Principal Component Analysis (PCA). PCA adalah teknik statistik untuk mengubah sekumpulan variabel berkorelasi menjadi sekumpulan variabel yang telah ditransformasikan dan tidak berkorelasi yang disebut komponen-komponen utama. Komponen-komponen utama adalah kombinasi linear

dari variabel-variabel asli. Komponen-komponen tersebut ortogonal satu sama lain. Karena komponen-komponen utama tidak berkorelasi, komponen-komponen tersebut menangkap jumlah variabilitas maksimum dalam data. Namun, satu-satunya tantangan adalah bahwa atribut-atribut asli hilang karena transformasi.

Teknik lain yang umum digunakan untuk reduksi dimensionalitas adalah Singular Value Decomposition (SVD).

Lebih lanjut mengenai konsep-konsep ini telah dibahas di Bab 4.

2.6.2 Pemilihan subset fitur

Pemilihan subset fitur atau yang biasa disebut pemilihan fitur, baik untuk pembelajaran terbimbing maupun tak terbimbing, mencoba mencari subset optimal dari seluruh set fitur yang secara signifikan mengurangi biaya komputasi tanpa dampak besar pada akurasi pembelajaran. Tampaknya subset fitur dapat menyebabkan hilangnya informasi yang berguna karena fitur tertentu akan dikecualikan dari set fitur akhir yang digunakan untuk pembelajaran. Namun, untuk eliminasi hanya fitur yang tidak relevan atau berlebihan yang dipilih.

Suatu fitur dianggap tidak relevan jika fitur tersebut memainkan peran yang tidak signifikan (atau hampir tidak memberikan informasi) dalam mengklasifikasikan atau mengelompokkan sekumpulan contoh data. Semua fitur yang tidak relevan dihilangkan saat memilih subset fitur akhir. Suatu fitur berpotensi redundan ketika informasi yang disumbangkan oleh fitur tersebut kurang lebih sama dengan satu atau beberapa fitur lainnya. Di antara sekelompok fitur yang berpotensi redundan, sejumlah kecil fitur dapat dipilih sebagai bagian dari subset

fitur akhir tanpa menyebabkan dampak negatif apa pun terhadap akurasi model pembelajaran.

Ada beberapa cara untuk memilih subset fitur. Bab 4, kami akan membahas pemilihan fitur secara rinci.

2.7 RINGKASAN

- Kumpulan data adalah kumpulan informasi atau catatan yang terkait.
- Data secara garis besar dapat dibagi menjadi dua jenis berikut;
 - Data kualitatif
 - Data kuantitatif
- Data kualitatif memberikan informasi tentang kualitas suatu objek atau informasi yang tidak dapat diukur. Data kualitatif dapat dibagi lagi menjadi dua jenis sebagai berikut:
 - Data nominal: memiliki nilai Bernama.
 - Data ordinal: memiliki nilai bernama yang dapat diurutkan secara alami. Data kuantitatif berkaitan dengan informasi tentang kuantitas suatu objek – karenanya dapat diukur. Ada dua jenis data kuantitatif: Data interval: data numerik yang selisih pasti antara nilai-nilainya diketahui. Akan tetapi, data tersebut tidak memiliki sesuatu yang disebut nilai 'nol sejati'.
- Data rasio: data numerik yang nilai pastinya dapat diukur dan tersedia angka nol mutlak.

CONTOH PERTANYAAN

SOAL PILIHAN GANDA (SOAL 1 NILAI) :

1. Suhu adalah
 1. Data interval
 2. Data rasio
 3. Data diskrit
 4. Tidak ada yang di atas
2. Komponen utama adalah teknik untuk
 1. Pemilihan fitur
 2. Pengurangan dimensi
 3. Eksplorasi
 4. Tidak ada yang di atas
3. Untuk eksplorasi data bivariat, _____ adalah alat yang efektif.
 1. Kotak plot
 2. Tab silang dua arah
 3. Histogram
 4. Tidak ada yang di atas
4. Untuk diagram kotak, panjang kumis atas dan bawah bergantung pada
 1. Rata-rata
 2. Berarti
 3. IQR
 4. Semua hal di atas
5. Pemilihan fitur mencoba untuk menghilangkan fitur-fitur yang
 1. Kaya
 2. Berulang
 3. Tidak relevan

4. Relevan
6. Ketika jumlah fitur meningkat
 1. Waktu komputasi meningkat
 2. Model menjadi rumit
 3. Akurasi pembelajaran menurun
 4. Semua hal di atas
7. Untuk data kategorikal, ____ tidak dapat digunakan sebagai ukuran kecenderungan sentral.
 1. Rata-rata
 2. Berarti
 3. Kuartil
 4. Tidak ada yang di atas
8. Untuk memahami hubungan antara dua variabel, ____ dapat digunakan.
 1. Kotak plot
 2. Diagram sebaran
 3. Histogram
 4. Tidak ada yang di atas
9. Dua jenis masalah data yang umum adalah
 1. Outlier
 2. Nilai hilang
 3. Nilai batas
 4. Tidak ada yang di atas
10. Eksplorasi data numerik dapat dilakukan dengan baik menggunakan
 1. Kotak Plot
 2. Histogram

3. Diagram sebaran
4. Tidak ada yang di atas
11. Data secara garis besar dapat dibagi menjadi dua jenis berikut
 1. Kualitatif
 2. Spekulatif
 3. Kuantitatif
 4. Tidak ada yang di atas
12. Data ordinal dapat secara alami _____.
 1. Terukur
 2. Diperintahkan
 3. Terbagi
 4. Tidak ada yang di atas

SOAL JAWABAN SINGKAT (SOAL 5 NILAI):

1. Apa saja aktivitas utama yang terlibat saat Anda bersiap untuk memulai pemodelan dalam pembelajaran mesin?
2. Apa saja tipe data dasar dalam machine learning? Berikan contoh masing-masing.
3. Membedakan:
 1. Atribut Kategoris vs. Numerik
 2. Pengurangan Dimensionalitas vs. Pemilihan Fitur
4. Tulis catatan singkat tentang dua hal berikut:
 1. Histogram
 2. Diagram sebaran
 3. PCA

5. Mengapa kita perlu mengeksplorasi data? Apakah ada perbedaan dalam cara mengeksplorasi data kualitatif dibandingkan data kuantitatif?
6. Apa saja bentuk histogram yang berbeda? Apa itu 'bins'?
7. Bagaimana kita dapat menangani outlier pada data?
8. Apa saja ukuran kecenderungan sentral yang berbeda? Mengapa mean, dalam kumpulan data tertentu, sangat berbeda dari median?
9. Jelaskan bagaimana hubungan bivariat dapat dieksplorasi menggunakan diagram sebar.
Bisakah outlier dideteksi menggunakan scatter plot?
10. Jelaskan bagaimana tabel silang dapat digunakan untuk memahami hubungan antara dua variabel.

SOAL JAWABAN PANJANG (SOAL 10 NILAI) :

1. Apa saja aktivitas utama yang terlibat dalam machine learning? Apa yang dimaksud dengan pra-pemrosesan data?
2. Jelaskan data kualitatif dan kuantitatif secara rinci. Bedakan antara keduanya.
3. Siapkan satu set data sederhana beserta beberapa contoh rekaman di dalamnya. Miliki setidaknya satu atribut dari berbagai jenis data yang digunakan dalam pembelajaran mesin.

4. Apa saja penyebab masalah data dalam pembelajaran mesin?
Apa saja dampaknya?
5. Jelaskan, dengan contoh yang tepat, berbagai cara mengeksplorasi data kategorikal.
6. Jika ada variabel dengan nilai tertentu yang hilang, apakah itu akan memengaruhi aktivitas pembelajaran? Jika ya, bagaimana cara mengatasinya?
7. Jelaskan secara rinci berbagai strategi untuk mengatasi nilai data yang hilang.
8. Apa saja teknik yang berbeda untuk pra-pemrosesan data? Jelaskan secara singkat, pengurangan dimensionalitas dan pemilihan fitur.
9.
 1. Apa itu IQR? Bagaimana cara mengukurnya?
 2. Jelaskan secara rinci berbagai komponen diagram kotak? Kapan kumis bawah akan lebih panjang daripada kumis atas? Bagaimana outlier dapat dideteksi menggunakan diagram kotak?
10.
 1. Tulis catatan singkat tentang dua hal berikut:
 1. Data interval
 2. Rentang antar kuartil
 3. Tab silang
 2. Tuliskan perbedaan antara (dua hal):
 1. Data nominal dan ordinal
 2. Kotak diagram dan histogram
 3. Rata-rata dan median

Bab 3 Pemodelan dan Evaluasi

Masna Wati, S.Si., M.T.

A. Tujuan Pembelajaran

Bab sebelumnya memberikan pemahaman menyeluruh tentang tipe data dasar dalam konteks pembelajaran mesin. Bab ini juga memungkinkan pemula di bidang pembelajaran mesin untuk memperoleh pemahaman tentang sifat dan kualitas data melalui eksplorasi kumpulan data yang efektif. Dalam bab ini, tujuannya adalah untuk memperkenalkan konsep dasar pembelajaran. Dalam hal ini, informasi yang dibagikan menyangkut aspek pemilihan dan penerapan model. Bab ini juga memberikan pengetahuan tentang cara menilai efektivitas model dalam melakukan tugas pembelajaran tertentu, baik yang diawasi maupun tidak, dan cara meningkatkan kinerja model menggunakan parameter penyetelan yang berbeda.

3.1 PENDAHULUAN

Proses pembelajaran mesin mungkin tampak sangat ajaib bagi seseorang yang baru mengenal pembelajaran mesin. Pemikiran bahwa mesin mampu berpikir dan mengambil tindakan cerdas mungkin memukau – seperti cerita fiksi ilmiah atau fantasi.

Namun, dengan menyelidiki lebih dalam, mereka akan menyadari bahwa hal itu tidak semagis yang terlihat. Faktanya, hal itu mencoba meniru pembelajaran manusia dengan menerapkan rumusan matematika

dan statistik. Dalam hal itu, baik pembelajaran manusia maupun mesin berusaha membangun rumusan atau pemetaan berdasarkan sejumlah pengamatan yang terbatas. Seperti yang diperkenalkan dalam Bab 1, proses pembelajaran dasar, terlepas dari kenyataan bahwa pelajar adalah manusia atau mesin, dapat dibagi menjadi tiga bagian:

1. Masukan Data
2. Abstraksi
3. Generalisasi

Meskipun di Bab 1 kita telah memahami aspek-aspek ini secara rinci, mari kita segarkan ingatan kita dengan sebuah contoh. Ini adalah situasi fiktif. Departemen detektif Kepolisian Kota Baru telah mendapat petunjuk bahwa dalam sebuah pertemuan kampanye untuk pemilihan umum mendatang, seorang penjahat akan melancarkan serangan terhadap kandidat utama. Namun, tidak diketahui siapa orang tersebut dan cukup jelas orang tersebut mungkin menggunakan penyamaran. Satu-satunya hal yang pasti adalah orang tersebut adalah seorang pelaku kejahatan atau penjahat yang memiliki catatan panjang kejahatan serius. Dari basis data kriminal, daftar penjahat tersebut beserta foto-foto mereka telah dikumpulkan. Selain itu, foto-foto yang diambil oleh kamera keamanan yang ditempatkan di tempat-tempat berbeda di dekat pertemuan tersebut tersedia di departemen detektif. Mereka harus mencocokkan foto-foto dari basis data kriminal dengan wajah-wajah di pertemuan tersebut untuk menemukan penyerang potensial. Jadi masalah utama di sini adalah menemukan wajah penjahat berdasarkan kecocokan dengan foto-foto di basis data kriminal.

Hal ini dapat dilakukan dengan menggunakan pembelajaran manusia, di mana seseorang dari departemen detektif dapat memindai

setiap foto terpilih dan mencoba mencocokkan foto tersebut dengan wajah-wajah dalam kumpulan foto tersebut. Seseorang yang memiliki ingatan kuat dapat melihat sekilas foto-foto semua penjahat dalam satu bidikan, lalu mencoba menemukan wajah dalam kumpulan foto yang sangat mirip dengan salah satu foto penjahat yang telah dilihatnya. Mudah, bukan? Namun, hal itu tidak mungkin dilakukan dalam kenyataan. Jumlah penjahat dalam basis data dan karenanya jumlah foto mencapai ratusan, bahkan ribuan. Jadi, melihat semua foto dan menghafalnya tidaklah mungkin. Selain itu, kecocokan yang tepat tidak mungkin dilakukan karena penjahat, kemungkinan besar, akan menyamar. Strategi yang harus diambil di sini adalah mencocokkan foto-foto dalam jumlah yang lebih sedikit dan juga berdasarkan ciri-ciri fisik tertentu yang menonjol seperti bentuk rahang, kemiringan dahi, ukuran mata, struktur telinga, dll. Jadi, foto-foto dari basis data penjahat membentuk data masukan. Berdasarkan hal itu, ciri-ciri utama dapat diabstraksikan. Karena pencocokan manusia untuk setiap foto dapat segera menyebabkan kelelahan visual sekaligus mental, generalisasi data berbasis fitur yang diabstraksikan merupakan cara yang baik untuk mendeteksi wajah-wajah kriminal yang potensial dalam pengumpulan. Misalnya, dari data berbasis fitur yang diabstraksikan, katakanlah diamati bahwa sebagian besar kriminal memiliki jarak yang lebih pendek antara sudut mata bagian dalam, sudut yang lebih kecil antara hidung dan sudut mulut, lengkungan yang lebih tinggi pada bibir atas, dll. Oleh karena itu, wajah dalam pengumpulan dapat diklasifikasikan sebagai 'berpotensi kriminal' berdasarkan apakah mereka cocok dengan pengamatan umum ini. Jadi, dengan menggunakan data masukan, abstraksi berbasis fitur dapat dibangun dan dengan menerapkan generalisasi data yang diabstraksikan,

pembelajaran manusia dapat mengklasifikasikan wajah-wajah tersebut sebagai wajah yang berpotensi kriminal yang pada akhirnya mengarah pada penemuan kriminal.

Hal yang sama juga dapat dilakukan dengan menggunakan pembelajaran mesin. Tidak seperti deteksi manusia, mesin tidak memiliki beban subjektif, tidak ada emosi, tidak ada bias karena pengalaman masa lalu, dan yang terpenting tidak ada kelelahan mental. Mesin juga dapat menggunakan data masukan yang sama, yaitu foto-foto basis data kriminal, menerapkan teknik komputasi untuk mengabstraksi peta konsep berbasis fitur dari data masukan dan menggeneralisasikannya dalam bentuk algoritma klasifikasi untuk memutuskan apakah wajah dalam kumpulan tersebut berpotensi kriminal atau tidak.

Ketika kita berbicara tentang proses pembelajaran, abstraksi merupakan langkah penting karena ia merepresentasikan data masukan mentah dalam format yang diringkas dan terstruktur, sehingga wawasan yang berarti diperoleh dari data tersebut. Representasi terstruktur dari data masukan mentah ke pola yang berarti ini disebut model. Model mungkin memiliki bentuk yang berbeda. Mungkin berupa persamaan matematika, mungkin berupa grafik atau struktur pohon, mungkin berupa blok komputasi, dll. Keputusan mengenai model mana yang akan dipilih untuk set data tertentu diambil oleh tugas pembelajaran, berdasarkan masalah yang harus dipecahkan dan jenis data. Misalnya, ketika masalah terkait dengan prediksi dan bidang target bersifat numerik dan kontinu, model regresi ditetapkan. Proses menetapkan model, dan menyesuaikan model tertentu dengan set data disebut pelatihan model. Setelah model dilatih, data masukan mentah diringkas menjadi bentuk abstrak.

Namun, dengan abstraksi, pembelajar hanya mampu meringkas pengetahuan. Pengetahuan ini mungkin masih sangat luas – terdiri dari sejumlah besar data berbasis fitur dan hubungan timbal balik. Untuk menghasilkan wawasan yang dapat ditindaklanjuti dari pengetahuan yang luas tersebut sangatlah sulit. Di sinilah generalisasi berperan. Generalisasi menelusuri kumpulan besar pengetahuan yang diabstraksikan untuk menghasilkan serangkaian temuan kunci yang kecil dan dapat dikelola. Tidak mungkin melakukan penelusuran menyeluruh dengan meninjau setiap temuan yang diabstraksikan satu per satu. Penelusuran heuristik digunakan, sebuah pendekatan yang juga digunakan untuk pembelajaran manusia (sering disebut sebagai 'gut-feel'). Sangat jelas bahwa heuristik terkadang menghasilkan hasil yang salah. Jika hasilnya secara sistematis salah, pembelajaran dikatakan memiliki bias.

3.2 MEMILIH MODEL

Sekarang setelah Anda terbiasa dengan proses pembelajaran dasar dan telah memahami abstraksi dan generalisasi model dalam konteks itu, mari kita coba memformalkannya dalam konteks contoh yang memotivasi. Melanjutkan alur potensi serangan selama kampanye pemilihan, departemen Kepolisian Kota Baru telah berhasil menggagalkan upaya untuk menyerang kandidat pemilihan. Namun, ini adalah peringatan bagi mereka dan mereka ingin mengambil tindakan proaktif untuk menghilangkan semua kegiatan kriminal di wilayah tersebut. Mereka ingin menemukan pola kegiatan kriminal di masa lalu, yaitu mereka ingin melihat apakah jumlah insiden kriminal per bulan memiliki hubungan dengan pendapatan rata-rata penduduk setempat, penjualan senjata, masuknya imigran, dan faktor-faktor lainnya. Oleh karena itu, hubungan

antara penyebab potensial gangguan dan insiden kriminal harus ditentukan. Dengan kata lain, tujuan atau targetnya adalah mengembangkan model untuk menyimpulkan bagaimana insiden kriminal berubah berdasarkan faktor-faktor potensial yang memengaruhi yang disebutkan di atas.

Dalam paradigma pembelajaran mesin, penyebab potensial gangguan, misalnya pendapatan rata-rata penduduk lokal, penjualan senjata, masuknya imigran, dll. adalah variabel input. Mereka juga disebut prediktor, atribut, fitur, variabel independen, atau hanya variabel. Jumlah insiden kriminal adalah variabel output (juga disebut respons atau variabel dependen). Variabel input dapat dilambangkan dengan X , sedangkan variabel input individual direpresentasikan sebagai $X_1, X_2, X_3, \dots, X_n$ dan variabel output dengan simbol Y . Hubungan antara X dan Y direpresentasikan dalam bentuk umum: $Y = f(X) + e$, di mana ' f ' adalah fungsi target dan ' e ' adalah istilah kesalahan acak.

Namun masalah yang baru saja kita bicarakan adalah salah satu jenis masalah spesifik dalam pembelajaran mesin. Kita telah melihatnya di [Bab 1](#) bahwa ada tiga kategori luas pendekatan pembelajaran mesin yang digunakan untuk menyelesaikan berbagai jenis masalah. Jika diringkas dengan cepat, pendekatan tersebut adalah

1. Diawasi
 1. Klasifikasi
 2. Regresi
2. Tanpa pengawasan
 1. Kelompokan
 2. Analisis asosiasi
3. Bantuan

Untuk setiap kasus, model yang harus dibuat/dilatih berbeda-beda. Beberapa faktor berperan saat kita mencoba memilih model untuk memecahkan masalah pembelajaran mesin. Faktor terpenting adalah (i) jenis masalah yang ingin kita pecahkan menggunakan pembelajaran mesin dan (ii) sifat data yang mendasarinya. Masalah tersebut mungkin terkait dengan prediksi nilai kelas seperti apakah tumor itu ganas atau jinak, apakah hari berikutnya akan bersalju atau hujan, dll. Masalah tersebut mungkin terkait dengan prediksi – tetapi dengan beberapa nilai numerik seperti berapa harga rumah pada kuartal berikutnya, berapa pertumbuhan yang diharapkan dari saham TI tertentu dalam 7 hari ke depan, dll. Masalah tertentu terkait dengan pengelompokan data seperti menemukan segmen pelanggan yang menggunakan produk tertentu, genre film yang lebih sukses di pasaran dalam satu tahun terakhir, dll. Jadi, sangat sulit untuk memberikan panduan umum terkait pembelajaran mesin mana yang harus dipilih. Dengan kata lain, tidak ada satu model yang paling cocok untuk setiap masalah pembelajaran mesin. Inilah yang juga dinyatakan oleh teorema 'Tidak Ada Makan Siang Gratis'.

Setiap model pembelajaran mencoba untuk mensimulasikan beberapa aspek dunia nyata. Akan tetapi, model tersebut disederhanakan hingga sebagian besar dengan menghilangkan semua detail yang rumit. Penyederhanaan ini didasarkan pada asumsi tertentu – yang sangat bergantung pada situasi. Berdasarkan situasi yang sebenarnya, yaitu masalah yang dihadapi dan karakteristik data, asumsi mungkin berlaku atau mungkin tidak berlaku. Jadi, model yang sama dapat menghasilkan hasil yang luar biasa dalam situasi tertentu sementara model tersebut mungkin gagal total dalam situasi yang berbeda. Itulah sebabnya, saat melakukan eksplorasi data, yang telah kita bahas di bab sebelumnya, kita

perlu memahami karakteristik data, menggabungkan pemahaman ini dengan masalah yang ingin kita selesaikan, lalu memutuskan model mana yang akan dipilih untuk menyelesaikan masalah tersebut.

Mari kita coba memahami filosofi pemilihan model secara terstruktur. Algoritme pembelajaran mesin secara umum terdiri dari dua jenis: model untuk pembelajaran terbimbing, yang terutama berfokus pada penyelesaian masalah prediktif dan model untuk pembelajaran tak terbimbing, yang menyelesaikan masalah deskriptif.

3.2.1 Model prediktif

Model untuk pembelajaran terbimbing atau model prediktif, seperti yang dapat dipahami dari namanya sendiri, mencoba untuk memprediksi nilai tertentu menggunakan nilai-nilai dalam set data masukan. Model pembelajaran mencoba untuk membangun hubungan antara fitur target, yaitu fitur yang diprediksi, dan fitur prediktor. Model prediktif memiliki fokus yang jelas pada apa yang ingin mereka pelajari dan bagaimana mereka ingin belajar.

Model prediktif, pada gilirannya, mungkin perlu memprediksi nilai kategori atau kelas tempat contoh data berada. Berikut ini beberapa contohnya:

1. Memprediksi menang/kalah dalam pertandingan kriket
2. Memprediksi apakah suatu transaksi merupakan penipuan
3. Memprediksi apakah pelanggan akan pindah ke produk lain

Model yang digunakan untuk memprediksi fitur target bernilai kategoris dikenal sebagai model klasifikasi. Fitur target dikenal sebagai

kelas dan kategori yang membagi kelas disebut level. Beberapa model klasifikasi yang populer meliputi k-Nearest Neighbor (kNN), Naïve Bayes, dan Decision Tree.

Model prediktif juga dapat digunakan untuk memprediksi nilai numerik fitur target berdasarkan fitur prediktor. Berikut ini beberapa contohnya:

1. Prediksi pertumbuhan pendapatan pada tahun berikutnya
2. Prediksi Jumlah Curah Hujan di Musim Hujan Mendatang
3. Prediksi jumlah pasien flu potensial dan permintaan vaksin flu musim dingin mendatang

Model yang digunakan untuk memprediksi nilai numerik dari fitur target dari suatu contoh data dikenal sebagai model regresi. Model regresi linier dan regresi logistik merupakan model regresi yang populer.

3.2.2 Model deskriptif

Model untuk pembelajaran tanpa pengawasan atau model deskriptif digunakan untuk mendeskripsikan kumpulan data atau memperoleh wawasan dari kumpulan data. Tidak ada fitur target atau fitur tunggal yang menarik dalam kasus pembelajaran tanpa pengawasan. Berdasarkan nilai semua fitur, pola atau wawasan menarik diperoleh tentang kumpulan data.

Model deskriptif yang mengelompokkan data-data serupa, yaitu data-data yang memiliki nilai yang sama dari fitur-fitur yang berbeda disebut model pengelompokan. Contoh pengelompokan meliputi:

1. Pengelompokan atau segmentasi pelanggan berdasarkan faktor sosial, demografi, etnis, dll.
2. Pengelompokan musik berdasarkan berbagai aspek seperti genre, bahasa, periode waktu, dll.

3. Pengelompokan komoditas dalam inventaris

Model yang paling populer untuk pengelompokan adalah k-Means.


Model deskriptif yang terkait dengan penemuan pola digunakan untuk analisis keranjang belanja data transaksional. Dalam analisis keranjang belanja, berdasarkan pola pembelian yang tersedia dalam data transaksional, kemungkinan pembelian satu produk berdasarkan pembelian produk lain ditentukan. Misalnya, data transaksional dapat mengungkapkan pola bahwa umumnya pelanggan yang membeli susu juga membeli biskuit pada saat yang sama. Ini dapat berguna untuk promosi yang ditargetkan atau pengaturan di dalam toko. Promosi yang terkait dengan biskuit dapat dikirim ke pelanggan produk susu atau sebaliknya. Selain itu, di dalam toko produk yang terkait dengan susu dapat ditempatkan dekat dengan biskuit.

3.3 PELATIHAN MODEL (UNTUK PEMBELAJARAN TERAWASI)

3.3.1 Metode Holdout

Dalam kasus pembelajaran terbimbing, model dilatih menggunakan data masukan berlabel. Namun, bagaimana kita dapat memahami kinerja model? Data uji mungkin tidak tersedia dengan segera. Selain itu, nilai label data uji tidak diketahui. Itulah alasan mengapa sebagian data masukan ditahan (begitulah asal mula nama holdout) untuk evaluasi model. Subset data masukan ini digunakan sebagai data uji untuk mengevaluasi kinerja model yang dilatih. Secara umum 70%–80% data masukan (yang jelas berlabel) digunakan untuk pelatihan model. Sisanya 20%–30% digunakan sebagai data uji untuk validasi kinerja model. Namun, proporsi yang berbeda dari pembagian data masukan menjadi

data pelatihan dan pengujian juga dapat diterima. Untuk memastikan bahwa data di kedua bucket tersebut serupa sifatnya, pembagian dilakukan secara acak. Angka acak digunakan untuk menetapkan item data ke partisi. Metode pembagian data masukan ini menjadi dua bagian – data pelatihan dan pengujian (digambarkan dalam [Gambar 3.1](#)), yaitu dengan menahan sebagian data input untuk memvalidasi model yang dilatih dikenal sebagai metode holdout.



GAMBAR 3.1Metode Holdout

Setelah model dilatih menggunakan data pelatihan, label data uji diprediksi menggunakan fungsi target model. Kemudian nilai prediksi dibandingkan dengan nilai label yang sebenarnya. Hal ini dimungkinkan karena data uji merupakan bagian dari data masukan dengan label yang diketahui. Kinerja model secara umum diukur berdasarkan keakuratan prediksi nilai label.

Dalam kasus tertentu, data input dibagi menjadi tiga bagian – data pelatihan dan pengujian, dan data validasi ketiga. Data validasi digunakan sebagai pengganti data pengujian, untuk mengukur kinerja model. Data validasi digunakan dalam iterasi dan untuk menyempurnakan model di setiap iterasi. Data pengujian hanya digunakan satu kali, setelah model

disempurnakan dan difinalisasi, untuk mengukur dan melaporkan kinerja akhir model sebagai referensi untuk upaya pembelajaran di masa mendatang.

Masalah yang jelas dalam metode ini adalah bahwa pembagian data dari kelas yang berbeda ke dalam data pelatihan dan pengujian mungkin tidak proporsional. Situasi ini lebih buruk jika persentase keseluruhan data yang terkait dengan kelas tertentu jauh lebih sedikit dibandingkan dengan kelas lainnya. Hal ini dapat terjadi meskipun pengambilan sampel acak digunakan untuk pemilihan data pengujian. Masalah ini dapat diatasi sampai batas tertentu dengan menerapkan pengambilan sampel acak berstrata sebagai pengganti pengambilan sampel. Dalam kasus pengambilan sampel acak berstrata, seluruh data dipecah menjadi beberapa kelompok atau strata yang homogen dan sampel acak dipilih dari setiap strata tersebut. Hal ini memastikan bahwa partisi acak yang dihasilkan memiliki proporsi yang sama dari setiap kelas.

3.3.2 Metode Validasi Silang K-fold

Metode holdout yang menggunakan pendekatan stratified random sampling masih menghadapi masalah dalam situasi tertentu. Khususnya, set data yang lebih kecil mungkin memiliki tantangan untuk membagi data beberapa kelas secara proporsional di antara set data pelatihan dan pengujian. Varian khusus dari metode holdout, yang disebut repeated holdout, terkadang digunakan untuk memastikan keacakan set data yang disusun. Dalam repeated holdout, beberapa holdout acak digunakan untuk mengukur kinerja model. Pada akhirnya, rata-rata semua kinerja diambil. Karena beberapa holdout telah diambil, data pelatihan dan pengujian (dan juga data validasi, jika diambil) lebih mungkin berisi data


representatif dari semua kelas dan sangat mirip dengan data input asli. Proses repeated holdout ini adalah dasar dari teknik k-fold crossvalidation. Dalam k-fold cross-validation, set data dibagi menjadi k partisi acak yang sama sekali berbeda atau tidak tumpang tindih yang disebut fold. Gambar 3.2 menggambarkan pendekatan keseluruhan untuk validasi silang k-fold.

Nilai 'k' dalam validasi silang k-fold dapat ditetapkan ke angka berapa pun. Namun, ada dua pendekatan yang sangat populer:


1. Validasi silang 10 kali lipat (CV 10 kali lipat)
2. Validasi silang keluar-satu (LOOCV)

Validasi silang 10 kali lipat sejauh ini merupakan pendekatan yang paling populer. Dalam pendekatan ini, untuk setiap 10 kali lipat, yang masing-masing terdiri dari sekitar 10% data, salah satu kali lipat digunakan sebagai data uji untuk memvalidasi kinerja model yang dilatih berdasarkan 9 kali lipat yang tersisa (atau 90% data). Ini diulang 10 kali, sekali untuk setiap 10 kali lipat yang digunakan sebagai data uji dan kali lipat yang tersisa sebagai data pelatihan. Kinerja rata-rata di semua kali lipat dilaporkan. Gambar 3.3 menggambarkan pendekatan terperinci untuk memilih lipatan 'k' dalam validasi silang lipatan k. Seperti yang dapat diamati dalam gambar, masing-masing lingkaran menyerupai rekaman dalam set data input sedangkan warna yang berbeda menunjukkan kelas yang berbeda tempat rekaman tersebut berada. Seluruh set data dipecah menjadi lipatan 'k' – yang mana satu lipatan dipilih dalam setiap iterasi sebagai set data uji. Lipatan yang dipilih sebagai set data uji dalam setiap iterasi 'k' berbeda. Perhatikan juga bahwa meskipun dalam gambar 3.3 lingkaran-lingkaran tersebut menyerupai catatan-catatan dalam set data input, lingkaran-lingkaran yang bersebelahan yang direpresentasikan sebagai lipatan-lipatan tidak berarti bahwa lingkaran-lingkaran tersebut

merupakan catatan-catatan berikutnya dalam set data. Ini lebih merupakan representasi virtual dan bukan representasi fisik. Seperti yang telah disebutkan, catatan-catatan dalam lipatan diambil dengan menggunakan teknik pengambilan sampel acak.



GAMBAR 3.2 Pendekatan keseluruhan untuk validasi silang K-fold




GAMBAR 3.3 Pendekatan terperinci untuk pemilihan lipatan

Leave-one-out cross-validation (LOOCV) adalah kasus ekstrem dari k-fold cross-validation yang menggunakan satu rekaman atau contoh data pada satu waktu sebagai data uji. Hal ini dilakukan untuk memaksimalkan jumlah data yang digunakan untuk melatih model. Jelas bahwa jumlah iterasi yang harus dijalankan sama dengan jumlah total data dalam set data masukan. Oleh karena itu, jelas, secara komputasi sangat mahal dan tidak banyak digunakan dalam praktik.

3.3.3 Pengambilan sampel bootstrap

Bootstrap sampling atau hanya bootstrapping adalah cara yang populer untuk mengidentifikasi set data pelatihan dan pengujian dari set data input. Ia menggunakan teknik Simple Random Sampling with Replacement (SRSWR), yang merupakan teknik terkenal dalam teori pengambilan sampel untuk mengambil sampel acak. Kita telah melihat sebelumnya bahwa k-fold cross-validation membagi data menjadi partisi terpisah – katakanlah 10 partisi dalam kasus crossvalidation 10-fold. Kemudian ia menggunakan instans data dari partisi sebagai data pengujian dan partisi yang tersisa sebagai data pelatihan. Tidak seperti pendekatan ini yang diadopsi dalam kasus k-fold cross-validation, bootstrapping secara acak memilih instans data dari set data input, dengan kemungkinan instans data yang sama dipilih beberapa kali. Ini pada dasarnya berarti bahwa dari set data input yang memiliki 'n' instans data, bootstrapping dapat membuat satu atau lebih set data pelatihan yang memiliki 'n' instans data, beberapa instans data diulang beberapa kali. Gambar 3.4 menyajikan secara singkat pendekatan yang diikuti dalam pengambilan sampel bootstrap.

Teknik ini khususnya berguna dalam kasus kumpulan data masukan berukuran kecil, yaitu memiliki jumlah contoh data yang sangat sedikit.



GAMBAR 3.4Pengambilan sampel bootstrap

CROSS-VALIDATION	BOOTSTRAPPING
It is a special variant of holdout method, called repeated holdout. Hence uses stratified random sampling approach (without replacement). Data set is divided into 'k' random partitions, with each partition containing approximately $\frac{n}{k}$ number of unique data elements, where 'n' is the total number of data elements and 'k' is the total number of folds.	It uses the technique of Simple Random Sampling with Replacement (SRSWR). So the same data instance may be picked up multiple times in a sample.
The number of possible training/test data samples that can be drawn using this technique is finite.	In this technique, since elements can be repeated in the sample, possible number of training/test data samples is unlimited.

3.3.4 Pembelajar yang malas vs. Pembelajar yang bersemangat

Pembelajaran yang bersemangat mengikuti prinsip-prinsip umum pembelajaran mesin – pembelajaran ini mencoba membangun fungsi

target yang digeneralisasi dan tidak bergantung pada input selama fase pelatihan model. Pembelajaran ini mengikuti langkah-langkah umum pembelajaran mesin, yaitu abstraksi dan generalisasi dan menghasilkan model yang terlatih di akhir fase pembelajaran. Oleh karena itu, ketika data uji masuk untuk klasifikasi, pembelajar yang bersemangat sudah siap dengan model tersebut dan tidak perlu merujuk kembali ke data pelatihan. Pembelajar yang bersemangat membutuhkan lebih banyak waktu dalam fase pembelajaran daripada pembelajar yang malas. Beberapa algoritme yang mengadopsi pendekatan pembelajaran yang bersemangat meliputi Pohon Keputusan, Mesin Vektor Pendukung, Jaringan Syaraf Tiruan, dll.

Sebaliknya, lazy learning sama sekali melewati proses abstraksi dan generalisasi, seperti yang dijelaskan dalam konteks proses machine learning pada umumnya. Dalam hal itu, secara tegas, lazy learner tidak 'mempelajari' apa pun. Ia menggunakan data pelatihan secara tepat, dan menggunakan pengetahuan untuk mengklasifikasikan data uji yang tidak berlabel. Karena lazy learning menggunakan data pelatihan apa adanya, ia juga dikenal sebagai hafalan (yaitu teknik menghafal berdasarkan pengulangan). Karena sangat bergantung pada instans data pelatihan yang diberikan, ia juga dikenal sebagai instance learning. Ia juga disebut pembelajaran non-parametrik. Lazy learner membutuhkan sedikit waktu dalam pelatihan karena tidak banyak pelatihan yang benar-benar terjadi. Namun, ia membutuhkan waktu yang cukup lama dalam klasifikasi karena untuk setiap tuple data uji, terjadi penugasan label berbasis perbandingan. Salah satu algoritma yang paling populer untuk lazy learning adalah k-nearest neighbor.

3.4 REPRESENTASI DAN INTERPRETABILITAS MODEL


Kita telah melihat bahwa tujuan pembelajaran mesin terbimbing adalah untuk mempelajari atau memperoleh fungsi target yang dapat menentukan variabel target dari kumpulan variabel input dengan paling baik. Pertimbangan utama dalam mempelajari fungsi target dari data pelatihan adalah sejauh mana generalisasi. Hal ini karena data input hanyalah tampilan terbatas dan spesifik dan data baru yang tidak diketahui dalam kumpulan data uji mungkin sedikit berbeda dari data pelatihan.

Kebugaran fungsi target yang diperkirakan oleh suatu algoritma pembelajaran menentukan seberapa tepat algoritma tersebut mengklasifikasikan serangkaian data yang belum pernah dilihatnya.

3.4.1 Pemasangan yang kurang pas

Jika fungsi target dibuat terlalu sederhana, fungsi tersebut mungkin tidak dapat menangkap nuansa penting dan merepresentasikan data yang mendasarinya dengan baik. Kasus underfitting yang umum dapat terjadi ketika mencoba merepresentasikan data non-linier dengan model linier seperti yang ditunjukkan oleh kedua kasus underfitting yang ditunjukkan pada [gambar 3.5](#). Seringkali underfitting terjadi karena tidak tersedianya data pelatihan yang cukup. Underfitting mengakibatkan kinerja yang buruk dengan data pelatihan serta generalisasi yang buruk terhadap data pengujian. Underfitting dapat dihindari dengan

1. menggunakan lebih banyak data pelatihan
2. mengurangi fitur dengan pemilihan fitur yang efektif



GAMBAR 3.5 Underfitting dan Overfitting model

3.4.2 Penyesuaian berlebihan

Overfitting mengacu pada situasi di mana model telah dirancang sedemikian rupa sehingga meniru data pelatihan terlalu dekat. Dalam kasus seperti itu, setiap penyimpangan tertentu dalam data pelatihan, seperti noise atau outlier, tertanam dalam model. Ini berdampak buruk pada kinerja model pada data uji. Overfitting, dalam banyak kasus, terjadi sebagai akibat dari upaya untuk menyesuaikan model yang sangat kompleks agar sesuai dengan data pelatihan. Ini direpresentasikan dengan kumpulan data sampel digambar 3.5. Fungsi target, dalam kasus ini, mencoba memastikan semua titik data pelatihan dipartisi dengan benar oleh batas keputusan. Namun, lebih sering daripada tidak, sifat yang tepat ini tidak direplikasi dalam set data uji yang tidak diketahui. Oleh karena itu, fungsi target menghasilkan klasifikasi yang salah dalam set data uji.

Overfitting menghasilkan kinerja yang baik dengan set data pelatihan, tetapi generalisasi yang buruk dan karenanya kinerja yang buruk dengan set data uji. Overfitting dapat dihindari dengan

1. menggunakan teknik pengambilan sampel ulang seperti validasi silang k-fold
2. menahan set data validasi
3. Hapus simpul-simpul yang memiliki sedikit atau tidak memiliki daya prediksi untuk masalah pembelajaran mesin yang diberikan.

Baik underfitting maupun overfitting menghasilkan kualitas klasifikasi yang buruk yang tercermin dari akurasi klasifikasi yang rendah.

3.4.3 Bias – trade-off varians.

Dalam pembelajaran terbimbing, nilai kelas yang ditetapkan oleh model pembelajaran yang dibangun berdasarkan data pelatihan mungkin berbeda dari nilai kelas yang sebenarnya. Kesalahan dalam pembelajaran ini dapat berupa dua jenis – kesalahan karena 'bias' dan kesalahan karena 'varians'. Mari kita coba memahami masing-masing secara terperinci.


3.4.3.1 Kesalahan karena 'Bias'

Kesalahan akibat bias muncul akibat penyederhanaan asumsi yang dibuat oleh model untuk membuat fungsi target kurang kompleks atau lebih mudah dipelajari. Singkatnya, hal ini terjadi karena model kurang sesuai. Model parametrik umumnya memiliki bias tinggi sehingga lebih mudah dipahami/diinterpretasikan dan lebih cepat dipelajari. Algoritme

ini memiliki kinerja yang buruk pada kumpulan data, yang sifatnya kompleks dan tidak sesuai dengan asumsi penyederhanaan yang dibuat oleh algoritme. Underfitting menghasilkan bias tinggi.

3.4.3.2 Kesalahan karena 'Varians'

Kesalahan akibat varians terjadi akibat perbedaan dalam set data pelatihan yang digunakan untuk melatih model. Set data pelatihan yang berbeda (diambil sampelnya secara acak dari set data input) digunakan untuk melatih model. Idealnya perbedaan dalam set data tidak boleh signifikan dan model yang dilatih menggunakan set data pelatihan yang berbeda tidak boleh terlalu berbeda. Namun, jika terjadi overfitting, karena model sangat cocok dengan data pelatihan, bahkan perbedaan kecil dalam data pelatihan akan diperbesar dalam model.



GAMBAR 3.6Kompromi bias-variens

Jadi, permasalahan dalam pelatihan model dapat terjadi karena (a) modelnya terlalu sederhana sehingga gagal menafsirkan data secara menyeluruh atau (b) modelnya sangat rumit dan membesar-besarkan perbedaan kecil dalam data pelatihan.

Seperti yang cukup bisa dimengerti:

- Meningkatkan bias akan mengurangi varians, dan
- Meningkatkan varians akan mengurangi bias

Di satu sisi, algoritma parametrik umumnya terlihat menunjukkan bias tinggi tetapi varians rendah. Di sisi lain, algoritma non-parametrik menunjukkan bias rendah dan varians tinggi.

Seperti yang dapat diamati di Gambar 3.6, solusi terbaik adalah memiliki model dengan bias rendah serta varians rendah. Namun, hal itu mungkin tidak memungkinkan dalam kenyataan. Oleh karena itu, tujuan pembelajaran mesin terbimbing adalah untuk mencapai keseimbangan antara bias dan varians. Algoritma pembelajaran yang dipilih dan parameter pengguna yang dapat dikonfigurasi membantu dalam mencapai keseimbangan antara bias dan varians. Misalnya, dalam algoritma terbimbing populer k-Nearest Neighbors atau kNN, parameter yang dapat dikonfigurasi pengguna 'k' dapat digunakan untuk melakukan keseimbangan antara bias dan varians. Di satu sisi, ketika nilai 'k' diturunkan, model menjadi lebih mudah untuk disesuaikan dan bias meningkat. Di sisi lain, ketika nilai 'k' dinaikkan, varians meningkat.

3.5 EVALUASI KINERJA MODEL

3.5.1 Pembelajaran terbimbing – klasifikasi

Dalam pembelajaran terbimbing, salah satu tugas utama adalah klasifikasi. Tanggung jawab model klasifikasi adalah menetapkan label kelas pada fitur target berdasarkan nilai fitur prediktor. Misalnya, dalam masalah memprediksi menang/kalah dalam pertandingan kriket, pengklasifikasi akan menetapkan nilai kelas menang/kalah pada fitur target berdasarkan nilai fitur lain seperti apakah tim memenangkan undian, jumlah pemutar bola dalam tim, jumlah kemenangan tim dalam turnamen, dll. Untuk mengevaluasi kinerja model, jumlah klasifikasi atau prediksi yang benar yang dibuat oleh model harus dicatat. Klasifikasi dikatakan benar jika, misalnya dalam masalah yang diberikan, telah diprediksi oleh model bahwa tim akan menang dan memang benar-benar menang.

Berdasarkan jumlah klasifikasi atau prediksi yang benar dan salah yang dibuat oleh sebuah model, akurasi model dihitung. Jika 99 dari 100 kali model telah mengklasifikasikan dengan benar, misalnya jika dalam 99 dari 100 pertandingan apa yang diprediksi model sama dengan apa yang terjadi, maka akurasi model dikatakan 99%. Namun, cukup relatif untuk mengatakan apakah sebuah model telah berkinerja baik hanya dengan melihat nilai akurasinya. Misalnya, akurasi 99% dalam kasus model prediktor kemenangan olahraga mungkin cukup baik tetapi angka yang sama mungkin tidak dapat diterima sebagai ambang batas yang baik ketika masalah pembelajaran berurusan dengan prediksi penyakit kritis. Dalam hal ini, bahkan prediksi yang salah 1% dapat menyebabkan hilangnya banyak nyawa. Jadi kinerja model perlu dievaluasi berdasarkan

masalah pembelajaran yang dimaksud. Selain itu, dalam kasus tertentu, berhati-hati mungkin lebih disukai dengan mengorbankan akurasi keseluruhan. Oleh karena itu, kita perlu mencermati lebih dekat keakuratan model dan pada saat yang sama juga mencermati ukuran kinerja model lainnya seperti sensitivitas, spesifisitas, presisi, dsb. Jadi, mari kita mulai dengan mencermati keakuratan model lebih dekat. Dan mari kita coba memahaminya dengan sebuah contoh.

Ada empat kemungkinan mengenai prediksi menang/kalah pertandingan kriket:

1. model tersebut meramalkan kemenangan dan tim tersebut menang
2. model tersebut meramalkan kemenangan dan tim tersebut kalah
3. model tersebut memprediksi kekalahan dan tim menang
4. model tersebut memprediksi kerugian dan tim tersebut kalah


Dalam masalah ini, kelas yang menarik adalah 'menang'.

Kasus pertama, yaitu model yang memprediksi kemenangan dan tim menang adalah kasus di mana model telah mengklasifikasikan contoh data dengan benar sebagai kelas yang diinginkan. Kasus-kasus ini disebut sebagai kasus True Positive (TP).

Kasus kedua, yaitu model yang memprediksi kemenangan dan tim yang kalah adalah kasus di mana model secara keliru mengklasifikasikan contoh data sebagai kelas yang diinginkan. Kasus-kasus ini disebut sebagai kasus False Positive (FP).

Kasus ketiga, yaitu model yang memprediksi kekalahan dan tim menang adalah kasus di mana model secara keliru mengklasifikasikan

bukan sebagai kelas yang diinginkan. Kasus-kasus ini disebut sebagai kasus False Negative (FN).



GAMBAR 3.7Rincian klasifikasi model

Kasus keempat, yaitu model yang memprediksikan kerugian dan tim yang kalah merupakan kasus dimana model telah mengklasifikasikan dengan benar bukan sebagai kelas yang diinginkan. Kasus-kasus ini disebut sebagai kasus True Negative (TN). Keempat kasus ini digambarkan dalam Gambar 3.7.

Untuk model klasifikasi apa pun, akurasi model diberikan oleh jumlah total klasifikasi yang benar (baik sebagai kelas yang diminati, yakni Benar

Positif maupun bukan kelas yang diminati, yakni Benar Negatif) dibagi dengan jumlah total klasifikasi yang dilakukan.

$$\text{Model accuracy} = \frac{TP + TN}{TP + FP + FN + TN}$$

Matriks yang berisi prediksi yang benar dan salah dalam bentuk TP, FP, FN, dan TN dikenal sebagai matriks kebingungan. Prediksi menang/kalah pertandingan kriket memiliki dua kelas yang menarik – menang dan kalah. Oleh karena itu, akan dihasilkan matriks kebingungan 2×2 . Untuk masalah klasifikasi yang melibatkan tiga kelas, matriks kebingungan akan menjadi 3×3 , dst.

Mari kita asumsikan matriks kebingungan prediksi menang/kalah pertandingan kriket adalah seperti di bawah ini:

	ACTUAL WIN	ACTUAL LOSS
Predicted Win	85	4
Predicted Loss	2	9

Dalam konteks matriks kebingungan di atas, jumlah total TP = 85, jumlah FP = 4, jumlah FN = 2 dan jumlah TN = 9.

$$\therefore \text{Model accuracy} = \frac{TP + TN}{TP + FP + FN + TN} = \frac{85 + 9}{85 + 4 + 2 + 9} = \frac{94}{100} = 94\%$$

Persentase kesalahan klasifikasi ditunjukkan dengan menggunakan tingkat kesalahan yang diukur sebagai

$$\text{Error rate} = \frac{FP + FN}{TP + FP + FN + TN}$$

Dalam konteks matriks kebingungan di atas,

$$\begin{aligned} \text{Error rate} &= \frac{FP + FN}{TP + FP + FN + TN} = \frac{4 + 2}{85 + 4 + 2 + 9} = \frac{6}{100} = 6\% \\ &= 1 - \text{Model accuracy} \end{aligned}$$

Terkadang, prediksi yang benar, baik TP maupun TN, dapat terjadi hanya karena kebetulan belaka. Karena kejadian ini meningkatkan akurasi model, idealnya hal ini tidak boleh terjadi. Nilai kappa suatu model

menunjukkan akurasi model yang disesuaikan. Nilai ini dihitung menggunakan rumus di bawah ini:

$$\text{Kappa value (k)} = \frac{P(a) - P(p_r)}{1 - P(p_r)}$$

$P(a)$ = Proportion of observed agreement between actual and predicted in overall data set

$$= \frac{TP + TN}{TP + FP + FN + TN}$$

$P(p_r)$ = Proportion of expected agreement between actual and predicted data both in case of class of interest as well as the other classes

$$= \frac{TP + FP}{TP + FP + FN + TN} \times \frac{TP + FN}{TP + FP + FN + TN} + \frac{FN + TN}{TP + FP + FN + TN} \times \frac{FP + TN}{TP + FP + FN + TN}$$

Dalam konteks matriks kebingungan di atas, jumlah total TP

= 85, jumlah FP = 4, jumlah FN = 2 dan jumlah TN = 9.

$$\therefore P(a) = \frac{TP + TN}{TP + FP + FN + TN} = \frac{85 + 9}{85 + 4 + 2 + 9} = \frac{94}{100} = 0.94$$

$$P(p_r) = \frac{85 + 4}{85 + 4 + 2 + 9} \times \frac{85 + 2}{85 + 4 + 2 + 9} + \frac{2 + 9}{85 + 4 + 2 + 9} \times \frac{4 + 9}{85 + 4 + 2 + 9}$$

$$= \frac{89}{100} \times \frac{87}{100} + \frac{11}{100} \times \frac{13}{100} = 0.89 \times 0.87 + 0.11 \times 0.13 = 0.7886$$

$$\therefore k = \frac{0.94 - 0.7886}{1 - 0.7886} = 0.7162$$

Seperti yang dibahas sebelumnya, dalam masalah pembelajaran tertentu sangat penting untuk memiliki jumlah kasus FN yang sangat rendah, jika diperlukan, dengan mengorbankan model klasifikasi yang konservatif. Meskipun ini adalah kasus kesalahan klasifikasi yang jelas dan akan berdampak buruk pada akurasi model, hal itu tetap diperlukan

karena kehilangan setiap kelas yang diminati dapat memiliki konsekuensi serius. Ini lebih sering terjadi pada masalah dari domain medis seperti masalah prediksi penyakit. Misalnya, jika tumor ganas tetapi salah diklasifikasikan sebagai jinak oleh pengklasifikasi, maka akibat dari kesalahan klasifikasi tersebut berakibat fatal. Tidak masalah jika jumlah tumor yang lebih tinggi yang jinak salah diklasifikasikan sebagai ganas. Dalam masalah ini ada beberapa ukuran kinerja model yang lebih penting daripada akurasi. Dua pengukuran kritis tersebut adalah sensitivitas dan spesifisitas model.

Sensitivitas model mengukur proporsi contoh TP atau kasus positif yang diklasifikasikan dengan benar. Hal ini diukur sebagai berikut:

$$\text{Sensitivity} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Dalam konteks matriks kebingungan di atas untuk masalah prediksi kemenangan pertandingan kriket,

$$\text{Sensitivity} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{85}{85 + 2} = \frac{85}{87} = 97.7\%$$

Jadi, sekali lagi mengambil contoh prediksi keganasan tumor, kelas yang dimaksud adalah 'ganas'. Ukuran sensitivitas memberikan proporsi tumor yang benar-benar ganas dan telah diprediksi sebagai ganas. Cukup jelas bahwa untuk masalah seperti itu ukuran yang paling penting dari kinerja model yang baik adalah sensitivitas. Nilai sensitivitas yang tinggi lebih diinginkan daripada nilai akurasi yang tinggi.

Kekhususan juga merupakan ukuran lain yang baik untuk menunjukkan keseimbangan yang baik antara model yang terlalu konservatif atau terlalu agresif. Spesifisitas model mengukur proporsi contoh negatif yang telah diklasifikasikan dengan benar. Dalam konteks prediksi keganasan tumor, spesifisitas memberikan proporsi tumor jinak

yang telah diklasifikasikan dengan benar. Dalam konteks matriks kebingungan di atas untuk masalah prediksi kemenangan pertandingan kriket,

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}} = \frac{9}{9 + 4} = \frac{9}{13} = 69.2\%$$

Nilai spesifisitas yang lebih tinggi akan menunjukkan kinerja model yang lebih baik. Namun, cukup dapat dipahami bahwa pendekatan konservatif untuk mengurangi Negatif Palsu justru dapat meningkatkan jumlah FP. Alasannya adalah bahwa model, untuk mengurangi FN, akan mengklasifikasikan lebih banyak tumor sebagai ganas. Jadi, peluang tumor jinak akan diklasifikasikan sebagai ganas atau FP akan meningkat.

Ada dua ukuran kinerja lain dari model pembelajaran terbimbing yang serupa dengan sensitivitas dan spesifisitas. Yaitu presisi dan ingatan. Sementara presisi memberikan proporsi prediksi positif yang benar-benar positif, ingatan memberikan proporsi kasus TP atas semua kasus yang benar-benar positif.

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Presisi menunjukkan keandalan model dalam memprediksi kelas yang diminati. Ketika model dikaitkan dengan prediksi menang/kalah kriket, presisi menunjukkan seberapa sering model memprediksi kemenangan dengan tepat. Dalam konteks matriks kebingungan di atas untuk masalah prediksi kemenangan pertandingan kriket,

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{85}{85 + 4} = \frac{85}{89} = 95.5\%$$

Cukup dapat dipahami bahwa model dengan presisi lebih tinggi dianggap lebih dapat diandalkan.

Recall menunjukkan proporsi prediksi positif yang benar terhadap jumlah total positif. Dalam kasus prediksi menang/kalah kriket, recall menyerupai proporsi total kemenangan yang diprediksi dengan benar.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Dalam konteks matriks kebingungan di atas untuk masalah prediksi kemenangan pertandingan kriket,

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{85}{85 + 2} = \frac{85}{87} = 97.7\%$$

3.5.1.1 Ukuran F

F-measure adalah ukuran lain dari kinerja model yang menggabungkan

$$F\text{-measure} = \frac{2 \times 0.955 \times 0.977}{0.955 + 0.977} = \frac{1.866}{1.932} = 96.6\%$$

Sebagai gabungan presisi dan recall. Ia mengambil rata-rata harmonik presisi dan recall sebagaimana dihitung sebagai

$$F\text{-measure} = \frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

Dalam konteks matriks kebingungan di atas untuk masalah prediksi kemenangan pertandingan kriket,

beberapa ukuran menjadi satu, skor F memberikan ukuran yang tepat yang dapat digunakan untuk membandingkan kinerja berbagai model. Namun, satu asumsi yang menjadi dasar perhitungan adalah bahwa presisi dan perolehan memiliki bobot yang sama, yang mungkin tidak selalu benar dalam kenyataan. Dalam masalah tertentu, masalah prediksi penyakit, misalnya, presisi dapat diberi bobot yang jauh lebih besar. Dalam kasus tersebut, bobot yang berbeda dapat diberikan untuk presisi dan perolehan. Namun, mungkin ada dilema serius mengenai nilai apa yang

harus diadopsi untuk masing-masing dan apa dasar untuk nilai spesifik yang diadopsi.

3.5.1.1.1 Kurva karakteristik operasi penerima (ROC)


Seperti yang telah kita lihat sejauh ini, meskipun akurasi merupakan ukuran yang paling populer, ada sejumlah ukuran lain untuk mengevaluasi kinerja model pembelajaran terbimbing. Akan tetapi, visualisasi merupakan cara yang lebih mudah dan efektif untuk memahami kinerja model. Visualisasi juga membantu dalam membandingkan efisiensi dua model.

Kurva Receiver Operating Characteristic (ROC) membantu dalam memvisualisasikan kinerja model klasifikasi. Kurva ini menunjukkan efisiensi model dalam mendeteksi positif sejati sekaligus menghindari terjadinya positif palsu. Untuk menyegarkan ingatan kita, positif sejati adalah kasus-kasus ketika model telah mengklasifikasikan contoh data dengan benar sebagai kelas yang diinginkan. Misalnya, model telah mengklasifikasikan tumor dengan benar sebagai ganas, dalam kasus masalah prediksi keganasan tumor. Di sisi lain, FP adalah kasus-kasus ketika model secara tidak benar mengklasifikasikan contoh data sebagai kelas yang diinginkan. Dengan menggunakan contoh yang sama, dalam kasus ini, model telah secara tidak benar mengklasifikasikan tumor sebagai ganas, yaitu tumor yang sebenarnya jinak telah diklasifikasikan sebagai ganas.

$$\text{True Positive Rate TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

$$\text{False Positive Rate FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$

Dalam kurva ROC, rasio FP diplot (pada sumbu horizontal) terhadap rasio positif sejati (pada sumbu vertikal) pada ambang klasifikasi yang berbeda. Jika kita mengasumsikan nilai ambang klasifikasi yang lebih rendah, model akan mengklasifikasikan lebih banyak item sebagai positif. Oleh karena itu, nilai Positif Palsu dan Positif Sejati meningkat. Nilai area di bawah kurva (AUC), seperti yang ditunjukkan pada [gambar 3.8a](#), adalah area ruang dua dimensi di bawah kurva yang membentang dari (0, 0) hingga (1, 1), di mana setiap titik pada kurva memberikan serangkaian nilai positif benar dan salah pada ambang klasifikasi tertentu. Kurva ini memberikan indikasi kualitas prediktif suatu model. Nilai AUC berkisar dari 0 hingga 1, dengan AUC kurang dari 0,5 menunjukkan bahwa pengklasifikasi tidak memiliki kemampuan prediktif. [Gambar 3.8b](#) menunjukkan kurva dari dua pengklasifikasi – pengklasifikasi 1 dan pengklasifikasi 2. Jelas sekali, AUC pengklasifikasi 1 lebih besar daripada AUC pengklasifikasi 2. Jadi, kita dapat menarik kesimpulan bahwa pengklasifikasi 1 lebih baik daripada pengklasifikasi 2.



GAMBAR 3.8Kurva ROC


Interpretasi indikatif cepat dari nilai prediksi dari 0,5 hingga 1,0 diberikan di bawah ini:

- 0,5 – 0,6 → Hampir tidak ada kemampuan prediksi
- 0,6 – 0,7 → Kemampuan prediksi lemah
- 0,7 – 0,8 → Kemampuan prediksi yang adil
- 0,8 – 0,9 → Kemampuan prediksi yang baik
- 0,9 – 1,0 → Kemampuan prediksi yang sangat baik

3.5.2 Pembelajaran terbimbing – regresi

Model regresi yang sesuai menghasilkan nilai prediksi yang mendekati nilai aktual. Oleh karena itu, model regresi yang memastikan bahwa perbedaan antara nilai prediksi dan nilai aktual rendah dapat dianggap sebagai model yang baik. Gambar 3.9 merupakan masalah yang sangat sederhana dalam memprediksi nilai properti yang diselesaikan menggunakan model regresi linier. Jika 'area' adalah variabel prediktor (misalkan x) dan 'value' adalah variabel target (misalkan y), model regresi linier dapat direpresentasikan dalam bentuk:

$$y = \alpha + \beta x$$



GAMBAR 3.9Kesalahan – Nilai yang diprediksi vs. nilai aktual

Untuk nilai x tertentu, misalnya $\hat{x}$, nilai y diprediksi sebagai $\hat{y}$ sedangkan nilai y yang sebenarnya adalah Y (misalnya). Jarak antara nilai sebenarnya dan nilai yang disesuaikan atau diprediksi, yaitu $\hat{y}$ dikenal sebagai residual. Model regresi dapat dianggap sesuai dengan baik jika perbedaan antara nilai aktual dan nilai yang diprediksi, yaitu nilai residual lebih kecil.

R-kuadrat merupakan ukuran yang baik untuk mengevaluasi kesesuaian model. Nilai ini juga dikenal sebagai koefisien determinasi, atau untuk regresi berganda, koefisien determinasi berganda. Nilai R-kuadrat berada di antara 0 hingga 1 (0%–100%) dengan nilai yang lebih besar menunjukkan kesesuaian yang lebih baik. Nilai ini dihitung sebagai:

$$R^2 = \frac{SST - SSE}{SST}$$

Jumlah Kuadrat Total (SST) = kuadrat selisih setiap observasi dari rata-rata keseluruhan $= \sum_{i=1}^n (y_i - \bar{y})^2$ di mana $\bar{y}$ adalah rata-rata.

Jumlah Kesalahan Kuadrat (SSE) (prediksi) = jumlah residual kuadrat = $\sum_{i=1}^n (Y_i - \hat{y})^2$ Di mana $\hat{y}$ adalah nilai prediksi dari y_i dan Y_i adalah nilai sebenarnya dari y_i .

3.5.3 Pembelajaran tanpa pengawasan - pengelompokan

Algoritme pengelompokan mencoba mengungkap pengelompokan alami di antara kumpulan data. Akan tetapi, cukup sulit untuk mengevaluasi kinerja algoritme pengelompokan. Pengelompokan, pada dasarnya, sangat subjektif dan apakah pengelompokan itu baik atau buruk masih terbuka untuk interpretasi. Telah dicatat, 'pengelompokan tergantung pada pandangan orang yang melihatnya'. Hal ini berasal dari dua tantangan inheren yang ada dalam proses pengelompokan:

1. Umumnya tidak diketahui berapa banyak kluster yang dapat diformulasikan dari satu set data tertentu. Dalam kebanyakan kasus, kluster sepenuhnya bersifat terbuka dan diberikan sebagai masukan pengguna ke algoritma pengelompokan.
2. Bahkan jika jumlah kluster diberikan, jumlah kluster yang sama dapat dibentuk dengan kelompok instansi data yang berbeda.

Secara lebih objektif, dapat dikatakan bahwa algoritma pengelompokan berhasil jika kluster yang diidentifikasi menggunakan algoritma tersebut mampu mencapai hasil yang tepat dalam keseluruhan

domain masalah. Misalnya, jika pengelompokan diterapkan untuk mengidentifikasi segmen pelanggan untuk kampanye pemasaran peluncuran produk baru, pengelompokan dapat dianggap berhasil hanya jika kampanye pemasaran berakhir dengan sukses, yaitu mampu menciptakan pengenalan merek yang tepat yang menghasilkan pendapatan tetap dari penjualan produk baru. Namun, ada beberapa pendekatan populer yang diadopsi untuk evaluasi kualitas kluster.

1. Evaluasi internal

Dalam pendekatan ini, kluster dinilai berdasarkan data dasar yang dikluster. Metode evaluasi internal umumnya mengukur kualitas kluster berdasarkan homogenitas data yang termasuk dalam kluster yang sama dan heterogenitas data yang termasuk dalam kluster yang berbeda. Homogenitas/heterogenitas diputuskan oleh beberapa ukuran kesamaan. Misalnya, koefisien siluet, yang merupakan salah satu metode evaluasi internal yang paling populer, menggunakan jarak (jarak Euclidean atau Manhattan yang paling umum digunakan) antara elemen data sebagai ukuran kesamaan. Nilai lebar siluet berkisar antara -1 dan $+1$, dengan nilai yang tinggi menunjukkan homogenitas intra-kluster dan heterogenitas antar-kluster yang tinggi.


Untuk kumpulan data yang dikelompokkan menjadi kluster 'k', lebar siluet dihitung sebagai:

$$\text{Silhouette width} = \frac{b(i) - a(i)}{\max \{a(i), b(i)\}}$$

$A(i)$ merupakan jarak rata-rata antara instansi data ke- i dengan seluruh instansi data lain yang termasuk dalam kluster yang sama, dan $b(i)$ merupakan jarak rata-rata terendah antara instansi data ke- i dengan instansi data dari seluruh kluster lainnya.

Mari kita coba memahami hal ini dalam konteks contoh yang digambarkan digambar 3.10. Terdapat empat cluster yaitu cluster 1, 2, 3, dan 4. Mari kita perhatikan elemen data acak 'i' di cluster 1, yang menyerupai tanda bintang. $a(i)$ adalah rata-rata jarak $a_{i1}, a_{i2}, \dots, a_{in_1}$ dari elemen data yang berbeda dari elemen data ke-i di cluster 1, dengan asumsi terdapat n_1 elemen data di cluster 1. Secara matematis,

$$a(i) = \frac{a_{i1} + a_{i2} + \dots + a_{in_1}}{n_1}$$



GAMBAR 3.10Perhitungan lebar siluet

Dengan cara yang sama, mari kita hitung jarak elemen data 'i' yang sembarangan di klaster 1 dengan elemen data yang berbeda dari

klaster lain, misalnya klaster 4 dan ambil rata-rata dari semua jarak tersebut. Oleh karena itu,

$$b_{14}(\text{average}) = \frac{b_{14}(1) + b_{14}(2) + \dots + b_{14}(n_4)}{(n_4)}$$

di mana n_4 adalah jumlah total elemen dalam klaster 4. Dengan cara yang sama, kita dapat menghitung nilai b_{12} (rata-rata) dan b_{13} (rata-rata). $b(i)$ adalah nilai minimum dari semua nilai ini. Oleh karena itu, kita dapat mengatakan bahwa,

$$B(i) = \text{minimum} [b_{12}(\text{rata-rata}), b_{13}(\text{rata-rata}), b_{14}(\text{rata-rata})]$$

2. Evaluasi eksternal

Dalam pendekatan ini, label kelas diketahui untuk kumpulan data yang menjadi sasaran pengelompokan. Akan tetapi, cukup jelas bahwa label kelas yang diketahui bukan merupakan bagian dari data yang digunakan dalam pengelompokan. Algoritme pengelompokan dinilai berdasarkan seberapa dekat hasil dibandingkan dengan label kelas yang diketahui tersebut. Misalnya, kemurnian merupakan salah satu ukuran algoritme pengelompokan yang paling populer – mengevaluasi sejauh mana pengelompokan memuat satu kelas.

Untuk himpunan data yang memiliki 'n' contoh data dan 'c' label kelas yang diketahui yang menghasilkan 'k' klaster, kemurnian diukur sebagai:

$$\text{Purity} = \frac{1}{n} \sum_k \max(c \cap k)$$

3.6 MENINGKATKAN KINERJA MODEL

Kini kita hampir mencapai akhir perjalanan membangun model pembelajaran. Kita telah memperoleh beberapa gagasan tentang apa itu pemodelan, bagaimana cara mendekatinya untuk memecahkan masalah pembelajaran, dan bagaimana mengukur keberhasilan model kita. Kini muncul pertanyaan yang sangat penting. Dapatkah kita meningkatkan kinerja model kita? Jika demikian, apa saja cara untuk meningkatkan kinerjanya? Bahkan sebelum itu muncul pertanyaan tentang pemilihan model – model mana yang harus dipilih untuk tugas pembelajaran mesin yang mana? Kita telah membahas sebelumnya bahwa pemilihan model dilakukan berdasarkan beberapa aspek:

1. Jenis pembelajaran tugas yang ada, yaitu diawasi atau tidak diawasi
2. Jenis data yaitu kategorikal atau numerik
3. Terkadang pada domain masalah
4. Yang terpenting, pengalaman dalam bekerja dengan berbagai model untuk memecahkan masalah di berbagai domain

Jadi, dengan asumsi pemilihan model sudah selesai, apa saja cara yang berbeda untuk meningkatkan kinerja model?

Salah satu cara efektif untuk meningkatkan kinerja model adalah dengan menyetel parameter model. Penyetelan parameter model adalah proses penyesuaian opsi pemasangan model. Misalnya, dalam model klasifikasi populer k-Nearest Neighbour (kNN), menggunakan nilai 'k' yang berbeda atau jumlah tetangga terdekat yang akan dipertimbangkan, model dapat disetel. Dengan cara yang sama, sejumlah lapisan tersembunyi dapat disesuaikan untuk menyetel kinerja dalam model


jaringan saraf. Sebagian besar model pembelajaran mesin memiliki setidaknya satu parameter yang dapat disetel.

Sebagai pendekatan alternatif untuk meningkatkan kinerja satu model, beberapa model dapat digabungkan bersama. Model-model dalam kombinasi tersebut saling melengkapi, yaitu satu model dapat mempelajari satu jenis set data dengan baik sementara kesulitan dengan jenis set data yang lain. Model lain dapat bekerja dengan baik dengan set data yang sebelumnya sulit dipelajari. Pendekatan menggabungkan berbagai model dengan kekuatan yang berbeda ini dikenal sebagai ensemble (digambarkan dalam Gambar 3.11). Ensemble membantu meratakan bias dari berbagai model dasar dan juga mengurangi varians. Metode ensemble menggabungkan pembelajar yang lebih lemah untuk menciptakan pembelajar yang lebih kuat. Peningkatan kinerja dapat diharapkan bahkan jika model dibangun seperti biasa dan kemudian digabungkan. Berikut ini adalah langkah-langkah umum dalam proses ensemble:

- Membangun sejumlah model berdasarkan data pelatihan untuk mendiversifikasi model yang dihasilkan, subset data pelatihan dapat divariasikan menggunakan fungsi alokasi.
- Teknik pengambilan sampel seperti bootstrapping dapat digunakan untuk menghasilkan set data pelatihan yang unik.
- Alternatifnya, data pelatihan yang sama dapat digunakan tetapi model yang digabungkan cukup bervariasi, misalnya SVM, jaringan saraf, kNN, dan lain-lain.

Output dari berbagai model digabungkan menggunakan fungsi kombinasi. Strategi penggabungan yang sangat sederhana, misalnya dalam kasus tugas prediksi menggunakan ensemble, dapat berupa

pemungutan suara mayoritas dari berbagai model yang digabungkan. Misalnya, 3 dari 5 kelas memprediksi 'menang' dan 2 memprediksi 'kalah' – maka hasil akhir ensemble menggunakan suara mayoritas akan menjadi 'menang'.



GAMBAR 3.11Ansambel

Salah satu model ensemble yang paling awal dan paling populer adalah bootstrap aggregating atau bagging. Bagging menggunakan metode bootstrap sampling (lihat [bagian 3.3.3](#)) untuk menghasilkan beberapa set data pelatihan. Set data pelatihan ini digunakan untuk menghasilkan (atau melatih) satu set model menggunakan algoritma pembelajaran yang sama. Kemudian hasil dari model digabungkan dengan pemungutan suara mayoritas (klasifikasi) atau dengan rata-rata (regresi). Bagging adalah teknik ensemble yang sangat sederhana yang dapat bekerja dengan sangat baik untuk pembelajar yang tidak stabil seperti pohon keputusan, di mana sedikit perubahan dalam data dapat memengaruhi hasil model secara signifikan.

Sama seperti bagging, boosting adalah teknik lain yang berbasis ensemble. Dalam jenis ensemble ini, model pembelajaran yang lebih lemah dilatih pada data yang diambil sampelnya kembali dan hasilnya digabungkan menggunakan pendekatan pemungutan suara berbobot berdasarkan kinerja berbagai model. Boost adaptif atau AdaBoost adalah varian khusus dari algoritma boosting. Ini didasarkan pada gagasan untuk menghasilkan pembelajar yang lemah dan belajar secara perlahan.

Hutan acak adalah teknik berbasis ensemble lainnya. Ini adalah ensemble pohon keputusan – maka dari itu dinamakan random forest untuk menunjukkan hutan pohon keputusan. Ini telah dibahas lebih rinci di Bab 7.

Dalam bab ini, Anda telah diperkenalkan pada inti pembelajaran mesin, yaitu pemodelan. Pemahaman menyeluruh tentang aspek teknis yang diuraikan dalam bab ini sangat penting untuk keberhasilan setiap proyek pembelajaran mesin. Misalnya, dilema pertama muncul tentang model mana yang akan dipilih. Sekali lagi, dalam kasus pembelajaran terbimbing, bagaimana kita dapat mengatasi tidak tersedianya data pelatihan yang memadai. Dengan cara yang sama, setelah model dilatih dalam kasus pembelajaran terbimbing atau pengelompokan dilakukan dalam kasus pengelompokan, bagaimana kita dapat memahami apakah pelatihan model (untuk terbimbing) atau pengelompokan yang dilakukan (untuk tanpa pengawasan) baik atau buruk. Semua ini dan lebih banyak lagi telah dibahas sebagai bagian dari bab ini.

3.7 RINGKASAN

- Representasi terstruktur dari data masukan mentah menjadi pola yang bermakna disebut model.
- Proses penyesuaian model tertentu dengan kumpulan data disebut pelatihan model. Model untuk pembelajaran terbimbing atau model prediktif mencoba memprediksi nilai tertentu menggunakan kumpulan data masukan.
- Model untuk pembelajaran tanpa pengawasan atau model deskriptif digunakan untuk mendeskripsikan kumpulan data atau memperoleh wawasan dari kumpulan data.

Metode pembagian data masukan menjadi dua bagian, yaitu data latih dan data uji, yang menahan sebagian data masukan untuk memvalidasi model yang telah dilatih, dikenal dengan metode holdout.

Dalam teknik validasi silang k-fold, kumpulan data dibagi menjadi k-partisi acak yang terpisah sepenuhnya yang disebut lipatan. Ini pada dasarnya adalah penahanan berulang ke dalam lipatan 'k'. Nilai 'k' dalam validasi silang k-fold dapat ditetapkan ke angka berapa pun. Dua pendekatan yang sangat populer adalah:

- Validasi silang 10 kali lipat (CV 10 kali lipat)
- Validasi silang keluar-satu (LOOCV)

Pengambilan sampel bootstrap atau bootstrapping adalah cara populer untuk mengidentifikasi set data pelatihan dan pengujian dari set data input. Teknik ini menggunakan Simple Random Sampling with Replacement (SRSWR). Bootstrapping mengambil contoh data secara acak dari set data input, dengan kemungkinan contoh data yang sama diambil beberapa kali.

Fungsi target dari suatu model adalah fungsi yang mendefinisikan hubungan antara variabel input (juga disebut prediktor atau independen) dan variabel output (juga disebut respons atau dependen atau target). Fungsi ini direpresentasikan dalam bentuk umum: $Y = f(X) + e$, di mana Y adalah variabel output, X mewakili variabel input dan ' e ' adalah suku galat acak.

Kebugaran suatu fungsi target yang didekati oleh suatu algoritma pembelajaran menentukan seberapa tepat algoritma tersebut dapat memprediksi nilai atau kelas untuk serangkaian data yang belum pernah dilihatnya.

Jika fungsi target dibuat terlalu sederhana, fungsi tersebut mungkin tidak dapat menangkap nuansa penting dan merepresentasikan data yang mendasarinya dengan baik. Hal ini dikenal sebagai underfitting.

Overfitting mengacu pada situasi di mana model telah dirancang sedemikian rupa sehingga meniru data pelatihan terlalu dekat. Dalam kasus seperti itu, nuansa tertentu dalam data pelatihan, seperti noise atau outlier, tertanam dalam model. Hal ini berdampak buruk pada kinerja model pada data pengujian. • Dalam pembelajaran terbimbing, nilai yang diprediksi oleh model pembelajaran yang dibangun berdasarkan data pelatihan mungkin berbeda dari nilai kelas yang sebenarnya. Kesalahan dalam pembelajaran ini dapat berupa dua jenis – kesalahan karena 'bias' dan kesalahan karena 'varians'. Kesalahan karena bias muncul dari penyederhanaan asumsi yang dibuat oleh model sedangkan kesalahan karena varians terjadi dari penyesuaian model yang berlebihan dengan set data pelatihan.

Untuk model klasifikasi apa pun, akurasi model merupakan indikator utama dari kebaikan model tersebut. Akurasi model ditentukan oleh jumlah total klasifikasi yang benar (baik sebagai kelas yang diminati, maupun bukan kelas yang diminati) dibagi dengan jumlah total klasifikasi yang dilakukan. Ada indikator lain seperti tingkat kesalahan, sensitivitas, spesifisitas, presisi, dan perolehan kembali.

Untuk pembelajaran tanpa pengawasan (pengelompokan), koefisien siluet (atau lebar) adalah salah satu metode evaluasi internal yang paling populer. Nilai lebar siluet yang tinggi menunjukkan homogenitas intra-klaster dan heterogenitas antar-klaster yang tinggi. Jika label kelas diketahui untuk kumpulan data, kemurnian adalah ukuran populer lainnya yang mengevaluasi sejauh mana klaster berisi satu kelas.

Penyetelan parameter model adalah proses penyesuaian opsi pemasangan model. Misalnya, dalam model klasifikasi populer k-Nearest Neighbour (kNN), menggunakan nilai 'k' yang berbeda atau jumlah tetangga terdekat yang akan dipertimbangkan, model dapat disetel.

Pendekatan menggabungkan berbagai model dengan kekuatan yang beragam dikenal sebagai ensemble. Metode ensemble menggabungkan pembelajar yang lemah untuk menciptakan pembelajar yang lebih kuat.

Salah satu model ensemble paling awal dan paling populer adalah bootstrap aggregating atau bagging. Bagging menggunakan bootstrapping untuk menghasilkan beberapa set data pelatihan. Set data pelatihan ini digunakan untuk menghasilkan serangkaian model menggunakan algoritma pembelajaran yang sama.

Sama seperti bagging, boosting adalah teknik lain yang penting dalam ensemble. Dalam boosting, model pembelajaran yang lebih lemah dilatih pada data yang diambil sampelnya kembali dan hasilnya digabungkan

menggunakan pendekatan pemungutan suara berbobot berdasarkan kinerja berbagai model.

Penguatan adaptif atau AdaBoost adalah varian khusus dari algoritma penguatan.

SOAL PILIHAN GANDA (SOAL 1 NILAI):

1. Representasi terstruktur dari data masukan mentah menjadi ____ yang bermakna disebut model.
 1. pola
 2. data
 3. obyek
 4. tidak ada yang benar
2. Untuk pembelajaran terbimbing, kami memiliki model ____.
 1. interaktif
 2. prediktif
 3. deskriptif
 4. bersifat menentukan
3. Untuk pembelajaran tanpa pengawasan, kita memiliki model ____.
 1. interaktif
 2. prediktif
 3. deskriptif
 4. bersifat menentukan
4. Manakah dari ukuran berikut yang tidak digunakan untuk model klasifikasi?
 1. Ketepatan

2. Mengingat
 3. Kemurnian
 4. Tingkat kesalahan
5. Manakah dari berikut ini merupakan ukuran kinerja untuk regresi?
1. Ketepatan
 2. Mengingat
 3. RMSE
 4. Tingkat kesalahan
6. Manakah dari berikut ini merupakan ukuran kualitas klaster?
1. Kemurnian
 2. Jarak
 3. Ketepatan
 4. semuanya di atas
7. Dari 200 email, model klasifikasi memprediksi 150 email spam dan 30 email palsu dengan tepat. Berapa akurasi model tersebut?
1. 10% 2. 90%
 3. 80%
 4. tidak ada yang benar
8. Dari 200 email, model klasifikasi memprediksi 150 email spam dan 30 email palsu dengan tepat. Berapa tingkat kesalahan model tersebut?
1. 10% 2. 90%
 3. 80%
 4. tidak ada yang benar

9. Tidak ada satu model yang paling cocok untuk setiap masalah pembelajaran mesin. Hal ini dinyatakan sebagai
 1. Teorema model celah yang pas
 2. Teorema satu model
 3. Teorema makan siang gratis
 4. Teorema tidak ada makan siang gratis
10. LOOCV dalam pembelajaran mesin adalah singkatan dari
 1. Cintai validasi silang satu-keluar
 2. Validasi silang dengan pengecualian satu
 3. Validasi silang berorientasi objek cuti
 4. Validasi kelas yang tidak menyertakan satu pun

SOAL JAWABAN SINGKAT (SOAL 5 NILAI):

1. Apa yang dimaksud dengan model dalam konteks pembelajaran mesin? Bagaimana cara melatih model?
2. Jelaskan teorema “Tidak Ada Makan Siang Gratis” dalam konteks pembelajaran mesin.
3. Jelaskan secara rinci proses validasi silang K-fold.
4. Jelaskan tentang bootstrap sampling. Mengapa hal itu diperlukan?
5. Mengapa kita perlu menghitung nilai Kappa untuk model klasifikasi? Tunjukkan, dengan kumpulan data contoh, cara menghitung nilai Kappa dari model klasifikasi.
6. Jelaskan proses penggabungan model. Apa perannya dalam pembelajaran mesin?
7. Apa tujuan utama model deskriptif? Sebutkan beberapa masalah dunia nyata yang dipecahkan menggunakan model deskriptif.

8. Jelaskan proses mengevaluasi model regresi linear.
9. Bedakan (dua apa saja):
 1. Model prediktif vs. deskriptif
 2. Model underfitting vs. overfitting
 3. Validasi silang vs. bootstrapping
10. Tulis catatan singkat tentang dua hal berikut:
 1. Bahasa Indonesia: LOOCV
 2. F -ukuran
 3. Lebar siluet
 4. Kurva ROC

PERTANYAAN JAWABAN PANJANG (PERTANYAAN 10 NILAI):

1. Apa itu fungsi target? Jelaskan fungsi target dalam konteks contoh kehidupan nyata. Bagaimana kebugaran fungsi target diukur?
2. Apa itu model prediktif? Apa itu model deskriptif? Berikan contoh kedua jenis model tersebut. Jelaskan perbedaan antara kedua jenis model tersebut.
3. Jelaskan secara rinci proses evaluasi kinerja model klasifikasi. Jelaskan berbagai parameter pengukuran.
4.
 1. Apa yang dimaksud dengan underfitting dalam konteks model machine learning? Apa penyebab utama terjadinya underfitting?
 2. Apa itu overfitting? Kapan hal itu terjadi?
 3. Jelaskan trade-off bias-varians dalam konteks penyesuaian model.

5. Dapatkah kinerja suatu model pembelajaran ditingkatkan? Jika ya, jelaskan caranya.
6. Bagaimana Anda mengevaluasi keberhasilan model pembelajaran tanpa pengawasan? Apa ukuran kinerja yang paling populer untuk model pembelajaran tanpa pengawasan?
7. Apakah ada cara untuk menggunakan model klasifikasi untuk data numerik atau model regresi pada data kategoris? Jelaskan jawaban Anda.
8. Jelaskan proses pemodelan prediktif untuk nilai numerik. Apa bedanya dengan pemodelan prediktif untuk nilai kategoris?
9. Saat memprediksi keganasan tumor pada sekumpulan pasien menggunakan model klasifikasi, berikut adalah data yang tercatat:
 1. Prediksi yang benar – 15 ganas, 75 jinak
 2. Prediksi salah – 3 ganas, 7 jinak
 Hitung tingkat kesalahan, nilai Kappa, sensitivitas, presisi, dan F-measure model.
10. 1. Tulis catatan singkat tentang dua hal berikut:
 1. Metode Holdout
 2. Validasi silang 10 kali lipat
 3. Penyetelan parameter
 2. Tuliskan perbedaan antara (dua hal):
 1. Kemurnian vs. Lebar Siluet
 2. Mengantongi vs. Mendorong
 3. Pembelajar yang malas vs. Pembelajar yang bersemangat

Bab 4 Dasar-dasar Rekayasa Fitur

Dr. Yodhi Yuniarthe, M.Kom.

A.Tujuan Pembelajaran.

Dalam tiga bab terakhir, Anda telah diperkenalkan dengan konsep dasar pembelajaran mesin. Selain itu, proses untuk memulai pemodelan masalah juga telah dibahas secara rinci. Dengan mempertimbangkan konteks ini, dalam bab ini, kami akan memperkenalkan Anda pada aspek lain yang sangat penting dari pembelajaran mesin, yaitu rekayasa fitur. Meskipun bukan bagian inti dari proses pembelajaran mesin, rekayasa fitur merupakan tugas terkait yang penting yang perlu kita lakukan untuk membuat pembelajaran lebih efektif. Rekayasa fitur memiliki tiga komponen utama – konstruksi fitur, pemilihan fitur, dan transformasi fitur, yang masing-masing akan dibahas secara rinci dalam bab ini.

4.1 PENDAHULUAN

Dalam tiga bab terakhir, kita telah memulai proses pembelajaran mesin. Pertama-tama kita mulai dengan apa itu pembelajaran manusia dan bagaimana berbagai jenis pembelajaran mesin meniru aspek-aspek pembelajaran manusia. Kita memiliki pandangan terperinci tentang berbagai jenis masalah yang dapat dipecahkan menggunakan teknik pembelajaran mesin. Sebelum menerapkan pembelajaran mesin untuk memecahkan masalah, ada beberapa langkah persiapan. Langkah-langkah persiapan ini telah dibahas secara terperinci. Setelah itu, kita telah

melakukan navigasi langkah demi langkah dari berbagai aktivitas pemodelan masalah menggunakan pembelajaran mesin. Pemodelan saja tidak membantu kita untuk menyadari efektivitas pembelajaran mesin sebagai alat pemecahan masalah. Jadi kita juga belajar bagaimana mengukur efektivitas model pembelajaran mesin dalam memecahkan masalah. Jika model tertentu tidak efektif, kita dapat menggunakan tuas yang berbeda untuk meningkatkan efektivitas. Tuas-tuas untuk meningkatkan kinerja model juga dibahas.

Sekarang setelah kita siap (hampir siap!) untuk mulai memecahkan masalah menggunakan pembelajaran mesin, kita perlu menyentuh aspek kunci lain yang memainkan peran penting dalam memecahkan masalah pembelajaran mesin apa pun – rekayasa fitur. Meskipun rekayasa fitur merupakan bagian dari kegiatan persiapan yang telah dibahas di Bab 2, kekritisan dan luasnya area tersebut mengharuskan penanganannya secara terpisah. Area ini menangani fitur-fitur dari kumpulan data, yang membentuk input penting dari setiap masalah pembelajaran mesin – baik pembelajaran terbimbing maupun tak terbimbing. Rekayasa fitur merupakan proses persiapan yang penting dalam pembelajaran mesin. Proses ini bertanggung jawab untuk mengambil data input mentah dan mengubahnya menjadi fitur-fitur yang selaras dengan baik yang siap digunakan oleh model-model pembelajaran mesin.

Namun sebelum kita mulai membahas rekayasa fitur, mari kita coba memahami lebih jelas apa itu fitur.

4.1.1 Apa itu fitur?

Fitur adalah atribut dari kumpulan data yang digunakan dalam proses pembelajaran mesin. Ada pandangan di antara praktisi pembelajaran

mesin tertentu bahwa hanya atribut yang bermakna bagi masalah pembelajaran mesin yang disebut sebagai fitur, tetapi pandangan ini harus diambil dengan sedikit keraguan. Faktanya, pemilihan subset fitur yang bermakna bagi pembelajaran mesin adalah sub-area rekayasa fitur yang menarik banyak minat penelitian. Fitur dalam kumpulan data juga disebut dimensinya. Jadi kumpulan data yang memiliki fitur 'n' disebut kumpulan data n-dimensi.

Mari kita ambil contoh kumpulan data pembelajaran mesin yang terkenal, Iris, yang diperkenalkan oleh ahli statistik dan biologi Inggris Ronald Fisher, sebagian ditunjukkan dalam Gambar 4.1. Ia memiliki lima atribut atau fitur yaitu Sepal.Length, Sepal.Width, Petal.Length, Petal.Width dan Species. Dari semuanya, fitur 'Species' mewakili variabel kelas dan fitur yang tersisa adalah variabel prediktor. Ia merupakan kumpulan data lima dimensi.

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
6.7	3.3	5.7	2.5	Virginica
4.9	3	1.4	0.2	Setosa
5.5	2.6	4.4	1.2	Versicolor
6.8	3.2	5.9	2.3	Virginica
5.5	2.5	4	1.3	Versicolor
5.1	3.5	1.4	0.2	Setosa
6.1	3	4.6	1.4	versicolor

GAMBAR 4.1Fitur set data

4.1.2 Apa itu rekayasa fitur?

Rekayasa fitur mengacu pada proses penerjemahan kumpulan data menjadi fitur-fitur sedemikian rupa sehingga fitur-fitur tersebut mampu merepresentasikan kumpulan data secara lebih efektif dan menghasilkan kinerja pembelajaran yang lebih baik.

Seperti yang telah kita ketahui, rekayasa fitur merupakan langkah pra-pemrosesan yang penting untuk pembelajaran mesin. Rekayasa fitur memiliki dua elemen utama:

1. transformasi fitur
2. pemilihan subset fitur

Transformasi fitur mengubah data – terstruktur atau tidak terstruktur, menjadi serangkaian fitur baru yang dapat mewakili masalah mendasar yang coba dipecahkan oleh pembelajaran mesin. Ada dua varian transformasi fitur:

1. konstruksi fitur
2. ekstraksi fitur

Keduanya terkadang dikenal sebagai penemuan fitur.

Konstruksi fitur Proses menemukan informasi yang hilang tentang hubungan antara fitur dan melengkapi ruang fitur dengan membuat fitur tambahan. Oleh karena itu, jika ada 'n' fitur atau dimensi dalam satu set data, setelah konstruksi fitur 'm' lebih banyak fitur atau dimensi dapat ditambahkan. Jadi pada akhirnya, set data akan menjadi berdimensi 'n + m'.

Ekstraksi fitur adalah proses mengekstraksi atau membuat serangkaian fitur baru dari serangkaian fitur asli menggunakan beberapa pemetaan fungsional.

Tidak seperti transformasi fitur, dalam kasus pemilihan subset fitur (atau sekadar pemilihan fitur), tidak ada fitur baru yang dihasilkan. Tujuan pemilihan fitur adalah untuk memperoleh subset fitur dari set fitur lengkap yang paling bermakna dalam konteks masalah pembelajaran mesin tertentu. Jadi, pada dasarnya tugas pemilihan fitur adalah memperoleh subset $F_j (F_1, F_2, \dots, F_m)$ dari $F_i (F_1, F_2, \dots, F_n)$, di mana $m <$

n, sehingga F_j paling bermakna dan memperoleh hasil terbaik untuk masalah pembelajaran mesin. Kami akan membahas konsep-konsep ini secara terperinci di bagian berikutnya.

4.2 TRANSFORMASI FITUR

Merekayasa ruang fitur yang baik merupakan prasyarat penting untuk keberhasilan model pembelajaran mesin apa pun. Akan tetapi, sering kali tidak jelas fitur mana yang lebih penting. Oleh karena itu, semua atribut yang tersedia dari kumpulan data digunakan sebagai fitur dan masalah mengidentifikasi fitur-fitur penting diserahkan kepada model pembelajaran. Ini jelas bukan pendekatan yang layak, khususnya untuk domain tertentu misalnya klasifikasi citra medis, kategorisasi teks, dsb. Jika suatu model harus dilatih untuk mengklasifikasikan dokumen sebagai spam atau bukan spam, kita dapat merepresentasikan dokumen sebagai sekumpulan kata. Kemudian ruang fitur akan berisi semua kata unik yang muncul di semua dokumen. Ini akan dengan mudah menjadi ruang fitur dari beberapa ratus ribu fitur. Jika kita mulai memasukkan bigram atau trigram bersama dengan kata-kata, jumlah fitur akan mencapai jutaan. Untuk mengatasi masalah ini, transformasi fitur berperan. Transformasi fitur digunakan sebagai alat yang efektif untuk pengurangan dimensionalitas dan karenanya untuk meningkatkan kinerja model pembelajaran. Secara umum, ada dua tujuan berbeda dari transformasi fitur:

- Mencapai rekonstruksi terbaik dari fitur asli dalam set data.
- Mencapai efisiensi tertinggi dalam tugas pembelajaran.

4.2.1 Konstruksi fitur

Konstruksi fitur melibatkan transformasi sekumpulan fitur input yang diberikan untuk menghasilkan sekumpulan fitur baru yang lebih canggih. Untuk memahami lebih jelas, mari kita ambil contoh kumpulan data real estat yang berisi rincian semua apartemen yang dijual di wilayah tertentu.

Kumpulan data memiliki tiga fitur – panjang apartemen, lebar apartemen, dan harga apartemen. Jika digunakan sebagai input untuk masalah regresi, data tersebut dapat menjadi data pelatihan untuk model regresi. Jadi, dengan data pelatihan tersebut, model tersebut seharusnya dapat memprediksi harga apartemen yang harganya belum diketahui atau yang baru saja dijual. Namun, daripada menggunakan panjang dan lebar apartemen sebagai prediktor, akan jauh lebih mudah dan lebih masuk akal untuk menggunakan luas apartemen, yang bukan merupakan fitur yang ada dalam kumpulan data. Jadi, fitur tersebut, yaitu luas apartemen, dapat ditambahkan ke kumpulan data. Dengan kata lain, kami mengubah kumpulan data tiga dimensi menjadi kumpulan data empat dimensi, dengan fitur luas apartemen yang baru 'ditemukan' ditambahkan ke kumpulan data asli. Hal ini digambarkan dalam Gambar 4.2.



apartment_ length	apartment_ breadth	apartment_ price
80	59	23,60,000
54	45	12,15,000
78	56	21,84,000
63	63	19,84,000
83	74	30,71,000
92	86	39,56,000

apartment_ length	apartment_ breadth	apartment_ area	apartment_ price
80	59	4,720	23,60,000
54	45	2,430	12,15,000
78	56	4,368	21,84,000
63	63	3,969	19,84,500
83	74	6,142	30,71,000
92	86	7,912	39,56,000

GAMBAR 4.2Konstruksi fitur (contoh 1)

Catatan: Meskipun demi kesederhanaan, fitur panjang apartemen dan lebar apartemen tetap dipertahankan Gambar 4.2, pada kenyataannya, lebih masuk akal untuk mengecualikan fitur-fitur ini saat membangun model.

Ada situasi tertentu di mana konstruksi fitur merupakan aktivitas penting sebelum kita dapat memulai tugas pembelajaran mesin. Situasi ini adalah;

- ketika fitur memiliki nilai kategoris dan pembelajaran mesin membutuhkan input nilai numerik.
- ketika fitur memiliki nilai numerik (kontinu) dan perlu diubah menjadi nilai ordinal.
- ketika konstruksi fitur khusus teks perlu dilakukan.

4.2.1.1 Pengkodean variabel kategori (nominal)

Mari kita ambil contoh kumpulan data lain tentang atlet, seperti yang disajikan di Gambar 4.3a. Katakanlah kumpulan data memiliki fitur usia, kota asal, orang tua atlet (yaitu menunjukkan apakah salah satu orang tua adalah atlet) dan Peluang Menang. Fitur peluang menang adalah variabel kelas sementara yang lain adalah variabel prediktor. Kita tahu bahwa setiap algoritma pembelajaran mesin, baik itu algoritma klasifikasi (seperti kNN) atau algoritma regresi, memerlukan angka numerik untuk dipelajari. Jadi ada tiga fitur – Kota asal, Orang tua atlet, dan Peluang menang, yang bersifat kategoris dan tidak dapat digunakan oleh tugas pembelajaran mesin apa pun.

Dalam kasus ini, konstruksi fitur dapat digunakan untuk membuat fitur dummy baru yang dapat digunakan oleh algoritma pembelajaran mesin. Karena fitur 'Kota asal' memiliki tiga nilai unik yaitu Kota A, Kota B,

dan Kota C, tiga fitur dummy yaitu `origin_city_A`, `origin_city_B`, dan `origin_city_C` dibuat. Dengan cara yang sama, fitur dummy `parents_athlete_Y` dan `parents_athlete_N` dibuat untuk fitur 'Parents athlete' dan `win_chance_Y` dan `win_chance_N` dibuat untuk fitur 'Chance of win'. Fitur dummy memiliki nilai 0 atau 1 berdasarkan nilai kategoris untuk fitur asli di baris tersebut. Misalnya, baris kedua memiliki nilai kategoris 'Kota B' untuk fitur 'Kota asal'. Jadi, fitur yang baru dibuat sebagai pengganti 'Kota asal', yaitu `origin_city_A`, `origin_city_B`, dan `origin_city_C` akan memiliki nilai 0, 1, dan 0, berturut-turut. Dengan cara yang sama, `parents_athlete_Y` dan `parents_athlete_N` akan memiliki nilai 0 dan 1, masing-masing di baris 2 karena fitur asli 'Parents athlete' memiliki nilai kategoris 'No' di baris 2. Seluruh rangkaian transformasi untuk kumpulan data atlet ditunjukkan pada Gambar 4.3b.

Age (Years)	City of origin	Parents athlete	Chance of win
18	City A	Yes	Y
20	City B	No	Y
23	City B	Yes	Y
19	City A	No	N
18	City C	Yes	N
22	City B	Yes	Y

(a)

Age (Years)	origin_city_A	origin_city_B	origin_city_C	parents_athlete_Y	parents_athlete_N	win_chance_Y	win_chance_N
18	1	0	0	1	0	1	0
20	0	1	0	0	1	1	0
23	0	1	0	1	0	1	0
19	1	0	0	0	1	0	1
18	0	0	1	1	0	0	1
22	0	1	0	1	0	1	0

(b)

Age (Years)	origin_city_A	origin_city_B	origin_city_C	parents_athlete_Y	win_chance_Y
18	1	0	0	1	1
20	0	1	0	0	1
23	0	1	0	1	1
19	1	0	0	0	0
18	0	0	1	1	0
22	0	1	0	1	1

(c)

GAMBAR 4.3Konstruksi fitur (pengkodean variabel nominal)

Akan tetapi, jika ditelusuri lebih lanjut, kita melihat bahwa fitur 'Orang tua atlet' dan 'Peluang menang' dalam kumpulan data asli hanya dapat memiliki dua nilai. Jadi, membuat dua fitur dari keduanya merupakan semacam duplikasi, karena nilai salah satu fitur dapat ditentukan dari nilai fitur lainnya. Untuk menghindari duplikasi ini, kita dapat meninggalkan satu fitur dan menghilangkan fitur lainnya, seperti yang ditunjukkan pada Gambar 4.3c.

4.2.1.2 Pengkodean variabel kategori (ordinal)

Mari kita ambil contoh kumpulan data siswa. Mari kita asumsikan bahwa ada tiga variabel – nilai sains, nilai matematika dan nilai rapor seperti yang ditunjukkan pada gambar.Gambar 4.4a Seperti yang dapat kita lihat, nilai adalah variabel ordinal dengan nilai A, B, C, dan D. Untuk mengubah variabel ini menjadi variabel numerik, kita dapat membuat fitur `num_grade` yang memetakan nilai numerik terhadap setiap nilai ordinal. Dalam konteks contoh saat ini, nilai A, B, C, dan D dalam Gambar 4.4a dipetakan ke nilai 1, 2, 3, dan 4 dalam variabel transformasi yang ditunjukkan pada Gambar 4.4b.

marks_science	marks_maths	Grade
78	75	B
56	62	C
87	90	A
91	95	A
45	42	D
62	57	B

(a)

marks_science	marks_maths	num_grade
78	75	2
56	62	3
87	90	1
91	95	1
45	42	4
62	57	2

(b)

GAMBAR 4.4Konstruksi fitur (pengkodean variabel ordinal)

4.2.1.3 Transformasi fitur numerik (kontinu) menjadi fitur kategoris

Terkadang ada kebutuhan untuk mengubah variabel numerik kontinu menjadi variabel kategoris. Misalnya, kita mungkin ingin memperlakukan masalah prediksi harga real estat, yang merupakan masalah regresi, sebagai prediksi kategori harga real estat, yang merupakan masalah klasifikasi. Dalam kasus tersebut, kita dapat 'mengelompokkan' data numerik ke dalam beberapa kategori berdasarkan rentang data. Dalam konteks contoh prediksi harga real estat, kumpulan data asli memiliki fitur numerik `apartment_price` seperti yang ditunjukkan pada [Gambar 4.5a](#) itu bisa jadi ditransformasikan ke variabel kategori harga-tingkat seperti yang ditunjukkan pada [Gambar 4.5b](#) atau seperti yang ditunjukkan pada [Gambar 4.5c](#).

4.2.1.4 Konstruksi fitur khusus teks

Di dunia saat ini, teks bisa dibilang merupakan media komunikasi yang paling dominan. Baik kita berpikir tentang jejaring sosial seperti Facebook atau saluran micro-blogging seperti Twitter atau email atau layanan pesan singkat seperti Whatsapp, teks memainkan peran utama dalam aliran informasi. Oleh karena itu, penambahan teks merupakan bidang penelitian yang penting – tidak hanya bagi praktisi teknologi tetapi juga bagi praktisi industri. Namun, memahami data teks, karena sifat data yang tidak terstruktur, tidaklah semudah itu. Pertama-tama, potongan data teks yang dapat kita pikirkan tidak memiliki fitur yang tersedia dengan mudah, seperti kumpulan data terstruktur, tempat tugas pembelajaran mesin dapat dieksekusi. Semua model pembelajaran mesin

memerlukan data numerik sebagai input. Jadi, data teks dalam kumpulan data perlu diubah menjadi fitur numerik.

apartment_area	apartment_price
4,720	23,60,000
2,430	12,15,000
4,368	21,84,000
3,969	19,84,500
6,142	30,71,000
7,912	39,56,000

(a)

apartment_area	apartment_grade
4,720	Medium
2,430	Low
4,368	Medium
3,969	Low
6,142	High
7,912	High

(b)

apartment_area	apartment_grade
4,720	2
2,430	1
4,368	2
3,969	1
6,142	3
7,912	3

(c)

GAMBAR 4.5Konstruksi fitur (numerik ke kategorikal)

Data teks, atau korpus yang merupakan kata kunci yang lebih populer, diubah menjadi representasi numerik dengan mengikuti proses yang dikenal sebagai vektorisasi. Dalam proses ini, kemunculan kata dalam semua dokumen yang termasuk dalam korpus dikonsolidasikan dalam bentuk bag-of-words. Ada tiga langkah utama yang diikuti:

1. membuat token
2. menghitung
3. menormalkan

Untuk membuat token pada korpus, spasi kosong dan tanda baca digunakan sebagai pemisah untuk memisahkan kata-kata, atau token. Kemudian jumlah kemunculan setiap token dihitung, untuk setiap dokumen. Terakhir, token diberi bobot dengan mengurangi kepentingan ketika muncul di sebagian besar dokumen. Sebuah matriks kemudian dibentuk dengan setiap token mewakili kolom dan dokumen tertentu dari korpus mewakili setiap baris. Setiap sel berisi jumlah kemunculan token dalam dokumen tertentu. Matriks ini dikenal sebagai matriks dokumen-istilah (juga dikenal sebagai matriks dokumen-istilah). Gambar 4.6 mewakili matriks dokumen istilah khas yang membentuk masukan ke model pembelajaran mesin.

This	House	Build	Feeling	Well	Theatre	Movie	Good	Lonely	...
2	1	1	0	0	1	1	1	0	
0	0	0	1	1	0	0	0	0	
1	0	0	2	1	1	0	0	1	
0	0	0	0	1	0	1	1	0	
-	-	-	-	-	-	-	-	-	
-	-	-	-	-	-	-	-	-	
-	-	-	-	-	-	-	-	-	

GAMBAR 4.6Konstruksi fitur (khusus teks)

4.2.2 Ekstraksi fitur

Dalam ekstraksi fitur, fitur baru dibuat dari kombinasi fitur asli. Beberapa operator yang umum digunakan untuk menggabungkan fitur asli meliputi:

1. Untuk fitur Boolean: Konjungsi, Disjungsi, Negasi, dll.
2. Untuk fitur nominal: produk Cartesien, M dari N, dll.

3. Untuk fitur numerik: Min, Maks, Penambahan, Pengurangan, Perkalian, Pembagian, Rata-rata, Kesetaraan, Ketimpangan, dll.

Mari kita ambil contoh dan coba pahami. Katakanlah, kita memiliki kumpulan data dengan kumpulan fitur F_i ($F_1, F_2, \dots, F_n$). Setelah ekstraksi fitur menggunakan fungsi pemetaan f ($F_1, F_2, \dots, F_n$), katakanlah, kita akan memiliki sekumpulan fitur $\hat{F}_i(\hat{F}_1, \hat{F}_2, \dots, \hat{F}_m)$ seperti yang $\hat{F}_i = f(F_i)$ dan $m < n$. Misalnya, $\hat{F}_1 = k_1 F_1 + k_2 F_2$. Hal ini digambarkan dalam Gambar 4.7.

Feat _A	Feat _B	Feat _C	Feat _D		Feat ₁	Feat ₂
34	34.5	23	233		41.25	185.80
44	45.56	11	3.44		54.20	53.12
78	22.59	21	4.5		43.73	35.79
22	65.22	11	322.3		65.30	264.10
22	33.8	355	45.2		37.02	238.42
11	122.32	63	23.2		113.39	167.74

$\text{Feat}_1 = 0.3 \times \text{Feat}_A + 0.9 \times \text{Feat}_B$	
$\text{Feat}_2 = \text{Feat}_A + 0.5 \text{Feat}_B + 0.6 \times \text{Feat}_C$	

GAMBAR 4.7 Ekstraksi fitur

Mari kita bahas algoritma ekstraksi fitur paling populer yang digunakan dalam pembelajaran mesin:

4.2.2.1 Analisis Komponen Utama

Setiap set data, seperti yang telah kita lihat, memiliki beberapa atribut atau dimensi – banyak di antaranya mungkin memiliki kesamaan satu sama lain. Misalnya, tinggi dan berat seseorang, secara umum, cukup

terkait. Jika tinggi lebih, umumnya berat lebih dan sebaliknya. Jadi jika set data memiliki tinggi dan berat sebagai dua atribut, jelas mereka diharapkan memiliki sedikit kesamaan. Secara umum, setiap algoritma pembelajaran mesin berkinerja lebih baik karena jumlah atribut atau fitur terkait berkurang. Dengan kata lain, kunci keberhasilan pembelajaran mesin terletak pada kenyataan bahwa fitur-fiturnya lebih sedikit jumlahnya serta kesamaan antara satu sama lain sangat sedikit. Ini adalah filosofi panduan utama dari teknik analisis komponen utama (PCA) dari ekstraksi fitur.

Dalam PCA, sekumpulan fitur baru diekstraksi dari fitur asli yang sifatnya sangat berbeda. Jadi ruang fitur ndimensi diubah menjadi ruang fitur mdimensi, yang dimensinya ortogonal satu sama lain, yaitu sepenuhnya independen satu sama lain. Untuk memahami konsep ortogonalitas, kita harus mundur sejenak dan menyelami sedikit konsep ruang vektor dalam aljabar linear.

Kita semua tahu bahwa vektor adalah kuantitas yang memiliki besaran dan arah dan karenanya dapat menentukan posisi suatu titik relatif terhadap titik lain dalam ruang Euclidean (yaitu ruang dua atau tiga atau ruang 'n' dimensi). Ruang vektor adalah sekumpulan vektor. Ruang vektor memiliki sifat yang dapat direpresentasikan sebagai kombinasi linier dari sekumpulan vektor yang lebih kecil, yang disebut vektor basis. Jadi, setiap vektor 'v' dalam ruang vektor dapat direpresentasikan sebagai

$$v = \sum_{i=1}^n a_i u_i$$

di mana, a_i mewakili skalar ' n ' dan u_i mewakili basis vektor. Vektor basis saling ortogonal. Ortogonalitas vektor dalam ruang vektor n -dimensi dapat dianggap sebagai perluasan vektor yang tegak lurus dalam ruang vektor dua dimensi. Dua vektor ortogonal sama sekali tidak berhubungan atau independen satu sama lain. Jadi transformasi sekumpulan vektor ke sekumpulan vektor basis yang sesuai sehingga setiap vektor dalam sekumpulan asli dapat dinyatakan sebagai kombinasi linear vektor basis membantu dalam menguraikan vektor menjadi sejumlah komponen independen.

Sekarang, mari kita perluas gagasan ini ke ruang fitur dari satu set data. Vektor fitur dapat diubah menjadi ruang vektor dari vektor basis yang disebut sebagai komponen utama. Komponen utama ini, seperti halnya vektor basis, saling ortogonal. Jadi, sekumpulan vektor fitur yang mungkin memiliki kesamaan satu sama lain diubah menjadi sekumpulan komponen utama yang sama sekali tidak terkait. Namun, komponen utama menangkap variabilitas ruang fitur asli. Selain itu, jumlah komponen utama yang diturunkan, seperti halnya vektor basis, jauh lebih kecil daripada sekumpulan fitur asli.

Tujuan PCA adalah melakukan transformasi sedemikian rupa sehingga

1. Fitur-fitur baru itu berbeda, yaitu kovariansi antara fitur-fitur baru, yaitu komponen-komponen utamanya adalah 0.
2. Komponen utama dibuat berdasarkan variabilitas data yang ditangkapnya. Oleh karena itu, komponen utama pertama harus menangkap variabilitas maksimum, komponen utama kedua harus menangkap variabilitas tertinggi berikutnya, dst.
3. Jumlah varians fitur baru atau komponen utama harus sama dengan jumlah varians fitur asli.

PCA bekerja berdasarkan proses yang disebut dekomposisi nilai eigen dari matriks kovariansi suatu kumpulan data. Berikut ini adalah langkah-langkah yang harus diikuti:

1. Pertama, hitung matriks kovariansi suatu kumpulan data.
2. Kemudian, hitung nilai eigen dari matriks kovariansi.
3. Vektor eigen yang memiliki nilai eigen tertinggi menunjukkan arah di mana terdapat varians tertinggi. Jadi ini akan membantu dalam mengidentifikasi komponen utama pertama.
4. Vektor eigen yang memiliki nilai eigen tertinggi berikutnya menunjukkan arah di mana data memiliki varians tertinggi yang tersisa dan juga ortogonal terhadap arah pertama. Jadi ini membantu dalam mengidentifikasi komponen utama kedua.
5. Seperti ini, identifikasi vektor eigen 'k' teratas yang memiliki nilai eigen 'k' teratas untuk mendapatkan komponen utama 'k'.

4.2.2.2 Dekomposisi nilai singular

Dekomposisi nilai singular (SVD) adalah teknik faktorisasi matriks yang umum digunakan dalam aljabar linier. SVD dari matriks A ($m \times n$) adalah faktorisasi dalam bentuk:

$$A = U \Sigma V$$

di mana, U dan V adalah matriks ortonormal, U adalah $m \times m$ matriks kesatuan, V adalah matriks kesatuan $n \times n$ dan Σ adalah matriks diagonal persegi panjang $m \times n$. Entri diagonal Σ dikenal sebagai nilai

singular matriks A. Kolom U dan V masing-masing disebut vektor singular kiri dan singular kanan matriks A.

SVD umumnya digunakan dalam PCA, setelah rata-rata setiap variabel dihilangkan. Karena tidak selalu disarankan untuk menghilangkan rata-rata atribut data, terutama ketika kumpulan data jarang (seperti dalam kasus data teks), SVD merupakan pilihan yang baik untuk pengurangan dimensionalitas dalam situasi tersebut.

SVD dari matriks data diharapkan memiliki properti yang disorot di bawah ini:

1. Pola dalam atribut ditangkap oleh vektor singular kanan, yaitu kolom V.
2. Pola di antara contoh-contoh ditangkap oleh singular kiri, yaitu kolom U.
3. Semakin besar suatu nilai singular, semakin besar pula bagian matriks A yang diperhitungkan dan vektor terkaitnya.
4. Matriks data baru dengan atribut 'k' diperoleh dengan menggunakan persamaan

$$D' = D \times [v_1, v_2, \dots, v_k]$$

Dengan demikian, dimensionalitas direduksi menjadi k SVD sering digunakan dalam konteks data teks.

4.2.2.3 Analisis Diskriminan Linier

Analisis diskriminan linier (LDA) adalah teknik ekstraksi fitur lain yang umum digunakan seperti PCA atau SVD. Tujuan LDA serupa dengan pengertian bahwa ia bermaksud mengubah kumpulan data menjadi ruang fitur berdimensi lebih rendah. Namun, tidak seperti PCA, fokus LDA bukanlah untuk menangkap variabilitas kumpulan data. Sebaliknya, LDA

berfokus pada keterpisahan kelas, yaitu memisahkan fitur berdasarkan keterpisahan kelas untuk menghindari over-fitting model pembelajaran mesin.

Berbeda dengan PCA yang menghitung nilai eigen dari matriks kovariansi kumpulan data, LDA menghitung nilai eigen dan vektor eigen dalam matriks sebaran kelas dan antarkelas. Berikut ini adalah langkah-langkah yang harus diikuti:

1. Hitunglah vektor rata-rata untuk masing-masing kelas.
2. Hitung matriks sebaran intra-kelas dan antar-kelas.
3. Hitung nilai eigen dan vektor eigen untuk SW^{-1} dan SB , dimana SW adalah matriks sebaran intra-kelas dan SB adalah matriks sebaran antar-kelas

$$S_W = \sum_{i=1}^c S_i;$$

$$S_i = \sum_{x \in D_i} (x - m_i)(x - m_i)^T$$

di mana, m_i adalah vektor rata-rata kelas ke- i

$$S_B = \sum_{i=1}^c N_i (m_i - m)(m_i - m)^T$$

di mana, m_i adalah rata-rata sampel untuk setiap kelas, m adalah rata-rata keseluruhan dari kumpulan data, N_i adalah ukuran sampel setiap kelas

4. Identifikasi vektor eigen 'k' teratas yang memiliki nilai eigen 'k' teratas

4.3 PEMILIHAN SUBSET FITUR

Pemilihan fitur bisa dibilang merupakan aktivitas pra-pemrosesan yang paling penting dalam setiap proyek pembelajaran mesin. Tujuannya adalah untuk memilih subset atribut atau fitur sistem yang memberikan kontribusi paling berarti dalam aktivitas pembelajaran mesin. Mari kita bahas contoh praktis untuk memahami filosofi di balik pemilihan fitur. Katakanlah kita mencoba memprediksi berat siswa berdasarkan informasi masa lalu tentang siswa yang serupa, yang terekam dalam set data 'berat siswa'. Set data berat siswa memiliki fitur seperti Nomor Rol, Usia, Tinggi, dan Berat. Kita dapat memahami dengan baik bahwa nomor rol tidak memiliki pengaruh apa pun dalam memprediksi berat siswa. Jadi kita dapat menghilangkan nomor rol fitur dan membangun subset fitur yang akan dipertimbangkan dalam masalah pembelajaran mesin ini. Subset fitur diharapkan memberikan hasil yang lebih baik daripada set lengkap. Hal yang sama telah digambarkan dalam Gambar 4.8.

Roll Number	Age	Height	Weight		Age	Height	Weight
12	12	1.1	23		12	1.1	23
14	11	1.05	21.6		11	1.05	21.6
19	13	1.2	24.7		13	1.2	24.7
32	11	1.07	21.3	→	11	1.07	21.3
38	14	1.24	25.2		14	1.24	25.2
45	12	1.12	23.4		12	1.12	23.4

GAMBAR 4.8Pemilihan fitur

Namun sebelum kita lanjut dengan pembahasan lebih rinci tentang pemilihan fitur, mari kita coba memahami isu-isu yang membuat pemilihan fitur menjadi masalah yang relevan untuk dipecahkan.

4.3.1 Masalah dalam data berdimensi tinggi

Dengan inovasi yang pesat di ruang digital, volume data yang dihasilkan telah meningkat hingga tingkat yang tak terbayangkan. Pada saat yang sama, terobosan dalam bidang teknologi penyimpanan telah membuat penyimpanan data dalam jumlah besar menjadi cukup murah. Hal ini semakin memotivasi penyimpanan dan penambahan kumpulan data yang sangat besar dan berdimensi tinggi.

Di samping itu, dua domain aplikasi baru telah mengalami perkembangan yang drastis. Salah satunya adalah penelitian biomedis, yang mencakup pemilihan gen dari data mikroarray. Yang lainnya adalah kategorisasi teks yang menangani sejumlah besar data teks dari situs jejaring sosial, email, dll. Domain pertama, yaitu penelitian biomedis menghasilkan set data yang memiliki sejumlah fitur dalam kisaran beberapa puluh ribu. Data teks yang dihasilkan dari berbagai sumber juga memiliki dimensi yang sangat tinggi. Dalam korpus dokumen besar yang memiliki beberapa ribu dokumen yang disematkan, jumlah token kata unik yang mewakili fitur set data teks, juga dapat berada dalam kisaran beberapa puluh ribu. Untuk mendapatkan wawasan dari data berdimensi tinggi tersebut mungkin menjadi tantangan besar bagi algoritma pembelajaran mesin apa pun. Di satu sisi, sumber daya komputasi yang sangat besar dan jumlah waktu yang besar akan diperlukan. Di sisi lain, kinerja model – baik untuk tugas pembelajaran mesin yang diawasi maupun tidak diawasi, juga menurun tajam karena gangguan yang tidak perlu dalam data. Selain itu, model yang dibangun di atas sejumlah besar fitur mungkin sangat sulit dipahami. Oleh karena itu, perlu mengambil sebagian fitur, bukan keseluruhan fitur.

Tujuan pemilihan fitur ada tiga:

- Memiliki model pembelajaran yang lebih cepat dan lebih hemat biaya (yaitu lebih sedikit membutuhkan sumber daya komputasi)
- Meningkatkan efisiensi model pembelajaran
- Memiliki pemahaman yang lebih baik tentang model dasar yang menghasilkan data

4.3.2 Penggerak utama pemilihan fitur – relevansi dan redundansi fitur

4.3.2.1 Relevansi fitur

Dalam pembelajaran terbimbing, set data masukan yang merupakan set data pelatihan, memiliki label kelas yang dilampirkan. Sebuah model diinduksi berdasarkan set data pelatihan – sehingga model yang diinduksi dapat menetapkan label kelas ke data baru yang tidak berlabel. Setiap variabel prediktor diharapkan memberikan informasi untuk memutuskan nilai label kelas. Jika sebuah variabel tidak memberikan informasi apa pun, variabel tersebut dikatakan tidak relevan. Jika kontribusi informasi untuk prediksi sangat sedikit, variabel tersebut dikatakan relevan secara lemah. Variabel yang tersisa, yang memberikan kontribusi signifikan terhadap tugas prediksi dikatakan sebagai variabel yang sangat relevan.

Dalam pembelajaran tanpa pengawasan, tidak ada set data pelatihan atau data berlabel. Pengelompokan contoh data yang serupa dilakukan dan kesamaan contoh data dievaluasi berdasarkan nilai variabel yang berbeda. Variabel tertentu tidak memberikan informasi yang berguna untuk memutuskan kesamaan atau ketidaksamaan contoh data. Oleh karena itu, variabel tersebut tidak memberikan kontribusi informasi yang signifikan dalam proses pengelompokan. Variabel ini ditandai sebagai

variabel yang tidak relevan dalam konteks tugas pembelajaran mesin tanpa pengawasan.

Untuk mendapatkan perspektif, kita dapat memikirkan contoh sederhana dari kumpulan data siswa yang telah kita bahas di awal bagian ini. Nomor induk siswa tidak memberikan informasi signifikan apa pun dalam memprediksi Berat Badan siswa. Demikian pula, jika kita mencoba mengelompokkan siswa dengan kemampuan akademis yang sama, Nomor induk tidak dapat memberikan informasi apa pun. Jadi, dalam konteks tugas terbimbing untuk memprediksi Berat Badan siswa atau tugas tak terbimbing untuk mengelompokkan siswa dengan prestasi akademis yang sama, variabel Nomor induk tidak relevan.

Fitur apa pun yang tidak relevan dalam konteks tugas pembelajaran mesin dapat ditolak saat kita memilih sebagian fitur. Kita dapat mempertimbangkan apakah fitur yang kurang relevan akan ditolak atau tidak berdasarkan kasus per kasus.

4.3.2.2 Redundansi fitur

Suatu fitur dapat memberikan informasi yang serupa dengan informasi yang diberikan oleh satu atau beberapa fitur lainnya. Misalnya, dalam masalah prediksi berat badan yang disebutkan sebelumnya di bagian ini, baik fitur Usia maupun Tinggi badan memberikan informasi yang serupa. Hal ini karena dengan peningkatan Usia, Berat badan diharapkan akan meningkat. Demikian pula, dengan peningkatan.

Tinggi dan Berat juga diharapkan meningkat. Selain itu, Usia dan Tinggi meningkat bersamaan. Jadi, dalam konteks masalah prediksi Berat, Usia dan Tinggi memberikan informasi yang serupa. Dengan kata lain,

terlepas dari apakah tinggi fitur hadir sebagai bagian dari subset fitur, model pembelajaran akan memberikan hasil yang hampir sama. Dengan cara yang sama, tanpa usia menjadi bagian dari variabel prediktor, hasil dari model pembelajaran akan kurang lebih sama. Dalam situasi seperti ini ketika satu fitur mirip dengan fitur lainnya, fitur tersebut dikatakan berpotensi redundan dalam konteks masalah pembelajaran.

Semua fitur yang berpotensi redundansi adalah kandidat untuk ditolak dalam subset fitur final. Hanya sejumlah kecil fitur representatif dari sekumpulan fitur yang berpotensi redundan yang dipertimbangkan sebagai bagian dari subset fitur final.

Jadi, singkatnya, tujuan utama pemilihan fitur adalah untuk menghilangkan semua fitur yang tidak relevan dan mengambil sebagian kecil fitur yang berpotensi berlebihan. Hal ini menghasilkan sebagian kecil fitur yang bermakna dalam konteks tugas pembelajaran tertentu.

Sekarang, pertanyaannya adalah bagaimana cara mengetahui fitur mana yang tidak relevan atau fitur mana yang berpotensi redundansi. Untuk itu, beberapa ukuran digunakan, beberapa di antaranya telah dibahas di sub-bagian berikutnya.

4.3.3 Ukuran relevansi dan redundansi fitur

4.3.3.1 Ukuran relevansi fitur

Seperti yang disebutkan sebelumnya, relevansi fitur diukur berdasarkan jumlah informasi yang disumbangkan oleh suatu fitur. Untuk pembelajaran terbimbing, informasi mutual dianggap sebagai ukuran kontribusi informasi suatu fitur yang baik untuk menentukan nilai label kelas. Itulah sebabnya informasi mutual merupakan indikator yang baik

untuk relevansi suatu fitur terhadap variabel kelas. Semakin tinggi nilai informasi mutual suatu fitur, semakin relevan fitur tersebut. Informasi mutual dapat dihitung sebagai berikut:

$$saya(C, f) = H(C) + H(f) - H(C, f)$$

di mana, entropi marginal kelas, $H(C) =$

$$- \sum_{i=1}^K p(C_i) \log_2 p(C_i)$$

entropi marginal fitur 'x', $H(f) =$

$$- \sum_c p(f = x) \log_2 p(f = x)$$

dan K = jumlah kelas, C = variabel kelas, f = set fitur

yang mengambil nilai diskret.

Dalam kasus pembelajaran tanpa pengawasan, tidak ada variabel kelas. Oleh karena itu, informasi mutual antar-fitur tidak dapat digunakan untuk mengukur kontribusi informasi dari fitur-fitur. Dalam kasus pembelajaran tanpa pengawasan, entropi dari kumpulan fitur tanpa satu fitur pada satu waktu dihitung untuk semua fitur. Kemudian, fitur-fitur tersebut diberi peringkat dalam urutan menurun dari perolehan informasi dari suatu fitur dan persentase 'β' teratas (nilai 'β' adalah parameter desain algoritma) dari fitur-fitur dipilih sebagai fitur yang relevan. Entropi dari suatu fitur f dihitung menggunakan rumus Shannon di bawah ini:

$$H(f) = - \sum_x p(f = x) \log_2 p(f = x)$$

$\sum_x$

hanya digunakan untuk fitur yang mengambil nilai diskrit. Untuk fitur kontinu, sebaiknya diganti dengan diskritisasi yang dilakukan terlebih dahulu untuk memperkirakan probabilitas $p(f = x)$.

4.3.3.2 Ukuran Redundansi Fitur

Redundansi fitur, seperti yang telah kita bahas, didasarkan pada kontribusi informasi yang serupa oleh beberapa fitur. Ada beberapa ukuran kesamaan kontribusi informasi, yang paling menonjol adalah

1. Pengukuran berbasis korelasi
2. Pengukuran berbasis jarak, dan
3. Ukuran berbasis koefisien lainnya

1. Ukuran kesamaan berbasis korelasi

Korelasi adalah ukuran ketergantungan linear antara dua variabel acak. Koefisien korelasi momen produk Pearson adalah salah satu ukuran korelasi yang paling populer dan diterima antara dua variabel acak. Untuk dua variabel fitur acak F_1 dan F_2 , koefisien korelasi Pearson didefinisikan sebagai:

$$\alpha = \frac{cov(F_1, F_2)}{\sqrt{var(F_1).var(F_2)}}$$
$$cov(F_1, F_2) = \sum (F_{1_i} - \bar{F}_1).(F_{2_i} - \bar{F}_2)$$
$$var(F_1) = \sum (F_{1_i} - \bar{F}_1)^2, \text{ where } \bar{F}_1 = \frac{1}{n} \cdot \sum F_{1_i}$$
$$var(F_2) = \sum (F_{2_i} - \bar{F}_2)^2, \text{ where } \bar{F}_2 = \frac{1}{n} \cdot \sum F_{2_i}$$

Nilai korelasi berkisar antara +1 dan -1. Korelasi 1 (+/-) menunjukkan korelasi sempurna, yaitu dua fitur memiliki hubungan linier yang sempurna. Jika korelasinya 0, maka fitur-fitur tersebut tampaknya tidak memiliki hubungan linier. Secara umum, untuk semua masalah pemilihan fitur, nilai ambang batas diadopsi untuk memutuskan apakah dua fitur memiliki kesamaan yang memadai atau tidak.

2. Pengukuran kesamaan berbasis jarak

Pengukuran jarak yang paling umum adalah jarak Euclidean, yang antara dua fitur F_1 dan F_2 dihitung sebagai:

$$d(F_1, F_2) = \sqrt{\sum_{i=1}^n (F_{1i} - F_{2i})^2}$$

di mana F_1 dan F_2 adalah fitur himpunan data n -dimensi.
 Lihat Gambar 4.9. Kumpulan data memiliki dua fitur, yaitu aptitude (F_1) dan komunikasi (F_2) yang sedang dipertimbangkan. Jarak Euclidean antara fitur telah dihitung menggunakan rumus yang diberikan di atas.

Aptitude (F_1)	Communication (F_2)	$(F_1 - F_2)$	$(F_1 - F_2)^2$
2	6	-4	16
3	5.5	-2.5	6.25
6	4	2	4
7	2.5	4.5	20.25
8	3	5	25
6	5.5	0.5	0.25
6	7	-1	1
7	6	1	1
8	6	2	4
9	7	2	4
			81.75

GAMBAR 4.9Perhitungan jarak antar fitur

Bentuk jarak Euclidean yang lebih umum adalah

Jarak Minkowski, diukur sebagai

$$d(F_1, F_2) = \sqrt[r]{\sum_{i=1}^n (F_{1i} - F_{2i})^r}$$

Jarak Minkowski mengambil bentuk jarak Euclidean (juga disebut norma L_2) ketika $r = 2$.


Pada $r = 1$, ia mengambil bentuk jarak Manhattan (juga disebut norma L_1), seperti yang ditunjukkan di bawah ini:

$$d(F_1, F_2) = \sum_{i=1}^n |F_{1i} - F_{2i}|$$

Contoh spesifik jarak Manhattan, yang lebih sering digunakan untuk menghitung jarak antara vektor biner adalah jarak Hamming. Misalnya, jarak Hamming antara dua vektor 01101011 dan 11001001 adalah 3, seperti yang diilustrasikan pada Gambar 4.10a.

3. Ukuran kesamaan lainnya

Indeks/koefisien Jaccard digunakan sebagai ukuran kesamaan antara dua fitur. Jarak Jaccard, ukuran ketidaksamaan antara dua fitur, merupakan pelengkap indeks Jaccard.



GAMBAR 4.10Ukuran jarak antar fitur

Untuk dua fitur yang memiliki nilai biner, indeks Jaccard diukur sebagai

$$J = \frac{n_{11}}{n_{01} + n_{10} + n_{11}}$$

di mana, n_{11} = jumlah kasus di mana kedua fitur memiliki nilai 1

N_{01} = jumlah kasus dimana fitur 1 memiliki nilai 0 dan fitur 2 memiliki nilai 1

N_{10} = jumlah kasus dimana fitur 1 memiliki nilai 1 dan fitur 2 memiliki nilai 0

Jarak Jaccard, $dJ = 1 - J$

Mari kita pertimbangkan dua fitur F1 dan F2 yang memiliki nilai (0, 1, 1, 0, 1, 0, 1, 0) dan (1, 1, 0, 0, 1, 0, 0, 0). Gambar 4.10b menunjukkan identifikasi nilai n_{11} , n_{01} dan n_{10} . Seperti yang ditunjukkan, kasus-kasus di mana kedua nilai tersebut adalah 0 telah dihilangkan tanpa batas – sebagai indikasi fakta bahwa mereka akan dikecualikan dalam perhitungan koefisien Jaccard.

Koefisien Jaccard dari F1 dan F2, $J =$

$$\frac{n_{11}}{n_{01} + n_{10} + n_{11}} = \frac{2}{1 + 2 + 2} = \frac{2}{5} \text{ or } 0.4.$$

∴ Jarak Jaccard antara F1 dan F2, $dJ = 1 - J = \frac{1}{2}$ atau 0,6.

Koefisien pencocokan sederhana (SMC) hampir sama dengan koefisien Jaccard kecuali fakta bahwa ia mencakup sejumlah kasus di mana kedua fitur memiliki nilai 0.

$$SMC = \frac{n_{11} + n_{00}}{n_{00} + n_{01} + n_{10} + n_{11}}$$

di mana, n_{11} = jumlah kasus di mana kedua fitur memiliki nilai 1

N_{01} = jumlah kasus dimana fitur 1 memiliki nilai 0 dan fitur 2 memiliki nilai 1

N_{10} = jumlah kasus dimana fitur 1 bernilai 1 dan fitur 2 bernilai 0
 n_{00} = jumlah kasus dimana kedua fitur bernilai 0

Cukup bisa dimengerti, jumlah total baris, $n = n_{00} + n_{01} + n_{10} + n_{11}$. Seperti yang ditunjukkan pada Gambar 4.10c, semua nilai telah dimasukkan dalam perhitungan SMC.

$$\therefore \text{SMC of } F_1 \text{ and } F_2 = \frac{n_{11} + n_{00}}{n_{00} + n_{01} + n_{10} + n_{11}} = \frac{2 + 3}{3 + 1 + 2 + 2} = \frac{1}{2} \text{ or } 0.5.$$

Satu lagi ukuran kesamaan menggunakan perhitungan koefisien kesamaan adalah Kesamaan Kosinus. Mari kita ambil contoh masalah klasifikasi teks yang umum. Korpus teks perlu diubah terlebih dahulu menjadi fitur dengan token kata sebagai fitur dan jumlah kemunculan kata dalam dokumen muncul sebagai nilai di setiap baris. Ada ribuan fitur dalam set data teks tersebut. Namun, set data tersebut sifatnya jarang karena hanya beberapa kata yang muncul dalam dokumen, dan karenanya dalam satu baris set data. Jadi setiap baris memiliki sangat sedikit nilai bukan nol. Namun, nilai bukan nol dapat berupa nilai integer apa pun karena kata yang sama dapat muncul beberapa kali. Selain itu, dengan mempertimbangkan kelangkaan set data, kecocokan 0-0 (yang jelas akan cukup tinggi) perlu diabaikan. Kesamaan kosinus yang merupakan salah satu ukuran paling populer dalam klasifikasi teks dihitung sebagai:

$$\cos(x, y) = \frac{x \cdot y}{\|x\| \cdot \|y\|}$$

dimana, $x \cdot y$ = perkalian titik vektor x dan $y = \sum_{i=1}^n x_i y_i$

$$\|x\| = \sqrt{\sum_{i=1}^n x_i^2} \text{ and } \|y\| = \sqrt{\sum_{i=1}^n y_i^2}$$

Mari kita hitung kesamaan kosinus dari x dan y , di mana $x = (2, 4, 0, 0, 2, 1, 3, 0, 0)$ dan $y = (2, 1, 0, 0, 3, 2, 1, 0, 1)$.

Dalam kasus ini, $x \cdot y = 2 \cdot 2 + 4 \cdot 1 + 0 \cdot 0 + 0 \cdot 0 + 2 \cdot 3 + 1 \cdot 2 + 3 \cdot 1 +$


$$0*0 + 0*1 = 19$$

$$\|x\| = \sqrt{2^2 + 4^2 + 0^2 + 0^2 + 2^2 + 1^2 + 3^2 + 0^2 + 0^2} = \sqrt{34} = 5.83$$

$$\|y\| = \sqrt{2^2 + 1^2 + 0^2 + 0^2 + 3^2 + 2^2 + 1^2 + 0^2 + 1^2} = \sqrt{20} = 4.47$$

$$\therefore \cos(x, y) = \frac{19}{5.83*4.47} = 0.729$$

Kesamaan kosinus sebenarnya mengukur sudut (lihat [Ara. 4.11](#)) antara vektor x dan y. Oleh karena itu, jika kesamaan kosinus bernilai 1, sudut antara x dan y adalah 0° yang berarti x dan y sama kecuali besarnya. Jika kesamaan kosinus bernilai 0, sudut antara x dan y adalah 90° . Oleh karena itu, keduanya tidak memiliki kesamaan apa pun (dalam kasus data teks, tidak ada istilah/kata yang umum). Dalam contoh di atas, sudutnya menjadi $43,2^\circ$.




GAMBAR 4.11 kesamaan kosinus

4.3.4 Proses pemilihan fitur secara keseluruhan

Pemilihan fitur adalah proses memilih subset fitur dalam kumpulan data. Seperti yang digambarkan dalam [Gambar 4.12](#), proses pemilihan fitur biasanya terdiri dari empat langkah:

1. pembangkitan subset yang mungkin
2. evaluasi subset
3. berhenti mencari berdasarkan beberapa kriteria penghentian
4. validasi hasil



GAMBAR 4.12Proses pemilihan fitur

Pembuatan subset, yang merupakan langkah pertama dari setiap algoritma pemilihan fitur, adalah prosedur pencarian yang idealnya harus menghasilkan semua kemungkinan subset kandidat. Namun, untuk set data ndimensi, 2^N subset dapat dihasilkan. Jadi, ketika nilai 'n' menjadi tinggi, menemukan subset optimal dari semua 2^N subset kandidat menjadi tidak dapat diatasi. Oleh karena itu, berbagai strategi pencarian perkiraan digunakan untuk menemukan subset kandidat untuk evaluasi. Di satu sisi, pencarian dapat dimulai dengan set kosong dan terus menambahkan fitur. Strategi pencarian ini disebut sebagai pemilihan maju berurutan. Di sisi lain, pencarian dapat dimulai dengan set lengkap dan secara berturut-turut menghapus fitur. Strategi ini disebut sebagai eliminasi mundur berurutan. Dalam kasus tertentu, pencarian dimulai dengan kedua ujung dan menambahkan serta menghapus fitur secara bersamaan. Strategi ini disebut sebagai pemilihan dua arah.

Setiap subset kandidat kemudian dievaluasi dan dibandingkan dengan subset dengan kinerja terbaik sebelumnya berdasarkan kriteria evaluasi tertentu. Jika subset baru berkinerja lebih baik, ia menggantikan subset sebelumnya.

Siklus pembangkitan dan evaluasi subset ini berlanjut hingga kriteria penghentian yang telah ditetapkan terpenuhi. Beberapa kriteria penghentian yang umum digunakan adalah:

1. Pencarian selesai

2. batas tertentu (misalnya jumlah iterasi tertentu) tercapai
3. penambahan (atau penghapusan) fitur selanjutnya tidak menghasilkan subset yang lebih baik
4. subset yang cukup baik (misalnya subset yang memiliki akurasi klasifikasi lebih baik daripada tolok ukur yang ada) dipilih


Kemudian subset terbaik yang dipilih divalidasi baik terhadap tolok ukur sebelumnya atau dengan eksperimen menggunakan data asli atau sintetis tetapi asli. Dalam kasus pembelajaran terbimbing, akurasi model pembelajaran dapat menjadi parameter kinerja yang dipertimbangkan untuk validasi. Akurasi model menggunakan subset yang diperoleh dibandingkan dengan akurasi model subset yang diperoleh menggunakan beberapa algoritma tolok ukur lainnya. Dalam kasus tanpa pengawasan, kualitas kluster dapat menjadi parameter untuk validasi.

4.3.5 Pendekatan pemilihan fitur

Ada empat jenis pendekatan untuk pemilihan fitur:


1. Pendekatan filter
2. Pendekatan pembungkus
3. Pendekatan hibrida
4. Pendekatan tertanam

Dalam pendekatan filter (seperti yang digambarkan dalam [Gambar 4.13](#)), subset fitur dipilih berdasarkan pengukuran statistik yang dilakukan untuk menilai keunggulan fitur dari perspektif data. Tidak ada algoritma pembelajaran yang digunakan untuk mengevaluasi kebaikan fitur yang dipilih. Beberapa uji statistik umum yang dilakukan pada fitur sebagai bagian dari pendekatan filter adalah – korelasi Pearson, perolehan informasi, skor Fisher, analisis varians (ANOVA), Chi-Square, dll.



GAMBAR 4.13Pendekatan filter

Dalam pendekatan pembungkus (seperti yang digambarkan dalam [Gambar 4.14](#)), identifikasi subset fitur terbaik dilakukan dengan menggunakan algoritma induksi sebagai kotak hitam. Algoritma pemilihan fitur mencari subset fitur yang baik menggunakan algoritma induksi itu sendiri sebagai bagian dari fungsi evaluasi. Karena untuk setiap subset kandidat, model pembelajaran dilatih dan hasilnya dievaluasi dengan menjalankan algoritma pembelajaran, pendekatan wrapper secara komputasi sangat mahal. Namun, kinerjanya secara umum lebih unggul dibandingkan dengan pendekatan filter.




GAMBAR 4.14Pendekatan pembungkus

Pendekatan hibrida memanfaatkan kedua pendekatan filter dan wrapper. Algoritme hibrida yang umum menggunakan kedua uji statistik seperti yang digunakan dalam pendekatan filter untuk memutuskan subset terbaik untuk kardinalitas tertentu dan algoritme pembelajaran untuk memilih subset terbaik akhir di antara subset terbaik di berbagai kardinalitas.

Pendekatan tertanam(seperti yang digambarkan dalam [Gambar 4.15](#)) cukup mirip dengan pendekatan wrapper karena pendekatan ini juga

menggunakan algoritma induktif untuk mengevaluasi subset fitur yang dihasilkan. Namun, perbedaannya adalah pendekatan ini melakukan pemilihan fitur dan klasifikasi secara bersamaan.



GAMBAR 4.15 Pendekatan tertanam

4.4 RINGKASAN

- Fitur adalah atribut kumpulan data yang digunakan dalam proses pembelajaran mesin.
- Rekayasa fitur adalah langkah pra-pemrosesan penting untuk pembelajaran mesin, yang memiliki dua elemen utama:
 1. transformasi fitur
 2. pemilihan subset fitur
- Transformasi fitur mengubah data menjadi serangkaian fitur baru yang dapat
- mewakili masalah pembelajaran mesin yang mendasarinya Ada dua varian transformasi fitur:
 1. konstruksi fitur
 2. ekstraksi fitur
- Proses konstruksi fitur menemukan informasi yang hilang tentang hubungan antara fitur dan menambah ruang fitur dengan membuat fitur tambahan.

- Ekstraksi fitur adalah proses mengekstraksi atau membuat sekumpulan fitur baru dari sekumpulan fitur asli menggunakan beberapa pemetaan fungsional. Beberapa algoritma ekstraksi fitur populer yang digunakan dalam pembelajaran mesin:
 1. Analisis Komponen Utama (PCA)
 2. Dekomposisi Nilai Singular (SVD)
 3. Analisis Diskriminan Linier (LDA)
- Pemilihan subset fitur dimaksudkan untuk memperoleh subset fitur dari set fitur lengkap. Tidak ada fitur baru yang dihasilkan.
- Tujuan pemilihan fitur ada tiga:
 1. Memiliki model pembelajaran yang lebih cepat dan lebih hemat biaya (yaitu lebih sedikit membutuhkan sumber daya komputasi)
 2. Meningkatkan efisiensi model pembelajaran
 3. Memiliki pemahaman yang lebih baik tentang model dasar yang menghasilkan data
 Pemilihan fitur bertujuan untuk membuang semua fitur yang tidak relevan dan mengambil sebagian kecil fitur yang berpotensi berlebihan. Hal ini menghasilkan sebagian kecil fitur yang bermakna dalam konteks tugas pembelajaran tertentu.
- Relevansi fitur ditunjukkan oleh perolehan informasi dari suatu fitur yang diukur berdasarkan entropi relatif.
- Redundansi fitur didasarkan pada informasi serupa yang disumbangkan oleh beberapa fitur yang diukur berdasarkan fitur ke fitur:
 1. Korelasi

2. Jarak (jarak Minkowski, misalnya Manhattan, Euclidean, dll. digunakan sebagai ukuran yang paling populer)
 3. Koefisien berbasis lainnya (Jaccard, SMC, Kesamaan kosinus, dll.)
- Pendekatan utama untuk pemilihan fitur adalah
1. Menyaring
 2. Pembungkus
 3. Hibrida
 4. Tertanam

SOAL PILIHAN GANDA (SOAL 1 NILAI)

1. Merekayasa ruang fitur yang baik merupakan hal yang krusial ____ untuk keberhasilan model pembelajaran mesin apa pun.
 1. Prasyarat
 2. Proses
 3. Tujuan
 4. Tidak ada yang di atas
2. n-gram berukuran 1 disebut
 1. Besar
 2. Bahasa Inggris Unigram
 3. Trigram
 4. Tidak ada yang di atas
3. Fitur ____ melibatkan transformasi serangkaian fitur masukan yang diberikan untuk menghasilkan serangkaian fitur baru yang lebih canggih.

1. Pilihan
2. Rekayasa
3. Transformasi
4. Rekayasa ulang
4. Konversi korpus teks ke representasi numerik dilakukan menggunakan proses ____.
 1. Tokenisasi
 2. Normalisasi
 3. Vektorisasi
 4. Tidak ada yang di atas
5. Pendekatan ____ menggunakan algoritma induksi untuk validasi subset.
 1. Menyaring
 2. Hibrida
 3. Pembungkus
 4. Tertanam
6. Dalam ekstraksi fitur, beberapa ____ yang umum digunakan digunakan untuk menggabungkan fitur asli.
 1. Operator
 2. Pembatas
 3. Kata-kata
 4. Semua hal di atas
7. Jarak Hamming antara vektor biner 1001 dan 0101 adalah
 1. 1
 2. 2
 3. 3
 4. 4
8. PCA adalah sebuah teknik untuk
 1. Ekstraksi fitur

2. Konstruksi fitur
 3. Pemilihan fitur
 4. Tidak ada yang di atas
9. Fitur-fitur baru yang dibuat di PCA dikenal sebagai
1. Komponen utama
 2. Vektor eigen
 3. Komponen sekunder
 4. Tidak ada yang di atas
10. Dalam LDA, matriks ____ intra-kelas dan antar-kelas dihitung.
1. Menyebarkan
 2. Kedekatan
 3. Kesamaan
 4. Tidak ada yang di atas
11. Kesamaan kosinus paling populer digunakan dalam
1. Klasifikasi teks
 2. Klasifikasi gambar
 3. Pemilihan fitur
 4. Tidak ada yang di atas
12. Pendekatan ini cukup mirip dengan pendekatan wrapper karena juga menggunakan algoritma induktif untuk mengevaluasi subset fitur yang dihasilkan.
1. Pendekatan tertanam
 2. Pendekatan filter
 3. Pendekatan Pro Wrapper
 4. Pendekatan hibrida

13. Dalam pendekatan ____, identifikasi subset fitur terbaik dilakukan menggunakan algoritma induksi sebagai kotak hitam.
1. Tertanam
 2. Menyaring
 3. Pembungkus
 4. Hibrida

SOAL JAWABAN SINGKAT (SOAL 5 NILAI)

1. Apa itu fitur? Jelaskan dengan contoh.
2. Apa saja situasi berbeda yang memerlukan konstruksi fitur?
3. Jelaskan proses pengkodean variabel nominal.
4. Jelaskan proses transformasi fitur numerik menjadi fitur kategoris.
5. Jelaskan pendekatan wrapper dalam pemilihan fitur. Apa kelebihan dan kekurangan pendekatan ini?
6. Kapan suatu fitur dapat disebut tidak relevan? Bagaimana fitur tersebut dapat diukur?
7. Kapan suatu fitur dapat disebut redundan? Apa saja ukuran untuk menentukan fitur yang berpotensi redundan?
8. Apa saja ukuran jarak yang dapat digunakan untuk menentukan kesamaan fitur?
9. Bandingkan jarak Euclidean dengan jarak Manhattan?
10. Bedakan transformasi fitur dengan pemilihan fitur
11. Tulis catatan singkat tentang dua hal berikut:
 1. Bahasa Indonesia: SVD
 2. Metode hibrida pemilihan fitur
 3. Lebar siluet

4. Kurva ROC

SOAL JAWABAN PANJANG (SOAL 10 NILAI)

1. Apa itu rekayasa fitur? Jelaskan secara rinci berbagai aspek rekayasa fitur?
2. Apa itu pemilihan fitur? Mengapa itu diperlukan? Apa saja pendekatan pemilihan fitur yang berbeda?
3. Jelaskan pendekatan filter dan wrapper dalam pemilihan fitur. Apa kelebihan dan kekurangan pendekatan ini?
4.
 1. Jelaskan proses keseluruhan pemilihan fitur
 2. Jelaskan, dengan sebuah contoh, konsep dasar utama ekstraksi fitur. Apa saja algoritma yang paling populer untuk ekstraksi fitur?
5. Jelaskan proses rekayasa fitur dalam konteks masalah kategorisasi teks.
6. Mengapa kesamaan kosinus merupakan ukuran yang tepat dalam konteks kategorisasi teks? Dua baris dalam matriks istilah dokumen memiliki nilai - (2, 3, 2, 0, 2, 3, 3, 0, 1) dan (2, 1, 0, 0, 3, 2, 1, 3, 1). Temukan kesamaan kosinusnya.
7.
 1. Bagaimana cara menghitung jarak Hamming? Cari jarak Hamming antara 10001011 dan 11001111.
 2. Bandingkan indeks Jaccard dan koefisien pencocokan kesamaan dua fitur yang memiliki nilai (1, 1, 0, 0, 1, 0, 1, 1) dan (1, 0, 0, 1, 1, 0, 0, 1).
8. Apa yang Anda pahami dengan kumpulan data berdimensi tinggi? Berikan beberapa contoh praktis? Apa tantangan saat menerapkan teknik pembelajaran mesin pada

kumpulan data berdimensi tinggi? Bagaimana hal itu dapat diatasi?

9.
 1. Tulis catatan singkat tentang dua hal berikut:
 1. PCA
 2. Vektorisasi
 3. Metode tertanam
 2. Tuliskan perbedaan antara (dua hal):
 1. Pemilihan maju berurutan vs. eliminasi mundur berurutan
 2. Metode pemilihan fitur filter vs. wrapper
 3. Koefisien Jaccard vs. SMC

Bab 5 Tinjauan Singkat tentang Probabilitas

Oktavia, S.Si., M.Si

A. Tujuan Pembelajaran

Prinsip-prinsip pembelajaran mesin sebagian besar bergantung pada penanganan ketidakpastian dalam data secara efektif dan prediksi hasil berdasarkan data yang ada. Semua proses pembelajaran yang akan kita bahas di bab-bab selanjutnya dari buku ini mengharapkan pembaca untuk memahami aturan dasar probabilitas, konsep variabel acak dan kontinu, distribusi, dan prinsip-prinsip pengambilan sampel, serta beberapa prinsip dasar seperti teorema limit pusat, pengujian hipotesis, dan perkiraan Monte Carlo. Karena aturan, teorema, dan prinsip-prinsip ini membentuk dasar prinsip-prinsip pembelajaran, kita akan membahasnya dalam bab ini dengan contoh dan ilustrasi.

5.1 PENDAHULUAN

Seperti yang telah kita bahas di bab-bab sebelumnya, pembelajaran mesin menyediakan serangkaian metode yang dapat secara otomatis mendeteksi pola dalam data, dan kemudian dapat digunakan untuk mengungkap pola guna memprediksi data masa depan, atau untuk melakukan jenis pengambilan keputusan lain dalam ketidakpastian. Cara terbaik untuk melakukan aktivitas tersebut di atas kumpulan data besar yang dikenal sebagai big data adalah dengan menggunakan alat teori

probabilitas karena teori probabilitas dapat diterapkan pada situasi apa pun yang melibatkan ketidakpastian. Dalam pembelajaran mesin mungkin ada ketidakpastian dalam berbagai bentuk seperti mencapai prediksi terbaik masa depan berdasarkan data masa lalu, mencapai model terbaik berdasarkan data tertentu, mencapai tingkat keyakinan saat memprediksi hasil masa depan berdasarkan data masa lalu, dll. Pendekatan probabilistik yang digunakan dalam pembelajaran mesin terkait erat dengan bidang statistik, tetapi penekanannya ada pada arah yang berbeda seperti yang kita lihat dalam bab ini. Dalam bab ini kita akan membahas alat, persamaan, dan model probabilitas yang berguna untuk domain pembelajaran mesin.

5.2 PENTINGNYA ALAT STATISTIK DALAM PEMBELAJARAN MESIN

Dalam pembelajaran mesin, kami melatih sistem dengan menggunakan kumpulan data terbatas yang disebut 'data pelatihan' dan berdasarkan tingkat keyakinan data pelatihan, kami berharap algoritme pembelajaran mesin menggambarkan perilaku kumpulan data aktual yang lebih besar. Jika kami melakukan pengamatan pada sebagian kecil kejadian, yang disebut 'sampel', maka akan ada ketidakpastian dalam menghubungkan hasil sampel dengan keseluruhan kumpulan atau populasi. Jadi, pertanyaannya adalah bagaimana pengetahuan terbatas tentang kumpulan sampel dapat digunakan untuk memprediksi perilaku kumpulan nyata dengan keyakinan tertentu. Para matematikawan menyadari bahwa meskipun beberapa pengetahuan didasarkan pada sampel, jika kita mengetahui jumlah ketidakpastian yang terkait

dengannya, maka pengetahuan tersebut dapat digunakan secara optimal tanpa menyebabkan hilangnya pengetahuan. Lihat Gambar 5.1



GAMBAR 5.1 Pengetahuan dan ketidakpastian

Teori probabilitas menyediakan landasan matematika untuk mengukur ketidakpastian pengetahuan ini. Karena pengetahuan tentang data pelatihan hadir dalam bentuk set fitur yang saling bergantung, teori probabilitas bersyarat (terutama teorema Bayes), yang dibahas kemudian dalam bab ini, membentuk dasar untuk memperoleh tingkat keyakinan yang diperlukan dari data pelatihan.

Berbagai prinsip distribusi yang dibahas dalam bab ini menciptakan pandangan tentang bagaimana kumpulan data yang akan kita hadapi dalam pembelajaran mesin dapat berperilaku, dalam hal distribusi fiturnya. Penting untuk memahami fungsi matematika di balik setiap distribusi ini sehingga kita dapat memahami bagaimana data disebarkan dari nilai rata-ratanya – dilambangkan dengan mean dan varians. Saat memilih sampel dari set distribusi ini, kita harus dapat menghitung sejauh mana sampel tersebut mewakili perilaku sebenarnya dari set data lengkap. Ini bersama dengan prinsip pengujian hipotesis membangun dasar untuk menemukan ketidakpastian dalam set data pelatihan untuk mewakili set data aktual yang merupakan prinsip dasar pembelajaran mesin.

5.3 KONSEP PROBABILITAS – INTERPRETASI FREKUENTIS DAN BAYESIAN

Konsep probabilitas bukanlah hal baru. Dalam kehidupan sehari-hari, kita menggunakan konsep probabilitas di banyak tempat. Misalnya, ketika kita berbicara tentang probabilitas mendapatkan sisi kepala dan sisi ekor ketika koin dilempar adalah sama, kita sebenarnya bermaksud mengatakan bahwa jika koin dilempar berkali-kali, koin akan mendarat di sisi kepala sebanyak jumlah sisi ekornya. Ini adalah interpretasi frekuentis dari probabilitas. Interpretasi ini menggambarkan frekuensi jangka panjang dari suatu kejadian. Interpretasi penting lainnya dari probabilitas mencoba mengukur ketidakpastian dari suatu kejadian dan dengan demikian berfokus pada informasi daripada percobaan yang berulang. Ini disebut interpretasi Bayesian dari probabilitas. Mengambil contoh yang sama dari lemparan koin ditafsirkan sebagai – koin tersebut sama-sama mungkin mendarat di sisi kepala atau sisi ekor ketika kita melempar koin berikutnya.

Alasan interpretasi Bayesian dapat digunakan untuk memodelkan ketidakpastian peristiwa adalah karena interpretasi tersebut tidak mengharapkan frekuensi jangka panjang dari peristiwa tersebut terjadi. Misalnya, jika kita harus menghitung probabilitas Brasil memenangkan final Piala Dunia 2018, peristiwa tersebut hanya dapat terjadi satu kali dan tidak dapat diulang terus-menerus untuk menghitung probabilitasnya. Namun, kita tetap harus dapat mengukur ketidakpastian tentang peristiwa tersebut dan hal ini hanya mungkin terjadi jika kita menginterpretasikan probabilitas dengan cara Bayesian. Untuk memberikan beberapa contoh yang lebih berorientasi pada pembelajaran mesin, kita memulai proyek implementasi perangkat lunak baru untuk

pelanggan besar dan ingin menghitung probabilitas proyek ini masuk ke eskalasi pelanggan berdasarkan data dari proyek serupa di masa lalu, atau kita ingin menghitung probabilitas tumor menjadi ganas atau tidak berdasarkan distribusi probabilitas kasus tersebut di antara pasien dengan profil yang sama. Dalam semua kasus ini, tidak mungkin untuk melakukan uji coba berulang terhadap peristiwa tersebut dan konsep Bayesian berlaku untuk menghitung ketidakpastian. Jadi, dalam buku ini, kita akan fokus pada interpretasi Bayesian untuk mengembangkan model pembelajaran mesin kita. Rumus dasar probabilitas tetap sama, apa pun interpretasi yang kita ambil.

5.3.1 Tinjauan singkat tentang teori probabilitas

Kami akan membahas teori probabilitas dasar secara singkat di bagian ini sebagai penyegaran agar kita dapat beralih ke dasar-dasar cara penggunaan probabilitas dalam pembelajaran mesin. Seperti yang dibahas dalam bab-bab sebelumnya, konsep dasar pembelajaran mesin adalah kita ingin memiliki sekumpulan data 'Pelatihan' terbatas yang kita gunakan sebagai representasi dari sekumpulan besar data Aktual dan melalui distribusi probabilitas kita mencoba mencari tahu bagaimana suatu kejadian yang cocok dengan data pelatihan dapat merepresentasikan hasil dengan keyakinan tertentu.

5.3.1.1 Aturan dasar

Kami akan mengulas aturan dasar probabilitas di bagian ini. Mari kita perkenalkan beberapa notasi yang akan digunakan di seluruh buku ini. $P(A)$ menunjukkan probabilitas bahwa peristiwa A benar. Untuk Misalnya,

A mungkin adalah pernyataan logis 'Brazil akan memenangkan final piala dunia sepak bola berikutnya'. Ekspresi $0 \leq p(A) \leq 1$ menunjukkan bahwa probabilitas terjadinya peristiwa ini berada di antara 0 dan 1, di mana $p(A) = 0$ berarti peristiwa itu pasti tidak akan terjadi, dan $p(A) = 1$ berarti peristiwa itu pasti akan terjadi. Notasi $p(\bar{A})$ menunjukkan probabilitas peristiwa bukan A; ini didefinisikan sebagai $p(\bar{A}) = 1 - p(A)$. Ini juga merupakan praktik umum untuk menulis $A = 1$ yang berarti peristiwa A benar, dan $A = 0$ yang berarti peristiwa A salah. Jadi, ini adalah peristiwa biner di mana peristiwa itu benar atau salah tetapi tidak bisa menjadi sesuatu yang tidak pasti.

Peluang memilih suatu kejadian A dari sampel berukuran X didefinisikan sebagai

$P(\text{SEBUAH}) = \frac{n}{X}$, di mana n adalah jumlah kali kejadian A muncul dalam sampel berukuran X.

5.3.1.2 Peluang gabungan dua kejadian

Dua kejadian A dan B disebut saling eksklusif jika keduanya tidak dapat terjadi bersamaan. Misalnya, kemenangan Inggris di Piala Dunia 2018 dan kemenangan Brasil di Piala Dunia 2018 adalah dua kejadian yang saling eksklusif dan tidak dapat terjadi bersamaan. Untuk dua kejadian apa pun, A dan B, kita mendefinisikan peluang A atau B sebagai

$$p(A \cup B) = p(A) + p(B) - p(A \cap B) \quad (5.1)$$

$$= p(A) + p(B), \text{ if A and B are mutually exclusive} \quad (5.2)$$

5.3.1.3 Probabilitas gabungan

Peluang kejadian gabungan A dan B didefinisikan sebagai aturan perkalian:

$$p(A, B) = p(A \cap B) = p(A|B) \cdot p(B) \quad (5.3)$$

di mana $p(A|B)$ didefinisikan sebagai probabilitas bersyarat Peristiwa A terjadi jika peristiwa B terjadi. Berdasarkan distribusi gabungan pada dua peristiwa $p(A, B)$, kita dapat mendefinisikan distribusi marginal sebagai berikut:

$$p(A) = \sum_b p(A, B) = \sum_b p(A|B = b)p(B = b) \quad (5.4)$$

menjumlahkan semua kemungkinan keadaan B memberikan total rumus probabilitas, yang juga disebut aturan penjumlahan atau aturan probabilitas total.

Dengan cara yang sama, $p(B)$ dapat didefinisikan sebagai

$$p(B) = \sum_a p(A, B) = \sum_a p(B|A = a)p(A = a) \quad (5.5)$$

Rumus ini dapat diperluas untuk jumlah kejadian yang tak terhingga dalam himpunan dan aturan rantai probabilitas dapat diturunkan jika aturan produk diterapkan beberapa kali.

$$p(X_{1:N}) = p(X_1)p(X_2|X_1)p(X_3|X_2, X_1) \\ p(X_4|X_1, X_2, X_3) \dots p(X_N|X_{1:N-1}) \quad (5.6)$$

5.3.1.4 Probabilitas bersyarat

Kita mendefinisikan probabilitas bersyarat dari peristiwa A, jika peristiwa B benar, sebagai berikut:

$$p(A|B) = p(A, B)/p(B), \text{ if } p(B) > 0 \quad (5.7)$$

di mana, $p(A, B)$ adalah probabilitas gabungan A dan B dan dapat juga dapat dilambangkan sebagai $p(A \cap B)$

Demikian pula,

$$p(B|A) = p(B, A)/p(A), \text{ if } p(A) > 0 \quad (5.8)$$

Ilustrasi. Di sebuah toko mainan, mesin otomatis memproduksi beberapa potong mainan yang cacat. Dari 1.000 potong mainan, 25 potong cacat. Jika dua sampel acak dipilih untuk pengujian tanpa penggantian (yang berarti sampel pertama tidak dikembalikan ke lot dan dengan demikian sampel kedua dipilih dari ukuran lot 999), hitunglah peluang bahwa kedua sampel tersebut cacat.

Larutan: Misalkan A menunjukkan probabilitas bagian pertama rusak dan B menunjukkan bagian kedua rusak. Di sini, kita harus menggunakan probabilitas bersyarat bagian kedua ditemukan rusak ketika bagian pertama sudah ditemukan rusak.

Berdasarkan hukum probabilitas, $p(A) = \frac{25}{1000} = 0.025$

Karena kami memilih sampel kedua tanpa mengganti sampel pertama ke dalam lot dan sampel pertama sudah ditemukan rusak, maka sekarang ada 24 buah rusak dari 999 buah yang tersisa dalam lot.

$$\text{Thus} \quad p(B|A) = \frac{24}{999} = 0.024$$

$$\begin{aligned} \text{As} \quad p(A, B) &= p(A \cap B) = p(B|A)p(A) \\ &= 0.025 \times 0.024 \\ &= 0.006006 \end{aligned}$$

yang merupakan probabilitas kedua bagian ditemukan rusak.

5.3.1.5 Aturan Bayes

Aturan Bayes, juga dikenal sebagai Teorema Bayes, dapat diturunkan dengan menggabungkan definisi probabilitas bersyarat dengan aturan produk dan jumlah, seperti di bawah ini:

$$p(A|B) = \frac{p(B|A)p(A)}{p(B)} \quad (5.9)$$

$$\begin{aligned}
 p(A = a|B = b) &= \frac{p(A = a, B = b)}{p(B = b)} \\
 &= \frac{p(A = a)p(B = b|A = a)}{\sum_a p(A = a)p(B = b|A = a)} \quad (5.10)
 \end{aligned}$$

Ilustrasi: Menandai email sebagai spam berdasarkan nama pengirim email

Mari kita ambil contoh untuk mengidentifikasi kemungkinan email benar-benar spam berdasarkan nama pengirimnya. Kami sering menerima email dari id email yang berisi karakter atau kata sampah seperti massal, massal, dsb. yang ternyata merupakan email spam. Jadi, kami ingin agen pembelajaran mesin kami menandai email spam tersebut agar kami dapat menghapusnya dengan mudah.

Mari kita asumsikan juga bahwa kita memiliki pengetahuan tentang keandalan asumsi bahwa email dengan nama pengirim 'mass' dan 'bulk' adalah email spam sebesar 80% yang berarti bahwa jika beberapa email memiliki nama pengirim dengan 'mass' atau 'bulk' maka email tersebut akan menjadi spam dengan probabilitas 0,8. Probabilitas alarm palsu adalah 10% yang berarti bahwa agen akan menunjukkan hasil positif sebagai spam meskipun email tersebut bukan spam dengan probabilitas 0,1. Selain itu, kita memiliki pengetahuan sebelumnya bahwa hanya 0,4% dari total email yang diterima adalah spam.

Larutan:

Misalkan x adalah kejadian di mana bendera ditetapkan sebagai spam karena nama pengirimnya mengandung kata 'massal' atau 'bulk' dan y adalah kejadian di mana beberapa email benar-benar merupakan spam.

Jadi, $p(x = 1|y = 1) = 0,8$, yang merupakan probabilitas bendera menjadi positif jika email tersebut adalah spam.

Seringkali probabilitas ini disalahartikan sebagai probabilitas email sebagai spam jika benderanya positif. Namun itu tidak benar, karena kita akan mengabaikan pengetahuan sebelumnya bahwa hanya 0,4% email yang benar-benar spam dan juga dapat terjadi alarm palsu dalam 10% kasus.

Jadi, $p(y = 1) = 0,004$ dan $p(y = 0) = 1 - p(y = 1) = 0,996$

$$P(x = 1 \mid y = 0) = 0,1$$

Dengan menggabungkan istilah-istilah ini menggunakan aturan Bayes, kita dapat menghitung jawaban yang benar sebagai berikut:

$$\begin{aligned} p(y = 1 \mid x = 1) &= \frac{p(x = 1 \mid y = 1)p(y = 1)}{p(x = 1 \mid y = 1)p(y = 1) + p(x = 1 \mid y = 0)p(y = 0)} \\ &= \frac{0.8 \times 0.004}{0.8 \times 0.004 + 0.1 \times 0.996} \\ &= 0.031 \end{aligned}$$

Artinya, jika kita gabungkan pengetahuan kita sebelumnya dengan hasil pengujian yang sebenarnya, maka hanya ada sekitar 3% kemungkinan email benar-benar menjadi spam jika nama pengirimnya mengandung istilah 'bulk' atau 'mass'. Ini jauh lebih rendah daripada asumsi sebelumnya yaitu 80% kemungkinan dan karenanya memerlukan pemeriksaan tambahan sebelum seseorang mulai menghapus email tersebut hanya berdasarkan tanda ini.

Rincian penerapan praktik teorema Bayes dalam pembelajaran mesin dibahas di Bab 6.

5.4 VARIABEL ACAK

Mari kita ambil contoh melempar koin sekali. Kita dapat mengaitkan variabel acak X dan Y sebagai $X(H) = 1, X(T) = 0$, yang berarti variabel ini berhubungan dengan hasil koin yang menghadap kepala.

$kamu(H) = 0, Y(T) = 1$, yang berarti variabel ini berhubungan dengan hasil koin yang menghadap sisi ekor.

Di sini, dalam ruang sampel S yang merupakan hasil yang terkait dengan pelemparan koin satu kali, variabel acak mewakili fungsi riil bernilai tunggal $[X(\zeta)]$ yang menetapkan bilangan riil, yang disebut nilainya, untuk setiap titik sampel S . Variabel acak bukanlah variabel tetapi merupakan fungsi. Ruang sampel S disebut domain variabel acak X dan kumpulan semua bilangan, yaitu nilai $X(\zeta)$, disebut rentang variabel acak.

Kita dapat mendefinisikan peristiwa ($X = x$) di mana x adalah bilangan riil tetap sebagai nilai x dan x +nya

Dengan demikian, kita dapat mendefinisikan kejadian-kejadian berikut untuk bilangan-bilangan tetap x, x_1 , dan x_2 :

$$(X \leq x) = \{ \zeta : X(\zeta) \leq x \}$$

$$\text{Contoh soal: } (X > x) = \{ \zeta : X(\zeta) > x \}$$

$$(x_1 < X \leq x_2) = \{ \zeta : x_1 < X(\zeta) \leq x_2 \}$$

Peluang kejadian-kejadian tersebut dilambangkan dengan P Tentukan nilai x dan x +nya

$$P(X \leq x) = P\{ \zeta : X(\zeta) \leq x \}$$

P Tentukan nilai x dan x +nya

$$P(x_1 < X \leq x_2) = P\{ \zeta : x_1 < X(\zeta) \leq x_2 \}$$

Kita akan menggunakan istilah cdf dalam buku ini untuk menunjukkan fungsi distribusi atau fungsi distribusi kumulatif, yang mengambil bentuk variabel acak X sebagai ;

Efek Tentukan nilai $x = P(x \leq x) - \infty < x < \infty$

Beberapa sifat penting dari $F_X(x)$ adalah

$$0 \leq F_X(x) \leq 1$$

$$F_X(x_1) \leq F_X(x_2) \quad \text{if } x_1 < x_2$$

$$\lim_{x \rightarrow \infty} F_X(x) = F_X(\infty) = 1$$

$$\lim_{x \rightarrow -\infty} F_X(x) = F_X(-\infty) = 0$$

5.4.1 Variabel acak diskrit

Mari kita perluas konsep kejadian biner dengan mendefinisikan variabel acak diskrit X . Misalkan X adalah variabel acak dengan cdf $F_X(x)$ dan ia hanya mengubah nilai dalam lompatan (jumlahnya dapat dihitung) dan tetap konstan di antara lompatan, maka ia disebut variabel acak diskrit. Jadi, definisi variabel acak diskrit adalah bahwa rentangnya atau himpunan X berisi jumlah titik yang terbatas atau tak terbatas.


Mari kita perhatikan bahwa lompatan $F_X(x)$ dari variabel acak diskrit X terjadi pada titik $x_1, x_2, x_3, \dots$, dimana deret ini merepresentasikan himpunan berhingga atau tak terhingga dan $x_i < x_j$ jika $i < j$. Lihat [Gambar 5.2](#).

$$\text{Then } F_X(x_i) - F_X(x_{i-1}) = P(X \leq x_i) - P(X \leq x_{i-1}) = P(X = x_i) \quad (5.11)$$

Kita dapat menyatakannya melalui notasi sebagai

$$p(x) = p(X = x) \quad (5.12)$$

Peluang kejadian $X = x$ dilambangkan dengan $p(X = x)$, atau singkatnya $p(x)$. p disebut fungsi massa probabilitas (pmf).



GAMBAR 5.2 Suatu variabel acak diskrit X dengan cdf $F_X(x) = P(X \leq x)$ untuk $x = 0, 1, 2, 3, 4$, dan $F_X(x)$ mempunyai lonjakan pada $x = 0, 1, 2, 3, 4$. Hal ini memenuhi sifat $0 \leq p(x) \leq 1$ dan $\sum_{x \in X} p(x) = 1$.

Fungsi distribusi kumulatif (cdf) $F_X(x)$ dari variabel acak diskrit X dapat dilambangkan sebagai

$$F_X(x) = P(X \leq x) = \sum_{x \in X} p(x) \quad (5.13)$$

Mengacu pada Gambar 5.3, pmf didefinisikan pada ruang keadaan hingga $X = \{1, 2, 3, 4\}$ yang menunjukkan distribusi seragam dengan $p(x) = \frac{1}{4}$. Distribusi ini berarti bahwa X selalu sama dengan nilai $\frac{1}{4}$, dengan kata lain, itu adalah suatu konstanta.

Contoh Misalkan X adalah variabel acak diskrit dengan


$X \in \{0, 1, 2, \dots\}$. kita dapat membuktikan $EX = \sum_{k=0}^{\infty} P(X > k)$.

Dari persamaan di atas,

$$\begin{aligned} P(X > 0) &= P(X=1) + P(X=2) + P(X=3) + P(X=4) + \dots, \\ P(X > 1) &= P(X=2) + P(X=3) + P(X=4) + \dots, \\ P(X > 2) &= P(X=3) + P(X=4) + P(X=5) + \dots \end{aligned}$$

Dengan demikian,

$$\begin{aligned}\sum_{k=0}^{\infty} P(X > k) &= P(X > 0) + P(X > 1) + P(X > 2) + \dots \\ &= P_X(1) + 2P_X(2) + 3P_X(3) + 4P_X(4) + \dots \\ &= EX\end{aligned}$$



GAMBAR 5.3 Distribusi seragam dalam himpunan $\{1, 2, 3, 4\}$ di mana $p(x = k) = \frac{1}{2}$

5.4.2 Variabel acak kontinyu

Kita telah membahas probabilitas kuantitas diskrit yang tidak pasti. Namun, sebagian besar kejadian dalam kehidupan nyata bersifat kontinu. Misalnya, jika kita harus mengukur waktu aktual yang dibutuhkan untuk

menyelesaikan suatu aktivitas, maka ada kemungkinan cara yang tak terbatas untuk menyelesaikan aktivitas tersebut. Dengan demikian, pengukurannya bersifat kontinu dan tidak diskrit karena tidak mirip dengan kejadian diskrit melempar dadu atau melempar koin. Di sini, fungsi $F_X(x)$ yang menggambarkan kejadian tersebut bersifat kontinu dan juga memiliki turunan. $\frac{dF_X(x)}{dx}$ yang ada dan berkesinambungan sepotong demi sepotong.

Fungsi kepadatan probabilitas (pdf) dari variabel acak kontinu x didefinisikan sebagai

$$f_X(x) = \frac{dF_X(x)}{dx}$$

Sekarang kita akan melihat cara memperluas probabilitas untuk menalar tentang kuantitas kontinu yang tidak pasti. Probabilitas bahwa x terletak pada interval $a \leq x \leq b$ dapat dihitung sebagai berikut.

Kita dapat mendefinisikan peristiwa $A = (x \leq a)$, $B = (x \leq b)$, dan $W = (a < x \leq b)$. Kita memperoleh bahwa $B = A \cup W$, dan karena A dan W saling eksklusif, menurut aturan penjumlahan:

$$p(B) = p(A) + p(W) \quad (5.14)$$

dan karenanya,

$$p(W) = p(B) - p(A) \quad (5.15)$$

Tentukan fungsi $F(q) = p(X \leq q)$. Fungsi distribusi kumulatif (cdf) dari variabel acak X dapat diperoleh dengan:

$$F_X(x) = p(X \leq x) = \int_{-\infty}^x f(x) dx$$

yang merupakan fungsi yang meningkat secara monoton. Dengan menggunakan ini notasi, kita punya

$$p(a < X \leq b) = F(b) - F(a) \quad (5.16)$$

menggunakan pdf x , kita dapat menghitung probabilitas variabel kontinu berada dalam interval terbatas sebagai berikut:

$$p(a < X \leq b) = \int_a^b f(x) dx \quad (5.17)$$

Ketika ukuran interval semakin kecil, maka kita dapat menulis

$$P(x \leq X \leq x + dx) \approx p(x) dx \quad (5.18)$$

5.4.2.1 Rata-rata dan varians

Rata-rata dalam istilah statistik merupakan rata-rata tertimbang (sering disebut sebagai nilai yang diharapkan) dari semua nilai yang mungkin dari variabel acak X dan setiap nilai ditimbang berdasarkan probabilitasnya. Nilai ini dilambangkan dengan μ_x atau $E(X)$ dan didefinisikan sebagai

$$\mu_x = E(X) = \sum_k x_k p_x(x_k) \text{ when } X \text{ is discrete} \quad (5.19)$$

$$\mu_x = E(X) = \int_{-\infty}^{\infty} x f_x(x) dx \text{ when } X \text{ is continuous} \quad (5.20)$$

mean adalah salah satu parameter penting untuk probabilitas distribusi.

Varians dari variabel acak X mengukur penyebaran atau dispersi X . Jika $E(X)$ adalah mean dari variabel acak X , maka varians diberikan oleh

$$\sigma_x^2 = \text{Var}(X) = E\{[X - E(X)]^2\} \quad (5.21)$$

$$\text{so, } \sigma_x^2 = \sum_k (x_k - \mu_x)^2 p_x(x_k) \text{ when } X \text{ is discrete} \quad (5.22)$$

$$\sigma_x^2 = \int_{-\infty}^{\infty} (x - \mu_x)^2 f_x(x) dx \text{ when } X \text{ is continuous} \quad (5.23)$$

5.5 BEBERAPA DISTRIBUSI DISKRET YANG UMUM

Pada bagian ini, kita akan membahas beberapa distribusi parametrik yang umum digunakan dan didefinisikan pada ruang keadaan diskrit, baik yang terhitung maupun yang tak terhitung.

5.5.1 Distribusi Bernoulli

Bila kita memiliki situasi di mana hasil dari suatu percobaan adalah 'berhasil' atau 'gagal', maka perilaku variabel acak X dapat direpresentasikan oleh distribusi Bernoulli. Percobaan atau eksperimen semacam itu disebut sebagai percobaan Bernoulli.

Jadi kita dapat menyimpulkan bahwa, suatu variabel acak X disebut variabel acak Bernoulli dengan parameter p ketika pmf-nya berbentuk

Tentukan nilai $k = P(X = k)$

$$k = 0, 1 \quad (5.24)$$

Dimana $0 \leq p \leq 1$. Jadi, dengan menggunakan cdf $F_X(x)$ variabel acak Bernoulli dinyatakan sebagai

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1 - p & 0 \leq x < 1 \\ 1 & X \geq 1 \end{cases} \quad (5.25)$$

Rata-rata dan varians variabel acak Bernoulli X adalah

$$\begin{aligned} \mu &= E(X) = p \\ \sigma^2 &= \text{Var}(X) = p(1 - p) \end{aligned}$$

di sini, kemungkinan keberhasilan adalah p dan kemungkinan kegagalan adalah $1 - p$. Ini jelas hanya kasus khusus dari distribusi Binomial dengan $n = 1$ seperti yang akan kita bahas di bawah ini.

5.5.2 Distribusi Binomial

Jika n percobaan Bernoulli yang independen dilakukan dan X merupakan jumlah keberhasilan dalam n percobaan tersebut, maka X disebut variabel acak binomial. Itulah sebabnya variabel acak Bernoulli merupakan kasus khusus dari variabel acak binomial dengan parameter $(1, p)$.

PMF dari X dengan parameter (n, p) diberikan oleh

$$P_x(k) = P(X = k) = \binom{n}{k} p^k (1-p)^{n-k} \quad k = 0, 1, \dots, n \quad (5.26)$$

Dimana, $0 \leq p \leq 1$ dan

$\binom{n}{k} = \frac{n!}{k!(n-k)!}$ juga disebut koefisien binomial yang merupakan jumlah cara memilih k item dari n .

Misalnya, jika kita melempar koin sebanyak n kali. Misalkan $X \in \{0, \dots, n\}$ adalah jumlah sisi kepala. Jika probabilitas sisi kepala adalah p , maka kita katakan X memiliki distribusi binomial, yang ditulis sebagai $X \sim \text{Bin}(n, p)$.

cdf yang sesuai dari x adalah


$$F_x = \sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} \quad n \leq x \leq n+1 \quad (5.27)$$

Distribusi ini memiliki mean dan varians sebagai berikut:

$$\mu = E(X) = np \quad (5.28)$$

$$\sigma^2 = \text{Var}(X) = np(1-p) \quad (5.29)$$

Gambar 5.4 menunjukkan distribusi binomial $n = 6$ dan $p = 0,6$



GAMBAR 5.4 Distribusi binomial $n = 6$ dan $p = 0,6$

5.5.3 Distribusi multinomial dan multinoulli

Distribusi binomial dapat digunakan untuk memodelkan hasil lemparan koin, atau untuk eksperimen yang hasilnya bisa berhasil atau gagal. Namun, untuk memodelkan hasil lemparan dadu bersisi K , atau untuk eksperimen yang hasilnya bisa berganda, kita dapat menggunakan distribusi multinomial. Ini didefinisikan sebagai: misalkan $x = (x_1, \dots, x_K)$ adalah vektor acak, di mana x_j adalah berapa kali sisi j dadu muncul. Maka x memiliki pmf berikut:

$$(p_1 + p_2 + \dots + p_K)^n = \sum_{x_1, x_2, \dots, x_K} \binom{n}{x_1, x_2, \dots, x_K} p_1^{x_1} p_2^{x_2} \dots p_K^{x_K} \quad (5.30)$$

di mana, $x_1 + x_2 + \dots + x_K = n$ dan koefisien multinomial didefinisikan sebagai

$$\binom{n}{x_1 x_2 \dots x_k} = \frac{n!}{x_1! x_2! \dots x_k!} \quad (5.31)$$

dan penjumlahannya adalah atas himpunan semua non-negatif bilangan bulat $x_1, x_2, \dots, x_k$ yang jumlahnya n .

Sekarang perhatikan kasus khusus $n = 1$, yang seperti melempar dadu bersisi K sekali, jadi x akan menjadi vektor 0 dan 1 (vektor bit), yang hanya dapat mengaktifkan satu bit. Ini berarti, jika dadu menunjukkan sisi k , maka bit ke- k akan aktif. Kita dapat menganggap x sebagai variabel acak kategoris skalar dengan status atau nilai K , dan x adalah penyandian tiruannya dengan $x = [\prod (x = 1), \dots, \prod (x = K)]$.

Misalnya, jika $K = 3$, ini menyatakan bahwa 1, 2, dan 3 dapat dikodekan sebagai (1, 0, 0), (0, 1, 0), dan (0, 0, 1). Ini juga disebut pengodean one-hot, karena kita mengartikan bahwa hanya satu dari K 'kabel' yang 'hot' atau aktif. Kasus khusus yang sangat umum ini dikenal sebagai distribusi kategoris atau diskret dan karena analogi dengan perbedaan Binomial/Bernoulli, Gustavo Lacerda menyarankan bahwa ini disebut distribusi multinoulli.

5.5.4 Distribusi Poisson

Variabel acak Poisson memiliki rentang aplikasi yang luas karena dapat digunakan sebagai perkiraan untuk binomial dengan parameter (n, p) ketika n besar dan p kecil sehingga np berukuran sedang. Contoh area aplikasinya adalah, jika mesin faks memiliki saluran transmisi yang rusak, maka probabilitas menerima digit yang salah dalam halaman tertentu yang dikirimkan dapat dihitung menggunakan variabel acak Poisson.


Jadi, variabel acak X disebut variabel acak Poisson dengan parameter λ (>0) ketika pmf terlihat seperti

$$p_x(k) = P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!} \text{ where } k = 0, 1, \dots \quad (5.32)$$

cdf diberikan sebagai:

$$F_x(x) = e^{-\lambda} \sum_{k=0}^n \frac{\lambda^k}{k!} \quad n \leq x \leq n+1 \quad (5.33)$$

Gambar 5.5 menunjukkan distribusi Poisson dengan $\lambda = 2$



GAMBAR 5.5Distribusi Poisson dengan $\lambda = 2$

5.6 BEBERAPA DISTRIBUSI BERKESINAMBUNGAN YANG UMUM

Pada bagian ini kami menyajikan beberapa distribusi probabilitas kontinu univariat (satu dimensi) yang umum digunakan.

5.6.1 Distribusi seragam


Pdf dari variabel acak seragam diberikan oleh:

$$F_x(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{Otherwise} \end{cases} \quad (5.34)$$

Dan cdf dari X adalah:

$$F_x(x) = \begin{cases} 0 & X \leq a \\ \frac{x-a}{b-a} & a < x < b \\ 1 & x \geq b \end{cases} \quad (5.35)$$

Melihat Gambar 5.6 yang mewakili distribusi seragam dengan $a = 3$, $b = 8$ dengan kenaikan 0,5 dan pengulangan 20.



GAMBAR 5.6 Distribusi seragam dengan $a = 3$, $b = 8$ dengan kenaikan 0,5 dan pengulangan 20

Contoh. Jika X adalah variabel acak kontinu dengan $X \sim \text{Uniform}(a, b)$. Temukan $E(X)$. Kita tahu seperti yang persamaan 5.33

$$F_x(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{Otherwise} \end{cases}$$

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty} x F_x(x) dx \\ &= \int_a^b x \left(\frac{1}{b-a} \right) dx \\ \text{So,} \quad &= \frac{1}{b-a} \left[\frac{1}{2} x^2 \right]_a^b = \frac{a+b}{2} \end{aligned}$$

Hal ini juga diperkuat oleh fakta bahwa karena X terdistribusi secara seragam pada interval $[a, b]$, kita dapat memperkirakan rata-rata berada di titik tengah, $E(X) = \frac{a+b}{2}$

Rata-rata dan varians dari variabel acak seragam X adalah

$$\mu = E(X) = \frac{a+b}{2} \quad (5.36)$$

$$\sigma^2 = \text{Var}(X) = \frac{(b-a)^2}{12} \quad (5.37)$$

Ini adalah distribusi yang berguna ketika kita tidak memiliki pengetahuan sebelumnya tentang pdf sebenarnya dan semua nilai kontinu dalam rentang yang sama tampaknya memiliki kemungkinan yang sama.

5.6.2 Distribusi Gaussian (normal)

Distribusi yang paling banyak digunakan dalam statistik dan pembelajaran mesin adalah distribusi Gaussian atau normal. PDF-nya diberikan oleh

$$f_x(x) = \frac{1}{\sqrt{2\pi} \sigma} e^{-(x-\mu)^2/(2\sigma^2)} \quad (5.38)$$

dan cdf yang sesuai terlihat seperti

$$F_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(\xi-\mu)^2}{2\sigma^2}} d\xi = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\frac{(x-\mu)}{\sigma}} e^{-\xi^2/2} d\xi \quad (5.39)$$

Untuk referensi yang lebih mudah, fungsi $\Phi(z)$ didefinisikan sebagai

$$\Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-\xi^2/2} d\xi \quad (5.40)$$


Yang akan membantu kita mengevaluasi nilai $F_X(x)$ yang dapat ditulis sebagai

$$F_X(x) = \Phi\left(\frac{x - \mu}{\sigma}\right) \quad (5.41)$$

Dapat disimpulkan bahwa

$$\Phi(-z) = 1 - \Phi(z)$$

Gambar 5.7 menunjukkan grafik distribusi normal dengan mean = 4, sd = 12.



GAMBAR 5.7 Grafik distribusi normal

Untuk variabel acak normal, mean dan varians adalah

$$\mu_X = E(X) = \mu \quad (5.42)$$

$$\sigma_X^2 = \text{Var}(X) = \sigma^2 \quad (5.43)$$


notasi $N(\mu; \sigma^2)$ digunakan untuk menyatakan bahwa $p(X = x) = N(x | \mu;$

kita²)

Variabel acak normal standar didefinisikan sebagai variabel yang memiliki nilai rata-rata 0 dan varians 1 yang berarti $Z = N(0;1)$. Plot untuk ini terkadang disebut kurva lonceng, (lihat Gambar 5.8)

Distribusi Gaussian atau Normal adalah distribusi yang paling banyak digunakan dalam studi fenomena acak dalam statistik alam karena beberapa alasan:

1. Ia memiliki dua parameter yang mudah ditafsirkan, dan yang menangkap beberapa sifat paling dasar dari suatu distribusi, yaitu rata-rata dan variansnya.
2. Teorema batas pusat (Bagian 5.8) memberikan hasil bahwa jumlah variabel acak independen memiliki distribusi Gaussian yang mendekati, yang menjadikannya pilihan yang baik untuk memodelkan kesalahan residual atau 'noise'.
3. Distribusi Gaussian membuat asumsi paling sedikit, dengan batasan memiliki nilai rata-rata dan varians tertentu, dan dengan demikian merupakan pilihan default yang baik dalam banyak kasus.
4. Bentuk matematikanya yang sederhana mudah diimplementasikan, tetapi seringkali sangat efektif.



GAMBAR 5.8 Grafik distribusi normal standar


5.6.3 Distribusi Laplace

Distribusi lain dengan ekor tebal adalah distribusi Laplace, yang juga dikenal sebagai distribusi eksponensial dua sisi. Distribusi ini memiliki pdf berikut:

$$\text{Lap}(x|\mu, b) = \frac{1}{2b} e^{-\frac{|x-\mu|}{b}} \quad (5.44)$$

Di sini μ adalah parameter lokasi dan $b > 0$ adalah parameter skala.

Gambar 5.9 mewakili distribusi Laplace $(0, \frac{1}{\sqrt{2}})$



Hal ini menempatkan kerapatan probabilitas lebih besar pada 0 daripada Gaussian.

Properti ini adalah cara yang berguna untuk mendorong kelangkaan dalam suatu model.

5.7 BEBERAPA VARIABEL ACAK

Sampai saat ini kita hanya berurusan dengan satu variabel acak dalam ruang sampel, tetapi dalam sebagian besar tujuan praktis terdapat dua atau lebih variabel acak pada ruang sampel yang sama. Kita akan membahas distribusi dan saling ketergantungannya.

5.7.1 Variabel acak bivariat

Mari kita perhatikan dua variabel acak X dan Y dalam ruang sampel S dari suatu eksperimen acak. Maka pasangan (X, Y) disebut variabel acak bivariat atau vektor acak dua dimensi di mana masing-masing X dan Y

dikaitkan dengan bilangan riil untuk setiap elemen S . Ruang rentang variabel acak bivariat (X, Y) dilambangkan dengan R_{xy} dan (X, Y) dapat dianggap sebagai suatu fungsi yang untuk setiap titik ζ di S menetapkan suatu titik (x, y) pada bidang.

$$R_{xy} = \{(x, y); \zeta \in S \text{ and } X(\zeta) = x, Y(\zeta) = y\} \quad (5.45)$$

(X, Y) disebut variabel acak bivariat diskrit jika variabel acak X dan Y keduanya diskrit. Demikian pula, (X, Y) disebut variabel acak bivariat kontinu jika variabel acak X dan Y keduanya kontinu dan disebut variabel acak bivariat campuran jika salah satu dari X dan Y diskrit dan yang lainnya kontinu.

5.7.2 Fungsi distribusi bersama

Fungsi distribusi kumulatif gabungan (atau cdf gabungan) dari X dan Y didefinisikan sebagai:

$$F_{XY}(x, y) = P(X \leq x, Y \leq y) \quad (5.46)$$

Untuk kejadian $(X \leq x, Y \leq y)$, kita dapat mendefinisikan Sebuah $A = \{\zeta \in S; X(\zeta) \leq x\}$ dan $B = \{\zeta \in S; Y(\zeta) \leq y\}$ Dan $P(A) = F_X(x)$ dan $P(B) = F_Y(y)$ Maka, $F_{XY}(x, y) = P(A \cap B)$.

Untuk nilai x dan y tertentu, jika A dan B adalah kejadian S yang saling bebas, maka

$$F_{XY}(x, y) = P(A \cap B) = P(A)P(B) = F_X(x)F_Y(y) \quad (5.47)$$

Beberapa sifat penting dari cdf gabungan dua variabel acak yang mirip dengan cdf variabel acak tunggal adalah

1. $0 \leq F_{XY}(x, y) \leq 1$ Jika $x_1 \leq x_2$ dan $y_1 \leq y_2$, maka

$F_{XY}(x_1, y_1) \leq$ Persamaan

Kuadrat $(x_2, y_1) \leq$ Persamaan

Kuadrat $(x_2, y_2) \leq$ Persamaan

Kuadrat $(x_1, y_1) \leq$ Persamaan

Kuadrat $(x_1, y_2) \leq$ Persamaan

Kuadrat (x_2, y_2)

$$\lim_{\substack{x \rightarrow \infty \\ y \rightarrow \infty}} F_{XY}(x, y) = F_{XY}(\infty, \infty) = 1$$

$$\lim_{x \rightarrow -\infty} F_{XY}(x, y) = F_{XY}(-\infty, y) = 0$$

$$\lim_{y \rightarrow -\infty} F_{XY}(x, y) = F_{XY}(x, -\infty) = 0$$

Rumus untuk persamaan x_1 adalah

$y_2, y_3, y_4, y_5, y_6, y_7, y_8, y_9, y_{10},$

$y_{11}, y_{12}, y_{13}, y_{14}, y_{15}, y_{16}, y_{17},$

$y_{18}, y_{19}, y_{21}, y_{19}, y_{22}, y_{19} \dots$

5.7.3 Fungsi massa probabilitas gabungan

Untuk variabel acak bivariat diskrit (X, Y) jika mengambil nilai (x_i, y_j) untuk bilangan bulat tertentu yang dibolehkan i dan j , maka fungsi massa probabilitas gabungan (pmf gabungan) dari (X, Y) diberikan oleh

$$p_{XY}(x_i, y_j) = P(X = x_i, Y = y_j) \quad (5.48)$$

Beberapa sifat penting dari $p_{XY}(x_i, y_j)$ adalah

$$1. 0 \leq p_{XY}(x_i, y_j) \leq 1$$

$$2. \sum_{x_i} \sum_{y_j} p_{XY}(x_i, y_j) = 1$$

3. Persamaan garis lurus $P[(X,Y) \in A] = \sum (x_i, y_j) \in RA \sum p_{XY}(x_i, y_j)$, di mana penjumlahan dilakukan pada titik-titik (x_i, y_j) dalam ruang rentang RA.

Nilai cdf gabungan dari variabel acak bivariat diskrit (X, Y) diberikan oleh

$$F_{XY}(x, y) = \sum_{x_i \leq x} \sum_{y_j \leq y} p_{XY}(x_i, y_j) \quad (5.49)$$

5.7.4 Fungsi kepadatan probabilitas gabungan

Jika (X, Y) adalah variabel acak bivariat kontinu dengan cdf $F_{XY}(x, y)$ maka fungsinya,

$$f_{XY}(x, y) = \frac{\partial^2 F_{XY}(x, y)}{\partial x \partial y} \quad (5.50)$$

disebut fungsi kepadatan probabilitas gabungan (joint pdf) dari (X, Y) . Jadi, dengan mengintegrasikan, kita memperoleh

$$F_{XY}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{XY}(\zeta, \varepsilon) d\varepsilon d\zeta \quad (5.51)$$

Beberapa sifat penting dari $f_{xy}(x, y)$ adalah

1. $f_{xy}(x, y) \geq 0$
2. $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{xy}(x, y) dx dy = 1$
3. $P[(X, Y) \in A] = \int_{R_A} f_{xy}(x, y) dx dy$

5.7.5 Distribusi bersyarat

Ketika bekerja dengan variabel acak bivariat diskrit, penting untuk menyimpulkan fungsi probabilitas bersyarat karena X dan Y terkait dalam ruang terbatas. Berdasarkan pmf gabungan (X, Y) , pmf bersyarat Y ketika $X = x_i$ didefinisikan sebagai

$$P_{Y|X}(y_j|x_i) = \frac{P_{XY}(x_i, y_j)}{P_X(x_i)} \text{ when } P_X(x_i) > 0 \text{ and} \quad (5.52)$$

$$P_{X|Y}(x_i|y_j) = \frac{P_{XY}(x_i, y_j)}{P_Y(y_j)} \text{ when } P_Y(y_j) > 0 \quad (5.53)$$

Perhatikan beberapa sifat penting dari $P_{Y|X}(y_j|x_i)$:

1. $0 \leq P_{Y|X}(y_j|x_i) \leq 1$
2. $\sum_{y_j} P_{Y|X}(y_j|x_i) = 1$

Dengan cara yang sama, ketika (X,Y) adalah variabel acak bivariat kontinu dan memiliki pdf gabungan $f_{XY}(x, y)$, maka cdf kondisional Y dalam kasus $X = x$ didefinisikan sebagai

$$f_{Y|X}(y|x) = \frac{f_{xy}(x, y)}{f_X(x)} \text{ when } f_X(x) > 0 \text{ and} \quad (5.54)$$

$$f_{X|Y}(x|y) = \frac{f_{xy}(x, y)}{f_Y(y)} \text{ when } f_Y(y) > 0 \quad (5.55)$$

Perhatikan beberapa properti penting dari $f_{Y|X}(y|x)$:

1. $f_{Y|X}(y|x) \geq 0$
2. $\int_{-\infty}^{\infty} f_{Y|X}(y|x) dy = 1$

5.7.6 Kovariansi dan korelasi

Kovariansi antara dua variabel acak X dan Y mengukur derajat hubungan (linier) X dan Y , yang berarti seberapa besar variasi X terhadap Y , dan sebaliknya.

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) \quad (5.56)$$

Jadi, jika variansi adalah ukuran bagaimana sebuah variabel acak bervariasi terhadap dirinya sendiri, maka kovariansi adalah ukuran bagaimana dua variabel acak bervariasi terhadap satu sama lain.

Kovariansi dapat berada di antara 0 dan tak terhingga. Terkadang, lebih mudah untuk bekerja dengan ukuran yang dinormalkan, karena kovariansi saja mungkin tidak memiliki cukup informasi tentang hubungan di antara variabel acak. Misalnya, mari kita definisikan 3 variabel acak yang berbeda berdasarkan lemparan koin:

$$\begin{aligned} X(n) &= \begin{cases} 2 & \text{if } n \text{ is head} \\ 1 & \text{if } n \text{ is tail} \end{cases} \\ Y(n) &= \begin{cases} 20 & \text{if } n \text{ is head} \\ 10 & \text{if } n \text{ is tail} \end{cases} \\ Z(n) &= \begin{cases} 200 & \text{if } n \text{ is head} \\ 100 & \text{if } n \text{ is tail} \end{cases} \end{aligned}$$

Hanya dengan melihat variabel acak ini, kita dapat memahami bahwa pada dasarnya variabel-variabel tersebut sama saja, hanya sebuah konstanta yang dikalikan pada output-nya. Namun, kovariansinya akan sangat berbeda ketika dihitung dengan persamaan 5.55:

$$\text{Penutup}(X, Y) = 2,5, \text{Cov}(X, Z) = 25, \text{Cov}(Y, Z) = 250$$

Untuk menyelesaikan masalah ini, perlu menambahkan istilah normalisasi yang menyediakan kecerdasan ini: $\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}$

$$\text{So, Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}} \quad (5.57)$$

Jika $\text{Cov}(X, Y) = 0$, maka kita dapat mengatakan X dan Y tidak berkorelasi. Maka dari itu persamaan 5.55, X dan Y tidak berkorelasi jika *Bahasa Inggris* $(X, Y) = E(X)E(Y)$

Jika X dan Y independen, maka dapat dibuktikan bahwa keduanya tidak berkorelasi, tetapi perlu dicatat bahwa kebalikannya tidak berlaku secara umum.

Jadi, kita harus mengingatnya

- Hasil dari Variabel Acak yang dibobot berdasarkan probabilitasnya adalah Harapan, $E(X)$.
- Perbedaan antara Harapan dari Variabel Acak kuadrat dan Harapan dari Variabel Acak kuadrat adalah Varians: $E(X^2) - X(x)^2$.
- Kovariansi, $E(XY) - E(X)E(Y)$ sama dengan Varians, tetapi di sini dua Variabel Acak dibandingkan, bukannya satu Variabel Acak terhadap dirinya sendiri.

- Korelasi, $\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}}$ adalah Kovariansi

dinormalisasi.

Beberapa sifat penting dari korelasi adalah

1. $-1 \leq \text{corr}[X, Y] \leq 1$. Jadi, dalam matriks korelasi, setiap entri pada diagonal adalah 1, dan entri lainnya berada antara -1 dan 1.
2. $\text{corr}[X, Y] = 1$ jika dan hanya jika $Y = aX + b$ untuk beberapa parameter a dan b ,
yaitu, jika ada hubungan linear antara X dan Y .
3. Dari sifat 2, tampaknya koefisien korelasi terkait dengan kemiringan garis regresi, yaitu, koefisien a dalam ekspresi $Y = aX + b$. Namun, koefisien regresi sebenarnya diberikan oleh $a = \text{cov}[X, Y] / \text{var}[X]$. Cara yang lebih baik untuk menginterpretasikan koefisien korelasi adalah sebagai derajat linearitas.

5.8 TEOREMA BATAS PUSAT

Ini adalah salah satu teorema terpenting dalam teori probabilitas. Teorema ini menyatakan bahwa jika $X_1, \dots, X_n$ adalah deret variabel acak

yang terdistribusi identik dan masing-masing memiliki mean μ dan varians σ^2

Dan $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n}(X_1 + \dots + X_n)$ then

$$Z_n = \frac{X_1 + \dots + X_n - n\mu}{\sigma \sqrt{n}} = \frac{\bar{X}_n - \mu}{\sigma / \sqrt{n}} \quad (5.58)$$

Ketika $n \rightarrow \infty$ (artinya untuk himpunan yang sangat besar tetapi terbatas) maka Z_n cenderung ke normal standar.

$$\lim_{n \rightarrow \infty} Z_n \sim N(0;1) \quad (5.59)$$

Atau

$$\lim_{n \rightarrow \infty} F_{Z_n}(z) = \lim_{n \rightarrow \infty} P(Z_n \leq z) = \Phi(z) \quad (5.60)$$

di mana, $\Phi(z)$ adalah cdf dari variabel acak normal standar.

Jadi, menurut teorema limit pusat, terlepas dari distribusi X_i individual, distribusi jumlah $S_n = X_1 + \dots + X_n$ kira-kira normal untuk n besar. Ini adalah hasil yang sangat penting karena setiap kali kita perlu menangani variabel acak yang merupakan jumlah dari sejumlah besar variabel acak, maka dengan menggunakan teorema limit pusat, kita dapat mengasumsikan bahwa jumlah ini terdistribusi secara normal.

5.9 DISTRIBUSI SAMPEL

Seperti yang telah kita bahas sebelumnya dalam bab ini, aplikasi penting statistik dalam pembelajaran mesin adalah cara menarik kesimpulan tentang suatu himpunan atau populasi berdasarkan model probabilitas sampel acak dari himpunan tersebut. Misalnya, berdasarkan hasil uji sampel keganasan dari beberapa kasus tumor acak, kita ingin memperkirakan proporsi semua tumor yang ganas dan dengan demikian memberi tahu dokter tentang perlu atau tidaknya biopsi pada setiap kasus tumor. Seperti yang dapat kita pahami, sampel acak yang berbeda dapat

memberikan perkiraan yang berbeda, jika kita dapat memperoleh pengetahuan tentang variabilitas semua perkiraan yang mungkin yang diperoleh dari sampel acak, maka kita seharusnya dapat mencapai kesimpulan yang masuk akal. Beberapa terminologi yang digunakan dalam bagian ini didefinisikan di bawah ini:

Populasi adalah sekumpulan objek terbatas yang sedang diselidiki.

Sampel acak merujuk pada sampel objek yang diambil dari suatu populasi sedemikian rupa sehingga setiap anggota populasi memiliki kesempatan yang sama untuk dipilih.

Distribusi sampel mengacu pada distribusi probabilitas variabel acak yang didefinisikan dalam ruang sampel acak.

5.9.1 Pengambilan sampel dengan penggantian

Ketika memilih sampel dari populasi, jika setiap objek yang dipilih dikembalikan ke populasi sebelum objek berikutnya dipilih, maka itu disebut pengambilan sampel dengan penggantian. Dalam hal ini, pengulangan diperbolehkan. Itu berarti, jika ukuran sampel n dipilih dari ukuran populasi N , maka jumlah sampel tersebut adalah

$N \times N \times \dots \times N = N^n$, karena setiap objek dapat diulang.

Selain itu, probabilitas setiap sampel yang dipilih adalah sama dan $\frac{1}{N^n}$.

Misalnya, mari kita pilih sampel acak 2 pasien dari populasi 3 pasien {A, B, C} dan penggantian diperbolehkan. Ada 9 pasangan berurutan seperti itu, seperti:

(A, A), (A, B), (A, C), (B, A), (B, B), (B, C), (C, A), (C, B), (C, C)

Artinya banyaknya sampel acak 2 dari populasi 3 adalah

$NN = 32 = 9$ dan setiap sampel acak memiliki probabilitas $\frac{1}{N^n} = \frac{1}{9}$ untuk dipilih.

5.9.2 Pengambilan sampel tanpa penggantian

Dalam kasus, kita tidak mengembalikan objek yang dipilih ke populasi sebelum memilih objek berikutnya, maka sampel acak berukuran n didefinisikan sebagai subset tak berurutan dari n objek dari populasi dan disebut pengambilan sampel tanpa penggantian. Jumlah sampel tersebut yang dapat diambil dari ukuran populasi N adalah

$$\binom{N}{n} = \frac{N!}{n!(N-n)!}$$

Dalam contoh kita sebelumnya, sampel tak berurutan sebanyak 2 yang dapat dibuat dari populasi 3 pasien ketika penggantian tidak diperbolehkan adalah

(A, B), (A, C), (B, C)

$$\binom{3}{2} = \frac{3!}{2!(3-2)!} = 3$$

Selain itu, masing-masing dari 3 sampel berukuran 2 ini memiliki peluang untuk dipilih sebagai $\frac{1}{3}$

5.9.3 Rata-rata dan varians sampel

Mari kita pertimbangkan X sebagai variabel acak dengan mean μ dan simpangan baku σ dari populasi N . Sampel acak berukuran n , yang diambil tanpa penggantian akan menghasilkan n nilai $x_1, x_2, \dots, x_n$ untuk X . Ketika

sampel diambil dengan penggantian, nilai-nilai ini saling independen dan dapat dianggap sebagai nilai n variabel acak independen $X_1, X_2, \dots, X_n$, yang masing-masing memiliki mean μ dan varians σ^2 . Rata-rata sampel adalah variabel acak $\bar{X}$ sebagai

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} \quad (5.61)$$

Karena $\bar{X}$ adalah variabel acak, maka ia juga memiliki mean $\mu_{\bar{X}}$ dan varians $\sigma_{\bar{X}}^2$ dan ini terkait dengan parameter populasi sebagai:

$$\mu_{\bar{X}} = \mu \text{ and } \sigma_{\bar{X}}^2 = \frac{\sigma^2}{n} \quad (5.62)$$

untuk sejumlah besar n , jika X kira-kira normal terdistribusi, maka $\bar{X}$ juga akan terdistribusi normal.

Bila sampel diambil tanpa penggantian, maka nilai sampel $x_1, x_2, \dots, x_n$ untuk variabel acak X tidak independen. Rata-rata sampel $\bar{X}$ memiliki rata-rata $\mu_{\bar{X}}$ dan varians $\sigma_{\bar{X}}^2$ diberikan oleh:

$$\mu_{\bar{X}} = \mu \text{ and } \sigma_{\bar{X}}^2 = \frac{\sigma^2}{n} \left(\frac{N - n}{N - 1} \right) \quad (5.63)$$

di mana, N adalah ukuran populasi dan $n < N$. Juga jika X berdistribusi normal maka $\bar{X}$ juga berdistribusi normal.

Sekarang, berdasarkan teorema batas pusat, jika ukuran sampel dari variabel acak berdasarkan populasi terbatas besar maka rata-rata sampel kira-kira terdistribusi normal terlepas dari distribusi populasi. Untuk sebagian besar aplikasi praktis pengambilan sampel, ketika ukuran sampel cukup besar (sebagai aturan praktis ≥ 30) rata-rata sampel kira-kira terdistribusi normal. Selain itu, ketika sampel acak diambil dari populasi besar, dapat diasumsikan bahwa nilai $x_1, x_2, \dots, x_n$ bersifat independen. Asumsi independensi ini adalah salah satu kunci penerapan teori probabilitas dalam inferensi statistik. Kita menggunakan istilah seperti

'populasi jauh lebih besar daripada ukuran sampel' atau 'populasi besar dibandingkan dengan ukuran sampelnya', dll. untuk menunjukkan bahwa populasi cukup besar untuk membuat sampel saling independen. Dalam praktiknya, jika $\sqrt{\frac{N-n}{N-1}} \cong 1$, maka kemerdekaan dapat diasumsikan.

5.10 PENGUJIAN HIPOTESIS

Saat berhadapan dengan variabel acak, situasi umum adalah ketika kita harus membuat keputusan atau pilihan tertentu berdasarkan pengamatan atau data yang sifatnya acak. Solusi untuk menghadapi situasi ini disebut teori keputusan atau pengujian hipotesis dan ini merupakan proses yang banyak digunakan dalam situasi kehidupan nyata. Seperti yang telah kita bahas sebelumnya, komponen utama pembelajaran mesin adalah menggunakan data pelatihan berbasis sampel yang dapat digunakan untuk merepresentasikan kumpulan data aktual yang lebih besar dan penting untuk memperkirakan seberapa yakin suatu hasil dapat dikaitkan dengan perilaku data pelatihan sehingga keputusan pada data aktual dapat dibuat. Jadi, pengujian hipotesis merupakan bagian integral dari pembelajaran mesin.

Dalam hal statistik, hipotesis adalah asumsi tentang hukum probabilitas variabel acak. Ambil contoh, sampel acak $(X_1, \dots, X_n)$ dari variabel acak yang pdf-nya pada parameter κ diberikan oleh $f(x, \kappa) = f(x_1, x_2, \dots, x_n; \kappa)$. Kita ingin menguji asumsi $\kappa = \kappa_0$ terhadap asumsi $\kappa = \kappa_1$. Dalam kasus ini, asumsi $\kappa = \kappa_0$ disebut hipotesis nol dan dilambangkan dengan H_0 . Asumsi $\kappa = \kappa_1$ disebut hipotesis alternatif dan dilambangkan dengan H_1 .

$$H_0: \kappa = \kappa_1$$

$$H_1: \kappa \neq \kappa_1$$

Hipotesis sederhana adalah hipotesis yang semua parameternya ditetapkan dengan nilai pasti, seperti H_0 atau H_1 dalam kasus ini. Namun, jika parameternya tidak memiliki nilai pasti, seperti $H_1: \kappa \neq \kappa_1$, maka H_1 bersifat komposit.

Konsep pengujian hipotesis adalah proses pengambilan keputusan yang digunakan untuk memvalidasi hipotesis. Kita dapat menginterpretasikan proses pengambilan keputusan dengan membagi ruang observasi, katakanlah R menjadi dua wilayah – R_0 dan R_1 . Jika $x = (x_1, \dots, x_n)$ adalah himpunan observasi, maka jika $x \in R_0$ keputusan mendukung H_0 dan jika $x \in R_1$ maka keputusannya mendukung H_1 . Daerah R_0 disebut daerah penerimaan karena hipotesis nol diterima dan R_1 adalah daerah penolakan. Ada 4 kemungkinan keputusan berdasarkan dua daerah dalam ruang observasi:

1. H_0 benar; terima $H_0 \rightarrow$ ini adalah keputusan yang benar
2. H_0 benar; tolak H_0 (yang berarti terima $H_1) \rightarrow$ ini adalah keputusan yang salah
3. H_1 benar; terima $H_1 \rightarrow$ ini adalah keputusan yang benar
4. H_1 benar; tolak H_1 (yang berarti terima $H_0) \rightarrow$ ini adalah keputusan yang salah

Jadi, kita dapat melihat ada kemungkinan 2 keputusan yang benar dan 2 keputusan yang salah dan tindakan yang sesuai. Keputusan yang salah dapat disebut sebagai:

Kesalahan tipe I: menolak H_0 (atau menerima H_1) ketika H_0 benar. Contoh situasi ini adalah dalam uji keganasan tumor, tumor jinak diterima

sebagai tumor ganas dan pengobatan yang sesuai dimulai. Ini juga disebut kesalahan Alpha di mana baik ditafsirkan sebagai buruk.

Kesalahan tipe II: menolak H_1 (atau menerima H_0) ketika H_1 benar. Contoh situasi ini adalah dalam uji keganasan tumor, tumor ganas diterima sebagai tumor jinak dan tidak ada pengobatan untuk keganasan yang dimulai. Ini juga disebut kesalahan Beta di mana yang buruk ditafsirkan sebagai baik dan dapat memiliki dampak yang lebih buruk.

Kemungkinan kesalahan Tipe I dan Tipe II adalah

$$PI = P(D_1 | H_0) = P(x \in R_1; H_0)$$

$$\text{Informasi Pribadi (PII)} = P(D_0 | H_1) = P(x \in \text{Nilai } R_0 \text{ dan } H_1)$$

di mana, D_i ($i = 0, 1$) menunjukkan peristiwa dimana keputusan tersebut adalah untuk menerima H_i . PI juga dilambangkan dengan α dan dikenal sebagai tingkat signifikansi sedangkan PII dilambangkan dengan β dan dikenal sebagai daya uji. Di sini, α dan β tidak independen satu sama lain karena keduanya mewakili probabilitas kejadian dari masalah keputusan yang sama. Jadi, biasanya penurunan pada satu jenis kesalahan menyebabkan peningkatan pada jenis kesalahan lain ketika ukuran sampel ditetapkan. Meskipun diinginkan untuk mengurangi kedua jenis kesalahan, hal itu hanya mungkin dilakukan dengan meningkatkan ukuran sampel. Dalam semua aplikasi praktis pengujian hipotesis, masing-masing dari empat kemungkinan hasil dan tindakan dikaitkan dengan kepentingan relatif atau biaya tertentu dan dengan demikian tujuan akhirnya adalah untuk mengurangi biaya keseluruhan.

Jadi, kemungkinan keputusan yang benar adalah

$$P(D_0 | H_0) = P(x \in \text{Nilai } R_0 \text{ dan } H_0)$$

$$P(D_1 | H_1) = P(x \in \text{Bahasa Indonesia: } R_1; H_1)$$

5.11. PERKIRAAN MONTE CARLO

Meskipun kita membahas fungsi distribusi variabel acak, dalam situasi praktis sulit untuk menghitungnya menggunakan rumus perubahan variabel. Aproksimasi Monte Carlo menyediakan alternatif yang sederhana namun ampuh untuk ini. Mari kita buat S sampel dari distribusi, sebagai $x_1, \dots, x_S$. Untuk sampel ini, kita dapat mengaproksimasi distribusi $f(X)$ dengan menggunakan distribusi empiris $\{f(x_s)\}_{s=1}^S$.

Pada prinsipnya, metode Monte Carlo dapat digunakan untuk memecahkan masalah apa pun yang memiliki interpretasi probabilistik. Kita tahu bahwa berdasarkan hukum bilangan besar, integral yang dijelaskan oleh nilai yang diharapkan dari beberapa variabel acak dapat didekati dengan mengambil rata-rata empiris (atau rata-rata sampel) dari sampel independen dari variabel acak. Sampler yang banyak digunakan adalah sampler Markov chain Monte Carlo (MCMC) untuk memparameterisasi distribusi probabilitas variabel acak. Ide utamanya adalah untuk merancang model rantai Markov yang bijaksana dengan distribusi probabilitas stasioner yang ditentukan. Teknik Monte Carlo sekarang banyak digunakan dalam statistik dan pembelajaran mesin juga. Dengan menggunakan teknik Monte Carlo, kita dapat memperkirakan nilai yang diharapkan dari setiap fungsi variabel acak dengan hanya mengambil sampel dari populasi variabel acak, dan kemudian menghitung rata-rata aritmatika dari fungsi yang diterapkan pada sampel, sebagai berikut:

$$E[f(X)] = \int f(x)p(x)dx \approx \frac{1}{S} \sum_{s=1}^S f(x_s) \text{ where } x_s \sim p(X). \quad (5.64)$$

Ini juga disebut integrasi Monte Carlo, dan lebih mudah dievaluasi daripada integrasi numerik yang mencoba mengevaluasi fungsi pada titik-

titik grid yang tetap. Monte Carlo mengevaluasi fungsi hanya di tempat-tempat yang memiliki probabilitas yang tidak dapat diabaikan.

Untuk fungsi $f()$ yang berbeda, perkiraan beberapa besaran penting dapat diperoleh:

- $\bar{x} = \frac{1}{S} \sum_{s=1}^S x_s \rightarrow E[X]$
- $\frac{1}{S} \sum_{s=1}^S (x_s - \bar{x})^2 \rightarrow \text{var}[X]$
- $\frac{1}{S} \#\{x_s \leq c\} \rightarrow P(X \leq c)$
- $\text{mediannya } X_1, \dots, X_S \rightarrow \text{median}(X)$

5.12 RINGKASAN

1. Penafsiran frekuentis terhadap probabilitas mewakili frekuensi jangka panjang berbagai peristiwa, sedangkan penafsiran Bayesian terhadap probabilitas mencoba mengukur ketidakpastian suatu peristiwa dan dengan demikian berfokus pada informasi, bukan pada percobaan berulang.
2. Menurut aturan Bayes, $p(A|B) = p(B|A)p(A)/p(B)$.
3. Variabel acak diskrit dinyatakan dengan fungsi massa probabilitas (pmf) $p(x) = p(X = x)$.
4. Variabel acak kontinu dinyatakan dengan fungsi kepadatan probabilitas (pdf) $p(x) = p(X = x)$.

5. Fungsi distribusi kumulatif (cdf) dari variabel acak X dapat

diperoleh dengan
$$F_x(x) = p(X \leq x) = \int_{-\infty}^x f_x(x) dx$$

6. Persamaan untuk mencari mean dari variabel acak X adalah:

$$\mu_x = E(X) = \sum_k x_k p_x(x_k) \quad \text{ketika } X \text{ diskrit}$$

$$\mu_x = E(X) = \int_{-\infty}^{\infty} x f_x(x) dx \quad \text{ketika } X \text{ kontinu.}$$

7. Persamaan untuk mencari varians variabel acak X adalah

$$\sigma_x^2 = \text{Var}(X) = E\{[X - E(X)]^2\} \text{ so,}$$

$$\sigma_x^2 = \sum_k (x_k - \mu_x)^2 p_x(x_k) \text{ when } X \text{ is discrete}$$

$$\sigma_x^2 = \int_{-\infty}^{\infty} (x - \mu_x)^2 f_x(x) dx \text{ when } X \text{ is continuous.}$$

8. Ketika kita memiliki situasi di mana hasil suatu percobaan adalah 'berhasil' atau 'gagal', maka perilaku variabel acak X dapat direpresentasikan oleh distribusi Bernoulli.
9. Jika n percobaan Bernoulli independen dilakukan dan X menyatakan jumlah keberhasilan dalam n percobaan tersebut, maka X disebut variabel acak binomial.
10. Untuk memodelkan hasil pelemparan dadu bersisi K , atau untuk percobaan yang hasilnya bisa berlipat ganda, kita dapat menggunakan distribusi multinomial.
11. Variabel acak Poisson memiliki jangkauan aplikasi yang luas karena dapat digunakan sebagai perkiraan untuk binomial dengan parameter (n, p) ketika n besar dan p kecil sehingga np berukuran sedang.

12. Distribusi seragam, distribusi Gaussian (normal), distribusi Laplace adalah contoh beberapa distribusi acak kontinu yang penting.
13. Jika ada dua variabel acak X dan Y dalam ruang sampel S suatu percobaan acak, maka pasangan (X, Y) disebut variabel acak bivariat.
14. Kovariansi antara dua variabel acak X dan Y mengukur derajat hubungan (linier) X dan Y .
15. Menurut teorema limit pusat, terlepas dari distribusi X_i individu, distribusi jumlah $S_n = X_1 + \dots + X_n$ kira-kira normal untuk n besar.
16. Dalam pengujian hipotesis:
Kesalahan tipe I: menolak H_0 (atau menerima H_1) ketika H_0 benar.
Kesalahan tipe II: tolak H_1 (atau terima H_0) ketika H_1 benar.
17. Dengan menggunakan teknik Monte Carlo, kita dapat memperkirakan nilai yang diharapkan dari fungsi apa pun dari variabel acak hanya dengan mengambil sampel dari populasi variabel acak, lalu menghitung rata-rata aritmatika fungsi yang diterapkan pada sampel tersebut.

SOAL PILIHAN GANDA (MASING-MASING BERI NILAI 1)

1. Pendekatan probabilistik yang digunakan dalam pembelajaran mesin terkait erat dengan:
 1. Statistik
 2. Fisika
 3. Matematika

4. Psikologi
2. Jenis penafsiran probabilitas ini mencoba mengukur ketidakpastian suatu peristiwa dan dengan demikian berfokus pada informasi ketimbang percobaan berulang.
 1. Interpretasi frekuensi probabilitas
 2. Interpretasi Gaussian tentang probabilitas
 3. Interpretasi probabilitas dengan pembelajaran mesin
 4. Interpretasi probabilitas Bayesian
3. Alasan interpretasi Bayesian dapat digunakan untuk memodelkan ketidakpastian peristiwa adalah karena ia tidak mengharapkan frekuensi jangka panjang dari peristiwa tersebut untuk terjadi.
 1. BENAR
 2. PALSU
4. $P(A,B) = p(A \cap B) = p(A|B) p(B)$ disebut sebagai:
 1. Probabilitas bersyarat
 2. Probabilitas tanpa syarat
 3. Aturan Bayes
 4. Aturan produk
5. Berdasarkan distribusi gabungan pada dua kejadian $p(A,B)$, kita dapat mendefinisikan distribusi ini sebagai berikut:
6. P Contoh soal $A = A, B = b$
 1. Distribusi bersyarat
 2. Distribusi marginal
 3. Distribusi Bayes
 4. Distribusi normal

7. Kita dapat mendefinisikan probabilitas ini sebagai $p(A|B) = p(A,B)/p(B)$ jika $p(B) > 0$
 1. Probabilitas bersyarat
 2. probabilitas marjinal
 3. probabilitas bayes
 4. Probabilitas normal
8. Dalam istilah statistik, ini merupakan skor rata-rata tertimbang.
 1. Perbedaan
 2. Berarti
 3. Rata-rata
 4. Lagi
9. Kovariansi antara dua variabel acak X dan Y mengukur tingkat hubungan (linier) antara X dan Y, yang berarti seberapa bervariasi X dengan Y dan sebaliknya. Apa rumus untuk Kovariansi (X,Y)?
 1. Persamaan $(x,y) = E(x,y) - E(x)E(y)$
 2. Persamaan $(X,Y) = E(XY) + E(X)E(Y)$
 3. Persamaan $(X,Y) = E(XY)/E(X)E(Y)$
 4. Persamaan $(X,Y) = E(X)E(Y)/ E(XY)$
10. Distribusi binomial dapat digunakan untuk memodelkan hasil lemparan koin.
 1. BENAR
 2. PALSU
11. Dua kejadian A dan B disebut saling eksklusif jika keduanya dapat terjadi bersama-sama.
 1. BENAR
 2. PALSU

SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI)

1. Jelaskan interpretasi Bayesian tentang probabilitas.
2. Tentukan peluang gabungan dua kejadian dengan persamaan.
3. Apa itu probabilitas gabungan? Apa rumusnya?
4. Apa itu aturan rantai probabilitas?
5. Apa yang dimaksud dengan probabilitas bersyarat? Apa rumusnya?
6. Apa itu variabel acak kontinu?
7. Apa itu distribusi Bernoulli? Apa rumusnya?
8. Apa itu distribusi binomial? Apa rumusnya?
9. Apa itu distribusi Poisson? Apa rumusnya?
10. Definisikan kovariansi.
11. Definisikan korelasi
12. Definisikan pengambilan sampel dengan penggantian. Berikan contoh.
13. Apa yang dimaksud dengan pengambilan sampel tanpa penggantian? Berikan contohnya.
14. Apa itu hipotesis? Berikan contoh.

SOAL JAWABAN PANJANG (SOAL 10 NILAI)

1. Misalkan X adalah variabel acak diskrit dengan PMF berikut

$$P_X(x) = \begin{cases} 0.1 & \text{for } x = 0.2 \\ 0.2 & \text{for } x = 0.4 \\ 0.2 & \text{for } x = 0.5 \\ 0.3 & \text{for } x = 0.8 \\ 0.2 & \text{for } x = 1 \\ 0 & \text{otherwise} \end{cases}$$

1. Temukan rentang RX dari variabel acak X.
 2. Temukan $P(X \leq 0,5)$
 3. Temukan $P(0,25 < X < 0,75)$
 4. Temukan $P(X = 0,2 | X < 0,6)$
2. Dua dadu yang sama dan adil dilempar dan kami mengamati dua angka X dan Y.
1. Temukan RX, RY dan PMF dari X dan Y.
 2. Temukan $P(X = 2, Y = 6)$.
 3. Temukan $P(X > 3 | Y = 2)$.
 4. Jika $Z = X + Y$. Tentukanlah range dan PMF dari Z.
 5. Temukan $P(X = 4 | Z = 8)$.
3. Dalam suatu ujian, ada 20 soal pilihan ganda. Setiap soal memiliki 44 kemungkinan jawaban. Seorang siswa mengetahui jawaban dari 10 soal, tetapi 10 soal lainnya tidak diketahuinya dan ia memilih jawaban secara acak. Jika skor siswa X sama dengan jumlah total jawaban yang benar, maka carilah PMF dari X. Berapakah $P(X > 15)$?
4. Jumlah mahasiswa yang datang ke suatu perguruan tinggi dalam selang waktu tertentu adalah variabel acak Poisson. Rata-rata 10 mahasiswa datang per jam. Misalkan X adalah jumlah siswa yang datang dari jam 10 pagi sampai jam 11:30 pagi. Berapakah $P(10 < X \leq 15)$?

5. Jika kita memiliki dua variabel acak independen X dan Y sehingga $X \sim \text{Poisson}(\alpha)$ dan $Y \sim \text{Poisson}(\beta)$. Tentukan variabel acak baru sebagai $Z = X + Y$. Carilah PMF dari Z.
6. Ada variabel acak diskrit X dengan pmf.

$$P_x(x) = \begin{cases} \frac{1}{4} & \text{when } x = -2 \\ \frac{1}{8} & \text{when } x = -1 \\ \frac{1}{4} & \text{when } x = 0 \\ \frac{11}{84} & \text{when } x = 1 \end{cases}$$

Jika kita mendefinisikan variabel acak baru $Y = (X + 1)^2$ Kemudian

1. Temukan rentang Y.
2. Temukan pmf dari Y.
7. Jika X adalah variabel acak kontinu dengan PDF

$$f_X(x) = \begin{cases} cx^2 & |x| \leq 1 \\ 0 & \text{Otherwise} \end{cases} \quad \text{Find the constant } c.$$

- 1.
2. Temukan EX dan $\text{Var}(X)$.
3. Temukan $P(X \geq \frac{1}{2})$.
8. Jika X adalah variabel acak kontinu dengan pdf

$$f_X(x) = \begin{cases} 4x^3 & 0 < x \leq 1 \\ 0 & \text{otherwise} \end{cases}$$

Find $P(X \leq \frac{2}{3} | X > \frac{1}{3})$

9. Jika $X \sim \text{Seragam}(\frac{-\pi}{2}, \pi)$ dan $Y = \sin(X)$, maka carilah $f_Y(y)$.
10. Jika X adalah variabel acak dengan CDF

$$F_X(x) = \begin{cases} 1 & X \geq 1 \\ \frac{1}{2} + \frac{x}{2} & \text{where } 0 \leq X < 1 \\ 0 & \text{where } x < 0 \end{cases}$$

1. Jenis variabel acak apakah X: diskrit, kontinu, atau campuran?
 2. Temukan PDF dari X, $f_X(x)$.
 3. Temukan $E(e^X)$.
 4. Temukan $P(X = 0 | X \leq 0,5)$.
11. Ada dua variabel acak X dan Y dengan PMF gabungan yang diberikan pada Tabel di bawah ini
1. Temukan $P(X \leq 2, Y \leq 4)$.
 2. Temukan PMF marginal dari X dan Y.
 3. Temukan $P(Y = 2 | X = 1)$.
 4. Apakah X dan Y independen?

(L)	Y = 2	Y = 4	Y = 5
X = 1	1/12	1/24	1/24
X = 2	1/6	1/12	1/8
X = 3	1/4	1/8	1/12

12. Ada sebuah kotak berisi 40 kemeja putih dan 60 kemeja hitam. Jika kita memilih 10 kemeja (tanpa penggantian) secara acak, maka carilah PMF gabungan dari X dan Y di mana X adalah banyaknya kemeja putih dan Y adalah banyaknya kemeja hitam.
13. Jika X dan Y adalah dua variabel acak yang kontinu bersama dengan PDF bersama

$$f_{XY}(x, y) = \begin{cases} 6xy & \text{where } 0 \leq x \leq 1, 0 \leq y \leq \sqrt{x} \\ 0 & \text{otherwise} \end{cases}$$

1. Temukan $f_X(x)$ dan $f_Y(y)$.
2. Apakah X dan Y independen satu sama lain?

3. Temukan PDF bersyarat dari X yang diberikan $Y = y$, $f_X|Y(x|y)$.
 4. Temukan $E[X|Y = y]$, untuk $0 \leq y \leq 1$.
 5. Carilah $\text{Var}(X|Y = y)$, untuk $0 \leq y \leq 1$.
14. Ada 100 orang di sebuah kapal. Jika X_i adalah berat orang ke i di kapal dan X_i bersifat independen dan terdistribusi secara identik dan juga $E X_i = \mu = 170$ dan $\sigma X_i = \sigma = 30$. Carilah peluang bahwa berat total orang di kapal melebihi 18.000.
15. Misalkan $X_1, X_2, \dots, X_{25}$ merupakan himpunan bebas dan terdistribusi identik.

$$P_X(k) = \begin{cases} 0.6 & k = 1 \\ 0.4 & k = -1 \\ 0 & \text{otherwise} \end{cases}$$

Dan memiliki PMF berikut ini

Jika $Y = X_1 + X_2 + \dots + X_n$, perkirakan $P(4 \leq Y \leq 6)$ menggunakan teorema limit pusat.

Bab 6 Pembelajaran Konsep Bayesian

Siti Nurhayati, S.Kom., M.Kom.

A. Tujuan Pembelajaran

Prinsip probabilitas untuk klasifikasi merupakan area penting dari algoritma pembelajaran mesin. Dalam kehidupan praktis, keputusan kita dipengaruhi oleh pengetahuan atau keyakinan kita sebelumnya tentang suatu peristiwa. Dengan demikian, suatu peristiwa yang sangat tidak mungkin terjadi dapat dianggap serius terjadi dalam situasi tertentu jika kita tahu bahwa di masa lalu, peristiwa tersebut pasti terjadi ketika peristiwa lain diamati. Konsep yang sama diterapkan dalam pembelajaran mesin menggunakan teorema Bayes dan algoritma terkait yang dibahas dalam bab ini. Konsep probabilitas yang dibahas dalam bab-bab sebelumnya digunakan secara luas dalam bab ini.

6.1 PENDAHULUAN

Pada bab terakhir, kita membahas aturan probabilitas dan kemungkinan penggunaan probabilitas, fungsi distribusi, dan prinsip pengujian hipotesis dalam domain pembelajaran mesin. Dalam bab ini, kita akan membahas detail teorema Bayesian dan bagaimana ia menyediakan dasar bagi konsep pembelajaran mesin. Teknik ini berasal dari karya matematikawan abad ke-18 Thomas Bayes. Ia mengembangkan prinsip matematika dasar, yang dikenal sebagai metode Bayesian, yang menggambarkan probabilitas kejadian, dan yang lebih penting,

bagaimana probabilitas harus direvisi ketika ada informasi tambahan yang tersedia.

6.2 MENGAPA METODE BAYESIAN PENTING?

Algoritme pembelajaran Bayesian, seperti pengklasifikasi Bayes naif, merupakan pendekatan yang sangat praktis untuk jenis masalah pembelajaran tertentu karena pendekatan ini dapat menghitung probabilitas eksplisit untuk hipotesis. Dalam banyak kasus, pendekatan ini sama-sama kompetitif atau bahkan mengungguli algoritme pembelajaran lainnya, termasuk algoritme pohon keputusan dan algoritma jaringan saraf.

Pengklasifikasi Bayesian menggunakan ide sederhana bahwa data pelatihan digunakan untuk menghitung probabilitas yang diamati dari setiap kelas berdasarkan nilai fitur. Ketika pengklasifikasi yang sama digunakan kemudian untuk data yang tidak terklasifikasi, pengklasifikasi tersebut menggunakan probabilitas yang diamati untuk memprediksi kelas yang paling mungkin untuk fitur-fitur baru. Penerapan pengamatan dari data pelatihan juga dapat dianggap sebagai penerapan pengetahuan atau keyakinan sebelumnya terhadap probabilitas suatu hasil, sehingga memiliki probabilitas yang lebih tinggi untuk memenuhi hasil aktual atau nyata. Konsep sederhana ini digunakan dalam aturan Bayes dan diterapkan untuk melatih mesin dalam istilah pembelajaran mesin. Beberapa penggunaan pengklasifikasi Bayesian dalam kehidupan nyata adalah sebagai berikut:

- Klasifikasi berbasis teks seperti penyaringan spam atau email sampah, identifikasi penulis, atau kategorisasi topik.

- Diagnosis medis seperti adanya sekumpulan gejala yang diamati selama suatu penyakit, mengidentifikasi kemungkinan pasien baru mengidap penyakit tersebut.
- Keamanan jaringan seperti mendeteksi intrusi ilegal atau anomali dalam jaringan komputer

Salah satu kelebihan pengklasifikasi Bayesian adalah bahwa pengklasifikasi tersebut memanfaatkan semua parameter yang tersedia untuk mengubah prediksi secara halus, sementara banyak algoritme lain cenderung mengabaikan fitur yang memiliki efek lemah. Pengklasifikasi Bayesian berasumsi bahwa meskipun beberapa parameter individual memiliki efek kecil pada hasil, efek kolektif dari parameter tersebut bisa jadi cukup besar. Untuk tugas pembelajaran seperti itu, pengklasifikasi Bayes naif adalah yang paling efektif.

Beberapa fitur metode pembelajaran Bayesian yang membuatnya populer adalah sebagai berikut:

- Pengetahuan awal tentang hipotesis kandidat digabungkan dengan data yang diamati untuk memperoleh probabilitas akhir dari suatu hipotesis. Jadi, dua komponen penting adalah probabilitas awal dari setiap hipotesis kandidat dan distribusi probabilitas atas kumpulan data yang diamati untuk setiap hipotesis yang mungkin.
- Pendekatan Bayesian terhadap pembelajaran lebih fleksibel daripada pendekatan lain karena setiap pola pelatihan yang diamati dapat memengaruhi hasil hipotesis dengan menambah atau mengurangi probabilitas yang diestimasikan tentang hipotesis tersebut, sedangkan sebagian besar algoritme lain cenderung menghilangkan hipotesis jika hal itu tidak konsisten dengan pola pelatihan tunggal.

- Metode Bayesian dapat bekerja lebih baik daripada metode lain saat memvalidasi hipotesis yang menghasilkan prediksi probabilistik. Misalnya, saat memulai proyek perangkat lunak baru, berdasarkan demografi proyek, kita dapat memprediksi kemungkinan menghadapi tantangan selama pelaksanaan proyek.
- Melalui pendekatan metode Bayesian yang mudah, adalah mungkin untuk mengklasifikasikan kejadian baru dengan menggabungkan prediksi beberapa hipotesis, yang dibobot berdasarkan probabilitasnya masing-masing.
- Dalam beberapa kasus, ketika metode Bayesian tidak dapat menghitung hasil secara deterministik, metode tersebut dapat digunakan untuk membuat standar keputusan optimal yang dapat digunakan sebagai dasar pengukuran kinerja metode lainnya.

Seperti yang telah kita bahas di atas, keberhasilan metode Bayesian sangat bergantung pada ketersediaan pengetahuan awal tentang probabilitas himpunan hipotesis. Jadi, jika probabilitas ini tidak kita ketahui sebelumnya, kita harus menggunakan beberapa pengetahuan latar belakang, data atau asumsi sebelumnya tentang himpunan data, dan fungsi distribusi probabilitas terkait. Untuk menerapkan metode ini. Selain itu, biasanya diperlukan biaya komputasi yang tinggi untuk mencapai hipotesis Bayes yang optimal.

6.3 TEOREMA BAYES

Sebelum kita membahas teorema Bayes dan penerapannya dalam pembelajaran konsep, kita harus memahami dengan jelas apa itu pembelajaran konsep. Mari kita ambil contoh bagaimana seorang anak

mulai mempelajari makna kata-kata baru, misalnya 'bola'. Anak diberikan contoh-contoh positif tentang 'objek' yaitu 'bola'. Pada awalnya, anak mungkin bingung dengan berbagai warna, bentuk, dan ukuran bola dan mungkin juga bingung dengan beberapa objek yang terlihat seperti bola, seperti balon atau bola dunia. Orang tua anak terus-menerus memberinya contoh-contoh positif seperti 'itu bola', 'ini bola hijau', 'bawakan aku bola kecil itu', dll. Jarang ada contoh-contoh negatif yang digunakan untuk pengajaran konsep seperti itu, seperti 'ini bukan bola', tetapi orang tua dapat menjernihkan kebingungan anak ketika anak menunjuk balon dan mengatakan itu bola dengan mengatakan 'itu bukan bola'. Namun, diamati bahwa pembelajaran lebih banyak dipengaruhi melalui contoh positif daripada contoh negatif, dan harapannya adalah anak akan mampu mengidentifikasi objek 'bola' dari berbagai macam objek dan berbagai jenis bola yang disatukan begitu konsep bola menjadi jelas baginya. Kita dapat memperluas contoh ini untuk menjelaskan bagaimana kita dapat mengharapkan mesin belajar melalui pemberian contoh positif, yang menjadi dasar pembelajaran konsep.

Untuk mengaitkan konsep pembelajaran yang disebutkan di atas dengan model matematika Bayes, kita dapat mengkorelasikan proses pembelajaran 'makna sebuah kata' sebagai padanan pembelajaran, sebuah konsep menggunakan klasifikasi biner. Mari kita definisikan himpunan konsep C dan fungsi $f(k)$ yang sesuai. Kita juga mendefinisikan $f(k) = 1$, ketika k berada dalam himpunan C dan $f(k) = 0$ jika tidak. Tujuan kita adalah mempelajari fungsi indikator f yang mendefinisikan elemen mana yang berada dalam himpunan C . Jadi, dengan menggunakan fungsi f , kita akan dapat mengklasifikasikan elemen baik di dalam maupun di luar himpunan konsep kita. Dalam teorema Bayes, kita akan mempelajari cara

menggunakan kalkulus probabilitas standar untuk menentukan ketidakpastian tentang fungsi f , dan kita dapat memvalidasi klasifikasi dengan memberikan contoh positif.

Ada beberapa notasi yang akan diperkenalkan sebelum membahas rincian teorema Bayes. **Bab 5**, kita sudah membahas aturan probabilitas Bayes seperti yang diberikan di bawah ini:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

di mana A dan B adalah peristiwa yang berhubungan secara kondisional dan $P(A|B)$ menunjukkan probabilitas terjadinya peristiwa A ketika peristiwa B telah terjadi.

Mari kita asumsikan bahwa kita memiliki set data pelatihan D di mana kita telah mencatat beberapa data teramati. Tugas kita adalah menentukan hipotesis terbaik dalam ruang H dengan menggunakan pengetahuan tentang D .

6.3.1 Sebelumnya

Pengetahuan atau keyakinan sebelumnya tentang probabilitas berbagai hipotesis dalam H disebut Prior dalam konteks teorema Bayes. Misalnya, jika kita harus menentukan apakah jenis tumor tertentu bersifat ganas bagi seorang pasien, pengetahuan sebelumnya tentang tumor tersebut yang menjadi ganas dapat digunakan untuk memvalidasi hipotesis kita saat ini dan merupakan probabilitas sebelumnya atau disebut Prior.

Mari kita perkenalkan beberapa notasi untuk menjelaskan konsep-konsep tersebut. Kita akan berasumsi bahwa $P(h)$ adalah probabilitas awal dari hipotesis ' h ' bahwa pasien memiliki tumor ganas berdasarkan hanya pada uji keganasan, tanpa mempertimbangkan pengetahuan sebelumnya

tentang kebenaran proses uji atau yang disebut data pelatihan. Demikian pula, $P(T)$ adalah probabilitas sebelumnya bahwa data pelatihan akan diamati atau, dalam kasus ini, probabilitas hasil uji keganasan positif. Kita akan menyatakan $P(T|h)$ sebagai probabilitas mengamati data T dalam ruang di mana ' h ' berlaku benar, yang berarti probabilitas hasil uji menunjukkan nilai positif ketika tumor sebenarnya ganas.

6.3.2 Belakang

Probabilitas bahwa hipotesis tertentu berlaku untuk kumpulan data berdasarkan Prior disebut probabilitas posterior atau hanya Posterior. Dalam contoh di atas, probabilitas hipotesis bahwa pasien memiliki tumor ganas dengan mempertimbangkan Prior dari kebenaran uji keganasan adalah probabilitas posterior. Dalam notasi kami, kami akan mengatakan bahwa kami tertarik untuk mengetahui $P(h|T)$, yang berarti apakah hipotesis berlaku benar mengingat data pelatihan yang diamati T . Ini disebut probabilitas posterior atau hanya Posterior dalam bahasa pembelajaran mesin. Jadi, probabilitas prior $P(h)$, yang mewakili probabilitas hipotesis yang independen dari data pelatihan (Prior), sekarang disempurnakan dengan pengenalan pengaruh data pelatihan sebagai $P(h|T)$.

Menurut teorema Bayes

$$P(h|T) = \frac{P(T|h)P(h)}{P(T)}$$

menggabungkan probabilitas sebelumnya dan probabilitas posterior bersama-sama.

Dari persamaan di atas, kita dapat menyimpulkan bahwa $P(h|T)$ meningkat seiring dengan peningkatan $P(h)$ dan $P(T|h)$ dan juga seiring

dengan penurunan $P(T)$. Penjelasan sederhananya adalah bahwa ketika ada lebih banyak kemungkinan bahwa T dapat terjadi secara independen dari h maka semakin kecil kemungkinan bahwa h dapat memperoleh dukungan dari T dalam kemunculannya.

Ini adalah pertanyaan umum dalam masalah pembelajaran mesin untuk mengetahui hipotesis maksimum yang mungkin h dari serangkaian hipotesis H ($h \in H$) dengan data pelatihan yang diamati T . Hipotesis yang paling mungkin ini disebut hipotesis posteriori maksimum (MAP). Dengan menggunakan teorema Bayes, kita dapat mengidentifikasi hipotesis MAP dari probabilitas posterior setiap hipotesis kandidat:

$$\begin{aligned} h_{\text{MAP}} &= \operatorname{argmax}_{h \in H} P(h|T) \\ &= \operatorname{argmax}_{h \in H} \frac{P(T|h)P(h)}{P(T)} \end{aligned}$$


dan karena $P(T)$ adalah konstanta yang tidak bergantung pada h , dalam kasus ini, kita dapat menulis

$$= \operatorname{argmax}_{h \in H} P(T|h)P(h) \quad (6.1)$$

6.3.3 Kemungkinan

Dalam masalah pembelajaran mesin tertentu, kita dapat menyederhanakannya lebih lanjut persamaan 6.1 jika setiap hipotesis dalam H memiliki kemungkinan apriori yang sama seperti $P(h_i) = P(h_j)$, maka kita dapat menentukan $P(h|T)$ dari probabilitas $P(T|h)$ saja. Jadi, $P(T|h)$ disebut kemungkinan data T yang diberikan h , dan setiap hipotesis yang memaksimalkan $P(T|h)$ disebut hipotesis kemungkinan maksimum (ML), h_{ML} . Lihat gambar 6.1 dan 6.2 untuk representasi konseptual dan matematis teorema Bayes dan hubungan Prior, Posterior dan Likelihood.

$$h_{\text{ML}} = \operatorname{argmax}_{h \in H} P(T|h) \quad (6.2)$$



GAMBAR 6.1 Teorema Bayes

$$P(h|T) = \frac{P(T|h) P(h)}{P(T)}$$

The diagram shows the formula for Bayes' Theorem with arrows pointing to its components: 'likelihood' points to $P(T|h)$, 'prior probability' points to $P(h)$, 'posterior probability' points to $P(h|T)$, and 'marginal likelihood' points to $P(T)$.

GAMBAR 6.2 Konsep prior, posterior, dan likelihood

Contoh. Mari kita ambil contoh identifikasi keganasan pada tumor pasien tertentu sebagai penerapan aturan Bayes. Kita akan menghitung bagaimana pengetahuan sebelumnya tentang persentase kasus kanker dalam populasi sampel dan probabilitas hasil uji yang benar memengaruhi probabilitas hasil diagnosis yang benar. Kita memiliki dua hipotesis alternatif: (1) tumor tertentu berjenis ganas dan (2) tumor tertentu berjenis tidak ganas. Priori yang tersedia adalah—1. hanya 0,5% dari populasi yang memiliki jenis tumor ini yang ganas, 2. laporan laboratorium memiliki sejumlah ketidaktepatan karena dapat mendeteksi keganasan hanya dengan akurasi 98% sedangkan dapat menunjukkan keganasan

tidak ada dengan benar hanya pada 97% kasus. Ini berarti uji tersebut memprediksi keganasan yang sebenarnya merupakan alarm palsu pada 2% kasus, dan juga gagal mendeteksi tumor ganas yang sebenarnya pada 3% kasus.

Larutan: Mari kita sebutkan Tumor Ganas = MT, Positif

Tes Lab = PT, Tes Lab Negatif = NT

H_1 = tumor tertentu adalah jenis ganas = MT di kami

contoh

H_2 = tumor tertentu bukan jenis ganas = !MT di

contoh kita

$$P(MT) = 0,005 \quad P(!MT) = 0,995$$

$$P(PT|MT) = 0,98 \quad P(PT|!MT) = 0,02$$

$$P(NT|!MT) = 0,97$$

Nah, untuk pasien baru ini, kalau hasil labnya positif, kita lihat apakah bisa dinyatakan sebagai kasus keganasan atau tidak:

$$\begin{aligned} P(h_1|PT) &= \frac{P(PT|h_1) \cdot P(h_1)}{P(PT)} \\ &= P(PT|MT) P(MT) \\ &= 0,98 \times 0,005 \\ &= 0,0049 \\ &= 0,49\% \end{aligned}$$

$$\begin{aligned} P(h_2|PT) &= \frac{P(PT|h_2) \cdot P(h_2)}{P(PT)} \\ &= P(PT|!MT) P(!MT) \\ &= 0,02 \times 0,995 \\ &= 0,0199 \\ &= 1,99\% \end{aligned}$$

Karena $P(h_2 | PT)$ lebih tinggi daripada $P(h_1 | PT)$, jelas bahwa hipotesis h_2 memiliki probabilitas lebih besar untuk menjadi kenyataan. Jadi, $hMAP = h_2 = \text{!MT}$.

Hal ini menunjukkan bahwa meskipun probabilitas posterior keganasan secara signifikan lebih tinggi daripada probabilitas nonkeganasan, probabilitas pasien ini tidak memiliki keganasan masih lebih tinggi berdasarkan pengetahuan sebelumnya. Perlu dicatat juga bahwa melalui teorema Bayes, kami mengidentifikasi probabilitas satu hipotesis lebih tinggi daripada hipotesis lainnya, dan kami tidak sepenuhnya menerima atau menolak hipotesis tersebut melalui teorema ini. Lebih jauh, terdapat ketergantungan yang sangat tinggi pada ketersediaan data sebelumnya untuk penerapan teorema Bayes yang berhasil.

6.4 TEOREMA BAYES DAN KONSEP PEMBELAJARAN

Salah satu pandangan sederhana tentang pembelajaran konsep adalah jika kita memberi mesin data pelatihan, maka mesin dapat menghitung probabilitas posterior hipotesis dan menghasilkan hipotesis yang paling mungkin. Ini juga disebut algoritma pembelajaran Bayesian brute-force, dan juga diamati bahwa konsistensi dalam memberikan hipotesis yang mungkin benar oleh algoritma ini sangat sebanding dengan algoritma lainnya.

6.4.1 Algoritma Bayesian dengan metode brute force

Sekarang kita akan membahas cara menggunakan output hipotesis MAP untuk merancang algoritma pembelajaran sederhana yang disebut

algoritma pembelajaran peta brute-force. Mari kita asumsikan bahwa pembelajar mempertimbangkan ruang hipotesis terbatas H di mana pembelajar akan mencoba mempelajari beberapa konsep target $c: X \rightarrow \{0,1\}$ di mana X adalah ruang instans yang sesuai dengan H . Urutan contoh pelatihan adalah $\{(x_1, t_1), (x_2, t_2), \dots, (x_m, t_m)\}$, di mana x_i adalah instans X dan t_i adalah konsep target x_i yang didefinisikan sebagai $t_i = c(x_i)$. Tanpa memengaruhi efisiensi algoritma, kita dapat mengasumsikan bahwa urutan instans $x = \{x_1, \dots, x_m\}$ dipertahankan tetap, dan kemudian, urutan nilai target menjadi $T = \{t_1, \dots, t_m\}$.

Untuk menghitung probabilitas posterior tertinggi, kita dapat menggunakan teorema Bayes seperti yang dibahas sebelumnya dalam bab ini:

Hitung probabilitas posterior setiap hipotesis h di H :

$$P(h|T) = \frac{P(T|h)P(h)}{P(T)}$$

Identifikasi hMAP dengan probabilitas posterior tertinggi.

$$H_{\text{PETA}} = \text{argmaks}_{h \in H} P(h|T)$$

Perlu dicatat bahwa menghitung probabilitas posterior untuk setiap hipotesis memerlukan volume komputasi yang sangat tinggi, dan untuk volume ruang hipotesis yang besar, hal ini mungkin sulit dicapai.

Mari kita coba menghubungkan masalah pembelajaran konseptual dengan masalah mengidentifikasi hMAP. Berdasarkan distribusi probabilitas $P(h)$ dan $P(T|h)$, kita dapat memperoleh pengetahuan awal dari tugas pembelajaran. Ada beberapa asumsi penting yang harus dibuat sebagai berikut:

1. Data pelatihan atau urutan target T bebas gangguan, yang berarti bahwa itu adalah fungsi langsung dari X saja (yaitu $t_i = c(x_i)$).
2. Konsep c terletak dalam ruang hipotesis H
3. Setiap hipotesis memiliki kemungkinan yang sama dan independen satu sama lain.

Berdasarkan asumsi 3, kita dapat mengatakan bahwa setiap hipotesis h dalam ruang H mempunyai probabilitas prior yang sama, dan juga karena asumsi 2, kita dapat mengatakan bahwa probabilitas prior ini berjumlah 1. Jadi, kita dapat menulis.

$$P(h) = \frac{1}{|H|} \text{ for all } h \text{ within } H \quad (6.3)$$

$P(T|h)$ adalah probabilitas mengamati nilai target t_i dalam himpunan tetap $\{x_i, \dots, x_m\}$ di ruang di mana h berlaku dan menggambarkan konsep c dengan benar. Dengan menggunakan asumsi 1 yang disebutkan di atas, kita dapat mengatakan bahwa jika T konsisten dengan h , maka probabilitas data T dengan hipotesis h adalah 1 dan jika tidak maka adalah 0:

$$P(T|h) = \begin{cases} 1 & \text{if } t_i = h(x_i) \text{ for all } t_i \text{ within } T \\ 0 & \text{otherwise} \end{cases} \quad (6.4)$$

Menggunakan teorema Bayes untuk mengidentifikasi probabilitas posterior.

$$P(h|T) = \frac{P(T|h)P(h)}{P(T)} \quad (6.5)$$

Untuk kasus ketika h tidak konsisten dengan data pelatihan T , menggunakan 6,5 kita memperoleh

$$P(h|T) = \frac{0 \times P(h)}{P(T)} = 0, \text{ ketika } h \text{ tidak konsisten dengan } T, \\ \text{dan ketika } h \text{ konsisten dengan } T$$

$$P(h|T) = \frac{1 \times \frac{1}{|H|}}{P(T)} = \frac{1}{|H|P(T)} \quad (6.6)$$

Sekarang, jika kita mendefinisikan subset dari hipotesis H yang konsisten dengan T sebagai H_D , maka dengan menggunakan persamaan probabilitas total, kita memperoleh

$$\begin{aligned} P(T) &= \sum_{h_i \in H_D} P(T|h_i)P(h_i) \\ &= \sum_{h_i \in H_D} 1 \cdot \frac{1}{|H|} + \sum_{h_i \notin H_D} 0 \cdot \frac{1}{|H|} \\ &= \sum_{h_i \in H_D} 1 \cdot \frac{1}{|H|} \\ &= \frac{|H_D|}{|H|} \end{aligned}$$

Ini membuat 6,5 sebagai

$$\begin{aligned} P(h|T) &= \frac{1}{|H| \cdot \frac{|H_D|}{|H|}} \\ &= \frac{1}{|H_D|} \end{aligned}$$

Jadi, dengan asumsi kita tentang $P(h)$ dan $P(T|h)$, kita memperoleh probabilitas posterior $P(h|T)$ sebagai

$$P(h|T) = \begin{cases} \frac{1}{|H_D|} & \text{if } h \text{ is consistent with } T \\ 0 & \text{otherwise} \end{cases} \quad (6.7)$$

di mana H_D adalah jumlah hipotesis dari ruang H yang konsisten dengan kumpulan data target T . Interpretasi dari evaluasi ini adalah bahwa pada awalnya, setiap hipotesis memiliki probabilitas yang sama dan, saat kita memasukkan data pelatihan, probabilitas posterior hipotesis yang tidak konsisten menjadi nol dan total probabilitas yang berjumlah 1 didistribusikan secara merata di antara hipotesis yang konsisten dalam kumpulan tersebut. Jadi, dalam kondisi ini, setiap hipotesis yang konsisten adalah hipotesis MAP dengan probabilitas posterior

kemungkinan $\frac{1}{|H_D|}$.

6.4.2 Konsep pembelajar yang konsisten

Dari pembahasan di atas, kita memahami perilaku kelas umum pembelajar yang kita sebut sebagai pembelajar konsisten. Jadi, kelompok pembelajar yang melakukan kesalahan nol atas data pelatihan dan mengeluarkan hipotesis disebut pembelajar konsisten. Jika data pelatihan bebas gangguan dan deterministik (yaitu $P(D|h) = 1$ jika D dan h konsisten dan 0 sebaliknya) dan jika ada distribusi probabilitas prior seragam atas H (jadi, $P(hm) = P(hn)$ untuk semua m, n), maka setiap pembelajar konsisten mengeluarkan hipotesis MAP. Aplikasi penting dari kesimpulan ini adalah bahwa teorema Bayes dapat mengkarakterisasi perilaku algoritma pembelajaran bahkan ketika algoritma tidak secara eksplisit memanipulasi probabilitas. Karena dapat membantu mengidentifikasi distribusi optimal $P(h)$ dan $P(T|h)$ di mana algoritma mengeluarkan hipotesis MAP, pengetahuan dapat digunakan untuk mengkarakterisasi asumsi di mana algoritma berperilaku optimal.

Meskipun kita membahas dalam bagian ini kasus khusus keluaran Bayesian yang sesuai dengan data pelatihan bebas gangguan dan prediksi mengatur gangguan.

6.4.3 Klasifikasi optimal Bayes

Pada bagian ini, kita akan membahas penggunaan hipotesis MAP untuk menjawab pertanyaan deterministik hipotesis di mana $P(T|h)$ bernilai 1 atau 0, teorema tersebut dapat digunakan dengan efektivitas

yang sama untuk data pelatihan yang terganggu dan asumsi tambahan tentang distribusi probabilitas yang apa klasifikasi yang paling mungkin dari contoh baru yang diberikan data pelatihan. Untuk mengilustrasikan konsep tersebut, mari kita asumsikan tiga hipotesis h_1 , h_2 , dan h_3 dalam ruang hipotesis H . Misalkan probabilitas posterior dari hipotesis ini masing-masing adalah 0,4, 0,3, dan 0,3. Ada contoh baru x , yang diklasifikasikan sebagai benar oleh h_1 , tetapi salah oleh h_2 dan h_3 .

Maka klasifikasi yang paling mungkin dari contoh baru (x) dapat diperoleh dengan menggabungkan prediksi semua hipotesis yang ditimbang dengan probabilitas posteriornya yang sesuai. Dengan menunjukkan kemungkinan klasifikasi contoh baru sebagai c_i dari himpunan C , probabilitas $P(c_i|T)$ bahwa klasifikasi yang benar untuk contoh baru adalah c_i adalah.

$$P(c_i|T) = \sum_{h_i \in H} P(c_i|h_i)P(h_i|T)$$

Klasifikasi optimal yang $P(c_i|T)$ -nya maksimum adalah

$$\text{Bayes optimal classifier} = \underset{c_i \in C}{\operatorname{argmax}} \sum_{h_i \in H} P(c_i|h_i)P(h_i|T)$$

Jadi, memperluas contoh di atas,

Himpunan kemungkinan hasil untuk kasus baru x ada dalam himpunan $C = \{\text{Benar, Salah}\}$ dan

$$P(h_1 | T) = 0,4, P(\text{Salah} | h_1) = 0, P(\text{Benar} | h_1) = 1$$

$$P(h_2 | T) = 0,3, P(\text{Salah} | h_2) = 1, P(\text{Benar} | h_2) = 0$$

$$P(h_3 | T) = 0,3, P(\text{Salah} | h_3) = 1, P(\text{Benar} | h_3) = 0$$

Kemudian,

$$\sum_{h_i \in H} P(\text{True} | h_i) P(h_i | T) = 0.4$$

$$\sum_{h_i \in H} P(\text{False} | h_i) P(h_i | T) = 0.6$$

Dan

$$\underset{c_i \in \{\text{True}, \text{False}\}}{\text{argmax}} \sum_{h_i \in H} P(c_i | h_i) P(h_i | T) = \text{False}$$

Metode ini memaksimalkan kemungkinan bahwa contoh baru diklasifikasikan dengan benar ketika data pelatihan yang tersedia, ruang hipotesis, dan probabilitas hipotesis sebelumnya diketahui. Oleh karena itu, metode ini juga disebut pengklasifikasi optimal Bayes.

6.4.4 Pengklasifikasi Naïve Bayes

Naïve Bayes adalah teknik sederhana untuk membangun pengklasifikasi: model yang menetapkan label kelas pada contoh masalah. Ide dasar aturan Bayes adalah bahwa hasil hipotesis dapat diprediksi berdasarkan beberapa bukti (E) yang dapat diamati.

Dari aturan Bayes, kita mengamati bahwa

1. Probabilitas sebelumnya dari hipotesis h atau $P(h)$: Ini adalah probabilitas suatu peristiwa atau hipotesis sebelum bukti diamati.
2. Probabilitas posterior h atau $P(h|D)$: Ini adalah probabilitas suatu kejadian setelah bukti diamati dalam populasi D .

$$\text{Posterior probability} = \frac{(\text{Prior probability} \times \text{Conditional Probability})}{\text{Evidence}}$$

Probabilitas Posterior berformat 'Berapa probabilitas bahwa suatu objek tertentu termasuk kelas i berdasarkan nilai fitur yang diamati?'

Misalnya, seseorang memiliki tinggi dan berat masing-masing 182 cm dan 68 kg. Berapa probabilitas bahwa orang ini termasuk dalam kelas "pemain basket"? Hal ini dapat diprediksi menggunakan pengklasifikasi Naïve Bayes. Klasifikasi ini dikenal sebagai klasifikasi probabilistik.

Dalam pembelajaran mesin, pengklasifikasi probabilistik adalah pengklasifikasi yang dapat diramalkan, berdasarkan persepsi atau informasi (input), kalkulasi kemungkinan atas sekumpulan kelas, alih-alih hanya menghasilkan (mengeluarkan) kelas yang paling mungkin menjadi tempat persepsi (observasi) tersebut. Estimasi parameter untuk model Naïve Bayes menggunakan metode ML.

Teorema Bayes digunakan ketika informasi baru dapat digunakan untuk merevisi probabilitas yang telah ditentukan sebelumnya. Bergantung pada sifat khusus model probabilitas, pengklasifikasi Naïve Bayes dapat dilatih secara sangat profesional dalam lingkungan pembelajaran terbimbing.

Mari kita lihat dasar untuk memperoleh prinsip-prinsip pengklasifikasi Naïve Bayes. Kita ambil tugas pembelajaran di mana setiap contoh x memiliki beberapa atribut dan fungsi target ($f(x)$) dapat mengambil nilai apa pun dari himpunan terbatas nilai klasifikasi C . Kita juga memiliki sekumpulan contoh pelatihan untuk fungsi target, dan himpunan atribut $\{a_1, a_2, \dots, a_n\}$ untuk contoh baru tersebut diketahui oleh kita. Tugas kita adalah memprediksi klasifikasi contoh baru tersebut.

Berdasarkan pendekatan dalam teorema Bayes, klasifikasi instance baru dilakukan dengan menetapkan target klasifikasi CMAP yang paling mungkin berdasarkan nilai atribut instance baru $\{a_1, a_2, \dots, a_n\}$. Jadi,

$$C_{\text{MAP}} = \underset{c_i \in C}{\operatorname{argmax}} \sum_{h_i \in H} P(c_i | a_1, a_2, \dots, a_n)$$

yang dapat ditulis ulang menggunakan teorema Bayes sebagai

$$C_{\text{MAP}} = \underset{c_i \in C}{\operatorname{argmax}} \sum_{h_i \in H} \frac{P(a_1, a_2, \dots, a_n | c_i) P(c_i)}{P(a_1, \dots, a_n)}$$

Karena gabungan probabilitas atribut yang mendefinisikan instance baru secara penuh selalu 1

$$C_{\text{MAP}} = \underset{c_i \in C}{\operatorname{argmax}} \sum_{h_i \in H} P(a_1, a_2, \dots, a_n | c_i) P(c_i) \quad (6.8)$$

Jadi, untuk mendapatkan pengklasifikasi yang paling mungkin, kita harus mengevaluasi dua suku $P(a_1, a_2, \dots, a_n | c_i)$ dan $P(c_i)$. Dalam skenario praktis, adalah mungkin untuk menghitung $P(c_i)$ dengan menghitung frekuensi setiap nilai target c_i dalam set data pelatihan. Namun, $P(a_1, a_2, \dots, a_n | c_i)$ tidak dapat diestimasi dengan mudah dan memerlukan upaya perhitungan yang sangat tinggi. Alasannya adalah bahwa jumlah suku-suku ini sama dengan hasil kali jumlah kemungkinan instans dan jumlah kemungkinan nilai target, dan dengan demikian, setiap instans dalam ruang instans perlu dikunjungi berkali-kali untuk sampai pada estimasi kemunculan. Dengan demikian, pengklasifikasi Naïve Bayes membuat asumsi sederhana bahwa nilai atribut secara kondisional independen satu sama lain untuk nilai target. Jadi, dengan menerapkan penyederhanaan ini, kita sekarang dapat mengatakan bahwa untuk nilai target suatu instans, probabilitas mengamati kombinasi $a_1, a_2, \dots, a_n$ adalah hasil kali probabilitas atribut individual $P(a_i | c_j)$.

$$P(a_1, a_2, \dots, a_n | c_j) = \prod_i P(a_i | c_j)$$

Kemudian, dari [persamaan 6.7](#), kita mendapatkan pendekatan untuk Naïve

Klasifikasi Bayes sebagai

$$C_{NB} = \underset{c_i \in C}{\operatorname{argmax}} \sum_{h_i \in H} P(c_i) \prod_i P(a_i | c_i) \quad (6.9)$$

Di sini, kita akan dapat menghitung $P(a_i | c_j)$ karena kita harus menghitungnya hanya untuk jumlah nilai atribut yang berbeda (a_i) dikalikan jumlah nilai target yang berbeda (c_j), yang merupakan himpunan yang jauh lebih kecil daripada hasil perkalian kedua himpunan tersebut. Alasan terpenting untuk popularitas pendekatan pengklasifikasi Naïve Bayes adalah bahwa tidak diperlukan untuk mencari seluruh ruang hipotesis untuk algoritma ini, tetapi kita dapat memperoleh pengklasifikasi target hanya dengan menghitung frekuensi berbagai kombinasi data dalam contoh pelatihan.

Singkatnya, pengklasifikasi Naïve Bayes adalah pengklasifikasi probabilistik utama yang didasarkan pada pandangan penerapan asumsi independensi teorema Bayes (dari inferensi Bayesian dengan naif yang kuat). Probabilitas sebelumnya dalam teorema Bayes yang diubah dengan bantuan informasi yang baru tersedia diklasifikasikan sebagai probabilitas posterior.

Manfaat utama dari pengklasifikasi Naïve Bayes adalah hanya memerlukan sedikit informasi pelatihan (data) untuk mengukur parameter (rata-rata dan selisih variabel) yang penting untuk klasifikasi (pengaturan). Dalam pengklasifikasi Naïve Bayes, variabel independen selalu diasumsikan, dan hanya perubahan (varians) faktor/variabel untuk setiap kelas yang harus ditentukan dan bukan seluruh matriks kovarians. Karena asumsi yang agak naif bahwa semua fitur dari kumpulan data sama pentingnya dan independen, ini disebut pengklasifikasi Naïve Bayes.

Pengklasifikasi Naïve Bayes adalah pengklasifikasi linier langsung yang dikenal sebagai hasil yang mudah dipahami, namun sangat efektif. Versi

modifikasi dari pengklasifikasi Naïve Bayes berasal dari asumsi bahwa pengumpulan informasi (kumpulan data) umumnya bersifat otonom (saling independen). Dalam sebagian besar skenario praktis, asumsi 'independensi' sering dilanggar. Namun, pengklasifikasi Naïve Bayes masih cenderung berkinerja sangat baik.

Beberapa kekuatan dan kelemahan utama dari pengklasifikasi Naïve Bayes dijelaskan dalam [Tabel 6.1](#).

Tabel 6.1*Kekuatan dan Kelemahan Klasifikasi Bayes*

Strengths	Weakness
Simple and fast in calculation but yet effective in result	The basis assumption of equal importance and independence often does not hold true
In situations where there are noisy and missing data, it performs well	If the target dataset contains large numbers of numeric features, then the reliability of the outcome becomes limited
Works equally well when smaller number of data is present for training as well as very large number of training data is available	Though the predicted classes have a high reliability, estimated probabilities have relatively lower reliability
Easy and straightforward way to obtain the estimated probability of a prediction	

Contoh. Mari kita asumsikan bahwa kita ingin memprediksi hasil pertandingan piala dunia sepak bola berdasarkan data performa masa lalu tim yang bertanding. Kita memiliki data pelatihan yang tersedia (lihat [Gambar 6.3](#)) untuk hasil pertandingan yang sebenarnya, sementara empat parameter dipertimbangkan – Kondisi Cuaca (Hujan, Mendung, atau Cerah), berapa banyak pertandingan yang dimenangkan oleh tim ini dari tiga pertandingan terakhir (satu pertandingan, dua pertandingan, atau tiga pertandingan), Kondisi Kelembapan (Tinggi atau Normal), dan

apakah mereka memenangkan undian (Benar atau Salah). Dengan menggunakan Naïve Bayesian, Anda perlu mengklasifikasikan kondisi saat tim ini menang dan kemudian memprediksi probabilitas tim ini memenangkan pertandingan tertentu saat Kondisi Cuaca = Hujan, mereka memenangkan dua dari tiga pertandingan terakhir, Kelembapan = Normal dan mereka memenangkan undian dalam pertandingan tertentu.

Weather Condition	Wins in last 3 matches	Humidity	Win toss	Won match?
Rainy	3 wins	High	FALSE	No
Rainy	3 wins	High	TRUE	No
OverCast	3 wins	High	FALSE	Yes
Sunny	2 wins	High	FALSE	Yes
Sunny	1 win	Normal	FALSE	Yes
Sunny	1 win	Normal	TRUE	No
OverCast	1 win	Normal	TRUE	Yes
Rainy	2 wins	High	FALSE	No
Rainy	1 win	Normal	FALSE	Yes
Sunny	2 wins	Normal	FALSE	Yes
Rainy	2 wins	Normal	TRUE	Yes
OverCast	2 wins	High	TRUE	Yes
OverCast	3 wins	Normal	FALSE	Yes
Sunny	2 wins	High	TRUE	No

GAMBAR 6.3Data pelatihan untuk metode Naïve Bayesian

6.4.4.1 Langkah-langkah pengklasifikasi Naïve Bayes

Langkah 1:Pertama buatlah tabel frekuensi. Tabel frekuensi dibuat untuk setiap atribut terhadap hasil target. Misalnya, dalamGambar 6.3, berbagai atributnya adalah (1) Kondisi Cuaca, (2) Berapa banyak pertandingan yang dimenangkan oleh tim ini dalam tiga pertandingan terakhir, (3) Kondisi Kelembaban, dan (4) apakah mereka memenangkan undian dan hasil targetnya adalah apakah mereka akan memenangkan pertandingan atau tidak?

Langkah 2:Identifikasi probabilitas kumulatif untuk 'Menang pertandingan = Ya' dan probabilitas untuk 'Menang pertandingan = Tidak' berdasarkan semua atribut. Jika tidak, kalikan saja probabilitas semua kondisi yang menguntungkan untuk memperoleh kondisi 'YA'. Kalikan probabilitas semua kondisi yang tidak menguntungkan untuk memperoleh kondisi 'Tidak'.

Langkah 3:Hitung probabilitas melalui normalisasi dengan menerapkan rumus di bawah ini.

$$P(\text{Yes}) = \frac{P(\text{Yes})}{P(\text{Yes}) + P(\text{No})}$$

$$P(\text{No}) = \frac{P(\text{No})}{P(\text{Yes}) + P(\text{No})}$$

$P(\text{Ya})$ akan memberikan kemungkinan keseluruhan kondisi yang menguntungkan dalam skenario yang diberikan.

$P(\text{Tidak})$ akan memberikan kemungkinan keseluruhan kondisi yang tidak menguntungkan dalam skenario yang diberikan.

Memecahkan masalah di atas dengan Naive Bayes

Langkah 1: Buatlah tabel frekuensi. Probabilitas posterior dapat dengan mudah diperoleh dengan membuat tabel frekuensi untuk setiap atribut terhadap target. Misalnya, frekuensi variabel Kondisi Cuaca dengan nilai 'Cerah' saat nilai target yang cocok adalah 'Ya', adalah $3/(3+4+2) = 3/9$.

Gambar 6.4 menunjukkan tabel frekuensi yang dibangun.

Langkah 2:

Untuk memprediksi apakah tim akan menang pada kondisi cuaca tertentu (a_1) =Hujan, Kemenangan dalam tiga pertandingan terakhir (a_2) = 2 kemenangan, Kelembapan (a_3) = Normal dan Undian menang

(a4) = Benar, kita perlu memilih 'Ya' dari tabel di atas untuk kondisi yang diberikan.

Dari teorema Bayes, kita memperoleh

$$P(\text{Win match} | a_1 \cap a_2 \cap a_3 \cap a_4) = \frac{P(a_1 \cap a_2 \cap a_3 \cap a_4 | \text{Win match}) P(\text{Win match})}{P(a_1 \cap a_2 \cap a_3 \cap a_4)}$$

Persamaan ini menjadi jauh lebih mudah dipecahkan jika kita mengingat bahwa pengklasifikasi Naïve Bayes mengasumsikan independensi di antara kejadian. Hal ini khususnya berlaku untuk independensi bersyarat kelas, yang berarti bahwa kejadian-kejadian tersebut independen selama dikondisikan pada nilai kelas yang sama. Selain itu, kita tahu bahwa jika kejadian-kejadian tersebut independen, maka aturan probabilitas mengatakan, $P(A \cap B) = P(A) P(B)$, yang membantu menyederhanakan persamaan di atas secara signifikan sebagai $P(\text{Menangkan pertandingan} | a_1 \cap a_2 \cap a_3 \cap a_4)$

$$\begin{aligned} &= \frac{P(a_1 | \text{Win match}) P(a_2 | \text{Win match}) P(a_3 | \text{Win match}) P(a_4 | \text{Win match}) P(\text{Win match})}{P(a_1) P(a_2) P(a_3) P(a_4)} \\ &= 2/9 * 4/9 * 6/9 * 9/14 \\ &= 0.014109347 \end{aligned}$$

Hal ini harus dibandingkan dengan $P(\text{!Menangkan pertandingan} | a_1 \cap a_2 \cap a_3 \cap a_4)$

$$\begin{aligned} &= \frac{P(a_1 | \text{!Win match}) P(a_2 | \text{!Win match}) P(a_3 | \text{!Win match}) P(a_4 | \text{!Win match}) P(\text{!Win match})}{P(a_1) P(a_2) P(a_3) P(a_4)} \\ &= 3/5 * 2/5 * 1/5 * 5/14 \\ &= 0.010285714 \end{aligned}$$

Weather condition			Humidity		
Won Match			Won Match		
	Yes	No		Yes	No
Sunny	3	2	High	3	4
OverCast	4	0	Normal	6	1
Rainy	2	3			
Total	9	5	Total	9	5

Wins in last 3 matches			Win toss		
Won Match			Won Match		
	Yes	No		Yes	No
3 wins	2	2	FALSE	6	2
1 win	4	2	TRUE	3	3
2 wins	3	1			
Total	9	5	Total	9	5

GAMBAR 6.4Membangun tabel frekuensi

Langkah 3:dengan menormalkan kedua probabilitas di atas, kita dapat memastikan bahwa jumlah kedua probabilitas ini adalah 1.

$$\begin{aligned}
 P(\text{Win match}) &= \frac{P(\text{Win match})}{P(\text{Win match}) + P(!\text{Win match})} \\
 &= \frac{0.014109347}{0.014109347 + 0.010285714} \\
 &= 0.578368999
 \end{aligned}$$

$$\begin{aligned}
 P(!\text{Win match}) &= \frac{P(!\text{Win match})}{P(\text{Win match}) + P(!\text{Win match})} \\
 &= \frac{0.010285714}{0.014109347 + 0.010285714} \\
 &= 0.421631001
 \end{aligned}$$

Kesimpulan: Hal ini menunjukkan bahwa ada 58% kemungkinan tim akan menang jika kondisi di atas menjadi kenyataan pada hari tersebut. Dengan demikian, pengklasifikasi Naïve Bayes menyediakan cara yang sederhana namun ampuh untuk mempertimbangkan pengaruh beberapa atribut pada hasil target dan menyempurnakan ketidakpastian kejadian berdasarkan pengetahuan sebelumnya karena mampu menyederhanakan perhitungan melalui asumsi independensi.

6.4.5 Aplikasi Klasifikasi Naïve Bayes

Klasifikasi teks:Klasifikasi Naïve Bayes termasuk salah satu algoritma yang paling berhasil untuk mempelajari cara mengklasifikasikan dokumen teks. Klasifikasi ini mengklasifikasikan dokumen yang kemungkinan mengklasifikasikan teksnya lebih besar. Klasifikasi ini menggunakan algoritma di atas untuk memeriksa permutasi dan kombinasi kemungkinan mengklasifikasikan dokumen di bawah 'Judul' tertentu. Klasifikasi ini memiliki berbagai aplikasi dalam kategorisasi dokumen, deteksi bahasa, dan deteksi sentimen, yang sangat berguna bagi pengecer tradisional, pengecer daring, dan bisnis lain dalam menilai sentimen klien mereka berdasarkan kata kunci dalam formulir umpan balik, komentar media sosial, dll.

Penyaringan spam:Penyaringan spam merupakan penggunaan klasifikasi teks Naïve Bayesian yang paling dikenal. Saat ini, hampir semua penyedia email memiliki fungsi bawaan ini, yang memanfaatkan pengklasifikasi Naïve Bayes untuk mengidentifikasi email spam berdasarkan kondisi tertentu dan juga kemungkinan mengklasifikasikan email sebagai 'Spam'. Penyaringan spam Naïve Bayesian telah berubah menjadi mekanisme utama untuk mengenali email spam yang tidak sah dari email yang jujur (terkadang disebut 'ham'). Pengguna juga dapat memasang program penyaringan email terpisah. Filter email sisi server seperti DSPAM, Spam Assassin, Spam Bayes, dan ASSP memanfaatkan teknik penyaringan spam Bayesian, dan fungsionalitasnya terkadang tertanam dalam perangkat lunak server email itu sendiri.

Sistem Rekomendasi Hibrida: Ia menggunakan pengklasifikasi Naïve Bayes dan penyaringan kolaboratif. Sistem rekomendasi (digunakan oleh pengecer seperti eBay, Alibaba, Target, Flipkart, dll.) menerapkan pembelajaran mesin dan teknik penambangan data untuk menyaring informasi yang tidak terlihat dan dapat memprediksi apakah pengguna menginginkan sumber daya tertentu. Misalnya, saat kita masuk ke situs web pengecer ini, berdasarkan penggunaan teks yang digunakan oleh login dan data historis pembelian, ia secara otomatis merekomendasikan produk untuk persona login tertentu. Salah satu algoritme menggabungkan pendekatan klasifikasi Naïve Bayes dengan penyaringan kolaboratif, dan hasil eksperimen menunjukkan bahwa algoritme ini memberikan kinerja yang lebih baik terkait akurasi dan cakupan daripada algoritme lainnya.

Analisis Sentimen Online: Aplikasi daring menggunakan pembelajaran mesin terbimbing (Naïve Bayes) dan komputasi yang bermanfaat. Dalam kasus analisis sentimen, mari kita asumsikan ada tiga sentimen seperti baik, buruk, atau netral, dan pengklasifikasi Naïve Bayes digunakan untuk membedakannya.

Pemodelan emosi sederhana menggabungkan pengklasifikasi berbasis statistik dengan model dinamis. Pengklasifikasi Naïve Bayes menggunakan fitur seperti 'kata tunggal' dan 'pasangan kata' dan menentukan sentimen pengguna. Klasifikasi ini mengalokasikan ucapan pengguna ke dalam kelas baik, buruk, dan netral, yang masing-masing diberi label +1, -1, dan 0. Keluaran biner ini menggerakkan sistem dinamis orde pertama yang sederhana, yang keadaan emosinya mewakili keadaan emosi yang disimulasikan dari personifikasi eksperimen.

6.4.6 Penanganan Fitur Numerik Kontinu dalam Naïve Bayes Classifier


Dalam contoh di atas, kita melihat bahwa model pengklasifikasi Naïve Bayes menggunakan tabel frekuensi data pelatihan untuk perhitungannya. Dengan demikian, setiap data atribut harus bersifat kategoris sehingga kombinasi nilai kelas dan fitur dapat dibuat. Namun, hal ini tidak mungkin dilakukan dalam kasus data numerik kontinu karena tidak memiliki kategori data.

Solusi yang diterapkan dalam kasus ini adalah mendiskritisasi data berkelanjutan berdasarkan beberapa rentang data. Ini juga disebut pengelompokan karena kategori individual disebut sebagai pengelompokan. Misalnya, mari kita asumsikan kita ingin memasarkan kartu kredit tertentu kepada semua nasabah yang mengunjungi bank tertentu. Kita harus mengklasifikasikan orang-orang yang mengunjungi bank sebagai kandidat yang berminat untuk mengambil kartu baru atau kandidat yang tidak berminat untuk kartu baru, dan berdasarkan klasifikasi ini, perwakilan akan mendekati nasabah untuk penjualan. Dalam kasus ini, nasabah mengunjungi bank secara terus-menerus selama jam operasional bank dan memiliki nilai yang berbeda untuk atribut yang ingin kita evaluasi sebelum mengklasifikasikan mereka ke dalam kategori berminat/tidak berminat.

Jika kita memetakan jumlah nasabah yang mengunjungi bank selama 8 jam waktu perbankan, grafik distribusinya akan menjadi grafik kontinu. Namun, jika kita memperkenalkan logika untuk mengkategorikan nasabah menurut waktu mereka memasuki bank, maka kita akan dapat menempatkan nasabah dalam 'kotak' atau ember untuk analisis kita. Kita kemudian dapat mencoba menilai rentang waktu apa yang paling cocok untuk menargetkan nasabah yang akan tertarik pada kartu kredit baru.

Kotak yang dibuat dengan mengkategorikan nasabah menurut waktu masuk mereka tampak seperti ini **Gambar 6.5**.

Ini menciptakan delapan wadah alami bagi kita (atau kita dapat mengubah jumlah wadah dengan mengubah kriteria kategorisasi kita), yang sekarang dapat digunakan untuk analisis Bayes.



GAMBAR 6.5Pembagian tempat sampah berdasarkan waktu masuk nasabah di bank

6.5 JARINGAN KEYAKINAN BAYESIAN

Kita harus mencatat bahwa asumsi penting dalam pengklasifikasi Naïve Bayes adalah bahwa nilai atribut $a_1, a_2, \dots$, dan bersifat independen secara kondisional untuk nilai target. Pengklasifikasi Naïve Bayes menghasilkan keluaran optimal saat kondisi ini terpenuhi. Meskipun asumsi ini secara signifikan mengurangi kompleksitas komputasi, dalam banyak skenario praktis, persyaratan independensi kondisional ini menjadi kendala yang sulit untuk penerapan algoritma ini. Jadi, di bagian ini, kita akan membahas pendekatan jaringan Keyakinan Bayesian, yang mengasumsikan bahwa dalam kumpulan atribut, distribusi probabilitas

dapat memiliki hubungan probabilitas kondisional serta asumsi independensi kondisional. Ini berbeda dari asumsi Naïve Bayes tentang independensi kondisional semua atribut karena jaringan keyakinan memberikan fleksibilitas untuk mendeklarasikan sebagian atribut sebagai dependen kondisional sambil membiarkan atribut lainnya memegang asumsi independensi kondisional. Pengetahuan atau keyakinan sebelumnya tentang pengaruh satu atribut terhadap yang lain ditangani melalui probabilitas gabungan seperti yang dibahas nanti di bagian ini.

Mari kita segarkan pikiran kita tentang konsep probabilitas bersyarat. Jika suatu peristiwa tak pasti A bergantung pada pengetahuan atau keyakinan K , maka tingkat keyakinan terhadap A dengan asumsi bahwa K diketahui dinyatakan sebagai $P(A|K)$. Secara tradisional, probabilitas bersyarat dinyatakan dengan probabilitas gabungan sebagai berikut:

$$P(A|K) = \frac{P(A, K)}{P(K)} \quad (6.10)$$

Dengan menata ulang (6.9), kita memperoleh aturan produk

$$P(A, K) = P(A|K)P(K)$$


Hal ini dapat diperluas untuk tiga variabel atau atribut sebagai

$$P(A, K, C) = P(A|K, C)P(K, C) = P(A|K, C)P(K|C)P(C)$$

Untuk sekumpulan n atribut, bentuk umum dari aturan produk menjadi

$$P(A_1, A_2, \dots, A_n) = P(A_1|A_2, \dots, A_n)P(A_2|A_3, \dots, A_n)P(A_{n-1}|A_n)P(A_n) \quad (6.10)$$

Versi umum dari aturan produk ini disebut Aturan Rantai.



GAMBAR 6.6Aturan rantai

Mari kita pahami aturan rantai dengan menggunakan diagram di Gambar 6.6. Dari rumus probabilitas gabungan 6.10, kita dapat menuliskan

$$P(A, B, C, D, E) = P(A|B, C, D, E)P(B|C, D, E)P(C|D, E)P(D|E)P(E)$$

Tapi dari Gambar 6.6, jelaslah bahwa E tidak berhubungan dengan C dan D, yang berarti bahwa probabilitas variabel C dan D tidak dipengaruhi oleh E dan sebaliknya. Demikian pula, A secara langsung hanya dipengaruhi oleh B. Dengan menerapkan pengetahuan tentang independensi ini, kita dapat menyederhanakan persamaan di atas sebagai

$$P(A, B, C, D, E) = P(A|B)P(B|C, D)P(C|D)P(D)P(E)$$

Mari kita bahas konsep independensi dan independensi bersyarat ini secara rinci di bagian berikutnya.

6.5.1 Independensi dan independensi bersyarat

Kami merepresentasikan probabilitas bersyarat A dengan pengetahuan tentang K sebagai $P(A|K)$. Variabel A dan K dikatakan independen jika $P(A|K) = P(A)$, yang berarti tidak ada pengaruh K terhadap ketidakpastian A . Demikian pula, probabilitas gabungan dapat ditulis sebagai $P(A,K) = P(A)P(K)$.

Dengan memperluas konsep ini, variabel A dan K dikatakan independen bersyarat jika C $P(A|C) = P(A|K, C)$.

Konsep independensi bersyarat ini juga dapat diperluas ke sekumpulan atribut. Kita dapat mengatakan bahwa sekumpulan variabel $A_1, A_2, \dots, A_n$ bersifat independen bersyarat terhadap sekumpulan variabel $B_1, B_2, \dots, B_m$ jika diberikan sekumpulan variabel $C_1, C_2, \dots, C_l$ jika


$$P(A_1, A_2, \dots, A_n | B_1, B_2, \dots, B_m, C_1, C_2, \dots, C_l) = P(A_1, A_2, \dots, A_n | C_1, C_2, \dots, C_l)$$

Jika kita bandingkan definisi ini dengan asumsi kita dalam pengklasifikasi Naïve Bayes, kita melihat bahwa pengklasifikasi Naïve Bayes mengasumsikan bahwa atribut instan A_1 bersifat independen secara kondisional terhadap atribut instan A_2 , dengan nilai target V , yang dapat ditulis menggunakan aturan produk umum dan penerapan rumus independensi kondisional sebagai

$$P(A_1, A_2 | V) = P(A_1 | A_2, V)P(A_2, V) = P(A_1, V)P(A_2, V)$$

Jaringan Kepercayaan Bayesian menggambarkan distribusi probabilitas gabungan dari sekumpulan atribut dalam ruang gabungannya. Gambar 6.7, disajikan sebuah jaringan Keyakinan Bayesian. Diagram tersebut terdiri dari simpul dan busur. Simpul mewakili variabel diskrit atau kontinu yang ingin kita hitung probabilitas kondisionalnya. Busur mewakili hubungan kausal variabel.

Dua titik informasi penting yang kita peroleh dari grafik jaringan ini digunakan untuk menentukan probabilitas gabungan variabel-variabel tersebut. Pertama, busur-busur tersebut menegaskan bahwa variabel-variabel simpul secara kondisional independen dari non-keturunannya dalam jaringan yang diberikan pendahulu langsungnya dalam jaringan. Jika dua variabel A dan B terhubung melalui jalur berarah, maka B disebut sebagai turunan dari A. Kedua, tabel probabilitas kondisional untuk setiap variabel menyediakan distribusi probabilitas variabel tersebut yang diberikan nilai-nilai pendahulu langsungnya. Kita dapat menggunakan probabilitas Bayesian untuk menghitung perilaku variabel yang berbeda dalam Gambar 6.7.



GAMBAR 6.7Jaringan kepercayaan Bayesian

1. Peluang tanpa syarat bahwa Tim terlambat ke kelas – $P(\text{Tim terlambat ke kelas})$

$$\begin{aligned}
&= P(\text{Waktu terlambat}|\text{Hujan Hari Ini})P(\text{Hujan Hari Ini}) + \\
&P(\text{Waktu terlambat}|\text{Tidak Hujan Hari ini})P(\text{Tidak Hujan Hari Ini}) \\
&= (0,8 \times 0,1) + (0,1 \times 0,9) \\
&= 0,17
\end{aligned}$$

Dari probabilitas tanpa syarat ini, penggunaan terpenting dari jaringan Keyakinan Bayesian adalah untuk mengetahui probabilitas yang direvisi berdasarkan pengetahuan sebelumnya. Jika kita berasumsi bahwa hari ini hujan, maka tabel probabilitas dapat dengan cepat memberi kita informasi tentang probabilitas Paul terlambat ke kelas atau probabilitas Tim terlambat ke kelas dari tabel distribusi probabilitas itu sendiri. Namun jika kita tidak tahu apakah hari ini hujan atau tidak, tetapi kita hanya tahu bahwa Tim terlambat ke kelas hari ini, maka kita dapat memperoleh probabilitas berikut –

2. Kemungkinan yang direvisi bahwa ada hujan hari ini –

$$\begin{aligned}
P(\text{Rain Today}|\text{Tim late to class}) &= \frac{P(\text{Tim late}|\text{Rain today}) P(\text{Rain today})}{P(\text{Tim late})} \\
&= \frac{(0,8 \times 0,1)}{0,17} \\
&= 0,47 \\
&= P(\text{Rain Today}) \text{ as Tim late to class is already known}
\end{aligned}$$

3. Kemungkinan yang direvisi bahwa Paul akan terlambat ke kelas hari ini –

$$P(\text{Paul terlambat masuk kelas hari ini})$$


$$\begin{aligned}
 &= P(\text{Paul terlambat}|\text{Hujan hari ini})P(\text{Hujan hari ini}) + P(\text{Paul terlambat}|\text{Tidak hujan hari ini})P(\text{Tidak hujan hari ini}) = (0,6 \times 0,47) + (0,5 \times (1-0,47)) \\
 &= 0,55
 \end{aligned}$$

Di sini, kami menggunakan konsep bukti keras dan bukti lunak. Bukti keras (instansiasi) dari sebuah simpul adalah bukti bahwa status variabel tersebut pasti sebagai nilai tertentu. Dalam contoh kami di atas, kami memiliki bukti keras bahwa 'Tim terlambat masuk kelas'. Jika simpul tertentu diinstansiasi, maka ia akan memblokir penyebaran bukti lebih jauh ke simpul anaknya. Bukti lunak untuk sebuah simpul adalah bukti yang menyediakan nilai probabilitas sebelumnya untuk simpul tersebut. Simpul 'Paul terlambat masuk kelas' adalah bukti lunak dengan pengetahuan sebelumnya bahwa 'Tim terlambat masuk kelas'.

Jaringan Kepercayaan Bayesian dapat menggambarkan skenario yang jauh lebih kompleks dengan konsep ketergantungan dan independensi. Ada tiga jenis koneksi yang mungkin dalam jaringan Kepercayaan Bayesian.


Koneksi yang Berbeda: Dalam jenis koneksi ini, bukti dapat ditransmisikan antara dua simpul anak dari induk yang sama asalkan induknya tidak diwujudkan. Gambar 6.7, kita telah melihat perilaku koneksi yang divergen.

Koneksi Serial: Dalam jenis koneksi ini, bukti apa pun yang dimasukkan di awal koneksi dapat dikirimkan melalui jalur terarah asalkan tidak ada simpul perantara pada jalur tersebut yang diwujudkan (lihat Gambar 6.8 untuk ilustrasi).



Gbr. 6.8 Koneksi serial

Koneksi Konvergen: Dalam jenis koneksi ini, bukti hanya dapat ditransmisikan antara dua orang tua ketika simpul anak (konvergen) telah menerima beberapa bukti dan bukti tersebut dapat berupa bukti lunak atau bukti keras (lihat Gambar 6.9 untuk ilustrasi).



Gbr. 6.9 Koneksi konvergen

Seperti yang dibahas di atas, dengan menggunakan jaringan Bayesian, kita ingin menyimpulkan nilai variabel target berdasarkan nilai-nilai yang diamati dari beberapa variabel lain. Harap dicatat bahwa tidak mungkin untuk menyimpulkan nilai tunggal dalam kasus variabel acak yang kita hadapi, tetapi tujuan kita adalah untuk menyimpulkan distribusi probabilitas variabel target berdasarkan nilai-nilai yang diamati dari variabel lain. Secara umum, jaringan Bayesian dapat digunakan untuk menghitung distribusi probabilitas dari setiap subset variabel simpul berdasarkan nilai-nilai atau distribusi variabel yang tersisa.

6.5.2 Penggunaan jaringan Keyakinan Bayesian dalam pembelajaran mesin

Kita telah melihat bahwa jaringan Bayesian menciptakan model lengkap untuk variabel dan hubungannya, sehingga dapat digunakan untuk menjawab pertanyaan probabilistik tentang variabel tersebut. Penggunaan umum jaringan ini adalah untuk mengetahui pengetahuan terkini tentang status subset variabel, sementara status subset lainnya (dikenal sebagai variabel bukti) diamati. Konsep ini, yang sering dikenal sebagai proses inferensi probabilistik untuk menghitung distribusi posterior variabel, dengan beberapa bukti, memberikan statistik yang cukup universal untuk aplikasi yang terkait dengan deteksi. Jadi, jika seseorang ingin memilih nilai untuk subset variabel guna meminimalkan beberapa fungsi kerugian yang diharapkan atau kesalahan keputusan, maka metode ini cukup efektif. Dengan kata lain, jaringan Bayesian adalah mekanisme untuk menerapkan teorema Bayes secara otomatis pada masalah yang kompleks. Jaringan Bayesian digunakan untuk memodelkan keyakinan dalam domain seperti biologi komputasional dan bioinformatika seperti struktur protein dan jaringan regulasi gen, obat-obatan, forensik, klasifikasi dokumen, pengambilan informasi, pemrosesan gambar, sistem pendukung keputusan, taruhan dan permainan olahraga, analisis pasar properti, dan berbagai bidang lainnya.

6.6 RINGKASAN

- Metode Bayesian memperkenalkan dasar bagi metode pembelajaran probabilistik yang mempertimbangkan pengetahuan tentang probabilitas sebelumnya dari alternatif hipotesis dan probabilitas kemungkinan atau pengamatan berbagai data pelatihan yang diberikan hipotesis. Kemudian menetapkan probabilitas posterior untuk setiap hipotesis

kandidat berdasarkan asumsi sebelumnya dan data yang diamati.

- Hipotesis MAP adalah hipotesis yang paling mungkin berdasarkan data. Karena tidak ada hipotesis lain yang lebih mungkin, ini juga merupakan hipotesis yang optimal. Pengklasifikasi optimal Bayes menghitung klasifikasi yang paling mungkin dari setiap contoh baru dengan menggabungkan prediksi dari semua hipotesis alternatif, yang dibobot berdasarkan probabilitas posteriornya.
- **Klasifikasi Naïve Bayes** membuat asumsi naif bahwa nilai atribut bersifat independen secara kondisional mengingat klasifikasi instans. Asumsi penyederhanaan ini secara signifikan mengurangi overhead perhitungan tanpa kehilangan efektivitas hasil. Dengan asumsi ini berlaku, pengklasifikasi Naïve Bayes menghasilkan klasifikasi MAP.
- Pengklasifikasi Naïve Bayes telah terbukti bermanfaat dalam banyak aplikasi praktis dan dianggap sebagai salah satu metode pembelajaran yang ampuh. Bahkan ketika asumsi independensi bersyarat tidak terpenuhi, pengklasifikasi Naïve Bayes cukup efektif dalam memberikan standar bagi metode pembelajaran lainnya.
- **Jaringan Kepercayaan Bayesian** menyediakan mekanisme untuk menangani skenario yang lebih praktis dalam mempertimbangkan independensi bersyarat dari sekumpulan variabel sambil mempertimbangkan distribusi probabilitas gabungan dari variabel yang tersisa berdasarkan observasi.

CONTOH PERTANYAAN

SOAL PILIHAN GANDA (MASING-MASING 1 NILAI)

1. Tiga perusahaan X, Y, dan Z memasok 40%, 45%, dan 15% seragam ke sebuah sekolah. Pengalaman sebelumnya menunjukkan bahwa 2%, 3%, dan 4% seragam yang dipasok oleh perusahaan-perusahaan ini cacat. Jika sebuah seragam ditemukan cacat, berapakah probabilitas bahwa seragam tersebut dipasok oleh Perusahaan X?
 1. $\frac{34}{69}$
 2. $\frac{25}{55}$
 3. $\frac{16}{55}$
 4. $\frac{16}{12}$
2. Kotak apel berisi 10 buah apel, 6 diantaranya cacat. Jika 3 buah apel dikeluarkan dari kotak secara berurutan tanpa pengembalian, Berapa besar peluang bahwa ketiga apel tersebut cacat semua?
 1. $(6*5*4)/(10*10*10)$
 2. $(6*5*4)/(10*9*8)$
 3. $(3*3*3)/(10*10*10)$
 4. $(3*2*1)/(10*9*8)$
3. Dua kotak berisi coklat diletakkan di atas meja. Kotak-kotak tersebut diberi label B1 dan B2. Kotak B1 berisi 6 coklat hitam dan 5 coklat putih. Kotak B2 berisi 3 coklat hitam dan 8 coklat oranye. Kotak-kotak tersebut disusun sedemikian rupa sehingga peluang memilih kotak B1 adalah $\frac{1}{3}$ dan peluang memilih kotak B2 adalah $\frac{2}{3}$. Sneha ditutup matanya dan diminta untuk

memilih cokelat. Dia akan memenangkan Rs. 10.000 jika dia memilih cokelat hitam. Berapa peluang Sneha akan memenangkan Rs. 10.000 (artinya, dia akan memilih cokelat hitam)?

1. $\frac{7}{33}$

2. $\frac{6}{33}$

3. $\frac{11}{33}$

4. $\frac{10}{33}$

4. Dua kotak berisi coklat diletakkan di atas meja. Kotak-kotak tersebut diberi label B1 dan B2. Kotak B1 berisi 6 coklat Cadbury dan 5 coklat Amul. Kotak B2 berisi 3 coklat Cadbury dan 8 coklat Nestle. Kotak-kotak tersebut disusun sedemikian rupa sehingga peluang memilih kotak B1 adalah $\frac{1}{3}$ dan peluang memilih kotak B2 adalah $\frac{2}{3}$. Sneha ditutup matanya dan diminta untuk memilih cokelat. Dia akan memenangkan Rs. 10.000 jika dia memilih cokelat Cadbury. Jika dia memenangkan Rs. 10.000, berapakah peluang dia memilih cokelat Cadbury dari kotak pertama?

1. $\frac{7}{12}$

2. $\frac{6}{12}$

3. $\frac{11}{12}$

4. $\frac{10}{33}$

5. Di sebuah klub basket, ada 4% pemain pria yang tingginya lebih dari 6 kaki dan 1% pemain wanita yang tingginya lebih dari 6 kaki. Rasio pemain pria dan wanita dalam populasi pemain secara keseluruhan adalah pria:wanita =

- 2:3. Seorang pemain dipilih secara acak dari antara semua pemain yang tingginya lebih dari 6 kaki. Berapa probabilitas bahwa pemain tersebut adalah perempuan?
1. Tanggal 3/11
 2. $\frac{2}{5}$
 3. Tanggal 2/11
 4. $\frac{1}{11}$
6. Kemungkinan bahwa hipotesis tertentu berlaku untuk kumpulan data berdasarkan Prior disebut
1. Probabilitas independen
 2. Kemungkinan posterior
 3. Kemungkinan interior
 4. Probabilitas dependen
7. Salah satu kelemahan utama pengklasifikasi Bayesian adalah bahwa pengklasifikasi ini menggunakan semua parameter yang tersedia untuk mengubah prediksi secara halus.
1. BENAR
 2. PALSU
8. Di sebuah pabrik baut, mesin A1, A2, dan A3 masing-masing memproduksi 25%, 35%, dan 40% dari total produksi. Dari jumlah tersebut, 5%, 4%, dan 2% merupakan baut yang cacat. Sebuah baut diambil secara acak dari produk tersebut dan ternyata cacat. Berapa probabilitas bahwa baut tersebut diproduksi oleh mesin A2?
1. 0,0952
 2. 0,452
 3. 0,952
 4. 0,125

9. Metode Bayesian dapat berkinerja lebih baik daripada metode lain saat memvalidasi hipotesis yang membuat prediksi probabilistik.
 1. BENAR
 2. PALSU
10. Pengklasifikasi Naïve Bayes membuat asumsi naif bahwa nilai atribut bergantung secara kondisional berdasarkan klasifikasi instansi.
 1. BENAR
 2. PALSU

SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI)

1. Apa itu probabilitas sebelumnya? Berikan contoh.
2. Apa itu probabilitas posterior? Berikan contoh.
3. Apa itu probabilitas kemungkinan? Berikan contoh.
4. Apa itu pengklasifikasi Naïve Bayes? Mengapa dinamakan demikian?
5. Apa itu pengklasifikasi Bayes yang optimal?
6. Tuliskan dua fitur metode pembelajaran Bayesian.
7. Jelaskan konsep pembelajar yang konsisten.
8. Tuliskan dua kekuatan pengklasifikasi Bayes.
9. Tuliskan dua kelemahan pengklasifikasi Bayes.
10. Jelaskan bagaimana pengklasifikasi Naïve Bayes digunakan untuk
 1. Klasifikasi teks
 2. Penyaringan spam
 3. Analisis sentimen pasar

SOAL JAWABAN PANJANG (MASING-MASING 10 NILAI)

1. Jelaskan konsep Prior, Posterior, dan Kemungkinan dengan sebuah contoh.
2. Bagaimana teorema Bayes mendukung prinsip pembelajaran konsep?
3. Jelaskan pengklasifikasi Naïve Bayes dengan contoh penggunaannya dalam kehidupan praktis.
4. Apakah mungkin menggunakan pengklasifikasi Naïve Bayes untuk data numerik kontinu? Jika ya, bagaimana caranya?
5. Apa itu jaringan keyakinan Bayesian? Di mana jaringan ini digunakan? Apakah jaringan ini dapat memecahkan semua jenis masalah?
6. Dalam sistem pemeriksaan keamanan bandara, penumpang diperiksa untuk mengetahui apakah ada penyusup. Biarkan $i \in \{0, 1\}$ adalah variabel acak yang menunjukkan apakah seseorang adalah penyusup ($i = 1$) atau tidak ($i = 0$) dan A dengan $\in \{0, 1\}$ adalah variabel yang menunjukkan alarm. Alarm akan dibunyikan jika seorang penyusup diidentifikasi dengan probabilitas $P(A = 1 | I = 1) = 0,98$ dan bukan penyusup dengan probabilitas $P(A = 1 | I = 0) = 0,001$, yang menyiratkan faktor kesalahan. Dalam populasi penumpang, probabilitas seseorang adalah penyusup adalah $P(I = 1) = 0,00001$. Berapa probabilitas alarm dibunyikan ketika seseorang benar-benar penyusup?

7. Uji resistensi antibiotik (variabel acak T) memiliki 1% positif palsu (yaitu 1% dari mereka yang tidak resisten terhadap antibiotik menunjukkan hasil positif dalam pengujian) dan 5% negatif palsu (yaitu 5% dari mereka yang sebenarnya resisten terhadap antibiotik menunjukkan hasil negatif). Mari kita asumsikan bahwa 2% dari mereka yang diuji resisten terhadap antibiotik. Tentukan probabilitas bahwa seseorang yang dites positif sebenarnya resisten (variabel acak D).
8. Untuk persiapan ujian, seorang siswa mengetahui bahwa satu soal harus dipecahkan dalam ujian, yaitu tipe A, B, atau C. Peluang munculnya soal A, B, atau C dalam ujian masing-masing adalah 30%, 20%, dan 50%. Selama persiapan, siswa tersebut memecahkan 9 dari 10 soal tipe A, 2 dari 10 soal tipe B, dan 6 dari 10 soal tipe C.
 1. Berapa besar peluang siswa tersebut dapat memecahkan soal ujian tersebut?
 2. Jika siswa tersebut memecahkan soal tersebut, berapakah peluang bahwa soal tersebut bertipe A?
9. CCTV dipasang di bank untuk memantau nasabah yang datang dan mengambil foto. Meskipun ada arus nasabah yang terus menerus, kami membuat kotak-kotak dengan jangka waktu masing-masing 5 menit. Dalam setiap jangka waktu 5 menit, mungkin ada nasabah yang masuk ke bank dengan probabilitas 5% atau tidak ada nasabah (sekali lagi, untuk menyederhanakan, kami berasumsi bahwa ada 1 nasabah atau tidak ada, bukan kasus beberapa nasabah). Jika ada nasabah, maka akan terdeteksi oleh CCTV dengan probabilitas 99%. Jika

tidak ada nasabah, kamera akan mengambil foto palsu dengan mendeteksi pergerakan benda lain dengan probabilitas 10%.

1. Berapa banyak nasabah yang datang ke bank rata-rata per hari (10 jam)?
 2. Berapa banyak foto palsu (ada foto yang diambil padahal tidak ada pelanggan) dan berapa banyak foto yang terlewat (tidak ada foto padahal ada pelanggan) yang terjadi rata-rata tiap harinya?
 3. Jika ada foto, berapa kemungkinan bahwa memang ada pelanggan?
10. Gambarkan jaringan Keyakinan Bayesian untuk merepresentasikan asumsi independensi bersyarat dari pengklasifikasi Naïve Bayes untuk masalah prediksi kemenangan pertandingan di Bagian 6.4.4. Buat tabel probabilitas bersyarat yang terkait dengan simpul Undian Menang.

Bab 7 Pembelajaran Terbimbing: Klasifikasi

Dr. Sri Lestari, S.Kom., M.Cs.

A. Tujuan pembelajaran

Pada bab terakhir tentang Pembelajaran Konsep Bayesian, Anda diperkenalkan pada algoritma pembelajaran terbimbing yang penting – algoritma Naïve Bayes. Seperti yang telah kita lihat, algoritma ini adalah pengklasifikasi yang sangat sederhana tetapi ampuh berdasarkan teorema probabilitas bersyarat Bayes. Akan tetapi, selain pengklasifikasi Naïve Bayes, ada lebih banyak algoritma untuk klasifikasi. Bab ini akan berfokus pada algoritma klasifikasi lainnya.

7.1 PENDAHULUAN


Algoritma pertama yang akan kita bahas dalam bab ini adalah k-Nearest Neighbour (kNN), yang mencoba mengklasifikasikan contoh data yang tidak berlabel berdasarkan kesamaan dengan contoh berlabel dalam data pelatihan. Kemudian, pengklasifikasi penting lainnya, yaitu pohon keputusan, akan dijelaskan secara rinci. Pohon keputusan, seperti namanya, adalah pengklasifikasi yang didasarkan pada serangkaian keputusan logis, yang menyerupai pohon dengan cabang-cabang. Berikutnya, kita akan menjelajahi pengklasifikasi hutan acak, yang jika disederhanakan, dapat dianggap sebagai kumpulan banyak pohon keputusan. Terakhir, pengklasifikasi yang sangat kuat dan populer bernama Support Vector Machine (SVM) akan dieksplorasi. Jadi, pada

akhir bab ini, Anda akan memperoleh pengetahuan yang cukup untuk mulai memecahkan masalah klasifikasi dengan menggunakan beberapa pengklasifikasi standar.

7.2 CONTOH PEMBELAJARAN TERAWASI

Dalam pembelajaran terbimbing, data pelatihan berlabel menyediakan dasar untuk pembelajaran. Menurut definisi pembelajaran mesin, data pelatihan berlabel ini adalah pengalaman atau pengetahuan atau keyakinan sebelumnya. Disebut pembelajaran terbimbing karena proses pembelajaran dari data pelatihan oleh mesin dapat dikaitkan dengan guru yang mengawasi proses pembelajaran siswa yang baru mengenal mata pelajaran tersebut. Di sini, guru adalah data pelatihan.

Data pelatihan adalah informasi masa lalu dengan nilai bidang kelas atau 'label' yang diketahui. Oleh karena itu, kita katakan bahwa 'data pelatihan diberi label' dalam kasus pembelajaran terbimbing (lihat [Gambar 7.1](#)). Sebaliknya, tidak ada data pelatihan berlabel untuk pembelajaran tanpa pengawasan. Pembelajaran semi-supervised, seperti yang digambarkan dalam [Gambar 7.1](#), menggunakan sejumlah kecil data berlabel bersama dengan data tidak berlabel untuk pelatihan.



GAMBAR 7.1 Pembelajaran dengan pengawasan vs. pembelajaran tanpa pengawasan

Di rumah sakit, banyak pasien yang dirawat di bangsal umum. Sebagai perbandingan, jumlah tempat tidur di Unit Perawatan Intensif (ICU) jauh lebih sedikit. Oleh karena itu, manajemen rumah sakit selalu merasa khawatir jika tiba-tiba kondisi sejumlah pasien di bangsal umum memburuk dan harus dipindahkan ke ICU. Tanpa perencanaan dan persiapan sebelumnya, lonjakan permintaan tersebut akan sulit ditangani oleh rumah sakit. Masalah ini dapat diatasi dengan lebih baik jika dapat diprediksi pasien mana di bangsal biasa yang kemungkinan kondisi kesehatannya memburuk dan harus dipindahkan ke ICU.

Masalah prediksi semacam ini termasuk dalam ranah pembelajaran terbimbing atau, lebih khusus lagi, klasifikasi. Rumah sakit sudah memiliki semua catatan pasien sebelumnya. Catatan pasien yang kondisi kesehatannya memburuk di masa lalu dan harus dipindahkan ke ICU dapat membentuk data pelatihan untuk masalah prediksi ini. Hasil tes pasien yang baru dirawat digunakan untuk mengklasifikasikan mereka sebagai pasien berisiko tinggi atau berisiko rendah.

Beberapa contoh lain dari pembelajaran terbimbing adalah sebagai berikut:

- Prediksi hasil pertandingan berdasarkan analisis hasil sebelumnya
- Memprediksi apakah tumor ganas atau jinak berdasarkan analisis data
- Prediksi harga dalam domain seperti real estat, saham, dll.

7.3 MODEL KLASIFIKASI

Mari kita pertimbangkan dua contoh, misalnya 'memprediksi apakah tumor ganas atau jinak' dan 'prediksi harga di bidang real estat'. Apakah kedua masalah ini memiliki sifat yang sama?


Jawabannya adalah 'tidak'. Memang benar bahwa keduanya merupakan masalah yang terkait dengan prediksi. Akan tetapi, untuk prediksi tumor, kita mencoba untuk memprediksi kategori atau kelas mana, yaitu 'ganas' atau 'jinak', data masukan yang tidak diketahui terkait dengan tumor tersebut. Dalam kasus lain, yaitu, untuk prediksi harga, kita mencoba untuk memprediksi nilai absolut dan bukan kelas.

Ketika kita mencoba memprediksi variabel kategoris atau nominal, masalahnya dikenal sebagai masalah klasifikasi. Masalah klasifikasi adalah masalah yang variabel keluarannya berupa kategori seperti 'merah' atau 'biru' atau 'tumor ganas' atau 'tumor jinak', dst.

Sedangkan ketika kita mencoba untuk memprediksi suatu variabel numerik seperti 'harga', 'berat', dan lain sebagainya, permasalahan tersebut termasuk dalam kategori regresi.

Kita dapat mengamati bahwa dalam klasifikasi, seluruh permasalahan berpusat pada pemberian label atau kategori atau kelas pada data uji berdasarkan informasi label atau kategori atau kelas yang diberikan oleh data pelatihan. Karena sasarannya adalah untuk memberikan label kelas, kita menyebut jenis permasalahan ini sebagai permasalahan klasifikasi. Gambar 7.2 menggambarkan proses klasifikasi yang umum dimana model klasifikasi diperoleh dari data pelatihan berlabel oleh algoritma pengklasifikasi. Berdasarkan model tersebut, label kelas (misalnya 'Intel' seperti pada kasus data uji yang disebutkan dalam Gambar 7.2) ditetapkan pada data uji.

Masalah klasifikasi yang kritis dalam konteks perbankan adalah mengidentifikasi transaksi yang berpotensi penipuan. Karena ada jutaan transaksi yang harus diteliti untuk mengidentifikasi apakah transaksi tertentu mungkin merupakan transaksi penipuan, tidak mungkin bagi manusia mana pun untuk melakukan tugas ini. Pembelajaran mesin dimanfaatkan secara efisien untuk melakukan tugas ini, dan ini adalah kasus klasifikasi klasik. Berdasarkan data transaksi sebelumnya, terutama yang diberi label penipuan, semua transaksi masuk baru ditandai atau diberi label sebagai transaksi biasa atau mencurigakan. Transaksi yang mencurigakan selanjutnya dipisahkan untuk ditinjau lebih dekat.



GAMBAR 7.2 Model klasifikasi

Singkatnya, klasifikasi adalah jenis pembelajaran terbimbing di mana fitur target, yang bertipe kategoris, diprediksi untuk data uji berdasarkan informasi yang diberikan oleh data pelatihan. Fitur kategoris target dikenal sebagai kelas.


Beberapa masalah klasifikasi yang umum meliputi hal berikut:

- Klasifikasi gambar
- Prediksi penyakit
- Prediksi menang-kalah pertandingan
- Prediksi bencana alam seperti gempa bumi, banjir, dll.
- Pengenalan tulisan tangan:

7.4 LANGKAH PEMBELAJARAN KLASIFIKASI

Pertama, ada masalah yang harus dipecahkan, kemudian, data yang dibutuhkan (yang terkait dengan masalah, yang sudah tersimpan dalam

sistem) dievaluasi dan diproses terlebih dahulu berdasarkan algoritma. Pemilihan algoritma merupakan titik kritis dalam pembelajaran terbimbing. Hasil setelah putaran pelatihan berulang adalah pengklasifikasi untuk masalah yang dihadapi (lihat Gambar 7.3).



GAMBAR 7.3Langkah-langkah model klasifikasi

Identifikasi Masalah: Mengidentifikasi masalah merupakan langkah pertama dalam model pembelajaran terbimbing. Masalah haruslah masalah yang terformulasi dengan baik, yaitu masalah dengan tujuan dan manfaat yang ditetapkan dengan baik, yang memiliki dampak jangka panjang.

Identifikasi Data yang Diperlukan: Berdasarkan masalah yang diidentifikasi di atas, kumpulan data yang diperlukan yang secara tepat mewakili masalah yang diidentifikasi perlu diidentifikasi/dievaluasi. Misalnya: Jika masalahnya adalah untuk memprediksi apakah suatu tumor

ganas atau jinak, maka kumpulan data pasien yang sesuai yang terkait dengan tumor ganas dan tumor jinak harus diidentifikasi.

Pra-pemrosesan Data: Hal ini terkait dengan pembersihan/pengubahan set data. Langkah ini memastikan bahwa semua elemen data yang tidak diperlukan/tidak relevan telah dihapus. Pra-pemrosesan data mengacu pada transformasi yang diterapkan pada data yang diidentifikasi sebelum memasukkannya ke dalam algoritme. Karena data dikumpulkan dari berbagai sumber, biasanya data dikumpulkan dalam format mentah dan tidak siap untuk analisis langsung. Langkah ini memastikan bahwa data siap untuk dimasukkan ke dalam algoritme pembelajaran mesin.

Definisi Set Data Pelatihan: Sebelum memulai analisis, pengguna harus memutuskan jenis set data apa yang akan digunakan sebagai set pelatihan. Dalam kasus analisis tanda tangan, misalnya, set data pelatihan mungkin berupa satu alfabet tulisan tangan, seluruh kata tulisan tangan (yaitu sekelompok alfabet) atau seluruh baris tulisan tangan (yaitu kalimat atau sekelompok kata). Dengan demikian, satu set 'meta-objek input' dan 'meta-objek output' yang sesuai juga dikumpulkan. Set pelatihan harus secara aktif mewakili penggunaan skenario yang diberikan di dunia nyata. Dengan demikian, satu set data input (X) dan output yang sesuai (Y) dikumpulkan baik dari pakar manusia atau eksperimen.

Pemilihan Algoritma: Ini melibatkan penentuan struktur fungsi pembelajaran dan algoritma pembelajaran yang sesuai. Ini adalah langkah paling penting dari model pembelajaran terbimbing. Berdasarkan berbagai parameter, algoritma terbaik untuk masalah tertentu dipilih.

Pelatihan: Algoritma pembelajaran yang diidentifikasi pada langkah sebelumnya dijalankan pada set pelatihan yang dikumpulkan untuk

penyempurnaan lebih lanjut. Beberapa algoritma pembelajaran terbimbing mengharuskan pengguna untuk menentukan parameter kontrol tertentu (yang diberikan sebagai masukan ke algoritma). Parameter ini (masukan yang diberikan ke algoritma) juga dapat disesuaikan dengan mengoptimalkan kinerja pada subset (disebut sebagai set validasi) dari set pelatihan.

Evaluasi dengan Set Data Uji: Data pelatihan dijalankan pada algoritma, dan kinerjanya diukur di sini. Jika hasil yang sesuai tidak diperoleh, pelatihan parameter lebih lanjut mungkin diperlukan.

7.5 ALGORITMA KLASIFIKASI UMUM

Sekarang mari kita bahas beberapa algoritma klasifikasi yang umum. Berikut ini adalah algoritma klasifikasi yang paling umum, di antaranya kita telah mempelajari tentang pengklasifikasi Naïve Bayes di [Bab 6](#). Kami akan membahas detail algoritma lainnya dalam bab ini.

1. *aku*-Tetangga Terdekat (kNN)
2. Pohon keputusan
3. Hutan acak
4. Mesin Vektor Pendukung (SVM)
5. Klasifikasi Naïve Bayes

7.5.1 k -Tetangga Terdekat (kNN)

Algoritma kNN adalah algoritma klasifikasi yang sederhana tetapi sangat canggih. Nama algoritma ini berasal dari filosofi dasar kNN – yaitu orang-orang yang memiliki latar belakang atau pola pikir yang sama cenderung untuk tetap dekat satu sama lain. Dengan kata lain, tetangga di

suatu lokasi memiliki latar belakang yang sama. Dengan cara yang sama, sebagai bagian dari algoritma kNN, data yang tidak diketahui dan tidak berlabel yang muncul untuk masalah prediksi dinilai berdasarkan elemen-elemen set data pelatihan yang mirip dengan elemen yang tidak diketahui. Jadi, label kelas dari elemen yang tidak diketahui ditetapkan berdasarkan label kelas dari elemen-elemen set data pelatihan yang serupa (secara metaforis dapat dianggap sebagai tetangga dari elemen yang tidak diketahui). Mari kita coba memahami algoritma dengan set data sederhana.

7.5.1.1 Cara kerja kNN

Mari kita pertimbangkan kumpulan data Siswa yang sangat sederhana seperti yang digambarkan pada Gambar 7.4. Terdiri dari 15 siswa yang belajar dalam satu kelas. Setiap siswa diberi skor pada skala 10 pada dua parameter kinerja – 'Bakat' dan 'Komunikasi'. Selain itu, nilai kelas diberikan kepada setiap siswa berdasarkan kriteria berikut:

1. Siswa yang memiliki keterampilan komunikasi yang baik serta tingkat bakat yang baik telah diklasifikasikan sebagai 'Pemimpin'
2. Siswa yang memiliki keterampilan komunikasi yang baik tetapi tingkat bakatnya tidak begitu baik telah diklasifikasikan sebagai 'Pembicara'
3. Siswa yang memiliki kemampuan komunikasi yang tidak begitu baik tetapi memiliki tingkat bakat yang baik telah diklasifikasikan sebagai 'Intel'

Name	Aptitude	Communication	Class
Karuna	2	5	Speaker
Bhuvna	2	6	Speaker
Gaurav	7	6	Leader
Parul	7	2.5	Intel
Dinesh	8	6	Leader
Jani	4	7	Speaker
Bobby	5	3	Intel
Parimal	3	5.5	Speaker
Govind	8	3	Intel
Susant	6	5.5	Leader
Gouri	6	4	Intel
Bharat	6	7	Leader
Ravi	6	2	Intel
Pradeep	9	7	Leader
Josh	5	4.5	Intel

GAMBAR 7.4Set data siswa

Seperti yang telah kita lihat di Bab 3, saat membangun model klasifikasi, sebagian dari data masukan berlabel disimpan sebagai data uji. Sisa data masukan digunakan untuk melatih model – oleh karena itu dikenal sebagai data pelatihan. Motivasi untuk menyimpan sebagian data sebagai data uji adalah untuk mengevaluasi kinerja model. Seperti yang telah kita lihat, kinerja model klasifikasi diukur dengan jumlah klasifikasi yang benar yang dibuat oleh model saat diterapkan pada set data yang tidak diketahui. Namun, tidak mungkin selama pengujian model untuk mengetahui nilai label sebenarnya dari data yang tidak diketahui. Oleh karena itu, data uji, yang merupakan bagian dari data masukan berlabel, digunakan untuk tujuan ini. Jika nilai kelas yang diprediksi untuk sebagian besar elemen data uji cocok dengan nilai kelas sebenarnya yang dimilikinya, maka kita katakan bahwa model klasifikasi memiliki akurasi yang baik. Dalam konteks set data Siswa, untuk menjaga semuanya tetap sederhana, kita mengasumsikan satu elemen data dari set data masukan sebagai data uji. Seperti yang digambarkan dalam Gambar 7.5, data siswa bernama Josh diasumsikan sebagai data uji. Sekarang setelah kita

mengidentifikasi data pelatihan dan data uji, kita dapat mulai membuat model.

Seperti yang telah kita bahas, dalam algoritma kNN, label kelas dari elemen data uji ditentukan oleh label kelas dari elemen data latih yang berdekatan, yaitu serupa sifatnya. Namun ada dua tantangan:

1. Apa dasar kesamaan ini atau kapan kita dapat mengatakan bahwa dua elemen data serupa?
2. Berapa banyak elemen serupa yang harus dipertimbangkan untuk menentukan label kelas setiap elemen data uji?

Untuk menjawab pertanyaan pertama, meskipun ada banyak ukuran kesamaan, pendekatan yang paling umum diadopsi oleh kNN untuk mengukur kesamaan antara dua elemen data adalah jarak Euclidean. Mempertimbangkan kumpulan data yang sangat sederhana yang memiliki dua fitur (misalnya f_1 dan f_2), jarak Euclidean antara dua elemen data d_1 dan d_2 dapat diukur dengan

$$\text{Euclidean distance} = \sqrt{(f_{11} - f_{12})^2 + (f_{21} - f_{22})^2}$$


di mana f_{11} = nilai fitur f_1 untuk elemen data d_1 f_{12} = nilai fitur f_1 untuk elemen data d_2 f_{21} = nilai fitur f_2 untuk elemen data d_1 f_{22} = nilai fitur f_2 untuk elemen data d_2



Name	Aptitude	Communication	Class
Karuna	2	5	Speaker
Bhuvna	2	6	Speaker
Gaurav	7	6	Leader
Parul	7	2.5	Intel
Dinesh	8	6	Leader
Jani	4	7	Speaker
Bobby	5	3	Intel
Parimal	3	5.5	Speaker
Govind	8	3	Intel
Susant	6	5.5	Leader
Gouri	6	4	Intel
Bharat	6	7	Leader
Ravi	6	2	Intel
Pradeep	9	7	Leader
Josh	5	4.5	Intel

GAMBAR 7.5Set data siswa yang terpisah

Jadi, seperti yang digambarkan di Gambar 7.6, titik data pelatihan dari Kumpulan data siswa hanya mempertimbangkan fitur 'Bakat' dan 'Komunikasi' dapat direpresentasikan sebagai titik-titik dalam ruang fitur dua dimensi. Seperti yang ditunjukkan pada gambar, titik-titik data pelatihan yang memiliki nilai kelas yang sama saling berdekatan. Alasan untuk mempertimbangkan ruang data dua dimensi adalah karena kita hanya mempertimbangkan dua fitur dari kumpulan data Siswa, yaitu 'Kecakapan' dan 'Komunikasi', untuk melakukan klasifikasi. Fitur 'Nama' diabaikan karena, seperti yang dapat kita pahami, fitur tersebut tidak berperan dalam menentukan nilai kelas. Titik data uji untuk siswa Josh direpresentasikan sebagai tanda bintang dalam ruang yang sama. Untuk mengetahui tetangga terdekat dari titik data uji, jarak Euclidean dari titik-titik yang berbeda perlu dihitung dari tanda bintang. Kemudian, nilai kelas dari tetangga terdekat membantu dalam menetapkan nilai kelas dari elemen data uji.



GAMBAR 7.6Representasi 2-D dari kumpulan data siswa

Sekarang, mari kita coba mencari jawaban untuk pertanyaan kedua, yaitu berapa banyak elemen serupa yang harus dipertimbangkan. Jawabannya terletak pada nilai 'k' yang merupakan parameter yang ditentukan pengguna yang diberikan sebagai input ke algoritma. Dalam algoritma kNN, nilai 'k' menunjukkan jumlah tetangga yang perlu dipertimbangkan. Misalnya, jika nilai k adalah 3, hanya tiga tetangga terdekat atau tiga elemen data pelatihan yang paling dekat dengan elemen data uji yang dipertimbangkan. Dari ketiga elemen data, kelas yang dominan dianggap sebagai label kelas yang akan ditetapkan ke data uji. Jika nilai k adalah 1, hanya elemen data pelatihan terdekat yang dipertimbangkan. Label kelas dari elemen data tersebut secara langsung ditetapkan ke elemen data uji. Hal ini digambarkan dalam Gambar 7.7.

Name	Aptitude	Communication	Class	Distance	k = 1	k = 2	k = 3
Karuna	2	5	Speaker	3.041			
Bhuvna	2	6	Speaker	3.354			
Parimal	3	5.5	Speaker	2.236			
Jani	4	7	Speaker	2.693			
Bobby	5	3	Intel	1.500			1.500
Ravi	6	2	Intel	2.693			
Gouri	6	4	Intel	1.118	1.118	1.118	1.118
Parul	7	2.5	Intel	2.828			
Govind	8	3	Intel	3.354			
Susant	6	5.5	Leader	1.414			
Bharat	6	7	Leader	2.693			
Gaurav	7	6	Leader	2.500			
Dinesh	8	6	Leader	3.354			
Pradeep	9	7	Leader	4.717			
Josh	5	4.5	???				

GAMBAR 7.7Perhitungan jarak antara titik uji dan pelatihan

Sekarang mari kita coba cari tahu hasil algoritma untuk kumpulan data Siswa yang kita miliki. Dengan kata lain, kita ingin melihat nilai kelas apa yang akan ditetapkan kNN untuk data uji untuk siswa Josh. Sekali lagi, mari kita lihat kembali [Gambar 7.7](#). Seperti yang terlihat, ketika nilai k diambil sebagai 1, hanya satu titik data pelatihan yang perlu dipertimbangkan. Rekaman pelatihan untuk siswa Gouri muncul sebagai yang paling dekat dengan rekaman pengujian Josh, dengan nilai jarak 1,118. Gouri memiliki nilai kelas 'Intel'. Jadi, titik data pengujian juga diberi nilai label kelas 'Intel'. Ketika nilai k diasumsikan sebagai 3, tetangga terdekat Josh dalam set data pelatihan adalah Gouri, Susant, dan Bobby dengan jarak masing-masing 1,118, 1,414, dan 1,5. Gouri dan Bobby memiliki nilai kelas 'Intel', sementara Susant memiliki nilai kelas 'Leader'. Dalam kasus ini, nilai kelas Josh diputuskan dengan suara terbanyak. Karena nilai kelas 'Intel' dibentuk oleh mayoritas tetangga, nilai kelas Josh ditetapkan sebagai 'Intel'. Proses yang sama ini dapat diperluas untuk nilai k apa pun.

Namun, sering kali sulit untuk menentukan nilai k . Alasannya adalah sebagai berikut:

- Jika nilai k sangat besar (dalam kasus ekstrem sama dengan jumlah total rekaman pada data latih), label kelas dari kelas mayoritas set data latih akan ditetapkan ke data uji tanpa mempedulikan label kelas tetangga yang paling dekat dengan data uji.
- Jika nilai k sangat kecil (dalam kasus ekstrem sama dengan 1), nilai kelas data berisik atau outlier di set data pelatihan yang merupakan tetangga terdekat dari data uji akan ditetapkan ke data uji.

Nilai k terbaik berada di antara dua nilai ekstrem ini.

Beberapa strategi, yang disorot di bawah ini, diadopsi oleh praktisi pembelajaran mesin untuk menghasilkan nilai k .

- Salah satu praktik umum adalah menetapkan k sama dengan akar kuadrat dari jumlah rekaman pelatihan.
- Pendekatan alternatif adalah menguji beberapa nilai k pada berbagai set data uji dan memilih salah satu yang memberikan kinerja terbaik.
- Pendekatan menarik lainnya adalah memilih nilai k yang lebih besar, tetapi menerapkan proses pemungutan suara tertimbang di mana suara tetangga dekat dianggap lebih berpengaruh daripada suara tetangga jauh.

7.5.1.2 Algoritma kNN

Masukan: Set data pelatihan, set data uji (atau titik data), nilai ' k ' (yaitu jumlah tetangga terdekat yang akan dipertimbangkan)

Tangga:

Lakukan untuk semua titik data uji

Hitung jarak (biasanya jarak Euclidean) titik data uji dari berbagai titik data pelatihan.

Temukan titik data pelatihan 'k' terdekat, yaitu titik data pelatihan yang jaraknya paling dekat dari titik data pengujian. Jika $k = 1$

Kemudian menetapkan label kelas dari titik data pelatihan ke titik data pengujian

Kalau tidak

Label kelas mana pun yang dominan hadir di titik data pelatihan, tetapkan label kelas tersebut ke titik data pengujian

Akhiri lakukan

7.5.1.3 Mengapa algoritma kNN disebut pembelajar malas?

Kita sudah membahasnya di Bab 3 bahwa pembelajar yang bersemangat mengikuti langkah-langkah umum pembelajaran mesin, yaitu melakukan abstraksi informasi yang diperoleh dari data masukan dan kemudian mengikutinya melalui langkah generalisasi. Namun, seperti yang telah kita lihat dalam kasus algoritma kNN, langkah-langkah ini sepenuhnya dilewati. Ia menyimpan data pelatihan dan secara langsung menerapkan filosofi pencarian tetangga terdekat untuk sampai pada klasifikasi. Jadi, untuk kNN, tidak ada pembelajaran yang terjadi dalam arti sebenarnya. Oleh karena itu, kNN termasuk dalam kategori pembelajar yang malas.

7.5.1.4 Kekuatan algoritma kNN

Algoritma yang sangat sederhana – mudah dipahami

- Sangat efektif dalam situasi tertentu, misalnya untuk desain sistem
- rekomendasi Sangat cepat atau hampir tidak memerlukan waktu
- untuk fase pelatihan

7.5.1.5 Kelemahan algoritma kNN

- Tidak mempelajari apa pun dalam arti sebenarnya. Klasifikasi dilakukan sepenuhnya berdasarkan data pelatihan. Jadi, klasifikasi sangat bergantung pada data pelatihan. Jika data pelatihan tidak mewakili domain masalah secara komprehensif, algoritme gagal membuat klasifikasi yang efektif. • Karena tidak ada model yang dilatih dalam arti sebenarnya dan klasifikasi dilakukan sepenuhnya berdasarkan data pelatihan, proses klasifikasi menjadi sangat lambat.
- Selain itu, sejumlah besar ruang komputasi diperlukan untuk memuat data pelatihan untuk klasifikasi.

7.5.1.6 Aplikasi algoritma kNN

Salah satu area paling populer dalam pembelajaran mesin tempat algoritma kNN diadopsi secara luas adalah sistem rekomendasi. Seperti yang kita ketahui, sistem rekomendasi merekomendasikan berbagai item yang mirip dengan item tertentu yang disukai pengguna. Pola kesukaan dapat terungkap dari pembelian sebelumnya atau riwayat penelusuran dan item yang mirip diidentifikasi menggunakan algoritma kNN.

Area lain yang banyak menggunakan kNN adalah pencarian dokumen/konten yang mirip dengan dokumen/konten tertentu. Ini adalah area inti dalam pencarian informasi dan dikenal sebagai pencarian konsep.


7.5.2 Pohon keputusan

Pembelajaran pohon keputusan merupakan salah satu algoritma yang paling banyak diadopsi untuk klasifikasi. Seperti namanya, algoritma ini membangun model dalam bentuk struktur pohon. Ketepatan pengelompokannya difokuskan dengan berbagai strategi, dan sangat produktif.

Pohon keputusan digunakan untuk analisis multidimensi dengan beberapa kelas. Pohon keputusan dicirikan oleh waktu eksekusi yang cepat dan kemudahan dalam penafsiran aturan. Tujuan pembelajaran pohon keputusan adalah untuk membuat model (berdasarkan data masa lalu yang disebut vektor masa lalu) yang memprediksi nilai variabel keluaran berdasarkan variabel masukan dalam vektor fitur.

Setiap simpul (atau simpul keputusan) dari pohon keputusan berkorespondensi dengan salah satu vektor fitur. Dari setiap simpul, terdapat tepi ke anak, di mana terdapat tepi untuk setiap nilai yang mungkin (atau rentang nilai) dari fitur yang terkait dengan simpul tersebut. Pohon tersebut berakhir pada simpul daun yang berbeda (atau simpul terminal) di mana setiap simpul daun mewakili nilai yang mungkin untuk variabel keluaran. Variabel keluaran ditentukan dengan mengikuti jalur yang dimulai dari akar dan dipandu oleh nilai variabel masukan.

Pohon keputusan biasanya direpresentasikan dalam format yang digambarkan dalam Gambar 7.8.



Gbr. 7.8Struktur pohon keputusan


Setiap simpul internal (diwakili oleh kotak) menguji suatu atribut (diwakili sebagai 'A'/'B' di dalam kotak). Setiap cabang sesuai dengan nilai atribut (T/F) dalam kasus di atas. Setiap simpul daun menetapkan suatu klasifikasi. Simpul pertama disebut sebagai Simpul 'Akar'. Cabang-cabang dari simpul akar disebut sebagai Simpul 'Daun' di mana 'A' adalah Simpul Akar (simpul pertama). 'B' adalah Simpul Cabang. 'T' & 'F' adalah Simpul Daun.

Jadi, pohon keputusan terdiri dari tiga jenis node:

- Simpul Akar
- Simpul Cabang
- Simpul Daun

Gambar 7.9 menunjukkan contoh pohon keputusan untuk mengemudikan mobil – keputusan yang harus diambil adalah apakah akan 'Terus Melaju' atau 'Berhenti', yang bergantung pada berbagai situasi seperti yang digambarkan dalam gambar. Jika sinyal berwarna MERAH,

maka mobil harus dihentikan. Jika tidak ada cukup bensin di dalam mobil, mobil harus dihentikan di pom bensin terdekat yang tersedia.



Gbr. 7.9Contoh pohon keputusan

7.5.2.1 Membangun pohon keputusan

Pohon keputusan dibangun sesuai dengan data pelatihan dengan mengikuti pendekatan yang disebut partisi rekursif. Pendekatan ini membagi data menjadi beberapa subset berdasarkan nilai fitur. Dimulai dari simpul akar, yang tidak lain adalah seluruh set data. Pertama-tama, ia memilih fitur yang memprediksi kelas target dengan cara terkuat. Pohon keputusan membagi set data menjadi beberapa partisi, dengan data di setiap partisi memiliki nilai yang berbeda untuk fitur yang menjadi dasar terjadinya partisi. Ini adalah set cabang pertama. Demikian pula, algoritme terus membagi node berdasarkan fitur yang membantu dalam partisi terbaik. Ini berlanjut hingga kriteria penghentian tercapai. Kriteria penghentian yang biasa adalah –

1. Semua atau sebagian besar contoh pada node tertentu memiliki kelas yang sama
2. Semua fitur telah digunakan dalam partisi
3. Pohon telah tumbuh hingga mencapai batas ambang yang telah ditentukan sebelumnya

Mari kita coba pahami hal ini dalam konteks sebuah contoh. Global Technology Solutions (GTS), penyedia solusi TI terkemuka, akan datang ke College of Engineering and Management (CEM) untuk merekrut mahasiswa B.Tech. Tahun lalu selama perekrutan kampus, mereka telah menyeleksi 18 mahasiswa untuk wawancara akhir. Sebagai perusahaan dengan reputasi internasional, mereka mengikuti proses wawancara yang ketat untuk memilih hanya mahasiswa terbaik. Informasi yang terkait dengan hasil evaluasi wawancara mahasiswa terpilih (menyembunyikan nama) berdasarkan berbagai parameter evaluasi tersedia untuk referensi di Gambar 7.10 Chandra, seorang mahasiswa CEM, ingin mengetahui apakah ia mungkin ditawarkan pekerjaan di GTS. IPK-nya cukup tinggi. Evaluasi dirinya terhadap parameter lainnya adalah sebagai berikut:
Komunikasi – Buruk; Bakat – Tinggi; Keterampilan pemrograman – Buruk


CGPA	Communication	Aptitude	Programming Skill	Job offered?
High	Good	High	Good	Yes
Medium	Good	High	Good	Yes
Low	Bad	Low	Good	No
Low	Good	Low	Bad	No
High	Good	High	Bad	Yes
High	Good	High	Good	Yes
Medium	Bad	Low	Bad	No
Medium	Bad	Low	Good	No
High	Bad	High	Good	Yes
Medium	Good	High	Good	Yes
Low	Bad	High	Bad	No
Low	Bad	High	Bad	No
Medium	Good	High	Bad	Yes
Low	Good	Low	Good	No
High	Bad	Low	Bad	No
Medium	Bad	High	Good	No
High	Bad	Low	Bad	No
Medium	Good	High	Bad	Yes

GAMBAR 7.10Data pelatihan untuk perekrutan GTS

Mari kita coba selesaikan masalah ini, yaitu memprediksi apakah Chandra akan mendapatkan tawaran pekerjaan, dengan menggunakan model pohon keputusan. Pertama, kita perlu menggambar pohon keputusan yang sesuai dengan data pelatihan yang diberikan dalam Gambar 7.10. Menurut tabel, kondisi tawaran pekerjaan (yaitu hasilnya) adalah SALAH untuk semua kasus di mana Bakat = Rendah, terlepas dari kondisi lainnya. Jadi, fitur Bakat dapat diambil sebagai simpul pertama dari pohon keputusan.

Untuk Bakat = Tinggi, kondisi tawaran kerja adalah BENAR untuk semua kasus di mana Komunikasi = Baik. Untuk kasus di mana Komunikasi = Buruk, kondisi tawaran kerja adalah BENAR untuk semua kasus di mana IPK = Tinggi.

Gambar 7.11 menggambarkan diagram pohon keputusan lengkap untuk tabel yang diberikan di Gambar 7.10.



GAMBAR 7.11 Pohon keputusan berdasarkan data pelatihan

7.5.2.2 Pencarian pohon keputusan

Dengan menggunakan pohon keputusan di atas yang digambarkan dalam Gambar 7.11, kita perlu memprediksi apakah Chandra akan mendapatkan tawaran pekerjaan untuk nilai parameter yang diberikan: IPK = Tinggi, Komunikasi = Buruk, Bakat = Tinggi, Keterampilan pemrograman = Buruk. Ada beberapa cara untuk mencari solusi untuk masalah prediksi yang diberikan melalui pohon keputusan yang telah dilatih.


Pencarian menyeluruh

1. Tempatkan item pada kelompok (kelas) pertama. Periksa solusi secara rekursif dengan item pada kelompok (kelas) pertama.
2. Tempatkan item tersebut pada kelompok (kelas) kedua. Periksa solusi secara rekursif dengan item pada kelompok (kelas) kedua.
3. Ulangi langkah di atas hingga solusi tercapai.

Pencarian menyeluruh menelusuri pohon keputusan secara menyeluruh, tetapi akan memakan banyak waktu apabila pohon keputusan itu besar dengan banyak daun dan banyak nilai atribut.

Pencarian cabang dan batas

Branch and bound menggunakan solusi terbaik yang ada untuk menghindari pencarian seluruh pohon keputusan secara penuh. Saat algoritme dimulai, solusi terbaik didefinisikan dengan baik untuk memiliki nilai terburuk yang mungkin; dengan demikian, solusi apa pun yang ditemukannya merupakan suatu peningkatan. Hal ini membuat algoritme awalnya berjalan ke cabang paling kiri dari pohon, meskipun hal itu tidak mungkin menghasilkan hasil yang realistis. Dalam masalah partisi, solusi itu sesuai dengan menempatkan setiap item dalam satu kelompok, dan itu adalah solusi yang tidak dapat diterima. Suatu program dapat mempercepat proses dengan menggunakan heuristik cepat untuk menemukan solusi awal. Ini dapat digunakan sebagai masukan untuk branch and bound. Jika heuristiknya benar, penghematannya bisa substansial.



GAMBAR 7.12 Pohon keputusan berdasarkan data pelatihan
(menggambarkan jalur sampel)

Gambar 7.12 menggambarkan contoh jalur (garis tebal) untuk kondisi IPK = Tinggi, Komunikasi = Buruk, Bakat = Tinggi, dan Keterampilan Pemrograman = Buruk. Berdasarkan pohon keputusan di atas, prediksi dapat dibuat karena Chandra akan mendapatkan tawaran pekerjaan.

Ada banyak implementasi pohon keputusan, yang paling menonjol adalah algoritma C5.0, CART (Classification and Regression Tree), CHAID (Chi-square Automatic Interaction Detector) dan ID3 (Iterative Dichotomiser 3). Tantangan terbesar dari algoritma pohon keputusan adalah untuk mengetahui fitur mana yang akan dipecah. Penggerak utama untuk mengidentifikasi fitur adalah bahwa data harus dipecah sedemikian rupa sehingga partisi yang dibuat oleh pemisahan harus berisi contoh-contoh yang termasuk dalam satu kelas. Jika itu terjadi, partisi tersebut dianggap murni. Entropi adalah ukuran ketidakmurnian atribut atau fitur yang diadopsi oleh banyak algoritma seperti ID3 dan C5.0. Keuntungan informasi dihitung berdasarkan penurunan entropi (S) setelah kumpulan data dipecah menurut atribut tertentu (A). Membangun pohon keputusan adalah tentang menemukan atribut yang mengembalikan keuntungan informasi tertinggi (yaitu cabang yang paling homogen).

7.5.2.3 Entropi pohon keputusan

Misalkan S adalah kumpulan sampel contoh pelatihan. Maka, Entropi (S) yang mengukur ketidakmurnian S didefinisikan sebagai

$$\text{Entropy}(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

di mana c adalah jumlah label kelas yang berbeda dan p mengacu pada dengan proporsi nilai yang termasuk dalam label kelas ke- i .

Misalnya, sehubungan dengan data pelatihan di Gambar 7.10, kita memiliki dua nilai untuk kelas target 'Job Offered?' – Ya dan Tidak. Nilai pi

untuk kelas nilai 'Ya' adalah 0,44 (yaitu 8/18) dan untuk kelas nilai 'Tidak' adalah 0,56 (yaitu 10/18). Jadi, kita dapat menghitung entropi sebagai **Entropi(S) = -0,44 log₂(0,44) - 0,56 log₂(0,56) = 0,99.**

7.5.2.4 Keuntungan informasi dari pohon keputusan

Perolehan informasi dibuat berdasarkan penurunan entropi (S) setelah kumpulan data dipecah menurut atribut tertentu (A). Membangun pohon keputusan adalah tentang menemukan atribut yang menghasilkan perolehan informasi tertinggi (yaitu cabang yang paling homogen). Jika perolehan informasi adalah 0, berarti tidak ada pengurangan entropi karena pemisahan kumpulan data menurut fitur tertentu. Di sisi lain, jumlah maksimum perolehan informasi yang mungkin terjadi adalah entropi kumpulan data sebelum pemisahan.

Perolehan informasi untuk fitur tertentu A dihitung berdasarkan perbedaan entropi sebelum pemisahan (atau S_{bs}) dengan entropi setelah pemisahan (S_{as}).

Keuntungan Informasi (S, A) = Entropi (S_{bs}) – Entropi (S_{as})

Untuk menghitung entropi setelah pemisahan, entropi untuk semua partisi perlu dipertimbangkan. Kemudian, penjumlahan entropi tertimbang untuk setiap partisi dapat diambil sebagai total entropi setelah pemisahan. Untuk melakukan penjumlahan tertimbang, proporsi contoh yang termasuk dalam setiap partisi digunakan sebagai bobot.

$$\text{Entropy}(S_{as}) = \sum_{i=1}^n w_i \text{Entropy}(p_i)$$

Mari kita periksa nilai perolehan informasi untuk set data pelatihan yang ditunjukkan pada Gambar 7.10. Kita akan menemukan nilai entropi di awal sebelum terjadi pemisahan dan kemudian lagi setelah pemisahan terjadi. Kita akan membandingkan nilai untuk semua kasus –

1. ketika fitur 'CGPA' digunakan untuk pemisahan
2. ketika fitur 'Komunikasi' digunakan untuk pemisahan
3. ketika fitur 'Aptitude' digunakan untuk split
4. ketika fitur 'Keterampilan Pemrograman' digunakan untuk pemisahan

Gambar 7.13 memberikan nilai entropi untuk pemisahan tingkat pertama untuk setiap kasus yang disebutkan di atas.

Seperti yang dihitung, entropi kumpulan data sebelum dipecah (yaitu Entropi (S_b) = 0,99, dan entropi kumpulan data setelah pemisahan (yaitu Entropi (S_a)) adalah

- 0.69 ketika fitur 'CGPA' digunakan untuk split
- 0.63 ketika fitur 'Komunikasi' digunakan untuk split
- 0.52 ketika fitur 'Aptitude' digunakan untuk split
- 0.95 ketika fitur 'Keterampilan pemrograman' digunakan untuk

(a) Original data set:

	Yes	No	Total
Count	8	10	18
pi	0.44	0.56	
$-\pi^i \log(\pi)$	0.52	0.47	0.99

Total Entropy = 0.99

(b) Splitted data set (based on the feature 'CGPA'):

CGPA = High

	Yes	No	Total
Count	4	2	6
pi	0.67	0.33	
$-\pi^i \log(\pi)$	0.39	0.53	0.92

Total Entropy = 0.69

CGPA = Medium

	Yes	No	Total
Count	4	3	7
pi	0.57	0.43	
$-\pi^i \log(\pi)$	0.46	0.52	0.99

Information Gain = 0.30

CGPA = Low

	Yes	No	Total
Count	0	5	5
pi	0.00	1.00	
$-\pi^i \log(\pi)$	0.00	0.00	0.00

(c) Splitted data set (based on the feature 'Communication'):

Communication = Good

	Yes	No	Total
Count	7	2	9
pi	0.78	0.22	
$-\pi^i \log(\pi)$	0.28	0.48	0.76

Total Entropy = 0.63

Communication = Bad

	Yes	No	Total
Count	1	8	9
pi	0.11	0.89	
$-\pi^i \log(\pi)$	0.35	0.15	0.50

Information Gain = 0.36

(d) Splitted data set (based on the feature 'Aptitude'):

Aptitude = High

	Yes	No	Total
Count	8	3	11
pi	0.73	0.27	
$-\pi^i \log(\pi)$	0.33	0.51	0.85

Total Entropy = 0.52

Aptitude = Low

	Yes	No	Total
Count	0	7	7
pi	0.00	1.00	
$-\pi^i \log(\pi)$	0.00	0.00	0.00

Information Gain = 0.47

(e) Splitted data set (based on the feature 'Programming Skill'):

Programming Skill = Good

	Yes	No	Total
Count	5	4	9
pi	0.56	0.44	
$-\pi^i \log(\pi)$	0.47	0.52	0.99

Total Entropy = 0.95

Programming Skill = Bad

	Yes	No	Total
Count	3	6	9
pi	0.33	0.67	
$-\pi^i \log(\pi)$	0.53	0.39	0.92

Information Gain = 0.04

Gbr. 7.13A Perhitungan entropi dan perolehan informasi (Level 1)

Oleh karena itu, perolehan informasi dari fitur 'CGPA' = $0,99 - 0,69 = 0,3$, sedangkan perolehan informasi dari fitur 'Komunikasi' = $0,99 - 0,63 = 0,36$. Demikian pula, perolehan informasi untuk 'Bakat' dan 'Keterampilan pemrograman' masing-masing adalah 0,47 dan 0,04.

Oleh karena itu, cukup jelas bahwa di antara semua fitur, 'Aptitude' menghasilkan perolehan informasi terbaik saat diadopsi untuk pemisahan. Jadi, pada level pertama, pemisahan akan diterapkan sesuai dengan nilai 'Aptitude' atau dengan kata lain, 'Aptitude' akan menjadi simpul pertama dari pohon keputusan yang terbentuk. Satu hal penting yang perlu dicatat di sini adalah bahwa untuk Aptitude = Low, entropi adalah 0, yang menunjukkan bahwa hasilnya akan selalu sama terlepas dari nilai fitur lainnya. Oleh karena itu, cabang menuju Aptitude = Low tidak akan berlanjut lebih jauh.

Sebagai bagian dari level 2, kita hanya akan memiliki satu cabang untuk dinavigasi dalam kasus ini – cabang untuk Bakat = Tinggi. Gambar 7.13b menyajikan perhitungan untuk level 2. Seperti yang dapat dilihat pada gambar, nilai entropi adalah sebagai berikut:

- 0,85 sebelum split
- 0,33 ketika fitur 'CGPA' digunakan untuk split
- 0,30 ketika fitur 'Komunikasi' digunakan untuk split
- 0,80 ketika fitur 'Keterampilan pemrograman' digunakan untuk split

Oleh karena itu, perolehan informasi setelah dipecah dengan fitur IPK, Komunikasi, dan Keterampilan Pemrograman masing-masing adalah 0,52, 0,55, dan 0,05. Oleh karena itu, fitur Komunikasi harus digunakan untuk pemecahan ini karena menghasilkan perolehan informasi tertinggi. Jadi, pada level kedua, pemecahan akan diterapkan berdasarkan nilai

'Komunikasi'. Sekali lagi, hal yang perlu dicatat di sini adalah bahwa untuk Komunikasi = Baik, entropi adalah 0, yang menunjukkan bahwa hasilnya akan selalu sama terlepas dari nilai fitur lainnya. Oleh karena itu, cabang menuju Komunikasi = Baik tidak akan berlanjut lebih jauh.

Aptitude = High

CGPA	Communication	Programming Skill	Job offered?
High	Good	Good	Yes
Medium	Good	Good	Yes
High	Good	Bad	Yes
High	Good	Good	Yes
High	Bad	Good	Yes
Medium	Good	Good	Yes
Low	Bad	Bad	No
Low	Bad	Bad	No
Medium	Good	Bad	Yes
Medium	Bad	Good	No
Medium	Good	Bad	Yes

(a) Level 2 starting set:

	Yes	No	Total
Count	8	3	11
pi	0.73	0.27	
-pi*log(pi)	0.33	0.51	0.85

Total Entropy = 0.85

(b) Splitted data set (based on the feature 'CGPA'):

CGPA = High

CGPA = Medium

CGPA = Low

	Yes	No	Total
Count	4	0	4
pi	1.00	0.00	
$-\pi \cdot \log(\pi)$	0.00	0.00	0.00

	Yes	No	Total
Count	4	1	5
pi	0.80	0.20	
$-\pi \cdot \log(\pi)$	0.26	0.46	0.72

	Yes	No	Total
Count	0	2	2
pi	0.00	1.00	
$-\pi \cdot \log(\pi)$	0.00	0.00	0.00

Total Entropy = 0.33

Information Gain = 0.52

(c) Split data set (based on the feature 'Communication'):

Communication = Good

Communication = Bad

	Yes	No	Total
Count	7	0	7
pi	1.00	0.00	
$-\pi \cdot \log(\pi)$	0.00	0.00	0.00

	Yes	No	Total
Count	1	3	4
pi	0.25	0.75	
$-\pi \cdot \log(\pi)$	0.50	0.31	0.81

Total Entropy = 0.30

Information Gain = 0.55

(d) Split data set (based on the feature 'Programming Skill'):

Programming Skill = Good

Programming Skill = Bad

	Yes	No	Total
Count	5	1	6
pi	0.83	0.17	
$-\pi \cdot \log(\pi)$	0.22	0.43	0.65

	Yes	No	Total
Count	3	2	5
pi	0.60	0.40	
$-\pi \cdot \log(\pi)$	0.44	0.53	0.97

Total Entropy = 0.80

Information Gain = 0.05

Gbr. 7.13B Perhitungan entropi dan perolehan informasi (Level 2)

Sebagai bagian dari level 3, kita hanya akan memiliki satu cabang untuk dinavigasi dalam kasus ini – cabang untuk Komunikasi = Buruk. Gambar 7.13 menyajikan perhitungan untuk level 3. Seperti yang dapat dilihat pada gambar, nilai entropi adalah sebagai berikut:

- 0,81 sebelum perpecahan.
- 0 ketika fitur 'CGPA' digunakan untuk split.
- 0,50 Ketika fitur 'Keterampilan Pemrograman' digunakan untuk

Aptitude = High & Communication = Bad

CGPA	Programming Skill	Job offered?
High	Good	Yes
Low	Bad	No
Low	Bad	No
Medium	Good	No

(a) Level 2 starting set:

	Yes	No	Total
Count	1	3	4
pi	0.25	0.75	
$-\pi \cdot \log(\pi)$	0.50	0.31	0.81

Total Entropy = 0.81

(b) Splitted data set (based on the feature 'CGPA'):

CGPA = High

	Yes	No	Total
Count	1	0	1
pi	1.00	0.00	
$-\pi \cdot \log(\pi)$	0.00	0.00	0.00

Total Entropy = 0.00

CGPA = Medium

	Yes	No	Total
Count	0	1	1
pi	0.00	1.00	
$-\pi \cdot \log(\pi)$	0.00	0.00	0.00

Information Gain = 0.81

CGPA = Low

	Yes	No	Total
Count	0	2	2
pi	0.00	1.00	
$-\pi \cdot \log(\pi)$	0.00	0.00	0.00

(c) Splitted data set (based on the feature 'Programming Skill'):

Programming Skill = Good

	Yes	No	Total
Count	1	1	2
pi	0.50	0.50	
$-\pi \cdot \log(\pi)$	0.50	0.50	1.00

Total Entropy = 0.50

Programming Skill = Bad

	Yes	No	Total
Count	0	2	2
pi	0.00	1.00	
$-\pi \cdot \log(\pi)$	0.00	0.00	0.00

Information Gain = 0.31

Gbr. 7.13CPerhitungan entropi dan perolehan informasi (Level 3)

Oleh karena itu, perolehan informasi setelah pemisahan dengan fitur CGPA adalah 0,81, yang merupakan perolehan informasi maksimum yang mungkin (karena entropi sebelum pemisahan adalah 0,81). Oleh karena itu, sebagaimana jelas, pemisahan akan diterapkan berdasarkan nilai

'CGPA'. Karena perolehan informasi maksimum telah tercapai, pohon tidak akan berlanjut lebih jauh.

7.5.2.5 Algoritma untuk pohon Keputusan.

Masukan: Set data pelatihan, set data uji (atau titik data)

Tangga:

Lakukan untuk semua atribut

 Hitung entropi E_i dari atribut F_i

 jika $E_i < E_{min}$

 maka $E_{min} = E_i$ dan

$F_{min} = F_i$ dan berakhir

 jika

Akhiri lakukan

 Memisahkan kumpulan data menjadi beberapa bagian menggunakan atribut F_{min}

 Gambarkan simpul pohon keputusan yang berisi atribut F_{min} dan bagi kumpulan data menjadi beberapa bagian

 Ulangi langkah-langkah di atas hingga pohon lengkap digambar yang mencakup semua atribut tabel asli.

7.5.2.6 Menghindari overfitting di pohon keputusan – pemangkasan

Algoritme pohon keputusan, kecuali kriteria penghentian diterapkan, dapat terus tumbuh tanpa batas – terbagi untuk setiap fitur dan terbagi menjadi partisi yang lebih kecil hingga titik di mana data diklasifikasikan dengan sempurna. Hal ini, sebagaimana yang cukup jelas, mengakibatkan masalah overfitting. Untuk mencegah pohon keputusan menjadi overfitting terhadap data pelatihan, pemangkasan pohon keputusan

sangat penting. Pemangkasan pohon keputusan mengurangi ukuran pohon sehingga model menjadi lebih umum dan dapat mengklasifikasikan data yang tidak diketahui dan tidak berlabel dengan cara yang lebih baik.

Ada dua pendekatan pemangkasan:

- Pra-pemangkasan: Hentikan pertumbuhan pohon sebelum mencapai kesempurnaan. Pemangkasan.
- pasca-pemangkasan: Biarkan pohon tumbuh sepenuhnya, lalu pangkas beberapa cabangnya.

Dalam kasus pemangkasan awal, pohon dihentikan pertumbuhannya lebih lanjut setelah mencapai sejumlah simpul keputusan atau keputusan tertentu. Oleh karena itu, dalam strategi ini, algoritme menghindari overfitting serta mengoptimalkan biaya komputasi. Namun, algoritme juga memiliki peluang untuk mengabaikan informasi penting yang disumbangkan oleh fitur yang terlewat, sehingga mengakibatkan hilangnya pola tertentu dalam data.

Di sisi lain, dalam kasus pemangkasan pasca, pohon dibiarkan tumbuh sepenuhnya. Kemudian, dengan menggunakan kriteria pemangkasan tertentu, misalnya tingkat kesalahan pada simpul, ukuran pohon dikurangi. Ini adalah pendekatan yang lebih efektif dalam hal akurasi klasifikasi karena mempertimbangkan semua informasi kecil yang tersedia dari data pelatihan. Namun, biaya komputasi jelas lebih besar daripada pra-pemangkasan.

7.5.2.7 Kekuatan pohon keputusan

- Model ini menghasilkan aturan yang sangat sederhana dan mudah dipahami. Untuk pohon yang lebih kecil, tidak banyak

pengetahuan matematika dan komputasi yang diperlukan untuk memahami model ini.

- Berfungsi dengan baik untuk sebagian besar masalah.
- Dapat menangani variabel numerik dan kategoris.
- Dapat bekerja dengan baik dengan set data pelatihan yang kecil dan besar.

Pohon keputusan memberikan petunjuk pasti tentang fitur mana yang lebih berguna untuk klasifikasi.

7.5.2.8 Kelemahan pohon keputusan

- Model pohon keputusan sering kali condong ke arah fitur yang memiliki lebih banyak kemungkinan nilai, yaitu level.
- Model ini mudah sekali menjadi terlalu pas atau kurang pas.
- Pohon keputusan rentan terhadap kesalahan dalam masalah.
- klasifikasi dengan banyak kelas dan jumlah contoh pelatihan yang relatif kecil.
- Pohon keputusan dapat memerlukan komputasi yang mahal untuk dilatih. Pohon yang besar sulit dipahami.

7.5.2.9 Penerapan pohon keputusan

Pohon keputusan dapat diterapkan dalam kumpulan data yang berisi daftar atribut terbatas dan setiap contoh data menyimpan nilai untuk atribut tersebut (misalnya 'Tinggi' untuk atribut CGPA). Bila setiap atribut memiliki sejumlah kecil nilai yang berbeda (misalnya 'Tinggi', 'Sedang', 'Rendah'), akan lebih mudah/cepat bagi pohon keputusan untuk menyarankan (atau memilih) solusi yang efektif. Algoritme ini dapat

diperluas untuk menangani atribut bernilai riil (misalnya suhu floating point).

Kasus yang paling mudah adalah ketika hanya ada dua nilai yang mungkin untuk suatu atribut (klasifikasi Boolean). Contoh: Komunikasi hanya memiliki dua nilai sebagai 'Baik' atau 'Buruk'. Pohon keputusan juga mudah diperluas untuk membuat fungsi target dengan lebih dari dua nilai keluaran yang mungkin. Contoh: IPK dapat mengambil salah satu nilai dari 'Tinggi', 'Sedang', dan 'Rendah'. Terlepas dari apakah itu nilai biner/beberapa nilai, sifatnya diskrit. Misalnya, Aptitude dapat mengambil nilai 'Tinggi' atau 'Rendah'. Tidak mungkin untuk menetapkan nilai 'Tinggi' dan 'Rendah' pada atribut Aptitude untuk menggambar pohon keputusan.


Tidak boleh ada pengulangan tak terbatas saat mengambil keputusan. Saat kita berpindah dari simpul akar ke simpul tingkat berikutnya, ia harus bergerak selangkah demi selangkah menuju simpul keputusan. Jika tidak, algoritme mungkin tidak memberikan hasil akhir untuk data tertentu. Jika sekumpulan kode berputar dalam satu putaran, ia akan terus berulang selamanya, kecuali jika sistemnya mogok.

Pohon keputusan bahkan dapat digunakan untuk beberapa contoh dengan atribut yang hilang dan contoh dengan kesalahan dalam klasifikasi contoh atau dalam nilai atribut yang menjelaskan contoh tersebut; contoh seperti itu ditangani dengan baik oleh pohon keputusan, sehingga menjadikannya metode pembelajaran yang tangguh.

7.5.3 Model hutan acak

Random forest merupakan pengklasifikasi ensemble, yaitu pengklasifikasi gabungan yang menggunakan dan menggabungkan banyak pengklasifikasi pohon keputusan. Ensembling biasanya dilakukan dengan

menggunakan konsep bagging dengan set fitur yang berbeda. Alasan penggunaan sejumlah besar pohon dalam random forest adalah untuk melatih pohon-pohon tersebut sedemikian rupa sehingga kontribusi dari setiap fitur muncul dalam sejumlah model. Setelah random forest dihasilkan dengan menggabungkan pohon-pohon, suara mayoritas diterapkan untuk menggabungkan keluaran dari berbagai pohon. Model random forest yang disederhanakan digambarkan dalam Gambar 7.14. Hasil dari model ensemble biasanya lebih baik daripada hasil dari model pohon keputusan individual.



GAMBAR 7.14 Model hutan acak

7.5.3.1 Bagaimana cara kerja hutan acak?

Algoritma hutan acak bekerja sebagai berikut:

- Jika terdapat N variabel atau fitur dalam set data input, pilih satu subset berisi ' m ' ($m < N$) fitur secara acak dari N fitur. Selain itu, observasi atau contoh data harus dipilih secara acak.
- Gunakan prinsip pemisahan terbaik pada fitur ' m ' ini untuk menghitung jumlah node ' d '.
- Terus pisahkan simpul-simpul menjadi simpul-simpul anak hingga pohon tumbuh pada tingkat semaksimal mungkin.
- Pilih subset data pelatihan yang berbeda 'dengan penggantian' untuk melatih pohon keputusan lain dengan mengikuti langkah (1) hingga (3). Ulangi ini untuk membangun dan melatih pohon keputusan ' n '.
- Tugas kelas akhir dilakukan berdasarkan suara terbanyak dari pohon ' n '.

7.5.3.2 Kesalahan out-of-bag (OOB) di hutan acak

Di hutan acak, kita telah melihat bahwa setiap pohon dibangun menggunakan sampel bootstrap yang berbeda dari data asli. Sampel yang tidak dimasukkan ke dalam bootstrap dan tidak digunakan dalam konstruksi pohon ke- i dapat digunakan untuk mengukur kinerja model. Di akhir pengujian, prediksi untuk setiap sampel yang dievaluasi setiap waktu dihitung, dan prediksi akhir untuk sampel tersebut diperoleh dengan melakukan pemungutan suara. Total tingkat kesalahan prediksi untuk sampel tersebut disebut sebagai tingkat kesalahan out-of-bag (OOB).

Tingkat kesalahan yang ditunjukkan dalam matriks kebingungan mencerminkan tingkat kesalahan OOB. Karena alasan ini, tingkat kesalahan yang ditampilkan sering kali sangat tinggi.

7.5.3.3 Kekuatan hutan acak

- Berjalan secara efisien pada set data yang besar dan ekspansif.
- Ia memiliki metode yang kuat untuk memperkirakan data yang hilang dan mempertahankan presisi ketika sebagian besar data tidak ada.
- Ia memiliki teknik yang ampuh untuk menyeimbangkan kesalahan dalam populasi kelas kumpulan data yang tidak seimbang.
- Memberikan estimasi (atau penilaian) tentang fitur mana yang paling penting dalam klasifikasi keseluruhan.
- Ini menghasilkan estimasi internal yang tidak bias (pengukur) dari kesalahan generalisasi seiring berjalannya pembuatan hutan.
- Hutan yang dihasilkan dapat disimpan untuk penggunaan masa mendatang pada data lain.

Terakhir, algoritma hutan acak dapat digunakan untuk memecahkan masalah klasifikasi dan regresi.

7.5.3.4 Kelemahan hutan acak

- Model ini, karena menggabungkan sejumlah model pohon keputusan, tidak semudah dipahami seperti model pohon keputusan.
- Secara komputasi, model ini jauh lebih mahal daripada model sederhana seperti pohon keputusan.

7.5.3.5 Aplikasi hutan acak

Random forest merupakan pengklasifikasi yang sangat kuat yang menggabungkan fleksibilitas dari banyak model pohon keputusan menjadi satu model. Karena hasil yang lebih unggul, model ensemble ini semakin diterima dan populer di kalangan praktisi machine learning untuk memecahkan berbagai masalah klasifikasi.


7.5.4 Mesin vektor pendukung

SVM adalah model yang dapat melakukan klasifikasi linear sekaligus regresi. SVM didasarkan pada konsep permukaan, yang disebut hyperplane, yang menggambarkan batas antara contoh data yang diplot dalam ruang fitur multidimensi. Prediksi keluaran SVM adalah salah satu dari dua kelas yang mungkin yang telah didefinisikan dalam data pelatihan. Singkatnya, algoritme SVM membangun model hyperplane N-dimensi yang menetapkan contoh masa depan ke dalam salah satu dari dua kelas keluaran yang mungkin.

7.5.4.1 Klasifikasi menggunakan hyperplane

Dalam SVM, sebuah model dibangun untuk membedakan data-data yang termasuk dalam kelas-kelas yang berbeda. Mari kita asumsikan demi kesederhanaan bahwa data-data tersebut dapat dipisahkan secara linier. Dalam kasus ini, ketika dipetakan dalam ruang dua dimensi, data-data yang termasuk dalam kelas-kelas yang berbeda berada di sisi-sisi yang berbeda dari garis lurus yang ditarik dalam ruang dua dimensi seperti yang digambarkan dalam Gambar 7.15a. Jika konsep yang sama diperluas ke ruang fitur multidimensi, garis lurus yang membagi contoh data yang termasuk dalam kelas yang berbeda berubah menjadi hiperbidang seperti yang digambarkan dalam Gambar 7.15b.

Dengan demikian, model SVM adalah representasi dari instans input sebagai titik-titik dalam ruang fitur, yang dipetakan sehingga celah yang tampak di antara keduanya membagi instans dari kelas-kelas yang terpisah. Dengan kata lain, tujuan analisis SVM adalah untuk menemukan bidang, atau lebih tepatnya hiperbidang, yang memisahkan instans berdasarkan kelas-kelasnya. Contoh-contoh baru (yaitu instans baru) kemudian dipetakan ke dalam ruang yang sama dan diprediksi termasuk dalam suatu kelas berdasarkan sisi celah tempat instans baru tersebut akan berada. Singkatnya, dalam keseluruhan proses pelatihan, algoritma SVM menganalisis data input dan mengidentifikasi permukaan dalam ruang fitur multidimensi yang disebut hiperbidang. Mungkin ada banyak hiperbidang yang memungkinkan, dan salah satu tantangan dengan model SVM adalah menemukan hiperbidang yang optimal.



GAMBAR 7.15 Contoh data yang dapat dipisahkan secara linier

Set data pelatihan yang memiliki pengelompokan periferik yang substansial akan berfungsi dengan baik dengan SVM. Kesalahan

generalisasi dalam hal SVM adalah ukuran seberapa akurat dan tepat model SVM ini dapat memprediksi nilai untuk data yang sebelumnya tidak terlihat (data baru). Margin yang keras dalam hal SVM berarti bahwa model SVM tidak fleksibel dalam klasifikasi dan mencoba bekerja secara luar biasa sesuai dengan set pelatihan, sehingga menyebabkan overfitting.

Vektor Pendukung: Vektor pendukung adalah titik data (yang mewakili kelas), komponen penting dalam kumpulan data, yang berada di dekat kumpulan garis yang diidentifikasi (bidang hiper). Jika vektor pendukung dihilangkan, hal itu akan mengubah posisi bidang hiper pemisah.

Hyperplane dan Margin: Untuk ruang fitur berdimensi N , bidang hiper adalah subruang datar berdimensi $(N-1)$ yang memisahkan dan mengklasifikasikan sekumpulan data. Misalnya, jika kita mempertimbangkan ruang fitur dua dimensi (yang tidak lain adalah kumpulan data yang memiliki dua fitur dan variabel kelas), bidang hiper akan menjadi subruang satu dimensi atau garis lurus. Dengan cara yang sama, untuk ruang fitur tiga dimensi (kumpulan data yang memiliki tiga fitur dan variabel kelas), bidang hiper adalah subruang dua dimensi atau bidang sederhana. Namun, cukup dapat dimengerti, sulit untuk memvisualisasikan ruang fitur yang lebih besar dari tiga dimensi, seperti halnya untuk subruang atau bidang hiper yang memiliki lebih dari tiga dimensi.

Secara matematis, dalam ruang dua dimensi, hiperbidang dapat didefinisikan dengan persamaan:

$C_0 + c_1X_1 + c_2X_2 = 0$, yang tidak lain adalah persamaan garis lurus.

Dengan memperluas konsep ini ke ruang berdimensi N , hiperbidang dapat didefinisikan dengan persamaan:

$c_0 + c_1x_1 + c_2x_2 + \dots + c_Nx_N = 0$ yang, singkatnya, dapat direpresentasikan sebagai berikut:

$$\vec{c} \cdot \vec{X} + c_0 = 0$$


Secara spontan, semakin jauh (atau semakin jauh) titik data dari bidang hiper, semakin yakin kita tentang kategorisasi yang benar. Jadi, ketika titik data/set data pengujian baru ditambahkan, sisi bidang hiper yang menjadi tempatnya akan menentukan kelas yang kita tetapkan padanya. Jarak antara bidang hiper dan titik data dikenal sebagai margin.

7.5.4.2 Mengidentifikasi hyperplane yang benar dalam SVM

Seperti yang telah kita bahas, mungkin ada beberapa opsi untuk hyperplane yang membagi data yang termasuk dalam kelas yang berbeda. Kita perlu mengidentifikasi mana yang akan menghasilkan klasifikasi terbaik. Mari kita periksa beberapa skenario sebelum sampai pada kesimpulan itu. Demi kesederhanaan visualisasi, hyperplane telah ditampilkan sebagai garis lurus di sebagian besar diagram.

Skenario 1

Seperti yang digambarkan dalam Gambar 7.16 Dalam skenario ini, kita memiliki tiga bidang hiper: A, B, dan C. Sekarang, kita perlu mengidentifikasi bidang hiper yang tepat yang dapat memisahkan dua kelas yang direpresentasikan oleh segitiga dan lingkaran dengan lebih baik. Seperti yang dapat kita lihat, bidang hiper 'A' telah menjalankan tugas ini dengan cukup baik.




Gbr. 7.16 Mesin vektor pendukung: Skenario 1

Skenario 2

Seperti yang digambarkan dalam Gambar 7.17, kita memiliki tiga bidang hiper: A, B, dan C. Kita harus mengidentifikasi bidang hiper yang tepat yang mengklasifikasikan segitiga dan lingkaran dengan cara sebaik mungkin. Di sini, memaksimalkan jarak antara titik data terdekat dari kedua kelas dan bidang hiper akan membantu kita menentukan bidang hiper yang tepat. Jarak ini disebut margin.


Di dalam Gambar 7.17b, Anda dapat melihat bahwa margin untuk bidang hiper A tinggi dibandingkan dengan bidang hiper B dan C. Oleh karena itu, bidang hiper A adalah bidang hiper yang benar. Alasan cepat lainnya untuk memilih bidang hiper dengan margin (jarak) yang lebih tinggi adalah ketahanan. Jika kita memilih bidang hiper yang memiliki margin (jarak) yang lebih rendah, maka ada kemungkinan besar terjadi kesalahan klasifikasi.



Gbr. 7.17 Mesin vektor pendukung: Skenario 2

Skenario 3

Gunakan aturan seperti yang dibahas di bagian sebelumnya untuk mengidentifikasi hyperplane yang benar dalam skenario yang ditunjukkan di **Gambar 7.18**. Beberapa dari Anda mungkin telah memilih hyperplane B karena memiliki margin (jarak dari kelas) yang lebih tinggi daripada A. Namun, inilah kendalanya; SVM memilih hyperplane yang mengklasifikasikan kelas secara akurat sebelum memaksimalkan margin. Di sini, hyperplane B memiliki kesalahan klasifikasi, dan A telah mengklasifikasikan semua contoh data dengan benar. Oleh karena itu, A adalah hyperplane yang benar.




Gambar. 7.18 Mesin vektor pendukung: Skenario 3

Skenario 4

Dalam skenario ini, seperti yang ditunjukkan pada Gambar 7.19a, tidaklah mungkin untuk memisahkan dua kelas secara jelas dengan menggunakan garis lurus, karena satu contoh data yang termasuk dalam salah satu kelas (segitiga) terletak di wilayah kelas lain (lingkaran) sebagai outlier.

Segitiga yang satu di ujung lainnya seperti outlier untuk kelas segitiga. SVM memiliki fitur untuk mengabaikan outlier dan menemukan hyperplane yang memiliki margin maksimum (hyperplane A, seperti yang ditunjukkan pada Gambar 7.19b). Oleh karena itu, kita dapat mengatakan bahwa SVM tangguh terhadap outlier.



Gbr. 7.19 Mesin vektor pendukung: Skenario 4


Jadi, dengan meringkas pengamatan dari berbagai skenario, kita dapat mengatakan bahwa

1. Hiperbidang harus memisahkan instansi data yang termasuk ke dalam dua kelas dengan cara sebaik mungkin.
2. Seharusnya memaksimalkan jarak antara titik data terdekat dari kedua kelas, yaitu memaksimalkan margin.
3. Jika ada kebutuhan untuk memprioritaskan antara margin yang lebih tinggi dan kesalahan klasifikasi yang lebih sedikit, hyperplane harus mencoba mengurangi kesalahan klasifikasi.

Fokus kami berikutnya adalah mencari cara mengidentifikasi hiperbidang yang memaksimalkan margin.

7.5.4.3 Hyperplane margin maksimum

Menemukan Hyperplane Margin Maksimum (MMH) tidak lain adalah mengidentifikasi hyperplane yang memiliki pemisahan terbesar dengan data instans dari dua kelas. Meskipun setiap set dari tiga hyperplane dapat melakukan klasifikasi yang benar, mengapa kita perlu mencari set hyperplane yang menyebabkan pemisahan terbesar? Jawabannya adalah dengan melakukan hal itu membantu kita dalam mencapai generalisasi yang lebih banyak dan dengan demikian mengurangi jumlah masalah dalam klasifikasi data yang tidak diketahui.




Gbr. 7.20 Vektor pendukung

Vektor pendukung, seperti yang dapat diamati di Gambar 7.20, adalah contoh data dari dua kelas yang paling dekat dengan MMH. Dapat dipahami bahwa harus ada setidaknya satu vektor pendukung dari setiap kelas. Identifikasi vektor pendukung memerlukan formulasi matematika yang intensif, yang berada di luar cakupan buku ini. Namun, cukup intuitif

untuk memahami bahwa pemodelan masalah menggunakan SVM tidak lain adalah mengidentifikasi vektor pendukung dan MMH yang sesuai dengan ruang masalah.

Mengidentifikasi MMH untuk data yang dapat dipisahkan secara linier

Menemukan MMH relatif mudah untuk data yang dapat dipisahkan secara linier. Dalam kasus ini, batas luar perlu dibuat untuk contoh data yang termasuk dalam kelas yang berbeda. Batas luar ini dikenal sebagai convex hull, seperti yang digambarkan dalam [Gambar 7.21](#) MMH dapat digambar sebagai garis bagi tegak lurus dari garis terpendek (yaitu garis penghubung yang memiliki panjang terpendek) antara lambung cembung.



Gbr. 7.21 Menggambar MMH untuk data yang dapat dipisahkan secara linier

Kita telah melihat sebelumnya bahwa sebuah hiperbidang dalam ruang fitur N dimensi dapat direpresentasikan oleh persamaan:

$$\vec{c} \cdot \vec{X} + c_0 = 0$$


Dengan menggunakan persamaan ini, tujuannya adalah untuk menemukan sekumpulan nilai untuk vektor $\vec{c}$ sedemikian rupa sehingga dua hiperbidang, yang direpresentasikan oleh persamaan di bawah, dapat ditentukan.

$$\begin{aligned}\vec{c} \cdot \vec{X} + c_0 &\geq +1 \\ \vec{c} \cdot \vec{X} + c_0 &\leq -1\end{aligned}$$

Hal ini untuk memastikan bahwa semua data yang termasuk dalam satu kelas berada di atas satu hyperplane dan semua data yang termasuk dalam kelas lain berada di bawah hyperplane lainnya. Menurut geometri vektor, jarak dari bidang-bidang ini harus $\frac{2}{\|\vec{c}\|}$. Sangat jelas bahwa untuk memaksimalkan jarak antar hyperplane, nilai $\|\vec{c}\|$ seharusnya diminimalkan. Jadi, secara ringkas, tugas SVM adalah memecahkan masalah optimasi:

$$\min \left(\frac{1}{2} \|\vec{c}\|^2 \right)$$

Mengidentifikasi MMH untuk data yang tidak dapat dipisahkan secara linier. Sekarang setelah kita memiliki pemahaman yang jelas tentang cara mengidentifikasi MMH untuk kumpulan data yang dapat dipisahkan secara linier, mari kita lakukan beberapa studi tentang bagaimana data yang tidak dapat dipisahkan secara linier perlu ditangani oleh SVM. Untuk ini, kita harus menggunakan variabel slack ξ , yang menyediakan beberapa margin lunak untuk contoh data dalam satu kelas yang berada di sisi yang salah dari hyperplane. Seperti yang digambarkan dalam [Gambar 7.22](#), contoh data yang termasuk dalam kelas lingkaran berada di sisi bidang hiper yang ditujukan untuk contoh data yang termasuk dalam kelas segitiga. Masalah yang sama juga terjadi pada contoh data yang termasuk dalam kelas segitiga.



Gbr. 7.22 Menggambar MMH untuk data yang tidak dapat dipisahkan secara linier


Nilai biaya 'C' dikenakan pada semua contoh data yang berada di sisi yang salah dari hyperplane. Tugas SVM sekarang adalah meminimalkan total biaya yang disebabkan oleh contoh data tersebut untuk menyelesaikan masalah optimasi yang telah direvisi:

$$\min \left(\frac{1}{2} \vec{c}^2 \right) + C \sum_{i=1}^N \xi_i$$

7.5.4.4 Trik kernel

Seperti yang telah kita lihat di bagian terakhir, salah satu cara untuk menangani data yang tidak dapat dipisahkan secara linier adalah dengan menggunakan variabel slack dan fungsi optimasi untuk meminimalkan nilai biaya. Namun, ini bukan satu-satunya cara untuk menggunakan SVM guna memecahkan masalah pembelajaran mesin yang melibatkan kumpulan data yang tidak dapat dipisahkan secara linier. SVM memiliki teknik yang disebut trik kernel untuk menangani data yang tidak dapat

dipisahkan secara linier. Seperti yang ditunjukkan di [Gambar 7.23](#), ini adalah fungsi yang dapat mengubah ruang input berdimensi lebih rendah ke ruang berdimensi lebih tinggi. Dalam prosesnya, ia mengubah data yang tidak dapat dipisahkan secara linear menjadi data yang dapat dipisahkan secara linear. Fungsi-fungsi ini disebut kernel.



Gbr. 7.23 Trik kernel dalam SVM

Beberapa fungsi kernel umum untuk melakukan transformasi dari dimensi lebih rendah 'i' ke dimensi lebih tinggi 'j' yang digunakan oleh berbagai implementasi SVM adalah sebagai berikut:

- Kernel linier: Bentuknya $K(\vec{x}_i, \vec{x}_j) = \vec{x}_i \cdot \vec{x}_j$
- Kernel polinomial: Dalam bentuk $K(\vec{x}_i, \vec{x}_j) = (\vec{x}_i \cdot \vec{x}_j + 1)^d$
- Kernel sigmoid: Bentuknya seperti ini $K(\vec{x}_i, \vec{x}_j) = \tan h(k\vec{x}_i \cdot \vec{x}_j - \theta)$
- Kernel Gaussian RBF: Bentuknya $K(\vec{x}_i, \vec{x}_j) = e^{-\frac{\|\vec{x}_i - \vec{x}_j\|^2}{2\sigma^2}}$

Ketika instance data dari kelas-kelas lebih dekat satu sama lain, metode ini dapat digunakan. Efektivitas SVM bergantung pada pemilihan fungsi kernel adopsi nilai untuk parameter kernel

7.5.4.5 Kekuatan SVM

- SVM dapat digunakan untuk klasifikasi dan regresi.
- Kuat, artinya tidak terlalu terpengaruh oleh data yang mengandung noise atau outlier.
- Hasil prediksi menggunakan model ini sangat menjanjikan.

7.5.4.6 Kelemahan SVM

- SVM hanya berlaku untuk klasifikasi biner, yaitu ketika hanya ada dua kelas dalam domain masalah.
- Model SVM sangat kompleks – hampir seperti kotak hitam ketika berhadapan dengan kumpulan data berdimensi tinggi. Oleh karena itu, sangat sulit dan hampir mustahil untuk memahami model dalam kasus seperti itu.
- Proses ini lambat untuk kumpulan data besar, yaitu kumpulan data dengan sejumlah besar fitur atau sejumlah besar contoh. Proses ini cukup menguras memori.

7.5.4.7 Penerapan SVM

SVM paling efektif bila digunakan untuk klasifikasi biner, yaitu untuk memecahkan masalah pembelajaran mesin dengan dua kelas. Satu masalah umum yang dapat diterapkan SVM adalah di bidang bioinformatika – lebih khusus lagi, dalam mendeteksi kanker dan kelainan genetik lainnya. SVM juga dapat digunakan dalam mendeteksi citra wajah melalui klasifikasi biner citra menjadi komponen wajah dan non-wajah. Lebih banyak aplikasi seperti itu dapat dijelaskan.

7.6 RINGKASAN

1. Tujuan klasifikasi adalah untuk memprediksi kelas objek yang tidak diketahui berdasarkan informasi terkait kelas sebelumnya dari objek serupa. Pembelajaran ini dapat digunakan ketika cara mengklasifikasikan data tertentu diketahui atau, dengan kata lain, nilai kelas dari contoh data tersedia.
2. Masalah klasifikasi yang kritis dalam konteks perbankan adalah mengidentifikasi transaksi yang berpotensi mengandung kecurangan. Karena ada jutaan transaksi yang harus diteliti untuk mengidentifikasi apakah transaksi tertentu mungkin merupakan transaksi penipuan, tidak mungkin bagi manusia mana pun untuk melaksanakan tugas ini.
3. Algoritma klasifikasi yang umum adalah kNN, pohon keputusan, hutan acak, SVM, dan Naïve Bayes.
4. Algoritma kNN termasuk salah satu algoritma pembelajaran mesin terbaik dan paling sederhana. Sebuah instance baru diklasifikasikan berdasarkan suara mayoritas tetangganya, dengan instance tersebut dialokasikan ke kelas yang paling dominan di antara kNN-nya.
5. Pembelajaran pohon keputusan merupakan pengklasifikasi yang paling banyak digunakan. Pembelajaran ini ditandai dengan waktu eksekusi yang cepat dan kemudahan dalam penafsiran aturan.
6. Algoritma pohon keputusan perlu mencari tahu pemisahan atribut yang menghasilkan perolehan informasi tertinggi. Untuk contoh contoh pelatihan S , entropi mengukur ketidakmurnian S .

$$\mathbf{Entropy}(S) = - \sum_{i=1}^C p_i \log_2 p_i$$

di mana c merupakan jumlah label kelas yang berbeda dan p merujuk pada proporsi nilai yang termasuk dalam label kelas ke- i .

7. Perolehan informasi dibuat berdasarkan penurunan entropi (S) setelah kumpulan data dipecah berdasarkan atribut tertentu (A). Perolehan informasi untuk fitur tertentu A dihitung berdasarkan perbedaan entropi sebelum pemecahan (S_{bs}) dengan entropi setelah pemecahan (S_{as}).

Keuntungan Informasi (S, A) = Entropi (S_{bs}) - Entropi (S_{as})

8. Random forest merupakan pengklasifikasi ensemble (pengklasifikasi gabungan) yang menggunakan dan menggabungkan banyak model pohon keputusan. Hasil dari model ensemble biasanya lebih baik daripada hasil dari salah satu model individual.
9. SVM adalah pengklasifikasi linier biner. Prediksi keluaran SVM adalah salah satu dari dua kelas yang mungkin yang sudah didefinisikan dalam data pelatihan. SVM juga merupakan contoh pengklasifikasi linier dan pengklasifikasi margin maksimum.
10. SVM memiliki teknik baru yang disebut trik kernel. Ini adalah fungsi yang mengambil ruang input berdimensi lebih rendah dan mengubahnya ke ruang berdimensi lebih tinggi dan dalam proses tersebut mengubah masalah yang tidak dapat dipisahkan secara linier menjadi masalah yang dapat dipisahkan secara linier. Fungsi ini disebut kernel. Ketika semua kelas lebih dekat satu sama lain, metode ini dapat digunakan.

SOAL PILIHAN GANDA

1. Memprediksi apakah tumor ganas atau jinak merupakan salah satu contoh dari? Pembelajaran Tanpa Pengawasan
Masalah Regresi Terbimbing
Masalah Klasifikasi Terbimbing
Atribut Kategoris
2. Prediksi harga di bidang real estate merupakan salah satu contoh?
 1. Pembelajaran Tanpa Pengawasan
 2. Masalah Regresi Terbimbing
 3. Masalah Klasifikasi Terbimbing
 4. Atribut Kategoris
3. Mari kita pertimbangkan dua contoh, katakanlah 'memprediksi apakah suatu tumor ganas atau jinak' dan 'prediksi harga di bidang real estat'.
Kedua masalah ini sama sifatnya.
 1. BENAR
 2. PALSU
4. Pembelajaran mesin yang diawasi sama baiknya dengan data yang digunakan untuk melatihnya.
 1. BENAR
 2. PALSU
5. Manakah jenis pembelajaran mesin di mana fitur target, yang bertipe kategoris, diprediksi untuk data uji berdasarkan informasi yang diberikan oleh data pelatihan?
 1. Pembelajaran Tanpa Pengawasan
 2. Regresi Terbimbing
 3. Klasifikasi Terbimbing
 4. Atribut Kategoris

6. Klasifikasi adalah jenis pembelajaran terbimbing di mana fitur target, yang bertipe kategoris, diprediksi untuk data uji berdasarkan informasi yang diberikan oleh data pelatihan. Fitur kategoris target dikenal sebagai?

1. Obyek
2. Variabel
3. Metode
4. Kelas

7. Ini adalah langkah pertama dalam model pembelajaran terbimbing.

1. Identifikasi Masalah
2. Identifikasi Data yang Diperlukan
3. Pra-Pengolahan Data
4. Definisi Training Data Set

8. Ini adalah pembersihan/transformasi kumpulan data dalam model pembelajaran terbimbing.

1. Identifikasi Masalah
2. Identifikasi Data yang Diperlukan
3. Pra-Pengolahan Data
4. Definisi Training Data Set

9. Hal ini mengacu pada transformasi yang diterapkan pada data yang diidentifikasi sebelum memasukkannya ke dalam algoritma.
Identifikasi Masalah

Identifikasi Data yang Diperlukan

Pra-Pengolahan Data

Definisi Training Data Set

Langkah pembelajaran terawasi ini menentukan 'jenis kumpulan data pelatihan'.

1. Identifikasi Masalah

2. Identifikasi Data yang Diperlukan
 3. Pra-Pengolahan Data
 4. Definisi Training Data Set
11. Seluruh desain program dilakukan di sini dalam pembelajaran yang diawasi.
1. Identifikasi Masalah
 2. Pelatihan
 3. Pra-pemrosesan Data
 4. Definisi Training Data Set
12. Data pelatihan yang dijalankan pada algoritma disebut sebagai?
1. Program
 2. Pelatihan
 3. Informasi Pelatihan
 4. Fungsi yang Dipelajari
13. SVM merupakan contoh dari?
1. Klasifikasi Linier dan Klasifikasi Margin Maksimum
 2. Klasifikasi Non-Linear dan Klasifikasi Margin Maksimum
 3. Klasifikasi Linier dan Klasifikasi Margin Minimum
 4. Klasifikasi Non-Linear dan Klasifikasi Margin Minimum
14. ----- dalam hal SVM berarti bahwa SVM tidak fleksibel dalam klasifikasi
1. Margin Keras
 2. Margin Lunak
 3. Margin Linier
 4. Klasifikasi Non-Linear
15. ----- adalah titik data (yang mewakili kelas), komponen penting dalam kumpulan data, yang berada di dekat kumpulan garis yang diidentifikasi (bidang hiper).

1. Margin Keras
 2. Margin Lunak
 3. Margin Linier
 4. Vektor Pendukung
16. ----- adalah garis yang memisahkan dan mengklasifikasikan sekumpulan data secara linear.
1. Bidang Hiper
 2. Margin Lunak
 3. Margin Linier
 4. Vektor Pendukung
17. Jarak antara hyperplane dan titik data disebut sebagai: Hyper Plan
Margin
Kesalahan
Vektor Pendukung
- 18 Manakah dari pernyataan berikut yang benar tentang SVM?
1. Ini hanya berguna di ruang berdimensi tinggi
 2. Itu selalu memberikan nilai perkiraan
 3. Itu akurat
 4. Memahami SVM itu sulit
19. Manakah dari pernyataan berikut yang benar tentang SVM?
1. Ini hanya berguna di ruang berdimensi tinggi
 2. Membutuhkan lebih sedikit memori
 3. SVM tidak bekerja dengan baik ketika kita memiliki kumpulan data yang besar
 4. SVM bekerja dengan baik ketika kita memiliki kumpulan data yang besar
20. Apa arti margin keras dalam SVM?

1. SVM memungkinkan kesalahan yang sangat rendah dalam klasifikasi
 2. SVM memungkinkan sejumlah besar kesalahan dalam klasifikasi
 3. Perlengkapan yang kurang
 4. SVM sangat fleksibel
21. Ukuran set data pelatihan apa yang tidak cocok untuk SVM?
1. Set data besar
 2. Set data pelatihan yang sangat kecil
 3. Set data pelatihan ukuran sedang
 4. Ukuran set data pelatihan tidak menjadi masalah
22. Vektor Pendukung berada di dekat hiperbidang.
1. BENAR
 2. PALSU
23. Dalam SVM, fungsi-fungsi ini mengambil ruang masukan berdimensi lebih rendah dan mengubahnya ke ruang berdimensi lebih tinggi.
1. Inti
 2. Vektor
 3. Vektor Pendukung
 4. Bidang Hiper
24. Manakah dari pilihan berikut yang benar tentang algoritma kNN?
1. Ini hanya dapat digunakan untuk klasifikasi
 2. Ini hanya dapat digunakan untuk regresi
 3. Ini dapat digunakan untuk klasifikasi dan regresi
 4. Tidak dapat digunakan untuk klasifikasi dan regresi
25. Manakah dari berikut ini yang merupakan jarak Euclidean antara dua titik data A(4,3) dan B(2,3)?
1. 1
 2. 2
 3. 4
 4. 8

26. Manakah dari berikut ini yang merupakan jarak Manhattan antara dua titik data A(8,3) dan B(4,3)?
1. 1
 2. 2
 3. 4
 4. 8
27. Bila Anda menemukan banyak gangguan pada data, opsi mana berikut yang akan Anda pertimbangkan dalam kNN?
1. Meningkatkan nilai k
 2. Kurangi nilai k
 3. Kebisingan tidak bergantung pada k
 4. *Bahasa Inggris: K= 0*
28. Apa hubungan antara waktu pelatihan yang dibutuhkan oleh 1NN, 2-NN, dan 3-NN?
1. $1\text{-NN} > 2\text{-NN} > 3\text{-NN}$
 2. $1\text{-NN} < 2\text{-NN} < 3\text{-NN}$
 3. $1\text{-NN} \sim 2\text{-NN} \sim 3\text{-NN}$
 4. Tidak ada satupun yang ini
29. Algoritma berikut manakah yang merupakan contoh algoritma pembelajaran ensemble?
1. Hutan Acak
 2. Pohon Keputusan
 3. *aku*Tidak ada
 4. Bahasa Indonesia: SVM
30. Manakah dari berikut ini yang bukan merupakan bias induktif dalam pohon keputusan?
1. Ia lebih menyukai pohon yang lebih panjang daripada pohon yang lebih pendek

2. Pohon yang menempatkan simpul di dekat akar dengan perolehan informasi tinggi lebih disukai
3. Overfitting adalah fenomena alami dalam pohon keputusan
4. Lebih memilih hipotesis terpendek yang sesuai dengan data

SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI)

1. Apa itu pembelajaran terbimbing? Mengapa disebut demikian?
2. Berikan contoh pembelajaran terawasi dalam industri rumah sakit.
3. Berikan tiga contoh pembelajaran terbimbing.
4. Apa itu klasifikasi dan regresi dalam pembelajaran terbimbing?
5. Berikan beberapa contoh algoritma klasifikasi umum.
6. Jelaskan model SVM secara singkat.
7. Berapa biaya kesalahan klasifikasi dalam SVM?
8. Tentukan Vektor Pendukung dalam model SVM.
9. Tentukan kernel dalam model SVM.
10. Apa saja faktor yang menentukan efektivitas SVM?
11. Apa keuntungan model SVM?
12. Apa kerugian model SVM?
13. Tulis catatan tentang
 - 1 kesalahan validasi dalam algoritma kNN
 - 2 memilih nilai k dalam algoritma kNN
 - 3 bias induktif dalam pohon keputusan
14. Apa keuntungan algoritma kNN?
15. Apa kerugian algoritma kNN?
16. Jelaskan secara singkat algoritma pohon keputusan.
17. Apa itu simpul dan daun dalam pohon keputusan?

18. Apa itu entropi pohon keputusan?
19. Tentukan perolehan informasi dalam pohon keputusan.
20. Tuliskan tiga kekuatan metode pohon keputusan.
21. Tuliskan tiga kelemahan metode pohon keputusan.
22. Jelaskan secara singkat model hutan acak?

SOAL JAWABAN PANJANG (MASING-MASING 10 NILAI)

1. Bedakan antara pembelajaran terawasi, pembelajaran semi-terawasi, dan pembelajaran tanpa pengawasan.
2. Jelaskan lima contoh masalah klasifikasi secara rinci.
3. Jelaskan langkah-langkah klasifikasi secara rinci.
4. Diskusikan model SVM secara detail dengan berbagai skenario.
5. Apa keuntungan dan kerugian yang terkait dengan SVM?
6. Diskusikan model kNN secara rinci.
7. Diskusikan tingkat kesalahan dan kesalahan validasi pada algoritma kNN.
8. Diskusikan cara menghitung jarak antara data uji dan data pelatihan untuk kNN.
9. Tulis algoritma untuk kNN.
10. Apa itu pohon keputusan? Apa saja jenis-jenis node? Jelaskan secara rinci
11. Jelaskan berbagai pilihan pencarian pohon keputusan.
12. Diskusikan algoritma pohon keputusan secara rinci.
13. Apa itu bias induktif dalam pohon keputusan? Bagaimana cara menghindari overfitting?
14. Apa kekuatan dan kelemahan metode pohon keputusan?
15. Diskusikan masalah yang sesuai untuk pembelajaran pohon keputusan secara rinci.

16. Jelaskan model random forest secara rinci. Apa saja fitur random forest?
17. Diskusikan kesalahan OOB dan kepentingan variabel dalam hutan acak.

Bab 8 Pembelajaran Terbimbing: Regresi

Pradita Eko Prasetyo Utomo, M.Cs.

A. Tujuan Pembelajaran

Dalam dua bab terakhir, Anda telah memperoleh gambaran konseptual yang cukup baik tentang algoritma pembelajaran terbimbing untuk prediksi data kategoris. Anda memperoleh pemahaman terperinci tentang semua model klasifikasi populer yang digunakan oleh praktisi pembelajaran mesin untuk memecahkan berbagai macam masalah prediksi di mana variabel target adalah variabel kategoris.

8.1 PENDAHULUAN

Dalam bab ini, kita akan membangun konsep tentang prediksi variabel numerik – yang merupakan area penting lain dari pembelajaran terbimbing. Area ini, yang dikenal sebagai regresi, berfokus pada penyelesaian masalah seperti memprediksi nilai real estat, perkiraan permintaan di ritel, perkiraan cuaca, dll. Pertama, Anda akan diperkenalkan dengan algoritma yang paling populer dan paling sederhana, yaitu regresi linier sederhana. Model ini berakar dari konsep statistik tentang pencocokan garis lurus dan metode kuadrat terkecil. Kita akan membahasnya algoritma secara terperinci. Dalam konteks yang sama, kita juga akan mengeksplorasi konsep regresi linier berganda. Kami kemudian akan secara singkat menyentuh algoritma penting lainnya dalam regresi, yaitu spline regresi adaptif multivariat, regresi logistik, dan estimasi kemungkinan maksimum. Pada akhir bab ini, Anda akan memperoleh pengetahuan yang cukup dalam semua aspek pembelajaran terbimbing dan menjadi siap untuk mulai memecahkan masalah sendiri.

8.2 CONTOH REGRESI

Kami telah menyebutkan berkali-kali bahwa prediksi harga real estat adalah masalah yang dapat dipecahkan dengan pembelajaran terbimbing atau, lebih khusus lagi, dengan regresi. Jadi, apa sebenarnya masalah ini? Mari kita bahas lebih dalam.

New City merupakan pusat utama kegiatan komersial di negara ini. Dalam beberapa dekade terakhir, dengan meningkatnya globalisasi, kegiatan komersial di New City semakin meningkat. Bersamaan dengan itu, banyak orang datang dan menetap di kota ini dengan impian untuk meraih pertumbuhan profesional dalam hidup mereka. Sebagai dampak yang nyata, sejumlah besar proyek perumahan telah dimulai di setiap sudut kota. Namun, permintaan apartemen masih melebihi pasokan. Untuk mendapatkan keuntungan dari ledakan bisnis real estat ini, Karen telah memulai agen pasar digital untuk membeli dan menjual real estat (termasuk apartemen, rumah independen, rumah kota, dll.). Awalnya, ketika bisnisnya masih kecil, ia biasa berinteraksi dengan pembeli dan penjual secara pribadi dan membantu mereka mencapai penawaran harga – baik untuk menjual properti (untuk penjual) atau untuk membeli properti (untuk pembeli). Pengalamannya yang panjang dalam bisnis real estat membantunya mengembangkan intuisi tentang harga penawaran properti yang tepat – mengingat nilai parameter standar tertentu seperti luas (m²) properti, lokasi, lantai, jumlah tahun sejak pembelian, fasilitas yang tersedia, dll. Namun, dengan lonjakan besar dalam bisnis tersebut, ia menghadapi tantangan besar. Ia tidak dapat mengelola interaksi pribadi serta menetapkan harga penawaran yang tepat untuk properti sendiri. Ia mempekerjakan seorang asisten untuk mengelola interaksi pelanggan. Namun, asisten tersebut, yang baru dalam bisnis real estat, kesulitan dengan penawaran harga. Bagaimana Karen dapat memecahkan masalah ini?

Untungnya, Karen punya teman, Frank, yang merupakan ilmuwan data dengan pengetahuan mendalam tentang model pembelajaran mesin. Frank menemukan solusi untuk masalah Karen. Ia membangun model yang dapat memprediksi nilai real estat yang tepat jika memiliki input standar tertentu seperti luas (m²) properti, lokasi, lantai, jumlah tahun sejak pembelian, fasilitas yang tersedia, dll. Wah, kedengarannya seperti Karen sendiri yang mengerjakannya! Penasaran ingin tahu model apa yang digunakan Frank? Ya, tebakkan Anda benar. Ia menggunakan model regresi untuk memecahkan masalah prediksi harga real estat Karen.

Jadi, kita baru saja membahas satu masalah yang dapat dipecahkan menggunakan regresi. Dengan cara yang sama, sejumlah masalah lain yang terkait dengan prediksi nilai numerik dapat dipecahkan menggunakan model regresi. Dalam konteks regresi, variabel dependen (Y) adalah variabel yang nilainya akan diprediksi, misalnya harga penawaran real estat dalam konteks masalah Karen. Variabel ini diasumsikan secara fungsional terkait dengan satu (misalnya, X) atau lebih variabel independen yang disebut prediktor. Dalam konteks masalah Karen, Frank menggunakan luas properti, lokasi, lantai, dsb. sebagai prediktor model yang dibangunnya. Dengan kata lain, variabel dependen bergantung pada variabel independen atau prediktor. Regresi pada dasarnya adalah menemukan hubungan (atau) asosiasi antara variabel dependen (Y) dan variabel independen (X), yaitu menemukan fungsi 'f' untuk asosiasi $Y = f(X)$.


8.3 ALGORITMA REGRESI UMUM

- Algoritma regresi yang paling umum adalah Regresi linier sederhana.
- Regresi linier berganda.
- Regresi polynomial.

- Regresi adaptif multivariat splines.
- Regresi logistik.
- Estimasi kemungkinan maksimum (kuadrat terkecil)

8.3.1 Regresi Linier Sederhana

Sesuai dengan namanya, regresi linier sederhana merupakan model regresi paling sederhana yang hanya melibatkan satu prediktor. Model ini mengasumsikan adanya hubungan linier antara variabel dependen dan variabel prediktor seperti yang ditunjukkan pada Gambar 8.1.



Gbr. 8.1 Regresi linier sederhana

Dalam konteks masalah Karen, jika kita mengambil Harga Properti sebagai variabel dependen dan Luas Properti (dalam m persegi) sebagai

variabel prediktor, kita dapat membangun model menggunakan regresi linier sederhana.

Properti Harga = f (Properti Area). Dengan mengasumsikan adanya hubungan linier, kita dapat merumuskan kembali model tersebut sebagai $\text{HargaProperti} = a + b \cdot \text{Properti Area}$ di mana 'a' dan 'b' adalah intersep dan kemiringan garis lurus, masing-masing.


Sekadar untuk mengingat, garis lurus dapat didefinisikan dalam bentuk kemiringan–perpotongan $Y = (a + bX)$, di mana a = perpotongan dan b = kemiringan garis lurus. Nilai perpotongan menunjukkan nilai Y ketika $X = 0$. Nilai ini dikenal sebagai 'perpotongan atau perpotongan Y ' karena menentukan di mana garis lurus memotong sumbu vertikal atau sumbu Y (lihat [Gambar 8.1](#))

8.3.1.1 Kemiringan model regresi linier sederhana

Kemiringan garis lurus menggambarkan seberapa besar garis pada grafik berubah dalam arah vertikal (sumbu Y) terhadap perubahan arah horizontal (sumbu X) seperti yang ditunjukkan pada [Gambar 8.2](#).

Kemiringan = Perubahan Y /Perubahan X

Kenaikan adalah perubahan pada sumbu Y ($Y_2 - Y_1$) dan Lari adalah perubahan pada sumbu X ($X_2 - X_1$). Jadi, kemiringan direpresentasikan seperti yang diberikan di bawah ini:



Gbr. 8.2Representasi bangkit dan lari

$$\text{Slope} = \frac{\text{Rise}}{\text{Run}} = \frac{Y_2 - Y_1}{X_2 - X_1}$$

Contoh kemiringan

Mari kita cari kemiringan grafik di mana titik terendah pada garis direpresentasikan sebagai $(-3, -2)$ dan titik tertinggi pada garis direpresentasikan sebagai $(2, 2)$.

$$(X_1, Y_1) = (-3, -2) \text{ dan } (X_2, Y_2) = (2, 2)$$

$$\begin{aligned} \text{Naik} &= (Y_2 - Y_1) = (2 - (-2)) = 2 + 2 = 4 \\ \text{Turun} &= (X_2 - X_1) = (2 - (-3)) = 2 + 3 = 5 \end{aligned}$$


$$\text{Kemiringan} = \text{Naik/Turun} = 4/5 = 0,8$$

Terdapat dua jenis kemiringan dalam model regresi linier: kemiringan positif dan kemiringan negatif. Berbagai jenis garis regresi berdasarkan jenis kemiringannya meliputi:

- Kemiringan positif linier
- Kurva kemiringan linier positif
- Kemiringan negatif linier
- Kurva kemiringan negatif linier

Kemiringan positif linier

Kemiringan positif selalu bergerak ke atas pada grafik dari kiri ke kanan (lihat Gambar 8.3).




Gbr. 8.3 Kemiringan positif linier

Kemiringan = Naik/Turun = $(Y_2 - Y_1) / (X_2 - X_1) = \text{Delta (Y)} / \text{Delta (X)}$

- Skenario 1 untuk kemiringan positif: Delta (Y) positif dan Delta (X) positif.
- Skenario 2 untuk kemiringan positif: Delta (Y) negatif dan Delta (X) negatif

Kurva kemiringan linier positif



Gbr. 8.4Kurva kemiringan linier positif


Kurva pada grafik ini (lihat [Gambar 8.4](#)) miring ke atas dari kiri ke kanan.

Kemiringan = $(Y_2 - Y_1) / (X_2 - X_1) = \text{Delta (Y)} / \text{Delta (X)}$

Kemiringan untuk suatu variabel (X) dapat bervariasi antara dua grafik, tetapi akan selalu positif; oleh karena itu, grafik di atas disebut sebagai grafik dengan kemiringan kurva linier positif.

Kemiringan negatif linier


Kemiringan negatif selalu bergerak ke bawah pada grafik dari kiri ke kanan. Ketika nilai X (pada sumbu X) meningkat, nilai Y menurun (lihat [Gambar 8.5](#)).



Gambar. 8.5 Kemiringan negatif linier

Kemiringan = Naik/Turun = $(Y_2 - Y_1) / (X_2 - X_1) = \text{Delta (Y)} / \text{Delta (X)}$

- Skenario 1 untuk kemiringan negatif: Delta (Y) positif dan Delta (X) negative.
 - Skenario 2 untuk kemiringan negatif: Delta (Y) negatif dan Delta (X) positif
- Kurva kemiringan negatif linier*



Gambar. 8.6 Kurva kemiringan negatif linier


Kurva pada grafik ini (lihat [Gambar 8.6](#)) miring ke bawah dari kiri ke kanan.

$$\text{Kemiringan} = (Y_2 - Y_1) / (X_2 - X_1) = \text{Delta (Y)} / \text{Delta (X)}$$

Kemiringan untuk suatu variabel (X) dapat bervariasi antara dua grafik, tetapi akan selalu negatif; oleh karena itu, grafik di atas disebut grafik dengan kemiringan linier kurva negatif.

8.3.1.2 Tidak ada grafik hubungan

Grafik sebaran ditunjukkan dalam [Gambar 8.7](#) menunjukkan kurva 'tidak ada hubungan' karena sangat sulit untuk menyimpulkan apakah hubungan antara X dan Y positif atau negatif.



Gambar. 8.7 Tidak ada grafik hubungan

8.3.1.3 Kesalahan dalam regresi sederhana

Model persamaan regresi dalam pembelajaran mesin menggunakan format kemiringan-intersep di atas dalam algoritme. Nilai X dan Y diberikan ke mesin, dan mesin mengidentifikasi nilai a (intersep) dan b (kemiringan) dengan menghubungkan nilai X dan Y. Namun, mengidentifikasi kecocokan nilai yang tepat untuk a dan b tidak selalu memungkinkan. Akan ada beberapa nilai kesalahan (ϵ) yang terkait dengannya. Kesalahan ini disebut kesalahan marginal atau residual.

$$\text{kamu} = (a + bX) + \epsilon$$


Sekarang setelah kita memiliki beberapa konteks mengenai model regresi sederhana, mari kita coba menelusuri contoh untuk memahami dengan jelas cara menentukan parameter model (yaitu nilai a dan b) untuk masalah tertentu.

8.3.1.4 Contoh regresi sederhana

Seorang profesor perguruan tinggi yakin bahwa jika nilai ujian internal di suatu kelas tinggi, nilai ujian eksternal juga akan tinggi. Sampel acak yang terdiri dari 15 mahasiswa di kelas tersebut dipilih, dan datanya diberikan di bawah ini:

Internal Exam	15	23	18	23	24	22	22	19	19	16	24	11	24	16	23
External Exam	49	63	58	60	58	61	60	63	60	52	62	30	59	49	68


Plot sebaran dibuat untuk mengeksplorasi hubungan antara variabel independen (nilai internal) yang dipetakan ke sumbu X dan variabel dependen (nilai eksternal) yang dipetakan ke sumbu Y seperti yang digambarkan pada [Gambar 8.8](#).



Gmbar. 8.8Diagram sebar dan garis regresi

Seperti yang dapat Anda amati dari grafik di atas, garis (yaitu garis regresi) tidak memprediksi data secara tepat (lihat Gbr. 8.8). Sebaliknya, ia hanya memotong data. Beberapa prediksi lebih rendah dari yang diharapkan, sementara beberapa lainnya lebih tinggi dari yang diharapkan.

Sisa adalah jarak antara titik prediksi (pada garis regresi) dan titik sebenarnya seperti yang digambarkan dalam Gambar 8.9.



Gambar. 8.9Kesalahan sisa

Seperti yang kita ketahui, dalam regresi linier sederhana, garis digambar menggunakan rumus regresi.

$$kamu = (a + bX) + \epsilon$$

Jika kita mengetahui nilai 'a' dan 'b', maka mudah untuk memprediksi nilai Y untuk setiap X yang diberikan dengan menggunakan rumus di atas. Namun pertanyaannya adalah bagaimana cara menghitung nilai 'a' dan 'b' untuk sekumpulan nilai X dan Y yang diberikan?

Garis lurus digambar sedekat mungkin di atas titik-titik pada diagram sebar. Ordinary Least Squares (OLS) adalah teknik yang digunakan untuk memperkirakan garis yang akan meminimalkan kesalahan (ϵ), yang merupakan perbedaan antara nilai Y yang diprediksi dan nilai Y yang sebenarnya. Ini berarti menjumlahkan kesalahan setiap prediksi atau, lebih tepatnya, Sum of the Squares of the Errors (SSE) $\left(\text{i.e. } \sum_i e_i^2 \right)$.

Terlihat bahwa SSE paling kecil ketika b mengambil nilai

$$b = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2} = \frac{\text{cov}(X, Y)}{\text{Var}(X)}$$

Nilai yang sesuai dari 'a' yang dihitung menggunakan nilai 'b' di atas adalah $a = \bar{Y} - b\bar{X}$

Jadi, mari kita hitung nilai a dan b untuk contoh yang diberikan. Untuk perhitungan lebih rinci, lihat Gambar 8.10.

Ringkasan perhitungan

Jumlah X = 299

Jumlah Y = 852

Rata-rata X, $\bar{X}$ = 19,93

Rata-rata Y, $\bar{Y}$ = 56,8

Jumlah kuadrat (SSX) = 226,9333

Jumlah produk (SP) = 429,8

regresi = $\hat{y} = bX + a$

$$b = \frac{SP}{SS_X} = \frac{429,8}{226,93} = 1.89395$$

$$A = \text{SAYA} - bMX = 56,8 - (1,89 \times 19,93) = 19,0473 \hat{y} = 1,89395X + 19,0473$$

Oleh karena itu, untuk contoh di atas, persamaan regresi yang diestimasi dibangun berdasarkan nilai estimasi a dan b:

$$\text{kita} = 1,89395X + 19,0473$$

Jadi, dalam konteks permasalahan yang diberikan, kita dapat mengatakan

$$\text{Nilai ujian eksternal} = 19,04 + 1,89 \times (\text{Nilai dalam ujian internal})$$

$$\text{atau, MExt} = 19,04 + 1,89 \times \text{MInt}$$

		Step 2		Step 3	Step 5
X	Y	X- mean (X)	Y- Mean (Y)	$(X_i - \bar{X})(Y_i - \bar{Y})$	$(X_i - \bar{X})^2$
15	49	-4.03	-7.8	38.454	24.3049
23	63	3.07	6.2	19.034	9.4249
18	58	-1.93	1.2	-2.316	3.7249
23	60	3.07	3.2	9.824	9.4249
24	58	4.07	1.2	4.884	16.5649
22	61	2.07	4.2	8.694	4.2849
22	60	2.07	3.2	6.624	4.2849
19	63	-0.93	6.2	-5.766	0.8649
19	60	-0.93	3.2	-2.976	0.8649
16	52	-3.93	-4.8	18.864	15.4449
24	62	4.07	5.2	21.164	16.5649
11	30	-8.93	-26.8	239.324	79.7449
24	59	4.07	2.2	8.954	16.5649
16	49	-3.93	-7.8	30.654	15.4449
23	68	3.07	11.2	34.384	9.4249
19.9	56.8		$\Sigma(X_i - \bar{X})(Y_i - \bar{Y})$	429.8	226.9335
Step 1		Step 4		Step 6	

Step 7: Divide (step4 / step6)

$$b = 429.28 / 226.93 = 1.89$$

Step 8: Calculate a using the value of b

$$a = \bar{Y} - b\bar{X}$$

$$a = 56.8 - 1.89 \times 19.9$$

$$a = 19.05$$

Gbr. 8.10Perhitungan rinci parameter regresi

Model yang dibangun di atas dapat direpresentasikan secara grafis sebagai


- versi yang diperluas
- (lihat Gambar 8.11) versi zoom-in (lihat Gambar 8.12)

Interpretasi intersepsi


Seperti yang telah kita lihat, model regresi linier sederhana yang dibangun berdasarkan data dalam contoh tersebut adalah

$$M_{\text{Ekst}} = 19,04 + 1,89 \times M_{\text{Int}}$$

Nilai intersep dari persamaan di atas adalah 19,05. Akan tetapi, tidak ada satu pun nilai internal yang bernilai 0. Jadi, intersep = 19,05 menunjukkan bahwa 19,05 merupakan bagian dari nilai pemeriksaan eksternal yang tidak dijelaskan oleh nilai pemeriksaan internal. **Gbr.**



Gambar 8.11 Versi lanjutan dari grafik regresi



Gambar. 8.12 Garis regresi perbesaran

Kemiringan mengukur perkiraan perubahan nilai rata-rata Y sebagai akibat dari perubahan satu satuan pada X. Di sini, kemiringan = 1,89 memberi tahu kita bahwa nilai rata-rata nilai ujian eksternal meningkat sebesar 1,89 untuk setiap tambahan 1 nilai dalam ujian internal.


Sekarang setelah kita memiliki pemahaman lengkap tentang cara membangun model regresi linier sederhana untuk masalah tertentu, saatnya merangkum algoritmanya.

8.3.1.5 Algoritma OLS

- Langkah 1: Hitung rata-rata X dan Y
- Langkah 2: Hitung kesalahan X dan Y
- Langkah 3: Dapatkan produknya
- Langkah 4: Dapatkan penjumlahan produk
- Langkah 5: Kuadratkan selisih X
- Langkah 6: Dapatkan jumlah selisih kuadrat
- Langkah 7: Membagi output langkah 4 dengan output langkah 6 untuk menghitung 'b'
- Langkah 8: Menghitung 'a' menggunakan nilai 'b'

8.3.1.6 Titik maksimum dan minimum kurva


Maksimum (ditunjukkan dalam Gambar 8.13) dan poin minimum (ditunjukkan dalam Gambar 8.14) pada grafik ditemukan pada titik-titik yang kemiringan kurvanya nol. Kemiringannya menjadi nol baik dari nilai positif maupun negatif. Titik maksimum adalah titik pada kurva grafik dengan koordinat y tertinggi dan kemiringan nol. Titik minimum adalah titik pada kurva grafik dengan koordinat y terendah dan kemiringan nol.



Gambarr. 8.13Titik kurva maksimum

Titik 63 berada pada titik maksimum untuk kurva ini (lihat Gambar 8.13). Titik 63 berada pada titik tertinggi pada kurva ini. Titik ini memiliki nilai koordinat y yang lebih besar daripada titik lain pada kurva dan memiliki kemiringan nol.

Titik 40 (ditandai dengan panah di Gambar 8.14) adalah titik minimum untuk kurva ini. Titik 40 berada pada titik terendah pada kurva ini. Titik ini memiliki nilai koordinat y yang lebih kecil daripada titik lain pada kurva dan memiliki kemiringan nol.



Gambar. 8.14Titik minimum kurva

8.3.2 Regresi Linier Berganda

Dalam model regresi berganda, dua atau lebih variabel independen, yaitu prediktor terlibat dalam model. Jika kita berpikir dalam konteks masalah Karen, di bagian terakhir, kita membuat regresi linier sederhana dengan mempertimbangkan Harga Properti sebagai variabel dependen dan Luas Properti (dalam m2) sebagai variabel prediktor. Namun, lokasi, lantai, jumlah tahun sejak pembelian, fasilitas yang tersedia, dll. juga merupakan prediktor penting yang tidak boleh diabaikan. Jadi, jika kita mempertimbangkan Harga Properti (dalam \$) sebagai variabel dependen dan Luas Properti (dalam m2), lokasi, lantai, jumlah tahun sejak pembelian, dan fasilitas yang tersedia sebagai variabel independen, kita dapat membentuk persamaan regresi berganda seperti yang ditunjukkan di bawah ini:

$\text{PriceProperty} = f(\text{AreaProperty}, \text{lokasi}, \text{lantai}, \text{Penuaan}, \text{Fasilitas})$

Model regresi linier sederhana dan model regresi berganda mengasumsikan bahwa variabel dependen bersifat kontinu.


Eksprei berikut menggambarkan persamaan yang melibatkan hubungan dengan dua variabel prediktor, yaitu X_1 dan X_2 .

$\text{kita} = b_1x_1 + b_2x_2$

Model menggambarkan bidang dalam ruang tiga dimensi $\hat{Y}$, X_1 , dan X_2 . Parameter ' a ' adalah titik potong bidang ini. Parameter ' b_1 ' dan ' b_2 ' disebut sebagai koefisien regresi parsial. Parameter b_1 menunjukkan perubahan respons rata-rata yang sesuai dengan perubahan satuan pada X_1 ketika X_2 dipertahankan konstan. Parameter b_2 menunjukkan perubahan respons rata-rata yang sesuai dengan perubahan satuan pada X_2 ketika X_1 dipertahankan konstan.

Perhatikan contoh model regresi linier berganda berikut dengan dua variabel prediktor yaitu X_1 dan X_2 (lihat [Gambar 8.15](#)).

$\text{kita} = 22 + 0,3X_1 + 1,2X_2$



Gambar. 8.15 Bidang regresi berganda

Regresi berganda untuk memperkirakan persamaan ketika ada 'n' variabel prediktor adalah sebagai berikut:

$$kita = b_1X_1 + b_2X_2 + b_3X_3 + \dots + b_nX_n$$

Saat mencari garis yang paling sesuai, kita dapat menggunakan regresi polinomial atau kurvilinear. Keduanya dikenal sebagai regresi polinomial atau kurvilinear.

8.3.3 Asumsi dalam Analisis Regresi

1. Variabel dependen (Y) dapat dihitung/dipredikatkan sebagai fungsi linear dari serangkaian variabel independen tertentu (X) ditambah istilah kesalahan (ϵ).
2. Jumlah observasi (n) lebih besar dari jumlah parameter (k) yang akan diestimasi, yaitu $n > k$.
3. Hubungan yang ditentukan melalui regresi hanyalah hubungan asosiasi berdasarkan kumpulan data dan belum tentu merupakan hubungan sebab akibat dari kelas yang ditentukan.
4. Garis regresi hanya berlaku pada rentang data yang terbatas. Jika garis tersebut diperpanjang (di luar rentang ekstrapolasi), hal itu hanya akan menghasilkan prediksi yang salah.
5. Jika kondisi bisnis berubah dan asumsi bisnis yang mendasari model regresi tidak lagi valid, maka kumpulan data masa lalu tidak akan lagi dapat memprediksi tren masa depan.
6. Variansnya sama untuk semua nilai X (homoskedastisitas).
7. Istilah kesalahan (ϵ) terdistribusi secara normal. Ini juga berarti bahwa rata-rata kesalahan (ϵ) memiliki nilai yang diharapkan sebesar 0.
8. Nilai kesalahan (ϵ) bersifat independen dan tidak terkait dengan nilai X mana pun. Ini berarti tidak ada hubungan antara X, Y tertentu yang terkait dengan nilai X, Y tertentu lainnya.

Mengingat asumsi di atas, maka estimator OLS adalah yang terbaik **Estimator Linier Tak Bias (BLUE)**, dan ini disebut Teorema Gauss-Markov.

8.3.4 Masalah Utama dalam Analisis Regresi

Dalam regresi berganda, ada dua masalah utama: multikolinearitas dan heteroskedastisitas.

8.3.4.1 Multikolinearitas

Dua variabel dikatakan kolinear sempurna jika terdapat hubungan linier yang tepat di antara keduanya. Multikolinearitas adalah situasi di mana derajat korelasi tidak hanya antara variabel dependen dan variabel independen, tetapi juga terdapat korelasi yang kuat di dalam (antara) variabel independen itu sendiri. Persamaan regresi berganda dapat membuat prediksi yang baik ketika terdapat multikolinearitas, tetapi sulit bagi kita untuk menentukan bagaimana variabel dependen akan berubah jika setiap variabel independen diubah satu per satu. Ketika multikolinearitas hadir, hal itu meningkatkan kesalahan standar koefisien. Dengan membesar-besarkan kesalahan standar, multikolinearitas mencoba membuat beberapa variabel tidak signifikan secara statistik padahal seharusnya signifikan (dengan kesalahan standar yang lebih rendah). Salah satu cara untuk mengukur multikolinearitas adalah dengan menghitung Variance Inflation Factor (VIF), yang menilai seberapa besar varians koefisien regresi yang diestimasikan meningkat jika prediktor berkorelasi. Jika tidak ada faktor yang berkorelasi, VIF akan sama dengan 1.

Asumsi tidak adanya kolinearitas sempurna menyatakan bahwa tidak ada hubungan linier yang pasti di antara variabel-variabel independen. Asumsi ini menyiratkan dua aspek data pada variabel-variabel independen. Pertama, tidak ada variabel independen, selain variabel yang

terkait dengan suku intersep, yang dapat berupa konstanta. Kedua, variasi pada X diperlukan. Secara umum, semakin banyak variasi pada variabel-variabel independen, semakin baik estimasi OLS dalam hal mengidentifikasi dampak dari berbagai variabel independen pada variabel dependen.

8.3.4.2 Heteroskedastisitas

Heteroskedastisitas mengacu pada varians istilah galat yang berubah-ubah. Jika varians istilah galat tidak konstan di seluruh set data, akan ada prediksi yang salah. Secara umum, agar persamaan regresi dapat membuat prediksi yang akurat, istilah galat harus independen, terdistribusi secara identik (normal) (iid).

Secara matematis asumsi ini ditulis sebagai

$$\begin{aligned}\text{var}(u_i|X) &= \sigma^2 \quad \text{and} \\ \text{cov}(u_i u_j|X) &= 0 \quad \text{for } i \neq j\end{aligned}$$

di mana 'var' mewakili varians, 'cov' mewakili kovarians, 'u' melambangkan istilah kesalahan, dan 'X' melambangkan variabel independen.

Asumsi ini lebih umum ditulis sebagai

$$\begin{aligned}\text{var}(u_i) &= \sigma^2 \quad \text{and} \\ \text{cov}(u_i u_j) &= 0 \quad \text{for } i \neq j.\end{aligned}$$

8.3.5 Meningkatkan Akurasi Regresi Linier

Model

Mari kita pahami bias dan varians dalam model regresi sebelum mempelajari cara meningkatkannya. Konsep bias dan varians mirip dengan akurasi dan prediksi. Akurasi mengacu pada seberapa dekat estimasi dengan nilai sebenarnya, sedangkan prediksi mengacu pada estimasi nilai yang berkelanjutan.

Bias tinggi = akurasi rendah (tidak mendekati nilai sebenarnya)

Varians tinggi = prediksi rendah (nilai tersebar)

Bias rendah = akurasi tinggi (mendekati nilai sebenarnya)

Varians rendah = prediksi tinggi (nilainya saling berdekatan)

Katakanlah kita memiliki model regresi yang sangat akurat dan sangat prediktif; oleh karena itu, kesalahan keseluruhan model kita akan rendah, yang menyiratkan bias rendah (akurasi tinggi) dan varians rendah (prediksi tinggi). Ini sangat disukai. Demikian pula, kita dapat mengatakan bahwa jika varians meningkat (prediksi rendah), sebaran titik data kita meningkat, yang menghasilkan prediksi yang kurang akurat. Saat bias meningkat (akurasi rendah), kesalahan antara nilai prediksi kita dan nilai yang diamati meningkat. Oleh karena itu, menyeimbangkan bias dan akurasi sangat penting dalam model regresi.

Dalam model regresi linier, diasumsikan bahwa jumlah observasi (n) lebih besar daripada jumlah parameter (k) yang akan diestimasi, yaitu $n > k$, dan dalam kasus tersebut, estimasi kuadrat terkecil cenderung memiliki varians rendah dan karenanya akan berkinerja baik pada observasi uji.

Akan tetapi, jika observasi (n) tidak jauh lebih besar daripada parameter (k), maka dapat terjadi variabilitas tinggi dalam penyesuaian kuadrat terkecil, yang mengakibatkan penyesuaian berlebihan dan mengarah pada prediksi yang buruk.

Jika $k > n$, maka regresi linier tidak dapat digunakan. Ini juga menunjukkan varians tak terbatas, dan karenanya, metode tersebut tidak dapat digunakan sama sekali.

Keakuratan regresi linier dapat ditingkatkan dengan menggunakan tiga metode berikut:

1. Pendekatan Penyusutan
2. Pemilihan Subset
3. Pengurangan Dimensionalitas (Variabel)

8.3.5.1 Pendekatan Penyusutan (Regularisasi)

Dengan membatasi (mengecilkan) koefisien yang diestimasi, kita dapat mencoba mengurangi varians dengan risiko peningkatan bias yang dapat diabaikan. Hal ini pada gilirannya dapat menghasilkan peningkatan substansial dalam akurasi model.

Beberapa variabel yang digunakan dalam model regresi berganda sebenarnya tidak terkait dengan respons keseluruhan dan disebut sebagai variabel tidak relevan; hal ini dapat menimbulkan kompleksitas yang tidak perlu dalam model regresi.

Pendekatan ini melibatkan pemasangan model yang melibatkan semua prediktor. Akan tetapi, koefisien yang diestimasi menyusut mendekati nol relatif terhadap estimasi kuadrat terkecil. Penyusutan ini (juga dikenal sebagai regularisasi) memiliki efek mengurangi varians keseluruhan. Beberapa koefisien juga dapat diestimasi menjadi nol, sehingga secara tidak langsung melakukan pemilihan variabel. Dua teknik yang paling terkenal untuk mengecilkan koefisien regresi menuju nol adalah

1. regresi punggungan
2. lasso (Operator Pemilih Penyusutan Absolut Terkecil)

Regresi punggungan melakukan regularisasi L2, yaitu menambahkan penalti yang setara dengan kuadrat besarnya koefisien

Tujuan minimisasi ridge = $LS\ Obj + \alpha \times (\text{jumlah kuadrat koefisien})$

Regresi ridge (termasuk semua k prediktor dalam model akhir) sangat mirip dengan kuadrat terkecil, kecuali bahwa koefisien diestimasi dengan meminimalkan kuantitas yang sedikit berbeda. Jika $k > n$, maka estimasi kuadrat terkecil bahkan tidak memiliki solusi unik, sedangkan regresi ridge masih dapat bekerja dengan baik dengan memperdagangkan sedikit peningkatan bias untuk penurunan varians yang besar. Dengan demikian, regresi ridge bekerja paling baik dalam situasi di mana estimasi kuadrat

terkecil memiliki varians yang tinggi. Salah satu kelemahan regresi ridge adalah bahwa ia akan mencakup semua k prediktor dalam model akhir. Ini mungkin tidak menjadi masalah untuk akurasi prediksi, tetapi dapat menciptakan tantangan dalam interpretasi model dalam pengaturan di mana jumlah variabel k cukup besar. Regresi ridge akan bekerja lebih baik ketika responsnya adalah fungsi dari banyak prediktor, semuanya dengan koefisien dengan ukuran yang kira-kira sama.

Regresi laso melakukan regularisasi L1, yaitu menambahkan penalti yang setara dengan nilai absolut besarnya koefisien.

Tujuan minimisasi ridge = LS Obj + $\alpha \times$ (nilai absolut besarnya koefisien). Laso mengatasi kelemahan ini dengan memaksa beberapa koefisien menjadi bernilai nol. Kita dapat mengatakan bahwa laso menghasilkan model yang jarang (hanya melibatkan subset) yang lebih sederhana dan lebih mudah diinterpretasikan. Laso diharapkan dapat bekerja lebih baik dalam pengaturan di mana sejumlah kecil prediktor memiliki koefisien yang substansial, dan prediktor yang tersisa memiliki koefisien yang sangat kecil atau sama dengan nol.

8.3.5.2 Pemilihan subset

Identifikasi subset prediktor yang diasumsikan terkait dengan respons dan kemudian sesuaikan model menggunakan OLS pada subset variabel terpilih yang telah direduksi. Ada dua metode untuk memilih subset regresi:

1. Pemilihan subset terbaik (mempertimbangkan semua kemungkinan (2^{ku}))
2. Pemilihan subset bertahap
 1. Pemilihan langkah maju (0 hingga k)
 2. Pemilihan langkah mundur (k ke 0)

Dalam pemilihan subset terbaik, kami menyesuaikan regresi kuadrat terkecil yang terpisah untuk setiap subset yang mungkin dari k prediktor. Karena alasan komputasi, pemilihan subset terbaik tidak dapat diterapkan dengan nilai prediktor yang sangat besar (k). Prosedur pemilihan subset terbaik mempertimbangkan semua kemungkinan (2^k) model yang berisi subset dari p prediktor.

Metode pemilihan subset bertahap dapat diterapkan untuk memilih subset terbaik. Ada dua metode pemilihan subset bertahap:

1. Pemilihan langkah maju (0 hingga k)
2. Pemilihan langkah mundur (k ke 0)

Pemilihan langkah maju merupakan alternatif yang efisien secara komputasi untuk pemilihan subset terbaik. Pemilihan langkah maju mempertimbangkan sekumpulan model yang jauh lebih kecil, yang juga langkah demi langkah, dibandingkan dengan pemilihan set terbaik. Pemilihan langkah maju dimulai dengan model yang tidak mengandung prediktor, dan kemudian, prediktor ditambahkan satu per satu ke dalam model, hingga semua k prediktor disertakan dalam model. Secara khusus, pada setiap langkah, variabel (X) yang memberikan peningkatan tambahan tertinggi pada kecocokan ditambahkan.

Seleksi langkah mundur dimulai dengan model kuadrat terkecil yang berisi semua k prediktor dan kemudian secara berulang menghilangkan prediktor yang paling tidak berguna satu per satu.

8.3.5.3 Pengurangan Dimensionalitas (Reduksi Variabel)

Metode sebelumnya, yaitu pemilihan subset dan penyusutan, mengendalikan varians baik dengan menggunakan subset dari variabel asli atau dengan mengecilkan koefisiennya ke arah nol. Dalam reduksi dimensionalitas, prediktor (X) ditransformasikan, dan model disiapkan menggunakan variabel yang ditransformasikan setelah reduksi dimensionalitas. Jumlah variabel dikurangi menggunakan metode reduksi

dimensionalitas. Analisis komponen utama adalah salah satu teknik reduksi dimensionalitas (variabel) yang paling penting.

8.3.6 Model Regresi Polinomial

Model regresi polinomial adalah perluasan dari model linier sederhana dengan menambahkan prediktor tambahan yang diperoleh dengan menaikkan (mengkuadratkan) setiap prediktor asli ke pangkat tertentu. Misalnya, jika ada tiga variabel, X , X^2 , dan X^3 digunakan sebagai prediktor. Pendekatan ini menyediakan cara sederhana untuk menghasilkan kecocokan non-linier pada data.


$$F(x) = c_0 + c_1.X^1 + c_2.X^2 + c_3.X^3$$

Dalam persamaan di atas, c_0 , c_1 , c_2 , dan c_3 adalah koefisien.


Contoh: Mari kita gunakan kumpulan data di bawah ini (X , Y) untuk polinomial derajat 3.

Internal Exam (X)	15	23	18	23	24	22	22	19	19	16	24	11	24	16	23
External Exam (Y)	49	63	58	60	58	61	60	63	60	52	62	30	59	49	68

Seperti yang dapat Anda amati, garis regresi (lihat [Gambar 8.16](#)) sedikit melengkung untuk derajat polinomial 3 dengan 15 titik data di atas. Garis regresi akan melengkung lebih jauh jika kita meningkatkan derajat polinomial (lihat [Gambar 8.17](#)). Pada nilai ekstrem seperti yang ditunjukkan di bawah ini, garis regresi akan terlalu sesuai dengan semua nilai asli X .



Gambar. 8.16Regresi polinomial derajat 3



Gambar. 8.17Derajat regresi polinomial 14

8.3.7 Regresi Logistik

Regresi logistik merupakan teknik klasifikasi dan regresi, tergantung pada skenario yang digunakan. Regresi logistik (regresi logit) merupakan jenis analisis regresi yang digunakan untuk memprediksi hasil variabel dependen kategoris yang mirip dengan regresi OLS. Dalam regresi logistik, variabel dependen (Y) adalah biner (0,1) dan variabel independen (X) bersifat kontinu. Probabilitas yang menggambarkan kemungkinan hasil (probabilitas $Y = 1$) dari satu uji coba dimodelkan sebagai fungsi logistik dari variabel prediktor. Dalam model regresi logistik, tidak ada R^2 untuk mengukur kecocokan model secara keseluruhan; namun, uji chi-square digunakan untuk mengukur seberapa baik model regresi logistik sesuai dengan data. Sasaran regresi logistik adalah untuk memprediksi kemungkinan bahwa Y sama dengan 1 (kemungkinan bahwa $Y = 1$, bukan 0) dengan nilai X tertentu. Artinya, jika X dan Y memiliki hubungan linier positif yang kuat, kemungkinan seseorang akan memiliki skor $Y = 1$ akan meningkat seiring dengan peningkatan nilai X. Jadi, kita memprediksi probabilitas, bukan skor variabel dependen.

Misalnya, kita mungkin mencoba memprediksi apakah proyek kecil akan berhasil atau gagal berdasarkan jumlah tahun pengalaman manajer proyek yang menangani proyek tersebut. Kita berasumsi bahwa manajer proyek yang telah mengelola proyek selama bertahun-tahun akan lebih mungkin berhasil. Ini berarti bahwa seiring dengan meningkatnya X (jumlah tahun pengalaman manajer proyek), probabilitas bahwa Y akan sama dengan 1 (keberhasilan proyek baru) akan cenderung meningkat. Jika kita mengambil contoh hipotetis di mana 60 proyek yang telah dilaksanakan dipelajari dan tahun pengalaman manajer proyek berkisar antara 0 hingga 20 tahun, kita dapat menggambarkan kecenderungan ini untuk meningkatkan probabilitas bahwa $Y = 1$ dengan grafik.

Untuk mengilustrasikan hal ini, akan lebih mudah untuk memisahkan tahun pengalaman ke dalam kategori (yaitu 0–8, 9–16, 17–24, 25–32, 33–40). Jika kita menghitung skor rata-rata pada Y (dengan merata-ratakan 0 dan 1) untuk setiap kategori tahun pengalaman, kita akan mendapatkan sesuatu seperti

X	Y
0–8	0.27
9–16	0.5
17–24	0.6
25–32	0.66
33–40	0.93


Bila grafik digambar untuk nilai X dan Y di atas, maka akan tampak seperti grafik pada **Gambar 8.18**. Seiring dengan meningkatnya X, probabilitas $Y = 1$ pun meningkat. Dengan kata lain, ketika manajer proyek memiliki lebih banyak tahun pengalaman, persentase keberhasilan proyek akan lebih besar. Hubungan yang sempurna menggambarkan S yang melengkung sempurna, bukan garis lurus, seperti yang terjadi pada regresi OLS. Jadi, untuk memodelkan hubungan ini, kita memerlukan aljabar/matematika canggih yang memperhitungkan lengkungan pada kurva.

Penjelasan tentang regresi logistik dimulai dengan penjelasan tentang fungsi logistik, yang selalu mengambil nilai antara nol dan satu. Rumus logistik dinyatakan dalam bentuk probabilitas bahwa $Y = 1$, yang disebut sebagai P.

Peluang bahwa Y adalah 0 adalah $1 - P$.

$$\ln\left(\frac{P}{1 - P}\right) = a + bX$$

$$\ln(p/1 - p) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \varepsilon$$



Gambar. 8.18 Regresi logistik

Simbol 'ln' mengacu pada logaritma natural dan $a + bX$ adalah persamaan garis regresi. Probabilitas (P) juga dapat dihitung dari persamaan regresi. Jadi, jika kita mengetahui persamaan regresi, secara teoritis kita dapat menghitung probabilitas yang diharapkan bahwa $Y = 1$ untuk nilai X tertentu.

$$P = \frac{\exp(a + bX)}{1 + \exp(a + bX)} = \frac{e^{a+bX}}{1 + e^{a+bX}}$$

'exp' adalah fungsi eksponen, yang terkadang juga ditulis sebagai e.

Misalkan kita memiliki model yang dapat memprediksi apakah seseorang berjenis kelamin laki-laki atau perempuan berdasarkan tinggi badannya. Jika tinggi badannya 150 cm, kita perlu memprediksi apakah orang tersebut berjenis kelamin laki-laki atau perempuan.

Kita tahu bahwa koefisien $a = -100$ dan $b = 0,6$. Dengan menggunakan persamaan di atas, kita dapat menghitung peluang laki-laki yang tingginya 150 cm atau lebih, secara formal $P(\text{laki-laki} | \text{tinggi} = 150)$.

$$kamu = e^{(a + b \times X)} / (1 + e^{(a + b \times X)})$$

$$y = \exp(-100 + 0,6 \times 150) / (1 + \exp(-100 + 0,6 \times X))$$

$$y = 0,000046$$

atau kemungkinan mendekati nol bahwa orang tersebut adalah laki-laki.

Asumsi dalam regresi logistik

Asumsi berikut harus berlaku saat membangun model regresi logistik:

- Terdapat hubungan linier antara fungsi logit dan variabel independent.
- Variabel dependen Y harus kategoris (1/0) dan mengambil biner, misal jika lulus maka $Y = 1$; jika tidak $Y = 0$
- nilai Data tersebut memenuhi kriteria 'iid', yaitu suku kesalahan, ϵ , saling independen dan terdistribusi secara identik.
- Istilah kesalahan mengikuti distribusi binomial $[n, p]$ $n = \#$ dalam data $p =$ probabilitas keberhasilan (lulus, catatan responden).

8.3.8 Estimasi Kemungkinan Maksimum

Koefisien dalam regresi logistik diestimasi menggunakan proses yang disebut Estimasi Kemungkinan Maksimum (MLE). Pertama, mari kita pahami apa itu fungsi kemungkinan sebelum beralih ke MLE. Hasil koin yang adil adalah jika kita melempar koin sebanyak 10 kali, maka kita akan mendapatkan 5 kali sisi Kepala dan 5 kali sisi Ekor.

Sekarang mari kita bahas tentang peluang untuk mendapatkan hanya Kepala sebagai hasil; peluangnya adalah $5/10 = 0,5$ dalam kasus di atas. Setiap kali angka ini (P) lebih besar dari 0,5, maka dikatakan mendukung Kepala. Setiap kali P lebih kecil dari 0,5, maka dikatakan menentang hasil untuk mendapatkan Kepala.

Mari kita gambarkan 'n' lemparan koin sebagai $X_1, X_2, X_3, \dots, X_n$. Sekarang X_i dapat mengambil nilai 1 atau 0.

$X_i = 1$ jika Kepala adalah hasilnya

$X_i = 0$ jika Tail adalah hasilnya

Ketika kita menggunakan distribusi Bernoulli, maka kita merepresentasikan setiap lemparan koin:

$$f(x_i|\theta) = \theta^{x_i}(1 - \theta)^{1-x_i}$$

Setiap observasi X_i bersifat independen dan juga terdistribusi identik (iid), dan distribusi gabungan disederhanakan menjadi produk distribusi. $f(x_1, \dots, x_n|\theta) = \prod_{i=1}^n f(x_i|\theta) = \theta^{x_1}(1 - \theta)^{1-x_1} \dots \theta^{x_n}(1 - \theta)^{1-x_n} = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}$, di mana $\sum x_i$ adalah jumlah lemparan yang menghasilkan hasil yang diharapkan (kepala dalam kasus ini).

Persamaan kemungkinan adalah

$$L(\theta|x) = \prod_{i=1}^n f(x_i|\theta)$$

Namun fungsi kemungkinan bukanlah sebuah probabilitas. Kemungkinan untuk beberapa koin mungkin adalah 0,25 atau 0 atau 1.

MLE adalah tentang memprediksi nilai parameter yang memaksimalkan fungsi kemungkinan.

$$\log L(\theta|x) = \sum_{i=1}^n \log f(x_i|\theta)$$

8.4 RINGKASAN

- Dalam pembelajaran terbimbing, ketika kita mencoba untuk memprediksi variabel bernilai riil seperti 'Harga', 'Berat', dll., masalahnya termasuk dalam kategori regresi. Masalah regresi mencoba untuk meramalkan hasil sebagai keluaran yang berkesinambungan.

- Variabel Dependen (Y) adalah nilai yang akan diprediksi. Variabel ini diasumsikan memiliki hubungan fungsional dengan variabel independen (X). Dengan kata lain, variabel dependen bergantung pada variabel independen. • Variabel Independen (X) disebut sebagai prediktor. Variabel independen (X) digunakan dalam model regresi untuk memperkirakan nilai variabel dependen (Y).
- Regresi pada dasarnya adalah menemukan hubungan (atau) asosiasi antara variabel dependen (Y) dan variabel independen (X).
- Jika regresi hanya melibatkan satu variabel independen, maka disebut regresi sederhana. Jadi, jika kita mengambil 'Harga mobil bekas' sebagai variabel dependen dan 'Tahun pembuatan mobil' sebagai variabel independen, kita dapat membuat regresi sederhana.
- Kemiringan menunjukkan seberapa besar garis pada grafik berubah dalam arah vertikal (sumbu Y) terhadap perubahan dalam arah horizontal (sumbu X). Kemiringan juga disebut sebagai laju perubahan pada grafik.
- Titik maksimum dan minimum pada grafik ditemukan pada titik-titik yang kemiringan kurvanya nol. Kemiringan kurva menjadi nol baik dari nilai positif maupun dari nilai negatif.
- Jika ada dua atau lebih variabel bebas yang terlibat, maka disebut regresi berganda. Jadi, jika kita mengambil 'Harga mobil bekas' sebagai variabel terikat dan tahun pembuatan (Tahun), merek mobil (Merek), dan jarak tempuh (Miles run) sebagai variabel bebas, kita dapat membentuk persamaan regresi berganda seperti yang diberikan di bawah ini:

$$\text{Harga mobil bekas (\$)} = \text{fungsi (Tahun, Merek, Jarak tempuh)}$$
- Multikolinearitas merupakan keadaan dimana derajat korelasi tidak hanya terdapat antara variabel dependen dan variabel independen

saja, tetapi juga terdapat korelasi yang kuat dalam (antar) variabel independen itu sendiri.

- Heteroskedastisitas mengacu pada varians istilah galat yang berubah-ubah. Jika varians istilah galat tidak konstan di seluruh set data, akan ada prediksi yang salah. Secara umum, agar persamaan regresi dapat membuat prediksi yang akurat, istilah galat harus independen, terdistribusi secara normal (identik) (iid).
- Istilah galat tidak boleh saling terkait.
- Keakuratan regresi linier dapat ditingkatkan dengan menggunakan tiga metode berikut:
 1. Pendekatan Penyusutan
 2. Pemilihan Subset
 3. Pengurangan Dimensionalitas
- Model regresi polinomial merupakan perluasan dari model linier sederhana dengan menambahkan prediktor tambahan, yang diperoleh dengan menaikkan (mengkuadratkan) setiap prediktor asli ke pangkat tertentu. Misalnya, jika ada tiga variabel, X , X^2 , dan X^3 digunakan sebagai prediktor.
- Dalam regresi logistik, variabel dependen (Y) adalah biner (0,1) dan variabel independen (X) bersifat kontinu. Probabilitas yang menggambarkan kemungkinan hasil (probabilitas bahwa $Y = 1$) dari satu percobaan dimodelkan sebagai fungsi variabel penjelas (prediktor) dengan menggunakan fungsi logistik.

CONTOH PERTANYAAN

SOAL PILIHAN GANDA

1. Ketika kita mencoba memprediksi variabel bernilai riil seperti '\$', 'Berat', permasalahannya masuk dalam kategori
 1. Pembelajaran tanpa pengawasan
 2. Masalah regresi terbimbing
 3. Masalah klasifikasi terbimbing
 4. Atribut kategoris
2. Prediksi harga minyak mentah merupakan salah satu contoh
 1. Pembelajaran tanpa pengawasan
 2. Masalah regresi terbimbing
 3. Masalah klasifikasi terbimbing
 4. Atribut kategoris
3. Nilai yang akan diprediksi dalam pembelajaran mesin disebut sebagai
 1. Lereng
 2. Regresi
 3. Variabel independen
 4. Variabel dependen
4. Ini disebut sebagai prediktor.
 1. Lereng
 2. Regresi
 3. Variabel independen
 4. Variabel dependen
5. Ini pada dasarnya menemukan hubungan (atau) asosiasi antara variabel dependen (Y) dan variabel independen (X).
 1. Lereng
 2. Regresi

3. Klasifikasi
4. Kategorisasi
6. Jika regresi hanya melibatkan satu variabel independen, maka disebut sebagai
 1. Regresi berganda
 2. Satu regresi
 3. Regresi sederhana
 4. Regresi independen
7. Persamaan manakah yang mewakili hubungan tidak sempurna yang sederhana?
 1. $kamu = (a + bx) + \varepsilon$
 2. $kamu = (a+bx)$
 3. $DY = \text{Perubahan } Y / \text{Perubahan } X$
 4. $kamu = b_1x_1 + b_2x_2$
8. Persamaan manakah yang mewakili hubungan sempurna sederhana?
 1. $kamu = (a + bx) + \varepsilon$
 2. $kamu = (a+bx)$
 3. $DY = \text{Perubahan } Y / \text{Perubahan } X$
 4. $kamu = b_1x_1 + b_2x_2$
9. Apa rumus kemiringan dalam persamaan linear sederhana?
 1. $kamu = (a + bx) + \varepsilon$
 2. $kamu = (a+bx)$
 3. $DY = \text{Perubahan } Y / \text{Perubahan } X$
 4. $kamu = b_1x_1 + b_2x_2$
10. Kemiringan ini selalu bergerak ke atas pada grafik dari kiri ke kanan.
 1. Kemiringan multilinear
 2. Tidak ada kemiringan hubungan

3. Kemiringan negatif
4. Kemiringan positif
11. Kemiringan ini selalu bergerak ke bawah pada grafik dari kiri ke kanan.
 1. Kemiringan multilinear
 2. Tidak ada kemiringan hubungan
 3. Kemiringan negatif
 4. Kemiringan positif
12. Titik maksimum dan minimum pada grafik ditemukan pada titik-titik dimana kemiringan kurvanya
 1. Nol
 2. Satu
 3. 0.5
 4. Angka acak
13. Dalam algoritma OLS, langkah pertama adalah
 1. Hitunglah rata-rata Y dan X
 2. Hitunglah kesalahan X dan Y
 3. Dapatkan produknya (kalikan)
 4. Jumlahkan produknya
14. Dalam algoritma OLS, langkah terakhir adalah
 1. Hitung 'a' menggunakan nilai 'b'
 2. Hitung 'b' menggunakan nilai 'a'
 3. Dapatkan produknya (kalikan)
 4. Jumlahkan produknya
15. Persamaan manakah di bawah ini yang disebut Variasi Tak Terjelaskan?
 1. SSR (Jumlah Kuadrat Akibat Regresi)
 2. SSE (Jumlah Kuadrat Akibat Kesalahan)
 3. SST (Jumlah Kuadrat Total):
 4. R-kuadrat (R^2)

16. Persamaan manakah di bawah ini yang disebut Variasi yang Dijelaskan?
1. SSR (Jumlah Kuadrat Akibat Regresi)
 2. SSE (Jumlah Kuadrat Akibat Kesalahan)
 3. SST (Jumlah Kuadrat Total)
 4. R-kuadrat (R^2)
17. Ketika prediktor baru (X) ditambahkan ke model regresi linier berganda, bagaimana R^2 berperilaku baik?
1. Menurun
 2. Meningkat atau menurun
 3. Meningkat dan menurun
 4. Meningkat atau tetap konstan
18. Memprediksi kejadian stokastik secara tepat tidaklah mungkin.
1. BENAR
 2. PALSU

SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI)

1. Apa yang dimaksud dengan variabel dependen dan variabel independen dalam persamaan linear?
2. Apa itu regresi linier sederhana? Berikan satu contoh.
3. Tentukan kemiringan dalam regresi linier.
4. Temukan kemiringan grafik di mana titik terendah pada garis direpresentasikan sebagai $(-3, -2)$ dan titik tertinggi pada garis direpresentasikan sebagai $(2, 2)$.
5. Apa saja syarat kemiringan positif dalam regresi linier?
6. Apa saja syarat kemiringan negatif dalam regresi linier?
7. Apa itu regresi linier berganda?
8. Tentukan jumlah kuadrat karena kesalahan dalam regresi linier berganda.
9. Tentukan jumlah kuadrat akibat regresi dalam regresi linier berganda.

10. Apa itu multikolinearitas dalam persamaan regresi?
11. Apa itu heteroskedastisitas?
12. Jelaskan regresi punggungan.
13. Jelaskan regresi laso.
14. Apa itu regresi polinomial?
15. Jelaskan fungsi basis.
16. Jelaskan regresi logistik.

SOAL JAWABAN PANJANG (MASING-MASING 10 NILAI)

1. Tentukan regresi linier sederhana menggunakan grafik yang menjelaskan kemiringan dan intersep.
2. Jelaskan kenaikan, penurunan, dan kemiringan dalam suatu grafik.
3. Jelaskan kemiringan, kemiringan positif linier, dan kemiringan negatif linier dalam grafik beserta berbagai kondisi yang mengarah pada kemiringan.
4. Jelaskan kurva kemiringan linier negatif dan kurva kemiringan linier positif dalam suatu grafik.
5. Jelaskan titik maksimum dan minimum kurva melalui grafik.
6. Jelaskan kuadrat terkecil biasa dengan rumus untuk a dan b .
7. Jelaskan algoritma OLS beserta langkah-langkahnya.
8. Berapakah standar error dari regresi tersebut? Gambarkan grafik untuk meng gambarkannya.
9. Jelaskan regresi linier berganda dengan sebuah contoh.
10. Jelaskan asumsi dalam analisis regresi dan konsep BLUE.
11. Jelaskan dua masalah utama dalam analisis regresi.
12. Bagaimana cara meningkatkan akurasi model regresi linier?
13. Jelaskan model regresi polinomial secara rinci dengan sebuah contoh.
14. Jelaskan regresi logistik secara rinci.
15. Apa saja asumsi dalam regresi logistik?

16. Bahas estimasi kemungkinan maksimum secara rinci.

Bab 9 Pembelajaran Tanpa Pengawasan

Sharfina Faza, S.Kom., M.Kom.

A.Tujuan Pembelajaran

Kami telah membahas cara melatih mesin kami dengan data masa lalu yang menjadi dasar mereka dapat belajar, memperoleh kecerdasan, dan menerapkan kecerdasan itu pada set data baru. Namun, ada situasi ketika kita tidak memiliki pengetahuan sebelumnya tentang set data yang sedang kita kerjakan, tetapi kita tetap ingin menemukan hubungan yang menarik di antara atribut data atau mengelompokkan data dalam segmen logis untuk analisis yang mudah. Tugas mesin kemudian adalah mengidentifikasi pengetahuan ini tanpa pelatihan sebelumnya dan itulah ruang pembelajaran tanpa pengawasan. Dalam bab ini, kita akan membahas bagaimana algoritma Clustering membantu dalam mengelompokkan set data ke dalam segmen logis dan analisis asosiasi yang memungkinkan untuk mengidentifikasi pola atau hubungan atribut dalam set data. Aplikasi menarik dari analisis asosiasi adalah Analisis Keranjang Belanja, yang digunakan secara luas oleh pengecer dan pengiklan di seluruh dunia.

9.1 PENDAHULUAN

Pembelajaran tanpa pengawasan adalah konsep pembelajaran mesin di mana informasi yang tidak berlabel dan tidak terklasifikasi dianalisis untuk menemukan pengetahuan tersembunyi. Algoritme bekerja pada data tanpa pelatihan sebelumnya, tetapi dibangun sedemikian rupa sehingga dapat mengidentifikasi pola, pengelompokan, urutan

penyortiran, dan banyak pengetahuan menarik lainnya dari kumpulan data.

9.2 PEMBELAJARAN TANPA PENGAWASAN VS PEMBELAJARAN DENGAN PENGAWASAN

Sampai saat ini, kita telah membahas tentang pembelajaran terbimbing yang bertujuan untuk memprediksi variabel hasil Y berdasarkan himpunan fitur $X_1:X_2: X_n$, dan kita membahas metode seperti regresi dan klasifikasi untuk hal yang sama. Sekarang kita akan memperkenalkan konsep pembelajaran tak terbimbing yang bertujuan untuk mengamati hanya fitur $X_1:X_2: X_n$; kita tidak akan memprediksi variabel hasil apa pun, tetapi tujuan kita adalah untuk mengetahui hubungan antara fitur atau pengelompokannya untuk memahami sifat data. Analisis ini dapat mengungkapkan korelasi yang menarik antara fitur atau perilaku umum dalam subkelompok data, yang memberikan pemahaman yang lebih baik tentang data.

Dalam hal statistik, algoritma pembelajaran terbimbing akan mencoba mempelajari probabilitas hasil Y untuk input tertentu X , yang disebut probabilitas posterior. Pembelajaran tak terbimbing terkait erat dengan estimasi kepadatan dalam statistik. Di sini, setiap input dan target terkait digabungkan untuk membuat serangkaian input baru seperti $\{(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)\}$, yang mengarah pada pemahaman yang lebih baik tentang korelasi X dan Y ; notasi probabilitas ini disebut probabilitas gabungan.

Mari kita ambil contoh bagaimana pembelajaran tanpa pengawasan membantu dalam mendorong promosi film ke kelompok orang yang tepat. Di masa lalu, promosi film merupakan dorongan membabi buta dari data yang sama ke semua demografi, sehingga setiap orang biasa menonton poster atau trailer yang sama terlepas dari pilihan atau

preferensi mereka. Jadi, dalam kebanyakan kasus, orang yang menonton promosi atau trailer akan mengabaikannya, yang menyebabkan pemborosan tenaga dan uang untuk promosi. Namun dengan munculnya perangkat dan aplikasi pintar, kini tersedia basis data besar untuk memahami jenis film apa yang disukai oleh segmen demografi yang mana. Pembelajaran mesin membantu menemukan pola atau perilaku berulang dari kelompok/kluster yang lebih kecil dalam basis data ini untuk memberikan kecerdasan tentang suka atau tidak suka jenis film tertentu oleh kelompok yang berbeda dalam demografi. Jadi, dengan menggunakan kecerdasan ini, aplikasi pintar dapat mendorong hanya promosi atau trailer film yang relevan ke kelompok yang dipilih, yang secara signifikan akan meningkatkan peluang untuk menargetkan orang yang tepat yang tertarik pada film tersebut.

Kita akan membahas dua metode dalam bab ini untuk menjelaskan prinsip yang mendasari pembelajaran tanpa pengawasan – Pengelompokan dan Analisis Asosiasi. Pengelompokan adalah kelas metode yang luas yang digunakan untuk menemukan subkelompok yang tidak diketahui dalam data, yang merupakan konsep terpenting dalam pembelajaran tanpa pengawasan. Teknik lainnya adalah Analisis Asosiasi yang mengidentifikasi representasi observasi berdimensi rendah yang dapat menjelaskan varians dan mengidentifikasi aturan asosiasi untuk penjelasannya.

9.3 PENERAPAN PEMBELAJARAN TANPA PENGAWASAN

Karena fleksibilitasnya yang dapat bekerja pada data yang tidak berkategori dan tidak berlabel, ada banyak domain di mana pembelajaran tanpa pengawasan dapat diterapkan. Berikut ini adalah beberapa contoh penerapannya:

- Segmentasi populasi konsumen sasaran oleh biro konsultan periklanan berdasarkan beberapa dimensi seperti demografi, data keuangan, kebiasaan pembelian, dll. sehingga pengiklan dapat menjangkau konsumen sasarannya secara efisien.
- Deteksi anomali atau penipuan di sektor perbankan dengan mengidentifikasi pola peminjam yang gagal bayar.
- Pengolahan gambar dan segmentasi gambar seperti pengenalan wajah, identifikasi ekspresi, dll.
- Pengelompokan karakteristik penting dalam gen untuk mengidentifikasi faktor-faktor penting yang memengaruhi bidang genetika baru.
- Pemanfaatan oleh ilmuwan data untuk mengurangi dimensi dalam data sampel guna menyederhanakan pemodelan Pengelompokan dokumen dan mengidentifikasi opsi pelabelan potensial.

Saat ini, pembelajaran tanpa pengawasan digunakan di banyak bidang yang melibatkan Kecerdasan Buatan (AI) dan Pembelajaran Mesin (ML). Chat bot, mobil yang dapat dikendarai sendiri, dan banyak inovasi terbaru lainnya merupakan hasil gabungan dari pembelajaran tanpa pengawasan dan pembelajaran dengan pengawasan.

Jadi, dalam bab ini, kita akan membahas dua aspek utama pembelajaran tanpa pengawasan, yaitu Pengelompokan yang membantu dalam segmentasi himpunan objek ke dalam kelompok objek serupa dan Analisis Asosiasi yang terkait dengan identifikasi hubungan antar objek dalam himpunan data.

9.4 PENGELOMPOKAN

Pengelompokan mengacu pada serangkaian teknik yang luas untuk menemukan subkelompok, atau kluster, dalam kumpulan data berdasarkan karakteristik objek dalam kumpulan data tersebut

sedemikian rupa sehingga objek dalam kelompok tersebut serupa (atau terkait satu sama lain) tetapi berbeda dari (atau tidak terkait dengan) objek dari kelompok lain. Efektivitas pengelompokan bergantung pada seberapa mirip atau terkait objek dalam suatu kelompok atau seberapa berbeda atau tidak terkait objek dalam kelompok yang berbeda satu sama lain. Sering kali domain tertentu menentukan apa yang dimaksud dengan dua objek yang serupa atau tidak serupa dan dengan demikian merupakan aspek penting dari tugas pembelajaran mesin tanpa pengawasan.

Sebagai contoh, misalkan kita ingin menjalankan beberapa iklan film baru untuk kegiatan promosi di seluruh negeri. Kita memiliki data untuk usia, lokasi, kondisi keuangan, dan stabilitas politik masyarakat di berbagai bagian negara. Kita mungkin ingin menjalankan jenis kampanye yang berbeda untuk berbagai bagian yang dikelompokkan menurut data yang kita miliki. Pengelompokan logis apa pun yang diperoleh dengan menganalisis karakteristik masyarakat akan membantu kita dalam menjalankan kampanye dengan cara yang lebih terarah. Analisis pengelompokan dapat membantu dalam kegiatan ini dengan menganalisis berbagai cara untuk mengelompokkan sekumpulan masyarakat dan menghasilkan berbagai jenis pengelompokan.

Ada banyak bidang berbeda di mana analisis cluster digunakan secara efektif, seperti;

- Penambangan data teks: ini mencakup tugas-tugas seperti kategorisasi teks, pengelompokan teks, peringkasan dokumen, ekstraksi konsep, analisis sentimen, dan pemodelan relasi entitas.
- Segmentasi pelanggan: menciptakan kelompok pelanggan berdasarkan parameter seperti demografi, kondisi keuangan, kebiasaan membeli, dll., yang dapat digunakan oleh pengecer dan pengiklan untuk mempromosikan produk mereka di segmen yang benar.

- Pemeriksaan anomali: pemeriksaan perilaku anomali seperti transaksi bank yang curang, intrusi komputer yang tidak sah, pergerakan mencurigakan pada pemindai radar, dll.
- Penambangan data: menyederhanakan tugas penambangan data dengan mengelompokkan sejumlah besar fitur dari kumpulan data yang sangat besar untuk membuat analisis dapat dikelola.

Pada bagian ini, kita akan membahas metode yang terkait dengan tugas pembelajaran mesin pengelompokan, yang melibatkan pencarian pengelompokan data alami. Fokusnya adalah pada;

- bagaimana tugas pengelompokan berbeda dari tugas klasifikasi dan bagaimana pengelompokan mendefinisikan kelompok.
- algoritma clustering klasik dan mudah dipahami yaitu k-means yang digunakan untuk clustering bersama dengan algoritma k-medoids.
- aplikasi clustering pada skenario kehidupan nyata.

9.4.1 Pengelompokan sebagai tugas pembelajaran mesin

Penggerak utama pengetahuan pengelompokan adalah penemuan daripada prediksi, karena kita mungkin tidak tahu apa yang kita cari sebelum memulai analisis pengelompokan. Jadi, pengelompokan didefinisikan sebagai tugas pembelajaran mesin tanpa pengawasan yang secara otomatis membagi data ke dalam kelompok atau klaster yang berisi item serupa. Analisis mencapai hal ini tanpa pengetahuan sebelumnya tentang jenis kelompok yang diperlukan dan dengan demikian dapat memberikan wawasan tentang pengelompokan alami dalam set data. Pedoman utama tugas pengelompokan adalah bahwa data di dalam klaster harus sangat mirip satu sama lain tetapi sangat berbeda dari yang ada di luar klaster. Kita dapat berasumsi bahwa definisi kesamaan mungkin berbeda di berbagai aplikasi, tetapi ide dasarnya selalu sama, yaitu


membuat kelompok sedemikian rupa sehingga elemen-elemen terkait ditempatkan bersama. Dengan menggunakan prinsip ini, setiap kali sekumpulan besar data yang beragam dan bervariasi disajikan untuk analisis, pengelompokan memungkinkan untuk merepresentasikan data dalam jumlah kelompok yang lebih sedikit. Ini membantu mengurangi kompleksitas dan memberikan wawasan tentang pola hubungan untuk menghasilkan struktur yang bermakna dan dapat ditindaklanjuti dalam data. Efektivitas pengelompokan diukur berdasarkan homogenitas dalam suatu kelompok serta perbedaan antara kelompok-kelompok yang berbeda. Lihat [Gambar 9.1](#) untuk referensi.

Dari pembahasan di atas, mungkin tampak bahwa melalui pengelompokan, kita mencoba memberi label objek dengan label kelas. Namun, pengelompokan agak berbeda dari klasifikasi dan prediksi numerik yang dibahas dalam bab pembelajaran terbimbing. Dalam setiap kasus ini, tujuannya adalah untuk membuat model yang menghubungkan fitur dengan hasil atau fitur lain dan model mengidentifikasi pola dalam data. Sebaliknya, pengelompokan membuat data baru. Objek yang tidak berlabel diberi label kluster yang disimpulkan sepenuhnya dari hubungan atribut dalam data.


Mari kita ambil contoh. Anda diundang untuk mengikuti sesi tentang Pembelajaran Mesin di sebuah universitas ternama untuk memperkenalkan para profesor mereka tentang subjek tersebut. Sebelum Anda membuat materi untuk sesi tersebut, Anda ingin mengetahui tingkat pengetahuan para profesor tentang subjek tersebut agar sesi tersebut berhasil. Namun, Anda tidak ingin bertanya kepada universitas yang mengundang, melainkan melakukan analisis sendiri berdasarkan data yang tersedia secara bebas. Karena Pembelajaran Mesin merupakan persimpangan antara Statistik dan Ilmu Komputer, Anda juga berfokus untuk mengidentifikasi para profesor dari kedua bidang ini. Jadi, Anda mencari daftar publikasi penelitian para profesor ini dari internet, dan

dengan menggunakan algoritma pembelajaran mesin, Anda sekarang ingin mengelompokkan makalah dan dengan demikian menyimpulkan keahlian para profesor ke dalam tiga kelompok – Statistik, Ilmu Komputer, dan Pembelajaran Mesin.

Setelah memetakan jumlah publikasi para profesor di dua bidang inti, yaitu Statistik dan Ilmu Komputer, Anda memperoleh diagram sebar seperti yang ditunjukkan pada Gambar 9.2.




GAMBAR 9.1Pembelajaran tanpa pengawasan – pengelompokan



Gambar. 9.2Kumpulan data untuk peserta konferensi

Beberapa kesimpulan yang dapat diambil dari analisis pola data adalah bahwa tampaknya ada tiga kelompok atau kluster yang muncul dari data tersebut. Ahli statistik murni memiliki lebih sedikit makalah terkait Ilmu Komputer, sedangkan profesor Ilmu Komputer murni memiliki lebih sedikit makalah terkait statistik daripada makalah terkait Ilmu Komputer. Ada kluster ketiga profesor yang telah menerbitkan makalah di kedua bidang ini dan dengan demikian dapat diasumsikan sebagai orang yang berpengetahuan dalam konsep pembelajaran mesin, seperti yang ditunjukkan dalam Gambar 9.3.

Jadi, dalam soal di atas, kami menggunakan indikasi visual pengelompokan data yang logis untuk mengidentifikasi pola atau kluster dan memberi label data dalam tiga kluster yang berbeda. Penggerak utama pengelompokan kami adalah kedekatan titik-titik satu sama lain untuk membentuk suatu kelompok. Algoritme pengelompokan menggunakan pendekatan yang sangat mirip untuk mengukur seberapa dekat titik-titik data saling terkait dan memutuskan apakah titik-titik tersebut dapat diberi label sebagai kelompok yang homogen. Di bagian berikutnya, kami akan membahas beberapa algoritme penting untuk pengelompokan.



GAMBAR 9.3 Kelompok untuk peserta konferensi

9.4.2 Berbagai jenis teknik pengelompokan

Teknik pengelompokan utama adalah

- Metode partisi,
- Metode hierarkis, dan metode berbasis kepadatan.

Pendekatan mereka terhadap pembuatan klaster, cara mengukur kualitas klaster, dan penerapannya berbeda. **Tabel 9.1** merangkum karakteristik utama setiap metode untuk setiap referensi.

Tabel 9.1 Berbagai Metode Pengelompokan

Method	Characteristics
Partitioning methods	• Uses mean or medoid (etc.) to represent cluster centre • Adopts distance-based approach to refine clusters • Finds mutually exclusive clusters of spherical or nearly spherical shape • Effective for data sets of small to medium size
Hierarchical methods	• Creates hierarchical or tree-like structure through decomposition or merger • Uses distance between the nearest or furthest points in neighbouring clusters as a guideline for refinement • Erroneous merges or splits cannot be corrected at subsequent levels
Density-based methods	• Useful for identifying arbitrarily shaped clusters • Guiding principle of cluster creation is the identification of dense regions of objects in space which are separated by low-density regions • May filter out outliers

Kami akan membahas masing-masing metode ini dan teknik terkait secara rinci di bagian berikut.

9.4.3 Metode partisi

Dua algoritma terpenting untuk pengelompokan berbasis partisi adalah k-means dan k-medoid. Dalam algoritma k-means, centroid prototipe diidentifikasi untuk pengelompokan, yang biasanya merupakan mean dari sekelompok titik. Demikian pula, algoritma k-medoid mengidentifikasi medoid yang merupakan titik paling representatif untuk

sekelompok titik. Kita juga dapat menyimpulkan bahwa dalam kebanyakan kasus, centroid tidak sesuai dengan titik data aktual, sedangkan medoid selalu merupakan titik data aktual. Mari kita bahas kedua algoritma ini secara terperinci.

9.4.3.1 K-means - Teknik berbasis centroid

Ini adalah salah satu algoritma tertua dan paling populer yang digunakan untuk pengelompokan. Prinsip dasar yang digunakan oleh algoritma ini juga menjadi dasar bagi algoritma lain yang lebih canggih dan kompleks. **Tabel 9.2** menyediakan kekuatan dan kelemahan algoritma ini.

Prinsip algoritma k-means adalah menetapkan setiap titik data 'n' ke salah satu dari K kluster, di mana 'K' adalah parameter yang ditentukan pengguna sebagai jumlah kluster yang diinginkan. Tujuannya adalah untuk memaksimalkan homogenitas dalam kluster dan juga memaksimalkan perbedaan antar kluster. Homogenitas dan perbedaan diukur berdasarkan jarak antara objek atau titik dalam kumpulan data.

Algoritma 9.1 menunjukkan algoritma sederhana K-means

Langkah 1: Pilih titik K di ruang data dan tandai sebagai loop centroid awal

Langkah 2: Tetapkan setiap titik dalam ruang data ke centroid terdekat untuk membentuk K cluster

Langkah 3: Ukur jarak setiap titik dalam cluster dari centroid

Langkah 4: Hitung Jumlah Kesalahan Kuadrat (SSE) untuk mengukur kualitas cluster (dijelaskan kemudian dalam bab ini)


Langkah 5: Identifikasi centroid baru setiap cluster berdasarkan jarak antar titik

Langkah 6: Ulangi Langkah 2 hingga 5 untuk menyempurnakan hingga titik pusat tidak berubah di akhir loop

Tabel 9.2Kekuatan dan Kelemahan K-means

Strengths	Weaknesses
• The principle used for identifying the clusters is very simple and involves very less complexity of statistical terms • The algorithm is very flexible and thus can be adjusted for most scenarios and complexities • The performance and efficiency are very high and comparable to those of any sophisticated algorithm in term of dividing the data into useful clusters	• The algorithm involves an element of random chance and thus may not find the optimal set of cluster in some cases • The starting point of guessing the number natural clusters within the data requires some experience of the user, so that the final outcome is efficient

Mari kita pahami algoritma ini dengan sebuah contoh. **Gambar 9.4**, kita memiliki kumpulan titik data tertentu, dan kita akan menerapkan algoritma kmeans untuk menemukan klaster yang dihasilkan dari kumpulan data ini. Mari kita tetapkan $K = 4$, yang menyiratkan bahwa kita ingin membuat empat klaster dari kumpulan data ini. Sebagai langkah pertama, kita tetapkan empat titik acak dari kumpulan data sebagai centroid, sebagaimana diwakili oleh tanda *, dan kita tetapkan titik data ke centroid terdekat untuk membuat empat klaster. Pada langkah kedua, atas dasar jarak titik dari centroid yang sesuai, centroid diperbarui dan titik ditugaskan kembali ke centroid yang diperbarui. Setelah tiga iterasi, kami menemukan bahwa centroid tidak bergerak karena tidak ada ruang untuk penyempurnaan, dan dengan demikian, algoritma k-means akan berakhir. Ini memberi kita empat pengelompokan atau klaster paling logis dari kumpulan data di mana homogenitas dalam kelompok paling tinggi dan perbedaan antara kelompok paling maksimum.



GAMBAR 9.4Konsep pengelompokan – sebelum dan sesudah pengelompokan

Memilih jumlah cluster yang tepat

Salah satu faktor keberhasilan terpenting dalam mencapai pengelompokan yang benar adalah memulai dengan jumlah asumsi pengelompokan yang benar. Jumlah pengelompokan awal yang berbeda mengarah pada jenis pemisahan data yang sama sekali berbeda. Akan selalu membantu jika kita memiliki beberapa pengetahuan sebelumnya tentang jumlah pengelompokan dan kita memulai algoritma k-means kita dengan pengetahuan sebelumnya itu. Misalnya, jika kita mengelompokkan data mahasiswa suatu universitas, akan selalu lebih baik untuk memulai dengan jumlah departemen di universitas itu. Terkadang, kebutuhan bisnis atau keterbatasan sumber daya mendorong jumlah pengelompokan yang diperlukan. Misalnya, jika seorang pembuat film ingin mengelompokkan film berdasarkan kombinasi dua parameter – anggaran film: tinggi atau rendah, dan pemeran film: bintang atau non-bintang, maka ada 4 kemungkinan kombinasi, dan dengan demikian, dapat ada empat pengelompokan untuk membagi data.

Untuk kumpulan data kecil, terkadang aturan praktis yang diikuti adalah

$$K = \sqrt{\frac{n}{2}}$$

yang berarti bahwa K ditetapkan sebagai akar kuadrat dari $n/2$ untuk suatu data kumpulan n contoh. Namun sayangnya, aturan praktis ini tidak berfungsi dengan baik untuk kumpulan data yang besar. Ada beberapa metode statistik untuk mendapatkan jumlah kluster yang sesuai.


Metode siku

Metode ini mencoba mengukur homogenitas atau heterogenitas dalam kluster dan untuk berbagai nilai 'K' dan membantu dalam mencapai 'K' yang optimal. Dari [Gambar 9.5](#), kita dapat melihat homogenitas akan meningkat atau heterogenitas akan menurun dengan peningkatan 'K' karena jumlah titik data di dalam setiap kluster berkurang dengan peningkatan ini. Namun iterasi ini membutuhkan upaya komputasi yang signifikan, dan setelah titik tertentu, peningkatan manfaat homogenitas tidak lagi sesuai dengan investasi yang diperlukan untuk mencapainya, seperti yang terlihat dari gambar. Titik ini dikenal sebagai titik siku, dan nilai 'K' pada titik ini menghasilkan kinerja pengelompokan yang optimal. Ada sejumlah besar algoritme untuk menghitung homogenitas dan heterogenitas kluster, yang tidak dibahas dalam buku ini.

Memilih titik pusat awal

Langkah kunci lain untuk algoritma k-means adalah memilih centroid awal dengan tepat. Salah satu praktik umum adalah memilih titik acak dalam ruang data berdasarkan jumlah kebutuhan kluster dan menyempurnakan titik saat kita beralih ke iterasi. Namun, hal ini sering kali menyebabkan kesalahan kuadrat yang lebih tinggi dalam pengelompokan akhir, sehingga menghasilkan solusi pengelompokan yang kurang optimal. Asumsi untuk memilih centroid acak adalah bahwa beberapa kali operasi berikutnya akan meminimalkan SSE dan

mengidentifikasi kluster yang optimal. Namun, hal ini sering kali tidak benar berdasarkan penyebaran set data dan jumlah kluster yang dicari. Jadi, salah satu pendekatan yang efektif adalah menggunakan teknik pengelompokan hierarkis pada titik sampel dari set data dan kemudian memperoleh sampel kluster K . Centroid dari kluster K awal ini digunakan sebagai centroid awal. Pendekatan ini praktis ketika set data memiliki sejumlah titik kecil dan K relatif kecil dibandingkan dengan titik data. Ada prosedur seperti membagi dua k -means dan penggunaan pascaproses untuk memperbaiki masalah pengelompokan awal; prosedur ini dapat menghasilkan centroid awal dengan kualitas lebih baik dan dengan demikian SSE lebih baik untuk kluster akhir.



Gambar. 9.5Titik siku untuk menentukan jumlah cluster yang tepat.

Menghitung ulang centroid cluster

Kami membahas dalam algoritma k-means bahwa langkah iteratif adalah menghitung ulang centroid dari kumpulan data setelah setiap iterasi. Kedekatan titik data satu sama lain dalam suatu kluster diukur untuk meminimalkan jarak. Jarak titik data dari centroid terdekatnya juga dapat dihitung untuk meminimalkan jarak untuk sampai pada centroid yang telah disempurnakan. Jarak Euclidean antara dua titik data diukur sebagai berikut:

$$\text{dist}(x, y) = \sqrt{\sum_1^n (x_i - y_i)^2} \quad (9.1)$$

Dengan menggunakan fungsi ini, jarak antara data contoh dan centroid terdekatnya serta objektif dihitung untuk meminimalkan jarak ini. Pengukuran kualitas pengelompokan menggunakan teknik SSE. Rumus yang digunakan adalah sebagai berikut:


$$\text{SSE} = \sum_{i=1}^k \sum_{x \in C_i} \text{dist}(c_i, x)^2 \quad (9.2)$$

di mana $\text{dist}()$ menghitung jarak Euclidean antara centroid c_i dari kluster C_i dan titik data x dalam kluster.


Penjumlahan jarak tersebut di semua kluster 'K' memberikan jumlah total kesalahan kuadrat. Seperti yang dapat Anda pahami, semakin rendah SSE untuk solusi pengelompokan, semakin baik posisi representatif centroid. Jadi, dalam algoritma pengelompokan kami di Algoritma 9.1, perhitungan ulang centroid melibatkan penghitungan SSE dari setiap centroid baru dan memperoleh identifikasi centroid yang optimal. Setelah centroid diposisikan ulang, titik data yang paling dekat dengan centroid ditetapkan untuk membentuk kluster yang disempurnakan. Dapat diamati bahwa centroid yang meminimalkan SSE kluster adalah rata-ratanya. Salah satu keterbatasan metode kesalahan kuadrat adalah bahwa dalam kasus adanya outlier dalam set data, kesalahan kuadrat dapat mendistorsi nilai rata-rata kluster.

Mari kita gunakan pemahaman ini untuk mengidentifikasi langkah cluster untuk kumpulan data pada Gambar 9.6. Asumsikan bahwa jumlah kebutuhan cluster, $K = 4$. Kita akan secara acak memilih empat centroid cluster seperti yang ditunjukkan oleh empat warna berbeda di Gambar 9.7.


Sekarang, berdasarkan kedekatan titik data dalam kumpulan data ini dengan centroid, kami membagi kumpulan data menjadi empat segmen seperti yang direpresentasikan oleh garis putus-putus di Gambar 9.8. Diagram ini disebut diagram Voronoi yang menciptakan batas-batas klaster. Kita memperoleh empat klaster awal, yaitu C1, C2, C3, dan C4, yang dibuat oleh garis putus-putus dari titik puncak klaster, yang merupakan titik dengan jarak maksimal dari pusat klaster. Kini mudah untuk memahami area yang dicakup oleh setiap klaster dan titik data dalam setiap klaster melalui representasi ini.



Gambar. 9.6 Pengelompokan set data



Gambar. 9.7 Pengelompokan dengan centroid awal




Gambar. 9.8 Iterasi 1: Empat cluster dan jarak titik dari centroid


Langkah berikutnya adalah menghitung SSE dari pengelompokan ini dan memperbarui posisi centroid. Kita juga dapat melanjutkan dengan pemahaman kita bahwa centroid baru harus menjadi rata-rata titik data di masing-masing cluster. Jarak titik data yang saat ini ditandai sebagai Cluster C3 dari centroid cluster C3 ditandai sebagai a_{i1} , a_{i2} , ..., a_{in} pada gambar dan itu menentukan homogenitas dalam cluster C3. Di sisi lain, jarak titik data cluster C4 dari centroid cluster C3 menentukan heterogenitas di antara dua cluster yang berbeda ini. Tujuan kita adalah untuk meminimalkan homogenitas dalam cluster dan memaksimalkan heterogenitas di antara cluster yang berbeda. Jadi, centroid yang direvisi seperti yang ditunjukkan pada Gambar 9.9.

Kita juga dapat mengetahui bahwa batas-batas klaster disempurnakan berdasarkan centroid baru dan identifikasi centroid terdekat untuk titik-titik data dan menugaskannya kembali ke centroid baru. Titik-titik baru yang diambil kembali oleh setiap klaster ditunjukkan dalam diagram.

Algoritma k-means berlanjut dengan pembaruan centroid sesuai dengan klaster baru dan penugasan ulang titik-titik, hingga tidak ada lagi titik data yang berubah karena pergeseran centroid. Pada titik ini, algoritma berhenti. Gambar 9.10 menunjukkan pengelompokan akhir dari kumpulan data yang kami gunakan. Kompleksitas algoritma k-means adalah $O(nKt)$, di mana ' n ' adalah jumlah total titik data atau objek dalam kumpulan data, ' K ' adalah jumlah klaster, dan ' t ' adalah jumlah iterasi. Biasanya, ' K ' dan ' t ' dibuat jauh lebih kecil daripada ' n ', dan dengan demikian, metode k-means relatif dapat diskalakan dan efisien dalam memproses kumpulan data besar.



Gambar. 9.9 Iterasi 2: Centroid dihitung ulang dan titik didistribusikan ulang di antara cluster sesuai dengan centroid terdekat



GAMBAR 9.10 Iterasi 3: Penataan kluster akhir: Centroid dihitung ulang dan titik didistribusikan ulang di antara kluster sesuai dengan centroid terdekat

aku-means sering menghasilkan optimum lokal dan bukan optimum global. Selain itu, hasilnya bergantung pada pemilihan awal centroid kluster acak. Merupakan praktik umum untuk menjalankan algoritme *k-means* beberapa kali dengan pusat kluster yang berbeda untuk mengidentifikasi kluster yang optimal. Keharusan untuk menetapkan nilai 'K' awal juga dianggap sebagai kerugian dari algoritme *k-means*. Ada beberapa metode untuk mengatasi masalah ini, seperti mendefinisikan rentang untuk 'K' dan kemudian membandingkan hasil pengelompokan dengan nilai 'K' yang berbeda tersebut untuk mendapatkan kluster terbaik yang memungkinkan. Cara untuk meningkatkan kinerja kluster merupakan area studi lebih lanjut, dan banyak teknik berbeda digunakan untuk mencapainya. Ini berada di luar cakupan buku ini tetapi dapat dilakukan untuk studi pembelajaran mesin tingkat lanjut.

9.4.4 K-Medoids: teknik berbasis objek yang representatif

Seperti yang dibahas sebelumnya, algoritme *k-means* sensitif terhadap outlier dalam set data dan secara tidak sengaja menghasilkan kluster yang miring ketika rata-rata titik data digunakan sebagai centroid. Mari kita ambil contoh delapan titik data, dan untuk menyederhanakannya, kita dapat menganggapnya sebagai data 1-D dengan nilai 1, 2, 3, 5, 9, 10, 11, dan 25. Titik 25 adalah outlier, dan memengaruhi pembentukan kluster secara negatif ketika rata-rata titik dianggap sebagai centroid.

Dengan $K = 2$, cluster awal yang kita dapatkan adalah {1, 2, 3, 6} dan {9, 10, 11, 25}. Rata-rata cluster $\{1, 2, 3, 6\} = \frac{12}{4} = 3$,

dan rata-rata cluster $\{9, 10, 12, 25\} = \frac{56}{4} = 14$.

Jadi, SSE dalam cluster tersebut adalah

$$(1 - 3)^2 + (2 - 3)^2 + (3 - 3)^2 + (6 - 3)^2 + (9 - 14)^2 + (10 - 14)^2 + (12 - 14)^2 + (25 - 14)^2 = 179$$

Jika kita bandingkan dengan cluster {1, 2, 3, 6, 9} dan {10, 11, 25},

$$\text{rata-rata cluster } \{1, 2, 3, 6, 9\} = \frac{21}{5} = 4.2,$$

$$\text{dan rata-rata cluster } \{10, 12, 25\} = \frac{47}{3} = 15.67.$$

Jadi, SSE dalam cluster tersebut adalah

$$(1 - 4.2)^2 + (2 - 4.2)^2 + (3 - 4.2)^2 + (6 - 4.2)^2 + (9 - 4.2)^2 \\ + (10 - 15.67)^2 + (12 - 15.67)^2 + (25 - 15.67)^2 = 113.84$$

Karena SSE dari pengelompokan kedua lebih rendah, k-means cenderung menempatkan titik 9 dalam pengelompokan yang sama dengan 1, 2, 3, dan 6 meskipun titik tersebut secara logis lebih dekat ke titik 10 dan 11. Kecenderungan ini disebabkan oleh titik outlier 25, yang menggeser mean menjauh dari pusat pengelompokan.

K-medoids memberikan solusi untuk masalah ini. Alih-alih dengan mempertimbangkan rata-rata titik data dalam klaster, k-medoids mempertimbangkan k titik data representatif dari titik-titik yang ada dalam kumpulan data sebagai pusat klaster. Kemudian, ia menetapkan titik data sesuai dengan jaraknya dari pusat-pusat ini untuk membentuk k klaster. Perhatikan bahwa medoid dalam kasus ini adalah titik data aktual atau objek dari kumpulan data dan bukan titik imajiner seperti dalam kasus ketika rata-rata kumpulan data dalam klaster digunakan sebagai centroid dalam teknik k-means. SSE dihitung sebagai

$$SSE = \sum_{i=1}^k \sum_{x \in C_i} \text{dist}(o_i, x)^2 \quad (9.3)$$

di mana o_i adalah titik atau objek representatif dari klaster C_i .

Dengan demikian, metode k-medoids mengelompokkan n objek dalam k klaster dengan meminimalkan SSE. Karena penggunaan medoid dari titik data representatif yang sebenarnya, k-medoids kurang dipengaruhi oleh outlier dalam data. Salah satu implementasi praktis dari


prinsip k-medoids adalah algoritma Partitioning Around Medoids (PAM). Lihat tabel Algoritma 2:

Algoritma 2: PAM

- Langkah 1:** Pilih secara acak k titik dalam set data sebagai titik representatif awal loop
- Langkah 2:** Tetapkan setiap titik yang tersisa ke cluster yang memiliki titik representatif terdekat
- Langkah 3:** Pilih secara acak titik yang tidak mewakili atau di setiap cluster
- Langkah 4:** Tukar titik representatif o_j dengan $atau$ dan hitung SSE baru setelah menukar
- Langkah 5:** Jika $SSE_{new} < SSE_{old}$, maka tukar o_j dengan $atau$ untuk membentuk himpunan baru berisi k objek representatif;
- Langkah 6:** Memperbaiki k cluster berdasarkan titik representatif terdekat. Logika berlanjut hingga tidak ada perubahan pada loop akhir.

Dalam algoritma ini, kami mengganti objek representatif saat ini dengan objek non-representatif dan memeriksa apakah objek tersebut meningkatkan kualitas pengelompokan. Dalam proses iteratif, semua penggantian yang memungkinkan dicoba hingga kualitas pengelompokan tidak lagi meningkat.

Jika $o_1, \dots, o_k$ adalah himpunan objek representatif atau medoid saat ini dan terdapat objek non-representatif $atau$, maka untuk menentukan apakah $atau$ merupakan penggantian o_j yang baik ($1 \leq j \leq k$), jarak setiap objek x dihitung dari medoid terdekatnya dari himpunan $\{o_1, o_2, \dots, o_{j-1}, atau, o_{j+1}, \dots, o_k\}$ dan SSE dihitung. Jika SSE setelah mengganti o_j dengan $atau$ menurun, artinya $atau$ merepresentasikan kluster lebih baik daripada o_j , dan titik data dalam himpunan tersebut ditetapkan ulang menurut medoid terdekat sekarang.



Gambar. 9.11Algoritma PAM: Penugasan kembali titik ke cluster yang berbeda

Seperti yang ditunjukkan pada Gambar 9.11, titik p_i termasuk dalam klaster dengan medoid o_{j+1} pada iterasi pertama, tetapi setelah o_j digantikan oleh o_r , ditemukan bahwa p_i paling dekat dengan medoid acak yang baru dan dengan demikian ditetapkan padanya. Dengan cara ini, klaster disempurnakan setelah setiap medoid diganti dengan medoid baru yang tidak representatif. Setiap kali penugasan ulang dilakukan, SSE berdasarkan medoid baru dihitung. Perbedaan antara SSE sebelum dan sesudah pertukaran menunjukkan apakah penggantian tersebut meningkatkan kualitas pengelompokan dengan menyatukan titik-titik yang paling mirip.

Meskipun algoritma k-medoids menyediakan cara yang efektif untuk menghilangkan noise atau outlier dalam set data, yang merupakan masalah dalam algoritma k-means, algoritma ini mahal dalam hal perhitungan. Kompleksitas setiap iterasi dalam algoritma k-medoids adalah $O(k(n - k)^2)$. Untuk nilai ' n ' dan ' k ' yang besar, perhitungan ini menjadi jauh lebih mahal dibandingkan dengan algoritma k-means.

9.4.5 Pengelompokan hierarkis

Sampai sekarang, kita telah membahas berbagai metode untuk mempartisi data ke dalam kluster yang berbeda. Namun, ada situasi ketika data perlu dipartisi ke dalam kelompok-kelompok pada tingkat yang berbeda seperti dalam hierarki. Metode pengelompokan hierarki digunakan untuk mengelompokkan data ke dalam hierarki atau struktur seperti pohon. Misalnya, dalam masalah pembelajaran mesin untuk mengatur karyawan universitas di berbagai departemen, pertama-tama karyawan dikelompokkan di bawah departemen yang berbeda di universitas, dan kemudian di dalam setiap departemen, karyawan dapat dikelompokkan menurut peran mereka seperti profesor, asisten profesor, supervisor, asisten lab, dll. Ini menciptakan struktur hierarki data karyawan dan memudahkan visualisasi dan analisis. Demikian pula, mungkin ada kumpulan data yang memiliki struktur hierarki yang mendasarinya yang ingin kita temukan dan kita dapat menggunakan metode pengelompokan hierarki untuk mencapainya.

Terdapat dua metode pengelompokan hierarkis utama: pengelompokan aglomeratif dan pengelompokan divisif. Pengelompokan aglomeratif adalah teknik bottom-up yang dimulai dengan objek individual sebagai klaster dan kemudian menggabungkannya secara berulang untuk membentuk klaster yang lebih besar. Di sisi lain, metode divisif dimulai dengan satu klaster dengan semua objek yang diberikan dan kemudian membaginya secara berulang untuk membentuk klaster yang lebih kecil. Lihat Gambar 9.12.


Metode pengelompokan hierarkis aglomeratif menggunakan strategi bottom-up. Dimulai dengan setiap objek membentuk klasternya sendiri, lalu secara berulang menggabungkan klaster tersebut sesuai dengan kesamaannya untuk membentuk klaster yang lebih besar. Metode ini berakhir saat kondisi pengelompokan tertentu yang ditetapkan oleh

pengguna tercapai atau saat semua klaster bergabung menjadi satu klaster.

Metode pengelompokan hierarkis yang terbagi menggunakan strategi top-down. Titik awalnya adalah klaster terbesar dengan semua objek di dalamnya, kemudian, klaster tersebut dipecah secara rekursif untuk membentuk klaster yang semakin kecil, sehingga membentuk hierarki. Akhir iterasi dicapai ketika objek dalam klaster akhir cukup homogen satu sama lain atau klaster akhir hanya berisi satu objek atau kondisi pengelompokan yang ditentukan pengguna tercapai.

Dalam kedua kasus ini, penting untuk memilih titik pemisahan dan penggabungan secara hati-hati, karena pemisahan atau penggabungan berikutnya akan menggunakan hasil dari pemisahan atau penggabungan sebelumnya dan tidak ada opsi untuk melakukan pertukaran objek apa pun di antara kluster atau memperbaiki keputusan yang dibuat pada langkah sebelumnya, yang dapat mengakibatkan buruknya kualitas pengelompokan pada akhirnya.

Dendrogram adalah representasi struktur pohon yang umum digunakan untuk pembuatan pengelompokan hierarkis langkah demi langkah. Dendrogram menunjukkan bagaimana pengelompokan digabungkan secara berulang (dalam kasus pengelompokan aglomeratif) atau dibagi secara berulang (dalam kasus pengelompokan divisif) untuk mendapatkan solusi pengelompokan yang optimal. Gambar 9.13 menunjukkan dendrogram dengan empat tingkat dan bagaimana objek digabungkan atau dipisah pada setiap tingkat untuk menghasilkan pengelompokan hierarkis.



Gambarr. 9.12 Pengelompokan hierarkis aglomeratif dan divisif

Salah satu ukuran utama kedekatan antar kluster adalah jarak antar kluster. Ada empat metode standar untuk mengukur jarak antar kluster:

Misalkan C_i dan C_j adalah dua kluster dengan n_i dan n_j masing-masing. p_i dan p_j masing-masing mewakili titik-titik dalam kluster C_i dan C_j . Kita akan menyatakan rata-rata kluster C_i sebagai m_i .


$$\text{Minimum distance } D_{\min}(C_i, C_j) = \min_{p_i \in C_i, p_j \in C_j} \{|p_i - p_j|\} \quad (9.4)$$

$$\text{Maximum distance } D_{\max}(C_i, C_j) = \max_{p_i \in C_i, p_j \in C_j} \{|p_i - p_j|\} \quad (9.5)$$

$$\text{Mean distance } D_{\text{mean}}(C_i, C_j) = \{|m_i - m_j|\} \quad (9.6)$$

$$\text{Average distance } D_{\text{avg}}(C_i, C_j) = \frac{1}{n_i n_j} \sum_{p_i \in C_i, p_j \in C_j} |p_i - p_j| \quad (9.7)$$

Mengacu pada Gambar 9.14 untuk memahami konsep jarak ini.



Gambar 9.13 Representasi dendrogram pengelompokan hierarkis



Gambar. 9.14 Pengukuran jarak dalam metode algoritmik

Seringkali ukuran jarak digunakan untuk memutuskan kapan harus menghentikan algoritma pengelompokan. Misalnya, dalam pengelompokan aglomeratif, iterasi penggabungan dapat dihentikan setelah jarak MIN antara dua kluster yang berdekatan menjadi kurang dari ambang batas yang ditetapkan pengguna. Jadi, ketika suatu algoritma menggunakan jarak minimum D_{min} untuk mengukur jarak antara kluster, maka itu disebut sebagai algoritma pengelompokan tetangga terdekat, dan jika keputusan untuk menghentikan algoritma didasarkan pada batas yang ditetapkan pengguna pada D_{min} , maka itu disebut algoritma hubungan tunggal.

Di sisi lain, jika suatu algoritma menggunakan jarak maksimum D_{max} untuk mengukur jarak antar klaster, maka algoritma tersebut disebut algoritma pengelompokan tetangga terjauh. Jika keputusan untuk menghentikan algoritma didasarkan pada batasan D_{max} yang ditentukan pengguna, maka algoritma tersebut disebut algoritma tautan lengkap.

Karena pengukuran minimum dan maksimum menyediakan dua opsi ekstrem untuk mengukur jarak antar klaster, pengukuran tersebut rentan terhadap outlier dan data yang bising. Sebaliknya, penggunaan jarak rata-rata dan mean membantu menghindari masalah tersebut dan memberikan hasil yang lebih konsisten.

9.4.6 Metode berbasis kepadatan - DBSCAN

Anda mungkin telah memperhatikan bahwa ketika kami menggunakan metode partisi dan pengelompokan hierarkis, kluster yang dihasilkan berbentuk bulat atau hampir bulat. Dalam kasus kluster

berbentuk lain seperti kluster berbentuk S atau kluster berbentuk tidak rata, kedua jenis metode di atas tidak memberikan hasil yang akurat. Pendekatan pengelompokan berbasis kepadatan memberikan solusi untuk mengidentifikasi kluster dengan bentuk yang berubah-ubah. Prinsipnya didasarkan pada identifikasi area padat dan area jarang dalam set data, lalu menjalankan algoritma pengelompokan. DBSCAN adalah salah satu algoritma berbasis kepadatan populer yang membuat kluster dengan menggunakan daerah terhubung dengan kepadatan tinggi.

9.5 MENEMUKAN POLA DENGAN MENGGUNAKAN ATURAN ASOSIASI

Aturan asosiasi menyajikan metodologi yang berguna untuk mengidentifikasi hubungan menarik yang tersembunyi dalam kumpulan data besar. Aturan ini juga dikenal sebagai analisis asosiasi, dan hubungan yang ditemukan dapat direpresentasikan dalam bentuk aturan asosiasi yang terdiri dari serangkaian item yang sering muncul. Aplikasi umum dari analisis ini adalah Analisis Keranjang Belanja yang digunakan pengecer untuk penjualan silang produk mereka. Misalnya, setiap toko kelontong besar mengumpulkan sejumlah besar data tentang pola pembelian pelanggan. Atas dasar item yang dibeli bersama, pengecer dapat mendorong penjualan silang baik dengan menempatkan item yang dibeli bersama di area yang berdekatan atau membuat beberapa penawaran kombo dengan jenis produk yang berbeda tersebut. Aturan asosiasi di bawah ini menandakan bahwa orang yang telah membeli roti dan susu sering kali juga membeli telur; jadi, bagi pengecer, masuk akal jika item-item ini ditempatkan bersama untuk peluang baru untuk penjualan silang.

$\{\text{Roti, Susu}\} \rightarrow \{\text{Telur}\}$

Penerapan analisis asosiasi juga tersebar luas di domain lain seperti bioinformatika, diagnosis medis, analisis data ilmiah, dan penambangan data web. Misalnya, dengan menemukan hubungan menarik antara kebiasaan makan dan pasien yang terkena kanker payudara, mekanisme pencegahan kanker baru dapat ditemukan yang akan bermanfaat bagi ribuan orang di dunia. Dalam buku ini, kami terutama akan mengilustrasikan teknik analisis dengan menggunakan contoh keranjang belanja, tetapi dapat digunakan lebih luas di seluruh domain untuk mengidentifikasi hubungan di antara item dalam data transaksional. Kumpulan besar data yang dihasilkan setiap hari melalui transaksi yang dilacak seperti pemindai kode batang, pembelian daring, dan sistem pelacakan inventaris telah memungkinkan sistem pembelajaran mesin untuk belajar dari kekayaan data ini. Kami akan membahas metode untuk menemukan hubungan yang berguna dalam basis data besar dengan menggunakan ukuran kinerja statistik sederhana sambil mengelola kekhasan bekerja dengan data transaksional tersebut. Salah satu tantangan signifikan dalam bekerja dengan volume data yang besar adalah bahwa secara komputasi mungkin sangat mahal untuk menemukan pola dari data tersebut. Selain itu, mungkin ada kasus ketika beberapa hubungan terjadi secara kebetulan, yang dapat menyebabkan pengetahuan yang berpotensi salah. Saat membahas analisis asosiasi, kami akan membahas kedua poin ini.

Kami akan menggunakan data transaksi dalam tabel di bawah ini untuk contoh analisis asosiasi kami. Versi data keranjang pasar yang disederhanakan ini akan menunjukkan bagaimana aturan asosiasi dapat digunakan secara efektif untuk analisis keranjang pasar.

9.5.1 Definisi istilah umum

Mari kita pahami beberapa terminologi umum yang digunakan dalam analisis asosiasi.

9.5.1.1 *Kumpulan item*

Satu atau beberapa item dikelompokkan bersama dan dikelilingi tanda kurung untuk menunjukkan bahwa item tersebut membentuk satu set, atau lebih khusus lagi, satu set item yang muncul dalam data dengan keteraturan tertentu. Misalnya, dalam **Tabel 9.3**, {Roti, Susu, Telur} dapat dikelompokkan bersama untuk membentuk itemset karena itemset tersebut sering dibeli bersama. Untuk menggeneralisasi konsep ini, jika $I = \{i_1, i_2, \dots, i_n\}$ adalah item dalam data keranjang pasar dan $T = \{t_1, t_2, \dots, t_n\}$ adalah himpunan semua transaksi, maka setiap transaksi t_i berisi subhimpunan item dari I . Kumpulan nol atau lebih item disebut itemset. Itemset null adalah item yang tidak berisi item apa pun. Dalam analisis asosiasi, itemset disebut k-itemset jika berisi k jumlah item. Jadi, itemset {Roti, Susu, Telur} adalah tiga-itemset.

Tabel 9.3Data Transaksi Keranjang Pasar

Transaction Number	Purchased Items
1	{Bread, Milk, Egg, Butter, Salt, Apple}
2	{Bread, Milk, Egg, Apple}
3	{Bread, Milk, Butter, Apple}
4	{Milk, Egg, Butter, Apple}
5	{Bread, Egg, Salt}
6	{Bread, Milk, Egg, Apple}

9.5.1.2 *Jumlah dukungan*

Jumlah dukungan menunjukkan jumlah transaksi yang melibatkan itemset tertentu. Ini adalah properti yang sangat penting dari sebuah itemset karena menunjukkan frekuensi kemunculan itemset tersebut. Hal ini dinyatakan sebagai

$$\sigma(X) = |\{t_i | X \subseteq t_i, t_i \in T\}|$$

di mana $|\{\}$ menunjukkan jumlah elemen dalam satu set

Di dalam **Tabel 9.3**, itemset {Roti, Susu, Telur} muncul bersamaan tiga kali dan dengan demikian memiliki jumlah dukungan 3.

9.5.2 Aturan asosiasi

Hasil analisis keranjang belanja dinyatakan sebagai seperangkat aturan asosiasi yang menentukan pola hubungan antar item. Aturan umum dapat dinyatakan sebagai {Roti, Susu} $\rightarrow$ {Telur}, yang menunjukkan bahwa jika Roti dan Susu dibeli, maka Telur juga cenderung dibeli. Dengan demikian, aturan asosiasi dipelajari dari subset itemset. Misalnya, aturan sebelumnya diidentifikasi dari himpunan {Roti, Susu, Telur}.

Perlu dicatat bahwa aturan asosiasi adalah ekspresi $X \rightarrow Y$ di mana X dan Y adalah itemset yang terpisah, yaitu $X \cap Y = \emptyset$.

Support dan confidence adalah dua konsep yang digunakan untuk mengukur kekuatan aturan asosiasi. Support menunjukkan seberapa sering aturan berlaku untuk kumpulan data tertentu. Confidence menunjukkan seberapa sering item dalam Y muncul dalam transaksi yang berisi X dalam total transaksi N . Confidence menunjukkan kekuatan prediktif atau akurasi aturan. Jadi, ekspresi matematika adalah

$$\text{Support}, s(X \rightarrow Y) = \frac{\sigma(X \cup Y)}{N} \quad (9.8)$$

$$\text{Confidence}, c(X \rightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)} \quad (9.9)$$

Dalam kumpulan data 9.3 kami, jika kita mempertimbangkan aturan asosiasi {Roti, Susu} $\rightarrow$ {Telur}, maka dari rumus di atas

$$\begin{aligned}\text{Confidence } c(\{\text{Bread, Milk}\} \rightarrow \{\text{Egg}\}) &= \frac{\text{support count of } \{\text{Bread, Milk, Egg}\}}{\text{support count of } \{\text{Bread, Milk}\}} \\ &= \frac{3}{4} \\ &= 0.75\end{aligned}$$

$$\begin{aligned}\text{Confidence } c(\{\text{Bread, Milk}\} \rightarrow \{\text{Egg}\}) &= \frac{\text{support count of } \{\text{Bread, Milk, Egg}\}}{\text{support count of } \{\text{Bread, Milk}\}} \\ &= \frac{3}{4} \\ &= 0.75\end{aligned}$$

Penting untuk memahami peran dukungan dan keyakinan dalam analisis asosiasi. Dukungan yang rendah dapat mengindikasikan bahwa aturan tersebut terjadi secara kebetulan. Selain itu, dari perspektif penerapannya, aturan ini mungkin bukan investasi bisnis yang sangat menarik karena barang-barang tersebut jarang dibeli bersama oleh pelanggan. Dengan demikian, dukungan dapat memberikan kecerdasan untuk mengidentifikasi aturan yang paling menarik untuk analisis.

Demikian pula, keyakinan memberikan pengukuran keandalan inferensi suatu aturan. Keyakinan yang lebih tinggi terhadap suatu aturan $X \rightarrow Y$ menunjukkan kemungkinan yang lebih besar untuk hadir dalam transaksi yang mengandung X karena merupakan estimasi probabilitas bersyarat Y yang diberikan X .

Pahami pula bahwa keyakinan X yang mengarah ke Y tidak sama dengan keyakinan Y yang mengarah ke X . Dalam contoh kita, keyakinan $\{\text{Roti, Susu}\} \rightarrow \{\text{Telur}\} = 0,75$ tetapi keyakinan

dari $\{\text{Egg}\} \rightarrow \{\text{Bread, Milk}\} = \frac{3}{5} = 0.6$. Di sini, aturannya $\{\text{Roti, Susu}\} \rightarrow \{\text{Telur}\}$ adalah aturan yang kuat.

Aturan asosiasi dikembangkan dalam konteks Big Data dan ilmu data dan tidak digunakan untuk prediksi. Aturan asosiasi digunakan untuk penemuan pengetahuan tanpa pengawasan dalam basis data besar, tidak seperti algoritma klasifikasi dan prediksi numerik. Namun, kita akan menemukan bahwa pembelajar aturan asosiasi terkait erat dengan dan berbagi banyak fitur pembelajar aturan klasifikasi. Karena pembelajar aturan asosiasi tidak diawasi, tidak perlu bagi algoritma untuk dilatih; ini

berarti tidak diperlukan pelabelan data sebelumnya. Program ini hanya dijalankan pada set data dengan harapan dapat ditemukan asosiasi yang menarik.

Jelas, sisi negatifnya adalah tidak ada cara mudah untuk mengukur kinerja pembelajar aturan secara objektif, selain mengevaluasinya berdasarkan kegunaan kualitatif. Perhatikan juga bahwa analisis aturan asosiasi digunakan untuk mencari hubungan yang menarik di antara sejumlah besar variabel. Meskipun manusia mampu memperoleh wawasan tersebut secara intuitif, terkadang diperlukan pengetahuan tingkat ahli atau banyak pengalaman untuk mencapai kinerja algoritma pembelajaran aturan. Selain itu, beberapa data mungkin terlalu besar atau rumit untuk diuraikan dan dianalisis oleh manusia dengan mudah.

9.5.3 Algoritma apriori untuk pembelajaran aturan asosiasi

Seperti yang dibahas sebelumnya, tantangan utama dalam menemukan aturan asosiasi dan mempelajarinya adalah besarnya volume data transaksional dan kompleksitas terkait. Karena variasi fitur dalam data transaksional, jumlah set fitur dalam satu set data biasanya menjadi sangat besar. Hal ini menyebabkan masalah dalam menangani sejumlah besar itemset, yang tumbuh secara eksponensial seiring dengan jumlah fitur. Jika ada k item yang mungkin atau mungkin tidak menjadi bagian dari satu itemset, maka ada 2^k cara membuat itemset dengan item-item tersebut. Misalnya, jika seorang penjual berurusan dengan 100 item yang berbeda, maka pembelajar perlu mengevaluasi $2^{100} = 1 \times 10^{30}$ itemset untuk mendapatkan aturan, yang secara komputasi tidak mungkin. Jadi, penting untuk menyaring itemset yang paling penting (dan dengan demikian dapat dikelola dalam ukuran) dan menggunakan sumber daya pada itemset tersebut untuk mendapatkan aturan asosiasi yang cukup efisien.

Langkah pertama bagi kita adalah menentukan dukungan minimum dan keyakinan minimum dari aturan asosiasi. Dari sekumpulan transaksi T , mari kita asumsikan bahwa kita akan menemukan semua aturan yang memiliki dukungan $\geq \text{minS}$ dan keyakinan $\geq \text{minC}$, di mana minS dan minC masing-masing adalah ambang batas dukungan dan keyakinan, agar aturan tersebut dianggap dapat diterima. Sekarang, bahkan jika kita menempatkan $\text{minS} = 20\%$ dan $\text{minC} = 50\%$, terlihat bahwa lebih dari 80% aturan dibuang; ini berarti bahwa sebagian besar upaya komputasi dapat dihindari jika itemset untuk pertimbangan terlebih dahulu dipangkas dan itemset yang tidak dapat menghasilkan aturan asosiasi dengan dukungan dan keyakinan yang wajar dihilangkan. Pendekatan untuk mencapai tujuan ini dibahas di bawah ini.

Langkah 1: pisahkan persyaratan dukungan dan keyakinan. Menurut rumus 9.8, dukungan aturan $X \rightarrow Y$ hanya bergantung pada dukungan itemset yang sesuai. Misalnya, semua aturan di bawah ini memiliki dukungan yang sama karena itemsetnya sama {Roti, Susu, Telur}:

- {Roti, Susu} $\rightarrow$ {Telur}
- {Roti, Telur} $\rightarrow$ {Susu}
- {Telur, Susu} $\rightarrow$ {Roti}
- {Roti} $\rightarrow$ {Telur, Susu}
- {Susu} $\rightarrow$ {Roti, Telur}
- {Telur} $\rightarrow$ {Roti, Susu}

Jadi, perlakuan yang sama dapat diterapkan pada aturan asosiasi ini berdasarkan frekuensi itemset. Dalam kasus ini, jika itemset {Roti, Susu, Telur} jarang dalam transaksi keranjang, maka keenam aturan ini dapat dibuang tanpa menghitung nilai dukungan dan keyakinan masing-masing. Ini mengidentifikasi beberapa strategi penting untuk mencapai aturan asosiasi:

1. **Hasilkan Itemset Sering:** Setelah minS ditetapkan untuk penugasan tertentu, identifikasi semua itemset yang memenuhi minS . Itemset ini disebut frequent itemset.
2. **Buat Aturan:** Dari itemset yang sering ditemukan pada langkah sebelumnya, temukan semua aturan dengan tingkat keyakinan tinggi. Aturan ini disebut aturan kuat.

Harap perhatikan bahwa persyaratan komputasi untuk mengidentifikasi frequent itemset lebih intensif daripada pembuatan aturan. Jadi, berbagai teknik telah dikembangkan untuk mengoptimalkan kinerja untuk pembuatan frequent itemset serta penemuan aturan seperti yang dibahas di bagian berikutnya.

9.5.4 Membangun aturan prinsip apriori

Salah satu algoritma yang paling banyak digunakan untuk mengurangi jumlah itemset untuk mencari aturan asosiasi dikenal sebagai Apriori. Algoritma ini terbukti berhasil menyederhanakan pembelajaran aturan asosiasi secara signifikan. Prinsip ini mendapatkan namanya dari fakta bahwa algoritma tersebut memanfaatkan keyakinan sebelumnya yang sederhana (yaitu apriori) tentang properti itemset yang sering muncul:

Jika sebuah itemset sering muncul, maka semua subsetnya juga harus sering muncul.


Prinsip ini secara signifikan membatasi jumlah itemset yang akan dicari untuk pembuatan aturan. Misalnya, jika dalam analisis keranjang belanja, ditemukan bahwa item seperti 'Garam' tidak begitu sering dibeli bersama dengan item sarapan, maka tidak masalah untuk menghapus semua itemset yang mengandung garam untuk pembuatan aturan karena kontribusinya terhadap dukungan dan keyakinan aturan tidak akan signifikan.

Kebalikannya juga berlaku:

Jika suatu itemset bersifat sering, maka semua superset juga harus sering..

Ini adalah prinsip yang sangat kuat yang membantu dalam pemangkasan ruang pencarian eksponensial berdasarkan ukuran dukungan dan dikenal sebagai pemangkasan berbasis dukungan. Properti utama dari ukuran dukungan yang digunakan di sini adalah bahwa dukungan untuk satu itemset tidak pernah melebihi dukungan untuk subset-nya. Ini juga dikenal sebagai properti anti-monoton dari ukuran dukungan.

Mari kita gunakan data transaksi di **Tabel 9.3** untuk mengilustrasikan Prinsip Apriori dan kegunaannya. Dari keseluruhan itemset yang berjumlah enam item {Roti, Susu, Telur, Mentega, Garam, Apel}, terdapat 2^6 cara membuat keranjang atau itemset (termasuk null itemset) seperti yang ditunjukkan pada **Gambar 9.15**:




Gambar. 9.15 Enam puluh empat cara membuat itemset dari 6 item

Tanpa menerapkan logika penyaringan apa pun, pendekatan brute-force akan melibatkan perhitungan jumlah dukungan untuk setiap itemset

di**Gambar 9.16**. Dengan demikian, dengan membandingkan setiap item dalam itemset yang dihasilkan dengan transaksi aktual yang disebutkan dalam**Tabel 9.3**, kita dapat menentukan jumlah dukungan itemset.

Misalnya, jika {Roti, Susu} hadir dalam transaksi apa pun di**Tabel 9.3**, maka jumlah dukungannya akan bertambah 1. Seperti yang dapat kita pahami, ini adalah aktivitas komputasi yang sangat berat, dan seperti yang dibahas sebelumnya, banyak komputasi yang mungkin terbuang di kemudian hari karena beberapa itemset akan ditemukan jarang dalam transaksi. Untuk mendapatkan gambaran tentang total komputasi yang harus dilakukan, jumlah perbandingan yang harus dilakukan adalah $T \times N \times L$, di mana T adalah jumlah transaksi (6 dalam kasus kami), N adalah jumlah itemset kandidat (64 dalam kasus kami), dan L adalah lebar transaksi maksimum (6 dalam kasus kami).



Gambar. 9.16 Membuang itemset yang berisi Salt

Mari kita terapkan prinsip Apriori pada kumpulan data ini untuk mengurangi jumlah itemset kandidat (N). Kita dapat mengidentifikasi dari transaksi**Tabel 9.3** bahwa Salt merupakan item yang jarang muncul. Jadi, dengan menerapkan prinsip Apriori, kita dapat mengatakan bahwa semua itemset yang merupakan superset dari Salt akan menjadi item yang jarang

muncul dan dengan demikian dapat dibuang dari perbandingan untuk menemukan aturan asosiasi seperti yang ditunjukkan pada [Gambar 9.16](#).

Pendekatan ini mengurangi upaya komputasi untuk sejumlah itemset yang baik dan akan membuat proses pencarian kita lebih efisien. Dengan demikian, dalam setiap iterasi tersebut, kita dapat menentukan jumlah dukungan setiap itemset, dan berdasarkan nilai dukungan minimum yang ditetapkan untuk analisis kita, setiap itemset dalam hierarki yang tidak memenuhi kriteria dukungan minimum dapat dibuang untuk membuat pembuatan aturan lebih cepat dan mudah.

Untuk menggeneralisasi contoh tersebut guna membangun seperangkat aturan dengan prinsip Apriori, kita akan menggunakan prinsip Apriori yang menyatakan bahwa semua subset dari frequent itemset juga harus sering muncul. Dengan kata lain, jika $\{X, Y\}$ sering muncul, maka $\{X\}$ dan $\{Y\}$ harus sering muncul. Selain itu, menurut definisi, metrik dukungan menunjukkan seberapa sering suatu itemset muncul dalam data. Jadi, jika kita tahu bahwa $\{X\}$ tidak memenuhi ambang batas dukungan yang diinginkan, tidak ada alasan untuk mempertimbangkan $\{X, Y\}$ atau itemset apa pun yang berisi $\{X\}$; tidak mungkin itu sering muncul.

Logika algoritma Apriori ini mengecualikan aturan asosiasi potensial sebelum benar-benar mengevaluasinya. Proses pembuatan aturan yang sebenarnya melibatkan dua fase:

- Mengidentifikasi semua itemset yang memenuhi ambang batas dukungan minimum yang ditetapkan untuk analisis
- Membuat aturan dari itemset ini yang memenuhi ambang batas keyakinan minimum yang mengidentifikasi aturan yang kuat

Tahap pertama melibatkan beberapa iterasi di mana setiap iterasi berikutnya memerlukan evaluasi dukungan penyimpanan sekumpulan itemset yang semakin besar. Misalnya, iterasi 1 mengevaluasi sekumpulan itemset satu-item (one-itemsets), iterasi 2 melibatkan evaluasi two-itemsets, dst. Hasil dari setiap iterasi N adalah sekumpulan semua N -

itemset yang memenuhi ambang batas dukungan minimum. Biasanya, semua itemset dari iterasi N digabungkan untuk menghasilkan itemset kandidat untuk evaluasi dalam iterasi $N + 1$, tetapi dengan menerapkan prinsip Apriori, kita dapat menghilangkan beberapa di antaranya bahkan sebelum iterasi berikutnya dimulai. Jika $\{X\}$, $\{Y\}$, dan $\{Z\}$ sering muncul dalam iterasi 1 sementara $\{W\}$ tidak sering muncul, maka iterasi 2 hanya akan mempertimbangkan $\{X, Y\}$, $\{X, Z\}$, dan $\{Y, Z\}$. Kita dapat melihat bahwa algoritme hanya perlu mengevaluasi tiga itemset daripada enam yang akan dievaluasi jika set yang berisi W tidak dihilangkan oleh apriori.

Dengan melanjutkan iterasi, mari kita asumsikan bahwa selama iterasi 2, ditemukan bahwa $\{X, Y\}$ dan $\{Y, Z\}$ sering muncul, tetapi $\{X, Z\}$ tidak. Meskipun iterasi 3 biasanya dimulai dengan mengevaluasi dukungan untuk $\{X, Y, Z\}$, langkah ini tidak perlu terjadi sama sekali. Prinsip Apriori menyatakan bahwa $\{X, Y, Z\}$ tidak dapat muncul, karena subset $\{X, Z\}$ tidak sering muncul. Oleh karena itu, dalam iterasi 3, algoritme dapat berhenti karena tidak ada itemset baru yang dapat dihasilkan.

Setelah kita mengidentifikasi itemset yang memenuhi syarat untuk analisis, fase kedua dari algoritma Apriori dimulai. Untuk set itemset yang sering muncul, aturan asosiasi dibuat dari semua subset yang mungkin. Misalnya, $\{X, Y\}$ akan menghasilkan aturan kandidat untuk $\{X\} \rightarrow \{Y\}$ dan $\{Y\} \rightarrow \{X\}$. Aturan-aturan ini dievaluasi terhadap ambang batas keyakinan minimum, dan aturan apa pun yang tidak memenuhi tingkat keyakinan yang diinginkan dihilangkan, sehingga akhirnya menghasilkan set aturan yang kuat.

Meskipun prinsip Apriori digunakan secara luas dalam analisis keranjang belanja dan penerapan aturan asosiasi lainnya yang membantu dalam penemuan hubungan baru di antara objek, ada beberapa kekuatan dan kelemahan yang perlu kita ingat sebelum menggunakannya pada kumpulan data target:

Strengths	Weaknesses
• Provides reasonable accuracy while working with very large amounts of transactional data • Discovers rules that are easy to understand • Provides valuable insight into the unexpected knowledge in data sets, which is a key aspect of learning	• Not very accurate in the case the data set is small as the smaller occurrences of itemsets may not be due to chance • Some effort is involved to separate the insight from the common sense • In the case of widespread presence of random patterns, the principle can draw spurious conclusions

9.6 RINGKASAN

- Pembelajaran tanpa pengawasan adalah konsep pembelajaran mesin di mana informasi yang tidak berlabel dan tidak terklasifikasi dianalisis untuk menemukan pengetahuan tersembunyi. Algoritme bekerja pada data tanpa pelatihan sebelumnya, tetapi data tersebut dibangun sedemikian rupa sehingga dapat mengidentifikasi pola, pengelompokan, urutan penyortiran, dan banyak pengetahuan menarik lainnya dari kumpulan data.
- Pengelompokan merujuk pada serangkaian teknik luas untuk menemukan subkelompok, atau klaster, di dalam kumpulan data berdasarkan karakteristik objek di dalam kumpulan data itu sendiri sedemikian rupa sehingga objek-objek di dalam kelompok tersebut serupa (atau terkait satu sama lain) tetapi berbeda dari (atau tidak terkait dengan) objek-objek dari kelompok lain. Teknik pengelompokan utama diklasifikasikan dalam tiga kategori papan
 - Metode partisi,
 - Metode hierarkis, dan metode berbasis kepadatan.

K-means dan k-medoids adalah teknik partisi yang paling populer. Prinsip algoritma k-means adalah menetapkan setiap n titik data ke salah

satu k klaster, di mana k adalah parameter yang ditentukan pengguna sebagai jumlah klaster yang diinginkan. Tujuannya adalah untuk memaksimalkan homogenitas dalam klaster dan memaksimalkan perbedaan antar klaster. Homogenitas dan perbedaan diukur dalam hal jarak antar titik.

- *K-medoids* menganggap titik data representatif dari titik yang ada dalam kumpulan data sebagai pusat klaster. Kemudian, ia menetapkan titik data berdasarkan jaraknya dari pusat tersebut untuk membentuk klaster.
- Metode pengelompokan hierarkis digunakan untuk mengelompokkan data ke dalam hierarki atau struktur seperti pohon.

Terdapat dua metode pengelompokan hierarkis utama: pengelompokan aglomeratif dan pengelompokan divisif. Pengelompokan aglomeratif adalah teknik bottom-up yang dimulai dengan objek individual sebagai klaster dan kemudian menggabungkannya secara berulang untuk membentuk klaster yang lebih besar. Di sisi lain, metode divisif dimulai dengan satu klaster dengan semua objek yang diberikan dan kemudian membaginya secara berulang untuk membentuk klaster yang lebih kecil.

- DBSCAN merupakan salah satu pendekatan pengelompokan berbasis kepadatan yang memberikan solusi untuk mengidentifikasi kelompok dengan bentuk yang berubah-ubah. Prinsipnya didasarkan pada identifikasi area padat dan area jarang dalam kumpulan data, lalu menjalankan algoritma pengelompokan.
- Aturan asosiasi menyajikan metodologi yang berguna untuk mengidentifikasi hubungan menarik yang tersembunyi dalam kumpulan data besar. Ini juga dikenal sebagai analisis asosiasi, dan hubungan yang ditemukan dapat direpresentasikan dalam

bentuk aturan asosiasi yang terdiri dari serangkaian item yang sering muncul. • Aplikasi umum dari analisis ini adalah Analisis Keranjang Pasar yang digunakan pengecer untuk penjualan silang produk mereka.

CONTOH PERTANYAAN

SOAL PILIHAN GANDA (MASING-MASING 1 NILAI)

1. *K*-berarti algoritma pengelompokan merupakan contoh metode pengelompokan yang mana?
 1. Hirarkis
 2. Pemisahan
 3. Berdasarkan kepadatan
 4. Acak
2. Pernyataan berikut manakah yang menggambarkan perbedaan antara teknik pengelompokan aglomeratif dan divisif dengan tepat?
 1. Aglomeratif adalah teknik bottom-up, sedangkan divisif adalah teknik top-down.
 2. Aglomeratif adalah teknik top-down, sedangkan divisif adalah teknik bottom-up.
 3. Teknik aglomeratif dapat dimulai dengan satu klaster
 4. Teknik pemisahan dapat diakhiri dengan satu cluster
3. Manakah di bawah ini yang merupakan kelebihan algoritma *k*-medoids dibandingkan dengan algoritma *k*-means?
 1. keduanya sama-sama rawan kesalahan
 2. *K*-medoid dapat menangani set data yang lebih besar daripada *k*-means
 3. *K*-medoids membantu mengurangi efek outlier pada objek
 4. *K*-medoids membutuhkan lebih sedikit komputasi untuk mencapai pengelompokan akhir

- .
- 4 Prinsip yang mendasari Analisis Keranjang Pasar dikenal sebagai
 1. Aturan asosiasi
 2. Aturan pembagian dua
 3. *aku-cara*
 4. Teorema Bayes
 5. Diagram Voronoi digunakan pada jenis pengelompokan yang mana?
 1. Hirarkis
 2. Pemisahan
 3. Berdasarkan kepadatan
 4. Berdasarkan intuisi
 6. SSE dari suatu pengelompokan diukur dengan:
 1. Jumlah awal klaster yang ditetapkan
 2. Jumlah cluster yang dihasilkan
 3. Biaya pengelompokan
 4. Kualitas pengelompokan
 7. Salah satu kelemahan algoritma k-means adalah outlier dapat mengurangi kualitas pengelompokan akhir.
 1. BENAR
 2. PALSU
 8. Manakah dari berikut ini yang dapat menjadi kondisi penghentian yang memungkinkan dalam KMeans?
 1. Untuk jumlah iterasi yang tetap.
 2. Penugasan observasi ke klaster tidak berubah antar iterasi. Kecuali untuk kasus dengan minimum lokal yang buruk.
 3. Sentroide tidak berubah antara iterasi yang berurutan.
 4. Semua hal di atas

- .
9. Algoritma pengelompokan berikut, manakah yang paling sensitif terhadap outlier?
 1. Algoritma pengelompokan K-means
 2. Algoritma pengelompokan K-median
 3. Algoritma pengelompokan K-medoid
 4. Algoritma pengelompokan K-mode
 10. Dalam situasi berikut manakah pengelompokan K-Means gagal memberikan hasil yang baik?
 1. Titik data dengan outlier
 2. Titik data dengan kepadatan berbeda
 3. Titik data dengan bentuk bulat
 4. Semua hal di atas

SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI)

1. Apa perbedaan antara pembelajaran tanpa pengawasan dengan pembelajaran dengan pengawasan? Jelaskan dengan beberapa contoh.
2. Sebutkan beberapa bidang aplikasi pembelajaran tanpa pengawasan.
3. Apa saja tiga kategori umum teknik pengelompokan? Jelaskan karakteristik masing-masing secara singkat.
4. Jelaskan bagaimana kualitas pengelompokan diukur dalam algoritma k-means?
5. Jelaskan perbedaan utama dalam pendekatan algoritma k-means dan k-medoids dengan diagram yang rapi.
6. Apa itu dendrogram? Jelaskan kegunaannya.
7. Apa itu SSE? Apa kegunaannya dalam konteks algoritma k-means?
8. Jelaskan metode k-means dengan algoritma langkah demi langkah.

9. Jelaskan konsep tautan tunggal dan tautan lengkap dalam konteks pengelompokan hierarkis.
10. Bagaimana prinsip apriori membantu mengurangi biaya perhitungan untuk analisis keranjang pasar? Berikan contoh untuk menjelaskannya.

SOAL JAWABAN PANJANG (MASING-MASING 10 NILAI)

1. Anda diberi sekumpulan titik data satu dimensi: {5, 10, 15, 20, 25, 30, 35}. Asumsikan bahwa $k = 2$ dan kumpulan pertama centroid acak dipilih sebagai {15, 32}, lalu disempurnakan dengan {12, 30}.
 1. Buat dua cluster dengan setiap set centroid yang disebutkan di atas mengikuti pendekatan k-means
 2. Hitung SSE untuk setiap set centroid
2. Jelaskan bagaimana Analisis Keranjang Pasar menggunakan konsep analisis asosiasi.
3. Jelaskan algoritma Apriori untuk pembelajaran aturan asosiasi dengan sebuah contoh.
4. Bagaimana jarak antar kluster diukur dalam pengelompokan hierarkis? Jelaskan penggunaan ukuran ini dalam membuat keputusan kapan harus menghentikan iterasi.
5. Bagaimana cara menghitung ulang sentroid kluster dalam algoritma k-means?
6. Diskusikan satu teknik untuk memilih jumlah kluster yang tepat pada awal latihan pengelompokan.
7. Diskusikan kekuatan dan kelemahan algoritma k-means.
8. Jelaskan konsep pengelompokan dengan diagram yang rapi.
9. Selama penelitian, Anda menemukan 7 observasi seperti yang dijelaskan dengan titik data di bawah ini. Anda ingin membuat 3

klaster dari observasi ini menggunakan algoritma K-means. Setelah iterasi pertama, klaster C1, C2, C3 memiliki observasi berikut:

Nomor 1: $\{(2,2), (4,4), (6,6)\}$

C2: $\{(0,4), (4,0)\}$

C3: $\{(5,5), (9,9)\}$

Jika Anda ingin menjalankan iterasi kedua, berapakah centroid klasternya? Berapa SSE dari pengelompokan ini?

- 10 Dalam sebuah proyek perangkat lunak, tim tersebut mencoba mengidentifikasi kesamaan cacat perangkat lunak yang diidentifikasi selama pengujian. Mereka ingin membuat 5 kelompok cacat serupa berdasarkan analisis teks dari deskripsi cacat tersebut. Setelah 5 kelompok cacat diidentifikasi, setiap cacat baru yang dibuat harus diklasifikasikan sebagai salah satu jenis yang diidentifikasi melalui pengelompokan. Jelaskan pendekatan ini melalui diagram yang rapi. Asumsikan 20 titik data Cacat yang dikelompokkan di antara 5 kelompok dan algoritma k-means digunakan.

Bab 10 Dasar-dasar Jaringan Syaraf Tiruan

Yuliana, M.Cs.

A.Tujuan Pembelajaran

Dalam 9 bab terakhir, Anda telah diperkenalkan dengan konsep pembelajaran mesin secara sangat rinci. Anda mulai dengan cara memutuskan apakah suatu masalah dapat dipecahkan dengan pembelajaran mesin, dan setelah Anda membuat keputusan itu, Anda belajar cara memulai dengan pemodelan masalah dalam paradigma pembelajaran mesin. Dalam konteks itu, Anda diperkenalkan dengan tiga jenis pembelajaran mesin – terbimbing, tak terbimbing, dan penguatan. Kemudian, Anda menjelajahi semua algoritme populer yang berbeda dari pembelajaran terbimbing dan tak terbimbing. Sekarang, Anda telah memperoleh cukup banyak latar belakang tentang dasar-dasar pembelajaran mesin, dan inilah saatnya bagi Anda untuk diperkenalkan dengan konsep jaringan saraf.

10.1 PENDAHULUAN

Dalam bab-bab sebelumnya, kita perlahan-lahan mengungkap misteri pembelajaran mesin, yaitu bagaimana mesin belajar untuk melakukan tugas dan meningkatkannya seiring waktu dari pengalaman, dengan bimbingan ahli atau dengan sendirinya. Pembelajaran mesin, seperti yang telah kita lihat, meniru bentuk pembelajaran manusia. Di sisi lain, pembelajaran manusia, atau dalam hal ini setiap tindakan manusia, dikendalikan oleh sistem saraf. Pada setiap manusia, sistem saraf mengoordinasikan berbagai tindakan dengan mengirimkan sinyal ke dan dari berbagai bagian tubuh. Sistem saraf tersusun dari jenis sel khusus,

yang disebut neuron atau sel saraf, yang memiliki struktur khusus yang memungkinkannya menerima atau mengirim sinyal ke neuron lain. Neuron terhubung satu sama lain untuk mengirimkan sinyal ke atau menerima sinyal dari neuron lain. Struktur ini pada dasarnya membentuk jaringan neuron atau jaringan saraf.

Berdasarkan miliaran neuron yang terhubung yang dimilikinya, jaringan saraf biologis merupakan jaringan komputasi paralel yang sangat besar dan kompleks. Berkat jaringan komputasi paralel yang sangat besar inilah sistem saraf membantu manusia untuk melakukan tindakan atau mengambil keputusan dengan kecepatan dan kemudahan yang membuat superkomputer tercepat di dunia pun akan iri. Misalnya, mari kita pikirkan tangkapan terbang yang luar biasa yang dilakukan oleh para pemain bertahan dalam piala dunia kriket. Kombinasi perhitungan yang unggul berdasarkan pengalaman kriket sebelumnya, pemahaman tentang kondisi lapangan setempat, dan antisipasi seberapa keras bola dipukul membuat pemain bertahan mengambil keputusan tentang kapan harus melompat, ke mana harus melompat, dan seberapa jauh harus melompat. Ini adalah tugas yang sangat kompleks, dan Anda mungkin berpikir bahwa tidak setiap manusia cukup terampil untuk melakukan tindakan ajaib seperti itu. Dalam hal ini, mari kita pikirkan sesuatu yang jauh lebih sederhana. Mari kita pertimbangkan tentang aktivitas sehari-hari yang sangat sederhana, yaitu berenang di kolam renang. Tampaknya, berenang mungkin terlihat sangat sepele, tetapi pikirkan tentang tindakan dan keputusan paralel yang perlu diambil untuk berenang. Diperlukan kombinasi yang tepat antara posisi tubuh, gerakan anggota tubuh, tarikan/keluarkan napas, dll. untuk berenang. Yang menambah tantangan adalah fakta bahwa air beberapa ratus kali lebih padat daripada udara. Jadi, mengarahkan gerakan tubuh dalam perbedaan skala itu merupakan hal yang sulit. Mengkoordinasikan tindakan dan mengambil keputusan untuk tugas yang

rumit seperti itu, yang mungkin tampak sepele, dimungkinkan karena jaringan kompleks paralel yang masif, yaitu jaringan saraf.

Kemampuan jaringan saraf biologis yang mengagumkan telah mengilhami lahirnya jaringan saraf buatan (ANN). ANN terdiri dari neuron buatan. Dalam bentuk yang paling umum, ANN adalah mesin yang dirancang untuk memodelkan fungsi sistem saraf atau, lebih khusus lagi, neuron. Satu-satunya perbedaan adalah bahwa bentuk biologis neuron direplikasi dalam bentuk elektronik atau digital neuron. Neuron digital atau neuron buatan membentuk unit pemrosesan terkecil dari ANN. Saat kita melanjutkan, mari kita menyelami lebih dalam struktur neuron biologis terlebih dahulu dan kemudian mencoba melihat bagaimana hal itu telah dimodelkan dalam neuron buatan.

10.2 MEMAHAMI NEURON BIOLOGIS


Sistem saraf manusia memiliki dua bagian utama – sistem saraf pusat (SSP) yang terdiri dari otak dan sumsum tulang belakang sistem saraf tepi yang terdiri dari saraf dan ganglia di luar otak dan sumsum tulang belakang.

Sistem saraf pusat mengintegrasikan semua informasi, dalam bentuk sinyal, dari berbagai bagian tubuh. Di sisi lain, sistem saraf tepi menghubungkan sistem saraf pusat dengan anggota tubuh dan organ. Neuron merupakan unit struktural dasar dari sistem saraf pusat. Neuron mampu menerima, memproses, dan mengirimkan informasi dalam bentuk sinyal kimia dan listrik. Gambar 10.1 menyajikan struktur neuron. Neuron memiliki tiga bagian utama untuk menjalankan fungsi utamanya, yaitu menerima dan mengirimkan informasi:

1. **Dendrit**– untuk menerima sinyal dari neuron tetangga.

2. **Soma**– badan utama neuron yang mengumpulkan sinyal yang datang dari berbagai dendrit. Ia 'menyala' ketika jumlah sinyal yang terkumpul mencukupi.
3. **Akson**– bagian terakhir neuron yang menerima sinyal dari soma, setelah neuron 'aktif', dan meneruskannya ke neuron tetangga melalui terminal akson (ke dendrit yang berdekatan dari neuron tetangga).

Terdapat celah yang sangat kecil antara terminal akson dari satu neuron dan dendrit yang berdekatan dari neuron tetangga. Celah kecil ini dikenal sebagai sinaps. Sinyal yang ditransmisikan melalui sinaps dapat bersifat eksitatori atau inhibitori.



GAMBAR 10.1 Struktur neuron biologis

10.3 MENJELAJAHI NEURON BUATAN

Jaringan saraf biologis telah dimodelkan dalam bentuk ANN dengan neuron buatan yang mensimulasikan fungsi neuron biologis. Seperti yang digambarkan dalam [Gambar 10.2](#), sinyal input x_i ($x_1, x_2, \dots, x_n$) masuk ke neuron buatan. Setiap neuron memiliki tiga komponen utama:

1. Seperangkat sinapsis 'i' yang memiliki bobot w_i . Sinyal x_i membentuk masukan ke sinapsis ke- i yang memiliki bobot w_i . Nilai bobot w_i bisa positif atau negatif. Bobot positif memiliki efek eksitatori, sedangkan

bobot negatif memiliki efek inhibisi pada keluaran dari simpulan penjumlahan, y_{sum} .


2. Persambungan penjumlahan untuk sinyal masukan diberi bobot berdasarkan bobot sinaptik masing-masing. Karena merupakan penggabung atau penjumlah linier dari sinyal masukan yang diberi bobot, keluaran dari persambungan penjumlahan, y_{sum} , dapat dinyatakan sebagai berikut:

$$y_{\text{sum}} = \sum_{i=1}^n w_i x_i$$

[Catatan: Biasanya, jaringan saraf juga menyertakan bias yang menyesuaikan input fungsi aktivasi. Namun, demi kesederhanaan, kami mengabaikan bias untuk sementara waktu. Dalam kasus bias 'b', nilai y_{sum} akan menjadi sebagai berikut:

$$y_{\text{sum}} = b + \sum_{i=1}^n w_i x_i$$

3. Fungsi aktivasi ambang batas (atau fungsi aktivasi sederhana, juga disebut fungsi squashing) menghasilkan sinyal keluaran hanya ketika sinyal masukan yang melampaui nilai ambang batas tertentu muncul sebagai masukan. Perilakunya mirip dengan neuron biologis yang mengirimkan sinyal hanya ketika total sinyal masukan memenuhi ambang batas pengaktifan.



GAMBAR 10.2Struktur neuron buatan

Output dari fungsi aktivasi, y_{out} , dapat dinyatakan sebagai berikut:

$$y_{out} = f(y_{sum})$$

10.4 JENIS FUNGSI AKTIVASI

Ada berbagai jenis fungsi aktivasi. Fungsi aktivasi yang paling umum digunakan disorot di bawah ini.

10.4.1 Fungsi identitas

Fungsi identitas digunakan sebagai fungsi aktivasi untuk lapisan input. Ini adalah fungsi linier yang memiliki bentuk


$$y_{out} = f(x) = x, \text{ for all } x$$

Seperti yang terlihat, outputnya tetap sama dengan inputnya.

10.4.2 Fungsi ambang batas/langkah

Fungsi langkah/ambang batas adalah fungsi aktivasi yang umum digunakan. Seperti yang digambarkan pada Gambar 10.3a, fungsi langkah memberikan 1 sebagai output jika inputnya 0 atau positif. Jika inputnya negatif, fungsi langkah memberikan 0 sebagai output. Secara matematis,

$$y_{out} = f(y_{sum}) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$



GAMBAR 10.3Fungsi langkah dan ambang batas

Fungsi ambang batas (digambarkan dalam [Gambar 10.3b](#)) hampir seperti fungsi langkah, dengan satu-satunya perbedaan adalah fakta bahwa θ digunakan sebagai nilai ambang batas, bukan 0. Jika diungkapkan secara matematis,


$$y_{\text{out}} = f(y_{\text{sum}}) = \begin{cases} 1, & x \geq \theta \\ 0, & x < \theta \end{cases}$$

10.4.3 Fungsi ReLU (Rectified Linear Unit)

ReLU adalah fungsi aktivasi yang paling populer digunakan di bidang jaringan saraf konvolusional dan pembelajaran mendalam. Bentuknya

$$f(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Ini berarti bahwa $f(x)$ bernilai nol ketika x kurang dari nol dan $f(x)$ sama dengan x ketika x di atas atau sama dengan nol. [Gambar 10.4](#) menggambarkan kurva untuk fungsi aktivasi ReLU.



GAMBAR 10.4 fungsi ReLU

Fungsi ini dapat dibedakan, kecuali pada satu titik $x = 0$. Dalam pengertian itu, turunan ReLU sebenarnya merupakan subturunan.

10.4.4 Fungsi sigmoid

Fungsi sigmoid, digambarkan dalam Gambar 10.5, sejauh ini merupakan fungsi aktivasi yang paling umum digunakan dalam jaringan saraf. Kebutuhan akan fungsi sigmoid berasal dari fakta bahwa banyak algoritma pembelajaran mengharuskan fungsi aktivasi bersifat diferensiabel dan karenanya kontinu. Fungsi langkah tidak cocok dalam situasi tersebut karena tidak kontinu. Ada dua jenis fungsi sigmoid:


1. Fungsi sigmoid biner
2. Fungsi sigmoid bipolar

10.4.4.1 Fungsi sigmoid biner

Fungsi sigmoid biner, digambarkan dalam Gambar 10.5a, berbentuk

$$y_{\text{out}} = f(x) = \frac{1}{1 + e^{-kx}}$$

di mana k = parameter kecuraman atau kemiringan sigmoid fungsi. Dengan memvariasikan nilai k , fungsi sigmoid dengan kemiringan yang berbeda dapat diperoleh. Fungsi ini memiliki rentang $(0, 1)$.



GAMBAR 10.5Fungsi sigmoid

Kemiringan pada titik asal adalah $k/4$. Ketika nilai k menjadi sangat besar, fungsi sigmoid menjadi fungsi ambang batas.

10.4.4.2 Fungsi sigmoid bipolar

Fungsi sigmoid bipolar, digambarkan dalam Gambar 10.5b, berbentuk

$$y_{\text{out}} = f(x) = \frac{1 - e^{-kx}}{1 + e^{-kx}}$$

Rentang nilai fungsi sigmoid dapat bervariasi tergantung pada aplikasinya. Namun, rentang $(-1, +1)$ adalah yang paling umum digunakan.

10.4.5 Fungsi tangen hiperbolik

Fungsi tangen hiperbolik adalah fungsi aktivasi kontinu lainnya, yang bersifat bipolar. Fungsi ini merupakan fungsi aktivasi yang diadopsi secara luas untuk jenis jaringan saraf khusus yang dikenal sebagai jaringan backpropagation (dibahas secara terperinci di Bagian 10.8) Fungsi tangen hiperbolik berbentuk

$$y_{\text{out}} = f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Fungsi ini mirip dengan fungsi sigmoid bipolar.

Perhatikan bahwa semua fungsi aktivasi yang didefinisikan dalam Bagian 10.4.2 dan 10.4.4 memiliki nilai yang berkisar antara 0 dan 1. Namun, dalam beberapa kasus, sebaiknya memiliki nilai yang berkisar antara -1 hingga $+1$. Dalam kasus tersebut, fungsi aktivasi perlu dibingkai ulang. Misalnya, dalam kasus fungsi langkah, definisi yang direvisi akan menjadi sebagai berikut:


$$y_{\text{out}} = f(y_{\text{sum}}) = \begin{cases} 1, & x > 0 \\ 0, & x = 0 \\ -1, & x < 0 \end{cases}$$

10.5 IMPLEMENTASI AWAL ANN

10.5.1 Model neuron McCulloch–Pitts

Model saraf McCulloch–Pitts (digambarkan dalam Gambar 10.6), yang merupakan model ANN paling awal, hanya memiliki dua jenis masukan – eksitatori dan inhibitori. Masukan eksitatori memiliki bobot besaran positif dan bobot inhibitori memiliki bobot besaran negatif. Masukan neuron McCulloch–Pitts bisa berupa 0 atau 1. Ia memiliki fungsi ambang sebagai fungsi aktivasi. Jadi, sinyal keluaran y_{out} adalah 1 jika jumlah masukan lebih besar dari atau sama dengan nilai ambang tertentu, jika tidak 0.

Neuron McCulloch–Pitts sederhana dapat digunakan untuk merancang operasi logis. Untuk tujuan tersebut, bobot koneksi perlu diputuskan dengan benar beserta fungsi ambang batas (lebih tepatnya nilai ambang batas fungsi aktivasi). Mari kita ambil contoh kecil.



GAMBAR 10.6neuron McCulloch–Pitts


John membawa payung jika cuaca cerah atau hujan. Ada empat situasi yang diberikan. Kita perlu memutuskan kapan John akan membawa payung. Situasinya adalah sebagai berikut:

- Situasi 1 – Tidak hujan dan tidak cerah.
- Situasi 2 – Tidak hujan, tetapi cerah.
- Situasi 3 – Hujan turun, dan cuaca tidak cerah.
- Situasi 4 – Wah, aneh sekali! Hujan turun sekaligus cerah.

Untuk menganalisis situasi menggunakan model saraf McCulloch–Pitts, kita dapat mempertimbangkan sinyal masukan sebagai berikut:

- $x_1 \rightarrow$ Apakah hujan?
- $x_2 \rightarrow$ Apakah cuaca cerah?

Jadi, nilai x_1 dan x_2 bisa berupa 0 atau 1. Kita dapat menggunakan nilai bobot x_1 dan x_2 sebagai 1 dan nilai ambang fungsi aktivasi sebagai 1. Jadi, model saraf akan terlihat seperti Gambar 10.7A.



GAMBAR 10.7 Model saraf McCulloch–Pitts (ilustrasi)

Secara formal, kita dapat mengatakan,

$$y_{sum} = \sum_{i=1}^2 w_i x_i$$

$$y_{out} = f(y_{sum}) = \begin{cases} 1, & x \geq 1 \\ 0, & x < 1 \end{cases}$$

Tabel kebenaran yang dibangun sehubungan dengan masalah tersebut digambarkan dalam Gambar 10.7b. Dari tabel kebenaran, kita dapat menyimpulkan bahwa dalam situasi di mana nilai y_{out} adalah 1,

John perlu membawa payung. Oleh karena itu, ia perlu membawa payung dalam situasi 2, 3, dan 4. Terkejut, karena ini tampak seperti masalah logika umum yang terkait dengan fungsi 'OR'? Jangan khawatir, ini benar-benar implementasi logika OR menggunakan model saraf McCulloch–Pitts.

10.5.2 Perseptron Rosenblatt

Perseptron Rosenblatt dibangun berdasarkan model saraf McCulloch–Pitts. Perseptron, seperti yang digambarkan dalam [Gambar 10.7](#), menerima sekumpulan input $x_1, x_2, \dots, x_n$. Penggabung linier atau simpul penjumlah menghitung kombinasi linier dari input yang diterapkan pada sinapsis dengan bobot sinapsis menjadi $w_1, w_2, \dots, w_n$. Kemudian, pembatas keras memeriksa apakah jumlah yang dihasilkan positif atau negatif. Jika input simpul pembatas keras positif, outputnya adalah +1, dan jika inputnya negatif, outputnya adalah -1. Secara matematis, input pembatas keras adalah

$$v = \sum_{i=1}^n w_i x_i$$

Namun, perceptron menyertakan nilai atau bias yang dapat disesuaikan sebagai bobot tambahan w_0 . Bobot tambahan w_0 ini dilampirkan ke input tiruan x_0 , yang selalu diberi nilai 1. Pertimbangan ini mengubah persamaan di atas menjadi

$$v = \sum_{i=0}^n w_i x_i$$


Output ditentukan oleh ekspresi

$$y_{\text{out}} = f(v) = \begin{cases} +1, & v > 0 \\ -1, & v < 0 \end{cases}$$

Tujuan dari perceptron adalah untuk mengklasifikasikan sekumpulan input ke dalam dua kelas, c_1 dan c_2 . Hal ini dapat dilakukan dengan menggunakan aturan keputusan yang sangat sederhana – tetapkan input $x_0, x_1, x_2, \dots, x_n$ ke c_1 jika output dari perceptron, yaitu y_{out} , adalah +1

dan c_2 jika y_{out} adalah -1 . Jadi, untuk ruang sinyal n -dimensi, yaitu ruang untuk ' n ' sinyal input $x_0, x_1, x_2, \dots, x_n$, bentuk perceptron yang paling sederhana akan memiliki dua daerah keputusan, menyerupai dua kelas, yang dipisahkan oleh hiperbidang yang didefinisikan oleh

$$\sum_{i=0}^n w_i x_i = 0$$



Gambar. 10.8 Perseptron Rosenblatt

Oleh karena itu, untuk dua sinyal masukan yang dilambangkan dengan variabel x_1 dan x_2 , batas keputusan adalah garis lurus dalam bentuk

$$w_0 x_0 + w_1 x_1 + w_2 x_2 = 0$$


$$\text{or, } w_0 + w_1 x_1 + w_2 x_2 = 0 [\because x_0 = 1]$$

Jadi, untuk sebuah perceptron yang mempunyai nilai bobot sinaptik w_0, w_1 , dan w_2 masing-masing sebesar $-2, \frac{1}{2}$, dan $\frac{1}{4}$, batas keputusan linier akan berbentuk

$$-2 + \frac{1}{2}x_1 + \frac{1}{4}x_2 = 0$$

$$\text{or, } 2x_1 + x_2 = 8$$

Jadi, titik mana pun (x_1, x_2) yang terletak di atas batas keputusan, seperti yang digambarkan pada Gambar 10.9, akan ditetapkan ke kelas c_1 dan titik-titik yang terletak di bawah batas ditetapkan ke kelas c_2 .



Gambar. 10.9Batas keputusan perceptron

Mari kita periksa apakah perseptrona ini mampu mengklasifikasikan sekumpulan titik yang diberikan di bawah ini:


$p_1 = (5, 2)$ dan $p_2 = (-1, 12)$ milik c_1 $p_3 = (3, -5)$ dan $p_4 = (-2, -1)$ milik c_2

Seperti yang digambarkan dalam Gambar 10.10, kita dapat melihat bahwa berdasarkan keluaran fungsi aktivasi, hanya titik p_1 dan p_2 yang menghasilkan keluaran 1. Oleh karena itu, titik-titik tersebut ditetapkan ke kelas c_1 seperti yang diharapkan. Di sisi lain, titik p_3 dan p_4 yang memiliki keluaran fungsi aktivasi negatif menghasilkan keluaran 0. Oleh karena itu, titik-titik tersebut ditetapkan ke kelas c_2 , seperti yang diharapkan.

point	$v = \sum w_i x_i$	$y_{out} = f(v)$	Class
p_1	$-2 + (\frac{1}{2}) * 5 + (\frac{1}{4}) * 2 = 1$	1	c_1
p_2	$-2 + (\frac{1}{2}) * (-1) + (\frac{1}{4}) * 12 = 0.5$	1	c_1
p_3	$-2 + (\frac{1}{2}) * 3 + (\frac{1}{4}) * (-5) = -1.75$	0	c_2
p_4	$-2 + (\frac{1}{2}) * (-2) + (\frac{1}{4}) * (-1) = -3.25$	0	c_2

GAMBAR 10.10Penugasan kelas melalui perceptron


Klasifikasi yang sama diperoleh dengan memetakan titik-titik di ruang input, seperti yang ditunjukkan pada Gambar 10.11.



Gambar 10.11 Klasifikasi berdasarkan batas keputusan

Dengan demikian, kita dapat melihat bahwa untuk kumpulan data dengan kelas-kelas yang dapat dipisahkan secara linear, perseptron selalu dapat digunakan untuk memecahkan masalah klasifikasi menggunakan garis keputusan (untuk ruang dua dimensi), bidang keputusan (untuk ruang tiga dimensi), atau hiperbidang keputusan (untuk ruang n -dimensi).

Nilai bobot sinaptik $w_0, w_1, w_2, \dots, w_n$ yang sesuai dapat diperoleh dengan melatih sebuah perseptron. Namun, satu asumsi agar perseptron berfungsi dengan baik adalah bahwa kedua kelas tersebut harus dapat dipisahkan secara linier (seperti yang digambarkan dalam Gambar 10.12a), yaitu kelas-kelas harus dipisahkan satu sama lain dengan cukup baik. Jika tidak, jika kelas-kelas tersebut tidak dapat dipisahkan secara linier (seperti yang digambarkan dalam Gambar 10.12b), maka masalah klasifikasi tidak dapat diselesaikan oleh perseptron.




Gambar. 10.12Keterpisahan kelas

10.5.2.1 Perceptron multilapis

Perseptron dasar bekerja dengan sangat baik untuk kumpulan data yang memiliki pola yang dapat dipisahkan secara linier. Namun, dalam situasi praktis, itu adalah situasi yang ideal. Inilah inti yang ditekankan oleh Minsky dan Papert dalam karya mereka (1969). Mereka menunjukkan bahwa perseptron dasar tidak dapat belajar menghitung bahkan XOR 2-bit yang sederhana. Mengapa demikian? Mari kita coba memahaminya.


Gambar 10.13 adalah tabel kebenaran yang menyoroti keluaran fungsi XOR 2-bit.



GAMBAR 10.13Pemisahan kelas dari keluaran fungsi XOR

Seperti yang bisa kita lihat di Gambar 10.13, data tidak dapat dipisahkan secara linear. Hanya batas keputusan yang melengkung yang dapat memisahkan kelas dengan baik.

Untuk mengatasi masalah ini, pilihan lainnya adalah menggunakan dua garis keputusan, bukan satu. Gambar 10.14 menunjukkan bagaimana batas keputusan linear dengan dua garis keputusan dapat membagi data dengan jelas.



GAMBAR 10.14 Klasifikasi dengan dua garis keputusan dalam keluaran fungsi XOR

Inilah filosofi yang digunakan untuk merancang model multi-layer perceptron. Berikut ini adalah beberapa hal penting dari model ini:


- Jaringan saraf berisi satu atau lebih lapisan perantara antara simpul masukan dan simpul keluaran, yang tersembunyi dari simpul masukan maupun keluaran.
- Setiap neuron dalam jaringan memiliki fungsi aktivasi non-linier yang dapat dibedakan.
- Neuron pada setiap lapisan terhubung dengan beberapa atau semua neuron pada lapisan sebelumnya.

Diagram di Gambar 10.15 menyerupai perceptron multilapis yang terhubung penuh dengan beberapa lapisan tersembunyi di antara lapisan


masukan dan keluaran. Disebut terhubung penuh karena setiap neuron di setiap lapisan perceptron terhubung dengan semua neuron (atau simpul masukan dalam kasus lapisan tersembunyi pertama) di lapisan sebelumnya. Sinyal mengalir dari satu lapisan ke lapisan lain dari kiri ke kanan.

10.5.3 Model jaringan ADALINE

Adaptive Linear Neural Element (ADALINE) merupakan ANN lapis tunggal awal yang dikembangkan oleh Profesor Bernard Widrow dari Universitas Stanford. Seperti yang digambarkan pada Gambar 10.16, ia hanya memiliki neuron keluaran. Nilai keluarannya bisa $+1$ atau -1 . Masukan bias x_0 (di mana $x_0 = 1$) yang memiliki bobot w_0 ditambahkan. Fungsi aktivasinya sedemikian rupa sehingga jika jumlah bobotnya positif atau 0, maka keluarannya adalah 1, jika tidak maka -1 . Secara formal, kita dapat mengatakan,



GAMBAR 10.15 Perseptron multi-lapis



GAMBAR 10.16Jaringan ADALINE

Algoritma pembelajaran terawasi yang diadopsi oleh jaringan ADALINE dikenal sebagai Least Mean Square (LMS) atau aturan Delta.

Jaringan yang menggabungkan sejumlah ADALINE disebut sebagai MADALINE (banyak ADALINE). Jaringan MADALINE dapat digunakan untuk memecahkan masalah yang terkait dengan pemisahan nonlinier.

10.6 ARSITEKTUR JARINGAN SYARAF

Seperti yang telah kita lihat sejauh ini, ANN adalah sistem komputasi yang terdiri dari sejumlah besar unit yang saling terhubung yang disebut neuron buatan. Koneksi antara neuron buatan dapat mengirimkan sinyal dari satu neuron ke neuron lainnya. Ada beberapa kemungkinan untuk menghubungkan neuron berdasarkan arsitektur mana yang akan kita adopsi untuk solusi tertentu. Beberapa pilihan tercantum di bawah ini:

- Mungkin hanya ada dua lapisan neuron dalam jaringan – lapisan masukan dan keluaran.

- Selain lapisan masukan dan keluaran, mungkin ada satu atau lebih lapisan neuron 'tersembunyi' perantara.
- Neuron dapat dihubungkan dengan satu atau lebih neuron di lapisan berikutnya.
- Neuron-neuron tersebut dapat dihubungkan dengan semua neuron di lapisan berikutnya.
- Mungkin ada satu atau beberapa sinyal keluaran.
- Jika ada beberapa sinyal keluaran, sinyal-sinyal tersebut mungkin saling terhubung.

Keluaran dari satu lapisan dapat menjadi masukan bagi neuron di lapisan yang sama atau sebelumnya.


10.6.1 Jaringan umpan maju satu lapis

Single-layer feed forward merupakan arsitektur ANN yang paling sederhana dan paling dasar. Arsitektur ini hanya terdiri dari dua lapisan seperti yang digambarkan pada Gambar 10.17– lapisan masukan dan lapisan keluaran. Lapisan masukan terdiri dari sekumpulan neuron masukan 'm' $X_1, X_2, \dots, X_m$ terhubung ke masing-masing neuron keluaran 'n' $Y_1, Y_2, \dots, Y_n$. Koneksi tersebut membawa bobot $w_{11}, w_{12}, \dots, w_{mn}$. Lapisan masukan neuron tidak melakukan pemrosesan apa pun – mereka meneruskan sinyal masukan ke neuron keluaran. Perhitungan hanya dilakukan oleh neuron di lapisan keluaran. Jadi, meskipun memiliki dua lapisan neuron, hanya satu lapisan yang melakukan perhitungan. Inilah alasan mengapa jaringan tersebut dikenal sebagai lapisan tunggal meskipun memiliki dua lapisan neuron. Selain itu, sinyal selalu mengalir dari lapisan masukan ke lapisan keluaran. Oleh karena itu, jaringan ini dikenal sebagai umpan maju.

Sinyal masukan bersih ke neuron keluaran diberikan oleh

$$y_{in_k} + x_1w_{1k} + x_2w_{2k} + \dots + x_mw_{mk} = \sum_{i=1}^m x_iw_{ik},$$


untuk neuron keluaran ke-k. Sinyal keluaran dari setiap neuron neuron keluaran akan bergantung pada fungsi aktivasi yang digunakan.



Gambar. 10.17Umpan maju satu lapis

10.6.2 Jaringan ANN umpan maju multi-lapis

Jaringan umpan maju berlapis-lapis cukup mirip dengan jaringan umpan maju berlapis-tunggal, kecuali fakta bahwa ada satu atau lebih lapisan neuron antara lapisan masukan dan lapisan keluaran. Oleh karena itu, jaringan ini disebut sebagai berlapis-lapis. Struktur jaringan ini digambarkan dalam [Gambar 10.18](#).



Gambar. 10.18Umpan maju multi-lapis

Setiap lapisan mungkin memiliki jumlah neuron yang berbeda-beda. Misalnya, yang ditunjukkan pada Gambar 10.18 memiliki 'm' neuron di lapisan masukan dan 'r' neuron di lapisan keluaran, dan hanya ada satu lapisan tersembunyi dengan 'n' neuron.

Sinyal masukan bersih ke neuron di lapisan tersembunyi diberikan oleh

$$y_{in_k} = x_1 w_{1k} + x_2 w_{2k} + \dots + x_m w_{mk} = \sum_{i=1}^m x_i w_{ik},$$

untuk neuron lapisan tersembunyi ke-k. Sinyal masukan bersih ke neuron di lapisan keluaran diberikan oleh


$$z_{in_k} = y_{out_1} w'_{1k} + y_{out_2} w'_{2k} + \dots + y_{out_n} w'_{nk} = \sum_{i=1}^n y_{out_i} w'_{ik},$$

untuk neuron lapisan keluaran ke-k.

10.6.3 Jaringan kompetitif

Jaringan kompetitif memiliki struktur yang hampir sama dengan jaringan umpan maju satu lapis. Satu-satunya perbedaan adalah neuron

keluaran saling terhubung (baik sebagian maupun seluruhnya). Gambar 10.19 menggambarkan jaringan kompetitif yang terhubung sepenuhnya.




Gambar. 10.19Jaringan kompetitif

Dalam jaringan kompetitif, untuk input tertentu, neuron output bersaing satu sama lain untuk merepresentasikan input tersebut. Ini merupakan bentuk algoritma pembelajaran tanpa pengawasan dalam ANN yang cocok untuk menemukan kluster dalam kumpulan data.

10.6.4 Jaringan berulang

Kita telah melihat bahwa dalam jaringan umpan maju, sinyal selalu mengalir dari lapisan masukan menuju lapisan keluaran (melalui lapisan tersembunyi dalam kasus jaringan umpan maju multilapis), yaitu dalam satu arah. Dalam kasus jaringan saraf berulang, terdapat penyimpangan kecil. Terdapat loop umpan balik, seperti yang digambarkan dalam Gambar 10.20, dari neuron dalam lapisan keluaran ke neuron lapisan masukan. Mungkin juga terdapat loop-sendiri.



Gambar. 10.20 Jaringan saraf berulang

10.7 PROSES PEMBELAJARAN DI ANN

Sekarang setelah kita memiliki gagasan yang jelas tentang neuron, bagaimana mereka membentuk jaringan menggunakan arsitektur yang berbeda, apa itu fungsi aktivasi dalam neuron, dan apa saja pilihan fungsi aktivasi yang berbeda, sekarang saatnya untuk menghubungkan semua ini dengan fokus utama kita, yaitu pembelajaran. Pertama, kita perlu memahami apa itu pembelajaran dalam konteks ANN? Ada empat aspek utama yang perlu diputuskan:

1. Jumlah lapisan dalam jaringan
2. Arah aliran sinyal
3. Jumlah node di setiap lapisan
4. Nilai bobot yang dilampirkan pada setiap interkoneksi antara neuron

10.7.1 Jumlah lapisan

Seperti yang telah kita lihat sebelumnya, jaringan saraf mungkin memiliki satu lapisan atau beberapa lapisan. Dalam kasus satu lapisan, satu set neuron dalam lapisan masukan menerima sinyal, yaitu satu fitur per neuron, dari set data. Nilai fitur tersebut diubah oleh fungsi aktivasi neuron masukan. Sinyal yang diproses oleh neuron dalam lapisan masukan kemudian diteruskan ke neuron dalam lapisan keluaran. Neuron dalam lapisan keluaran menggunakan fungsi aktivasi mereka sendiri untuk menghasilkan prediksi akhir.

Jaringan yang lebih kompleks dapat dirancang dengan beberapa lapisan tersembunyi antara lapisan input dan lapisan output. Sebagian besar jaringan multi-lapis terhubung sepenuhnya.

10.7.2 Arah aliran sinyal

Dalam jaringan tertentu, yang disebut sebagai jaringan umpan maju, sinyal selalu diumpankan dalam satu arah, yaitu dari lapisan masukan menuju lapisan keluaran melalui lapisan tersembunyi, jika ada. Namun, jaringan tertentu, seperti jaringan berulang, juga memungkinkan sinyal untuk bergerak dari lapisan keluaran ke lapisan masukan.

Ini juga merupakan pertimbangan penting untuk memilih model pembelajaran yang tepat.

10.7.3 Jumlah node dalam lapisan

Dalam kasus jaringan multi-lapis, jumlah simpul di setiap lapisan dapat bervariasi. Namun, jumlah simpul atau neuron di lapisan masukan sama dengan jumlah fitur dari set data masukan. Demikian pula, jumlah simpul

keluaran akan bergantung pada kemungkinan hasil, misalnya jumlah kelas dalam kasus pembelajaran terbimbing. Jadi, jumlah simpul di setiap lapisan tersembunyi harus dipilih oleh pengguna. Jumlah simpul yang lebih banyak di lapisan tersembunyi membantu meningkatkan kinerja. Namun, terlalu banyak simpul dapat mengakibatkan overfitting serta peningkatan biaya komputasi.

10.7.4 Bobot interkoneksi antar neuron

Menentukan nilai bobot yang dikaitkan dengan setiap interkoneksi antara neuron sehingga masalah pembelajaran tertentu dapat dipecahkan dengan benar merupakan masalah yang cukup sulit. Mari kita coba memahaminya dalam konteks suatu masalah. Mari kita mundur selangkah dan melihat masalah di Bagian 10.6.2.

Kita memiliki sekumpulan titik dengan label yang diketahui seperti yang diberikan di bawah ini. Kita harus melatih model ANN menggunakan data ini, sehingga model tersebut dapat mengklasifikasikan data uji baru, misalnya p_5 (3, -2).

- $P_1 = (5, 2)$ dan $p_2 = (-1, 12)$ milik c_1
- $P_3 = (3, -5)$ dan $p_4 = (-2, -1)$ milik c_2

Ketika kita membahas masalah di Bagian 10.6.2, kita mengasumsikan nilai bobot sinaptik w_0 , w_1 , dan w_2 masing-masing adalah -2 , $\frac{1}{2}$, dan $\frac{1}{4}$. Namun, dari mana kita memperoleh nilai-nilai tersebut? Apakah kita akan memperoleh nilai bobot ini untuk setiap masalah pembelajaran yang akan kita coba selesaikan menggunakan ANN? Jawabannya adalah TIDAK.

Untuk memecahkan masalah pembelajaran menggunakan ANN, kita dapat memulai dengan serangkaian nilai untuk bobot sinaptik dan terus melakukan perubahan pada nilai-nilai tersebut dalam beberapa iterasi. Dalam kasus pembelajaran terbimbing, tujuan yang ingin dicapai adalah mengurangi jumlah kesalahan klasifikasi. Idealnya, iterasi untuk membuat

perubahan pada nilai bobot harus dilanjutkan hingga tidak ada lagi kesalahan klasifikasi. Namun, dalam praktiknya, kriteria penghentian seperti itu mungkin tidak dapat dicapai. Kriteria penghentian praktis mungkin adalah tingkat kesalahan klasifikasi kurang dari nilai ambang tertentu, misalnya 1%, atau jumlah maksimum iterasi mencapai ambang batas, misalnya 25, dst. Mungkin ada tantangan praktis lain yang harus dihadapi, seperti tingkat kesalahan klasifikasi yang tidak berkurang secara progresif. Ini mungkin menjadi masalah yang lebih besar ketika jumlah interkoneksi dan karenanya jumlah bobot terus meningkat. Ada cara untuk menghadapi tantangan tersebut, yang akan kita lihat lebih detail di bagian berikutnya. Jadi, untuk merangkum, proses pembelajaran menggunakan ANN merupakan gabungan dari beberapa aspek – yang meliputi penentuan jumlah lapisan tersembunyi, jumlah node dalam setiap lapisan tersembunyi, arah aliran sinyal, dan yang terakhir namun tidak kalah pentingnya, penentuan bobot koneksi.

Jaringan umpan maju multi-lapis merupakan arsitektur yang umum diadopsi. Telah diamati bahwa jaringan saraf dengan satu lapisan tersembunyi pun dapat digunakan untuk memperkirakan fungsi kontinu apa pun secara wajar. Metode pembelajaran yang diadopsi untuk melatih jaringan umpan maju multi-lapis disebut sebagai backpropagation, yang akan kita pelajari di bagian berikutnya.

10.8 PROPAGASI KEMBALI

Kita telah melihat bahwa salah satu aktivitas paling penting dalam melatih ANN adalah menetapkan bobot koneksi antar neuron. Ini bisa menjadi pekerjaan yang sangat intensif, terlebih lagi untuk jaringan saraf yang memiliki banyak lapisan tersembunyi atau banyak simpul dalam satu lapisan. Pada tahun 1986, ditemukan metode pelatihan ANN yang efisien. Dalam metode ini, kesalahan, yaitu perbedaan nilai keluaran dari lapisan

keluaran dan nilai yang diharapkan, disebarkan kembali dari lapisan keluaran ke lapisan sebelumnya. Oleh karena itu, algoritma yang menerapkan metode ini dikenal sebagai backpropagation, yaitu menyebarkan kesalahan ke belakang ke lapisan sebelumnya.


Algoritma backpropagation dapat diaplikasikan untuk jaringan feed forward multi-layer. Ini adalah algoritma pembelajaran terbimbing yang terus menyesuaikan bobot neuron yang terhubung dengan tujuan untuk mengurangi deviasi sinyal output dari output target. Algoritma ini terdiri dari beberapa iterasi, yang juga dikenal sebagai epoch. Setiap epoch terdiri dari dua fase ;

- Fase maju di mana sinyal mengalir dari neuron di lapisan input ke neuron di lapisan output melalui lapisan tersembunyi. Bobot interkoneksi dan fungsi aktivasi digunakan selama aliran. Di lapisan output, sinyal output dihasilkan.
- Fase mundur di mana sinyal keluaran dibandingkan dengan nilai yang diharapkan. Kesalahan yang dihitung disebarkan mundur dari keluaran ke lapisan sebelumnya. Kesalahan yang disebarkan kembali digunakan untuk menyesuaikan bobot interkoneksi antara lapisan.

Iterasi berlanjut hingga kriteria penghentian tercapai. Gambar 10.21 menggambarkan versi algoritma backpropagation yang cukup disederhanakan.

Salah satu bagian utama dari algoritma ini adalah menyesuaikan bobot interkoneksi. Hal ini dilakukan dengan menggunakan teknik yang disebut sebagai penurunan gradien. Secara sederhana, algoritma menghitung turunan parsial dari fungsi aktivasi oleh setiap bobot interkoneksi untuk mengidentifikasi 'gradien' atau tingkat perubahan bobot yang diperlukan untuk meminimalkan fungsi biaya. Oleh karena itu,

dapat dipahami bahwa fungsi aktivasi perlu dibedakan. Mari kita coba memahami hal ini secara lebih rinci.



Gambar. 10.21Algoritma backpropagation


Kita telah melihat bahwa jaringan saraf multi-lapis memiliki beberapa lapisan tersembunyi. Selama fase pembelajaran, bobot interkoneksi disesuaikan berdasarkan kesalahan yang dihasilkan oleh jaringan, yaitu perbedaan sinyal keluaran jaringan terhadap nilai yang diharapkan. Kesalahan yang dihasilkan pada lapisan keluaran disebarkan kembali ke lapisan sebelumnya. Karena kesalahan yang disebarkan ke belakang yang terjadi selama fase pembelajaran, jaringan ini juga disebut jaringan perambatan balik atau hanya jaringan perambatan balik. Salah satu jaringan perambatan balik dengan satu lapisan tersembunyi digambarkan dalam Gambar 10.22 Dalam jaringan ini, X_0 merupakan masukan bias ke lapisan tersembunyi dan Y_0 merupakan masukan bias ke lapisan keluaran.

Sinyal masukan bersih ke neuron lapisan tersembunyi diberikan oleh

$$y_{in_k} = x_0w_{0k} + x_1w_{1k} + x_2w_{2k} + \dots + x_mw_{mk} = w_{0k} + \sum_{i=1}^m x_iw_{ik},$$

untuk neuron ke-k pada lapisan tersembunyi. Jika f_y adalah fungsi aktivasi lapisan tersembunyi, maka

$$y_{out_k} = f_y(y_{in_k})$$



Gambar. 10.22Jaringan propagasi balik

Sinyal masukan bersih ke neuron lapisan keluaran diberikan oleh

$$z_{in_k} = y_0w'_{0k} + y_{out_1}w'_{1k} + y_{out_2}w'_{2k} + \dots + y_{out_n}w'_{nk} = w'_{0k} + \sum_{i=1}^n y_{out_i}w'_{ik},$$

untuk neuron ke-k di lapisan keluaran. Perhatikan bahwa masukan sinyal ke X_0 dan Y_0 diasumsikan sebagai 1. Jika f_z adalah fungsi aktivasi lapisan tersembunyi, maka

$$z_{out_k} = f_z(z_{in_k})$$

Jika t_k adalah keluaran target dari neuron keluaran ke- k , maka fungsi biaya yang didefinisikan sebagai kesalahan kuadrat dari lapisan keluaran diberikan oleh

$$\begin{aligned} E &= \frac{1}{2} \sum_{k=1}^n (t_k - z_{out_k})^2 \\ &= \frac{1}{2} \sum_{k=1}^n (t_k - f_z(z_{in_k}))^2 \end{aligned}$$

Jadi, sebagai bagian dari algoritma penurunan gradien, turunan parsial dari fungsi biaya E harus dilakukan terhadap masing-masing bobot interkoneksi w'_{01} , w'_{02} , ..., w'_{nr} . Secara matematis, hal ini dapat direpresentasikan sebagai berikut:

$$\frac{\partial E}{\partial w'_{jk}} = \frac{\partial}{\partial w'_{jk}} \left\{ \frac{1}{2} \sum_{k=1}^n (t_k - f_z(z_{in_k}))^2 \right\},$$

untuk bobot interkoneksi antara neuron ke- j di lapisan tersembunyi dan neuron ke- k di lapisan keluaran. Ini ekspresi dapat disimpulkan menjadi

$$\frac{\partial E}{\partial w'_{jk}} = -(t_k - z_{out_k}) \cdot f'_z(z_{in_k}) \cdot \frac{\partial}{\partial w'_{jk}} \left(\sum_{i=0}^n y_{out_i} \cdot w_{ik} \right),$$

$$\text{where } f'_z(z_{in_k}) = \frac{\partial}{\partial w'_{jk}} (f_z(z_{in_k}))$$

$$\text{or, } \frac{\partial E}{\partial w'_{jk}} = -(t_k - z_{out_k}) \cdot f'_z(z_{in_k}) \cdot y_{out_i}$$

Jika kita berasumsi $\delta w_k = -(t_k - z_{out_k}) \cdot f'_z(z_{in_k})$ sebagai komponen dari penyesuaian bobot yang dibutuhkan untuk bobot w_{jk} sesuai dengan neuron keluaran ke- k , maka

$$\frac{\partial E}{\partial w'_{jk}} = \delta w'_k \cdot y_{out_i}$$

Berdasarkan hal ini, bobot dan bias perlu diperbarui sebagai berikut:

$$\text{For weights: } \Delta w_{jk} = -\alpha \cdot \frac{\partial E}{\partial w'_{jk}} = -\alpha \cdot \delta w'_k \cdot y_{\text{out}_j}$$

$$\text{Hence, } w'_{jk} (\text{new}) = w'_{jk} (\text{old}) + \Delta w'_{jk}$$

$$\text{For bias: } \Delta w_{0k} = -\alpha \cdot \delta w'_k$$

$$\text{Hence, } w'_{0k} (\text{new}) = w'_{0k} (\text{old}) + \Delta w'_{0k}$$

Perhatikan bahwa ' α ' adalah laju pembelajaran jaringan saraf.

Dengan cara yang sama, kita dapat melakukan perhitungan untuk bobot interkoneksi antara lapisan input dan tersembunyi. Bobot dan bias untuk interkoneksi antara lapisan input dan tersembunyi perlu diperbarui sebagai berikut:

$$\text{For weights: } \Delta w_{ij} = -\alpha \cdot \frac{\partial E}{\partial w_{ij}} = -\alpha \cdot \delta w_j \cdot x_{\text{out}_i}$$

$$\text{Hence, } w_{ij} (\text{new}) = w_{ij} (\text{old}) + \Delta w_{ij}$$

$$\text{For bias: } \Delta w_{0j} = -\alpha \cdot \delta w_j$$

$$\text{Hence, } w_{0j} (\text{new}) = w_{0j} (\text{old}) + \Delta w_{0j}$$

10.9 PEMBELAJARAN MENDALAM

Jaringan saraf, seperti yang telah kita lihat dalam bab ini, adalah kelas algoritma pembelajaran mesin. Seperti yang telah kita lihat, ada beberapa pilihan arsitektur untuk jaringan saraf, jaringan saraf multi-lapis menjadi salah satu yang paling banyak diadopsi. Namun, dalam jaringan saraf multi-lapis, saat kita terus meningkatkan jumlah lapisan tersembunyi, komputasi menjadi sangat mahal. Melampaui dua hingga tiga lapisan menjadi sangat sulit secara komputasi. Satu-satunya cara untuk menangani komputasi yang begitu intens adalah dengan menggunakan komputasi unit pemrosesan grafis (GPU).

Bila jumlah lapisan tersembunyi lebih sedikit – paling banyak dua hingga tiga lapisan, maka itu adalah jaringan saraf normal, yang terkadang diberi nama keren 'jaringan saraf dangkal'. Namun, bila jumlah lapisannya bertambah, maka disebut sebagai jaringan saraf dalam. Salah satu jaringan saraf dalam yang paling awal memiliki tiga lapisan tersembunyi. Pembelajaran mendalam adalah istilah yang lebih kontemporer untuk jaringan saraf dalam, yaitu jaringan saraf berlapis yang memiliki lebih dari tiga lapisan. Pemahaman yang lebih rinci tentang pembelajaran mendalam berada di luar cakupan buku ini.

10.10 RINGKASAN

Jaringan syaraf tiruan (JST) terinspirasi oleh jaringan syaraf biologis. Dalam JST, bentuk biologis neuron direplikasi dalam bentuk elektronik atau digital neuron.

- Setiap neuron memiliki tiga komponen utama:
 - Satu set sinapsis yang memiliki bobot Persimpangan penjumlahan untuk sinyal masukan yang dibobot oleh bobot sinaptik masing-masing
 - Fungsi aktivasi ambang batas menghasilkan sinyal keluaran hanya ketika sinyal masukan yang melebihi nilai ambang batas tertentu muncul sebagai masukan. Berbagai jenis fungsi aktivasi meliputi:
 - ✓ Fungsi Ambang/Langkah
 - ✓ Fungsi identitas
 - ✓ fungsi ReLU
 - ✓ Fungsi sigmoid
 - ✓ Fungsi tangen hiperbolik
- Beberapa implementasi ANN sebelumnya meliputi:
 - ✓ Model Neuron McCulloch–Pitts

- ✓ Perseptron Rosenblatt
- ✓ Model Jaringan ADALINE
- Beberapa arsitektur jaringan saraf meliputi:
 - ✓ ANN umpan maju lapisan tunggal: arsitektur paling sederhana dan paling dasar yang terdiri dari lapisan masukan dan keluaran.
 - ✓ ANN umpan maju berlapis-lapis – terdapat satu atau lebih lapisan neuron perantara tersembunyi di antara lapisan masukan dan keluaran Jaringan kompetitif – mirip dengan jaringan umpan maju satu lapis. Satu-satunya perbedaan adalah bahwa neuron keluaran terhubung satu sama lain (baik sebagian maupun seluruhnya).
 - Jaringan berulang – satu atau beberapa lapis, dengan loop umpan balik dari neuron di lapisan keluaran ke neuron di lapisan masukan. Mungkin juga ada loop sendiri.

Ada empat aspek utama yang perlu diputuskan saat belajar menggunakan JST:

- Jumlah lapisan dalam jaringan
- Arah aliran sinyal
- Jumlah node di setiap lapisan

Nilai bobot yang dilampirkan pada setiap interkoneksi antara neuron Dalam algoritma backpropagation, kesalahan disebarkan kembali dari lapisan keluaran ke lapisan sebelumnya. Algoritma backpropagation berlaku untuk jaringan umpan maju multi-lapis.

- Teknik yang disebut penurunan gradien digunakan untuk menyesuaikan bobot interkoneksi antara neuron di lapisan yang berbeda.

Bila jumlah lapisan tersembunyi dalam jaringan saraf multilapis lebih dari tiga, maka disebut jaringan saraf dalam. Pembelajaran mendalam adalah istilah yang lebih kontemporer untuk jaringan saraf dalam.

CONTOH PERTANYAAN
SOAL PILIHAN GANDA

1. ANN terdiri dari ____ neuron.
 1. biologis
 2. digital
 3. logis
 4. tidak ada yang benar
2. Neuron biologis tidak terdiri dari:
 1. dendrit
 2. sinaps
 3. ikan lele
 4. akson
3. Sebuah neuron mampu ____ informasi dalam bentuk sinyal kimia dan listrik.
 1. menerima
 2. proses
 3. mengirimkan
 4. semuanya di atas
4. Persimpangan penjumlahan adalah ____ untuk sinyal masukan.
 1. pembuat token
 2. pengali
 3. penggabung linier
 4. Tidak ada yang di atas

5. Fungsi langkah memberikan __ sebagai output jika inputnya 0 atau positif.
1. angka 0
 2. -1
 3. 1
 4. Tidak ada yang di atas
6. Fungsi sigmoid biner memiliki rentang ____.
1. (-1, +1)
 2. (0, -1)
 3. (0, 1)
 4. (1, 0)
7. Fungsi sigmoid bipolar memiliki jangkauan ____.
1. (-1, +1)
 2. (0, -1)
 3. (0, 1)
 4. (1, 0)
8. Masukan dari neuron McCulloch–Pitts dapat berupa ____.
1. baik -1 atau 1
 2. baik 0 atau 1
 3. baik 0 atau -1
 4. tidak ada yang benar
9. Perseptron lapisan tunggal mampu menangani
1. data yang dapat dipisahkan secara linier
 2. data yang dapat dipisahkan secara non-linier
 3. data yang tidak dapat dipisahkan secara linier
 4. tidak ada yang benar
10. Jaringan umpan maju lapisan tunggal terdiri dari ____ lapisan.
1. dua
 2. satu

- 3. tiga
 - 4. banyak
11. Jaringan umpan maju berlapis-lapis terdiri dari ____ lapisan.
- 1. dua
 - 2. satu
 - 3. tiga
 - 4. banyak
12. Dalam jaringan kompetitif, neuron keluaran terhubung dengan ____.
- 1. satu sama lain
 - 2. neuron masukan
 - 3. sinaps
 - 4. tidak ada yang benar
13. Jaringan berulang
- 1. mirip dengan jaringan umpan maju berlapis-lapis
 - 2. mungkin memiliki loop sendiri
 - 3. memiliki umpan balik
 - 4. semuanya di atas
14. Manakah dari berikut ini merupakan aspek penting pembelajaran di ANN?
- 1. Jumlah lapisan dalam jaringan
 - 2. Jumlah node di setiap lapisan
 - 3. Bobot interkoneksi
 - 4. semuanya di atas
15. Dalam algoritma backpropagation, beberapa iterasi dikenal sebagai
- 1. derajat
 - 2. masa
 - 3. kardinalitas

- 4. tidak ada yang benar
- 16. Setiap zaman terdiri dari fase-fase – 1. maju
 - 2. ke belakang
 - 3. keduanya a dan b
 - 4. tidak ada yang benar
- 17. Jaringan saraf dalam umumnya memiliki lebih dari ____ lapisan tersembunyi.
 - 1. 1 2. 2
 - 3. 3
 - 4. tidak ada yang benar
- 18. Untuk menangani komputasi intensif pada pembelajaran mendalam, ____ diperlukan.
 - 1. komputasi paralel
 - 2. Komputasi tradisional berbasis CPU
 - 3. komputasi GPU
 - 4. tidak ada yang benar

SOAL JAWABAN SINGKAT (MASING-MASING 5 NILAI)

- 1. Apa fungsi dari simpulan penjumlahan neuron? Apa fungsi aktivasi ambang batas?
- 2. Apa itu fungsi langkah? Apa perbedaan fungsi langkah dengan fungsi ambang?
- 3. Jelaskan model neuron McCulloch–Pitts.
- 4. Jelaskan model jaringan ADALINE.
- 5. Apa kendala dari sebuah perceptron sederhana? Mengapa ia bisa gagal dengan kumpulan data dunia nyata?
- 6. Apa yang dimaksud dengan masalah linear tak terpisahkan? Apa peran lapisan tersembunyi?

7. Jelaskan masalah XOR dalam kasus perceptron sederhana.
8. Rancanglah suatu persepsi berlapis-lapis untuk mengimplementasikan $A \text{ XOR } B$.
9. Jelaskan arsitektur umpan maju satu lapis dari ANN.
10. Jelaskan arsitektur jaringan kompetitif ANN.
11. Pertimbangkan jaringan saraf multi-lapisan. Sebutkan dan jelaskan langkah-langkah dalam algoritma backpropagation yang digunakan untuk melatih jaringan.
12. Apa keuntungan dan kerugian jaringan saraf?
13. Tulis catatan singkat tentang dua hal berikut:
 1. Neuron biologis
 2. fungsi ReLU
 3. ANN umpan maju lapisan tunggal
 4. Turunan gradien
 5. Jaringan berulang

SOAL JAWABAN PANJANG (MASING-MASING 10 NILAI)

1. Jelaskan struktur neuron buatan. Bagaimana kemiripannya dengan neuron biologis? Apa saja komponen utamanya?
2. Apa saja jenis fungsi aktivasi yang umum digunakan? Jelaskan masing-masing jenisnya.
3.
 1. Jelaskan secara rinci model perceptron Rosenblatt. Bagaimana sekumpulan data dapat diklasifikasikan menggunakan perceptron sederhana?
 2. Gunakan perseptrona sederhana dengan bobot w_0 , w_1 , dan w_2 masing-masing sebagai -1 , 2 , dan 1 untuk mengklasifikasikan titik data $(3, 4)$; $(5, 2)$; $(1, -3)$; $(-8, -3)$; $(-3, 0)$.

4. Jelaskan struktur dasar dari multi-layer perceptron. Jelaskan bagaimana ia dapat menyelesaikan masalah XOR.
5. Apa itu jaringan syaraf tiruan (ANN)? Jelaskan beberapa hal penting dalam berbagai pilihan arsitektur untuk ANN.
6. Jelaskan proses pembelajaran ANN. Jelaskan, dengan contoh, tantangan dalam menetapkan bobot sinaptik untuk interkoneksi antar neuron? Bagaimana tantangan ini dapat diatasi?
7. Jelaskan secara rinci algoritma backpropagation. Apa saja keterbatasan algoritma ini?
8. Jelaskan secara rinci proses penyesuaian bobot interkoneksi dalam jaringan saraf multilapis.
9. Apa saja langkah-langkah dalam algoritma backpropagation? Mengapa jaringan saraf multi-lapis diperlukan?
10.
 1. Tulis catatan singkat tentang dua hal berikut:
 1. Neuron buatan
 2. Perseptron multi-lapis
 3. Pembelajaran mendalam
 4. Kecepatan belajar
 2. Tuliskan perbedaan antara (dua)
 1. Fungsi aktivasi vs fungsi ambang batas
 2. Fungsi langkah vs fungsi sigmoid
 3. Perceptron lapisan tunggal vs. perceptron lapisan ganda

Bab 11 PEMBELAJARAN REPRESENTASI

Rezza Anugrah Mutiarawan, S. Kom, M. Kom. / Zulfan, S.T, M.T.

A. Tujuan Pembelajaran

Pada bab-bab sebelumnya, Anda telah memperoleh pemahaman yang baik tentang algoritma pembelajaran terbimbing dan algoritma pembelajaran tak terbimbing. Pada bab ini, kita akan membahas jenis-jenis pembelajaran yang tidak dibahas pada bab-bab sebelumnya, yaitu pembelajaran representasi, pembelajaran aktif, pembelajaran berbasis contoh, aturan asosiasi, dan pembelajaran ansambel. Pada akhir bab ini, Anda akan memperoleh pengetahuan yang cukup dalam semua aspek pembelajaran dan siap untuk mulai memecahkan masalah sendiri.

11.1 PENDAHULUAN

Dalam bab ini, kita akan membahas jenis pembelajaran yang tidak dibahas dalam bab sebelumnya, yaitu pembelajaran representasi, pembelajaran aktif, pembelajaran berbasis contoh, aturan asosiasi, dan pembelajaran ansambel.

11.2 PEMBELAJARAN REPRESENTASI

Nama lain untuk pembelajaran representasi adalah pembelajaran fitur. Sementara banyak perusahaan saat ini menyimpan sejumlah besar data terkait bisnis, sebagian besar data tersebut sering kali tidak terstruktur dan tidak berlabel. Membuat label baru umumnya merupakan usaha yang memakan waktu dan mahal. Akibatnya, algoritma

pembelajaran mesin yang dapat langsung menambang struktur dari data yang tidak berlabel untuk meningkatkan kinerja bisnis dinilai cukup berharga. Pembelajaran representasi adalah salah satu jenis pembelajaran di mana ekstraksi dari keseluruhan data yang tidak berlabel terjadi menggunakan 'jaringan saraf'. Tujuan utama pembelajaran representasi (pembelajaran fitur) adalah untuk menemukan representasi data yang tepat berdasarkan fitur untuk melakukan tugas pembelajaran mesin. Pembelajaran representasi telah menjadi bidang tersendiri karena popularitasnya. Lihat **Bab 4** berjudul 'Dasar-Dasar Rekayasa Fitur' untuk memahami lebih lanjut tentang fitur dan proses pemilihan fitur. Contoh beberapa karakteristik segitiga adalah sudutnya (atau titik sudut), sisi, dan derajat sudutnya. Setiap segitiga memiliki tiga sudut dan tiga sudut. Jumlah ketiga sudut segitiga sama dengan 180° . Jenis-jenis segitiga beserta karakteristiknya diberikan di bawah ini. Pertimbangkan Anda ditugaskan untuk mengklasifikasikan/mengidentifikasi jenis segitiga (Lihat **Tabel 11.1**). Cara melakukannya adalah dengan menemukan karakteristik unik dari jenis segitiga yang diberikan sebagai masukan.

Sistemnya mungkin bekerja seperti ini ;

- **Masukan**— Gambar segitiga
- **Perwakilan**— Tiga sudut, panjang sisi.
- **Model**— Mendapatkan representasi input (sudut, panjang sisi) dan menerapkan aturan sesuai **Tabel 11.1** untuk mendeteksi jenis segitiga.

Hebat! Sekarang, kita memiliki sistem kerja representasional utama untuk mendeteksi jenis segitiga.

Apa yang terjadi ketika kita mulai memasukkan bentuk seperti persegi, persegi panjang, lingkaran, atau berbagai bentuk lainnya, bukan segitiga? Bagaimana jika gambar tersebut berisi segitiga dan lingkaran? Mendesain untuk beradaptasi dengan fitur semacam ini memerlukan


keahlian domain yang mendalam saat kita mulai bekerja dengan aplikasi dunia nyata. Pembelajaran Mendalam melangkah lebih jauh dan mempelajari/mencoba mempelajari fitur-fitur dengan sendirinya. Yang akan kita lakukan hanyalah memasukkan gambar sebagai input dan membiarkan sistem mempelajari fitur-fitur seperti yang dilakukan manusia.

Pembelajaran representasi paling banyak digunakan dalam kata-kata, pengenalan ucapan, pemrosesan sinyal, musik, dan identifikasi gambar. Misalnya, sebuah kata dapat memiliki makna berdasarkan konteksnya.

Tabel 11.1Jenis Segitiga

S. No	Types of triangle	Characteristics
1	Acute triangle	A triangle in which all three angles are less than 90°
2	Obtuse triangle	An obtuse triangle is a triangle in which one of the angles is greater than 90°.
3	Right triangle	A right triangle is triangle with an angle of 90°.
4	Scalene triangle	A triangle with three unequal sides.
5	Isosceles triangle	An isosceles triangle is a triangle with (at least) two equal sides.
6	Equilateral triangle	An equilateral triangle is a triangle with all three sides of equal length.
7	Equiangular triangle	An equiangular triangle is a triangle, which has three equal angles.

Generation and Recognition in Representation Learning



GAMBAR 11.1Generasi versus pengakuan

Di dalam Gambar 11.1, V merupakan data input, dan H merupakan penyebab. Ketika penyebab (H) menjelaskan data (V) yang kita amati, maka hal ini disebut sebagai Pengenalan. Ketika penyebab yang tidak

diketahui (H) digabungkan, maka hal ini juga dapat menghasilkan data (V), hal ini disebut sebagai Generatif (atau) Generasi.

Pembelajaran representasi terinspirasi oleh fakta bahwa tugas pembelajaran mesin seperti klasifikasi secara teratur memerlukan masukan numerik yang secara matematis dan komputasi mudah diproses. Namun, sulit untuk menentukan fitur secara algoritmik untuk objek dunia nyata seperti gambar dan video. Alternatifnya adalah menemukan fitur atau representasi tersebut hanya melalui pemeriksaan, tanpa mengandalkan algoritme eksplisit. Jadi, pembelajaran representasi dapat dilakukan dengan pengawasan atau tanpa pengawasan.

1. Jaringan saraf terbimbing dan perseptor multilayer
2. Analisis komponen independen (tanpa pengawasan)
3. Autoencoder (tanpa pengawasan) dan
3. Berbagai bentuk pengelompokan.


11.2.1 Jaringan saraf terbimbing dan multilayer perceptron

Merujuk ke Bab 10 berjudul 'Dasar-dasar Jaringan Saraf' untuk memahami lebih lanjut tentang topik jaringan saraf.

11.2.2 Analisis komponen independen (Tanpa pengawasan)

Analisis komponen independen, atau ICA mirip dengan analisis komponen utama (PCA), dengan pengecualian bahwa komponen-komponennya independen dan tidak berkorelasi. ICA digunakan terutama untuk memisahkan sinyal sumber yang tidak diketahui dari campuran linier yang diamati setelah campuran linier dengan matriks yang tidak dikenal (A). Tidak ada informasi yang diketahui tentang sumber atau proses pencampuran kecuali bahwa ada N campuran terekam yang berbeda. Tugasnya adalah memulihkan versi (U) dari sumber (S) yang identik kecuali untuk penskalaan dan permutasi, dengan menemukan


matriks persegi (W) yang menentukan filter spasial yang secara linier membalikkan proses pencampuran, yaitu $U = WX$. Memaksimalkan entropi gabungan, $H(y)$, dari keluaran prosesor saraf meminimalkan informasi timbal balik di antara komponen keluaran (Lihat [Gambar 11.2](#)).



GAMBAR 11.2 Analisis komponen independent

11.2.3 Pengode Otomatis

Autoencoder termasuk dalam keluarga jaringan saraf (Referensi [Ara. 11.3](#)) dan mirip dengan Principal Component Analysis (PCA). Keduanya lebih fleksibel daripada PCA. Autoencoder merepresentasikan transformasi linear dan non-linear, sedangkan PCA hanya merepresentasikan transformasi linear. Target output jaringan neural (autoencoder) adalah inputnya (x) dalam bentuk yang berbeda (x'). Dalam Autoencoder, dimensionalitas input sama dengan dimensionalitas output, dan pada dasarnya yang kita inginkan adalah $x' = x$. $x' = \text{Decode}(\text{Encode}(x))$



GAMBAR 11.3 Pengode Otomatis

Untuk mendapatkan nilai dari lapisan tersembunyi, kita kalikan bobot (input ke tersembunyi) dengan input. Untuk mendapatkan nilai dari output, kita kalikan bobot (tersembunyi ke output) dengan nilai lapisan tersembunyi.

$$Z = f(\text{Lebar } x)$$

$$Y = g(Vz)$$

$$\text{Jadi } Y = g(V f(Wx)) = VWx$$

$$\text{Jadi Fungsi Tujuan } J = \sum [X_n - VWx(n)]^2$$

Heuristik untuk Autoencoder

Algoritma pelatihan Autoencoder dapat diringkas sebagai berikut:
Untuk setiap masukan x

1. Lakukan umpan maju untuk menghitung aktivasi di semua lapisan tersembunyi, lalu di lapisan keluaran untuk mendapatkan keluaran X'
2. Mengukur deviasi X' dari masukan X
3. Melakukan backpropagation kesalahan melalui jaringan dan melakukan pembaruan bobot.

11.2.4 Berbagai bentuk pengelompokan

Merujuk Bab 9 berjudul 'Pembelajaran Tanpa Pengawasan' untuk mengetahui lebih lanjut tentang berbagai bentuk Pengelompokan.

11.3 PEMBELAJARAN AKTIF

Pembelajaran aktif adalah jenis pembelajaran semi-terawasi di mana algoritma pembelajaran dapat secara interaktif mengajukan pertanyaan kepada pengguna untuk memperoleh keluaran yang diinginkan pada titik data baru.

Misalkan P adalah kumpulan populasi dari semua data yang dipertimbangkan. Misalnya, semua mahasiswa laki-laki yang belajar di perguruan tinggi diketahui memiliki pola belajar yang sangat menarik.

Selama tiap iterasi, P (total populasi) dipecah menjadi tiga subset.

1. $P(K, i)$: Titik data di mana labelnya diketahui (K).
2. $P(U, i)$: Titik data yang labelnya tidak diketahui (U)
3. $P(C, i)$: Subset dari $P(U, i)$ yang dipilih (C) untuk diberi label.

Penelitian terkini dalam jenis pembelajaran aktif ini berfokus pada identifikasi metode terbaik $P(C, i)$ untuk memilih (C) titik data.

11.3.1 Heuristik untuk pembelajaran aktif

1. Mulailah dengan kumpulan data tak berlabel $P(U, i)$
2. Pilih beberapa titik secara acak dan dapatkan labelnya $P(C, i)$
3. Mengulang Beberapa algoritma pembelajaran aktif dibangun di atas mesin vektor pendukung (SVM) untuk menentukan titik data yang akan diberi label. Metode tersebut biasanya menghitung margin (W) dari setiap datum yang tidak berlabel dalam $P(U, i)$ dan menganggap W sebagai jarak ruang n -

dimensi yang mulai mencakup datum dan bidang hiper pemisah.

Teknik minimum marginal hyperplane (MMH) menyetujui bahwa catatan data dengan margin minimum (W) adalah yang paling tidak pasti bagi SVM dan karenanya harus disimpan dalam $P(C, i)$ untuk diberi label. Pendekatan lain yang sebanding, seperti Maximum Marginal Hyperplane, memilih data dengan W yang signifikan (ruang n -dimensi). Pendekatan lain untuk memilih kombinasi W terkecil dan terbesar.

11.3.2 Strategi kueri pembelajaran aktif

Beberapa logika untuk menentukan titik data mana yang harus diberi label adalah

1. Pengambilan sampel ketidakpastian
2. Pertanyaan oleh komite
3. Perubahan model yang diharapkan
4. Pengurangan kesalahan yang diharapkan
5. Pengurangan varians

Pengambilan sampel ketidakpastian: Dalam metode ini, algoritma pembelajaran aktif pertama-tama mencoba memberi label titik-titik di mana model saat ini paling tidak spesifik (karena ini berarti banyak kebingungan) pada keluaran yang benar.

Permintaan oleh komite: Sejumlah model dilatih pada data berlabel saat ini, dan memberikan suara pada keluaran untuk data yang tidak berlabel; memberi label pada poin-poin yang paling tidak disetujui oleh 'komite'. Perubahan model yang diharapkan: Dalam metode ini, algoritma pembelajaran aktif pertama-tama mencoba memberi label pada titik-titik yang paling banyak mengubah model yang ada.

Pengurangan kesalahan yang diharapkan: Dalam metode ini, algoritma pembelajaran aktif pertama-tama mencoba memberi label pada titik-titik yang paling dapat mengurangi kesalahan generalisasi model.

Pengurangan varians: Dalam metode ini, algoritma pembelajaran aktif pertama-tama mencoba memberi label titik-titik yang akan mengurangi varians keluaran (yang juga merupakan salah satu komponen kesalahan).

11.4 PEMBELAJARAN BERBASIS INSTANCE (PEMBALASAN BERBASIS MEMORI)


Dalam pembelajaran berbasis instans (pembelajaran berbasis memori), algoritme membandingkan instans masalah baru dengan instans yang sudah terlihat dalam pelatihan, yang telah disimpan dalam memori sebagai referensi alih-alih melakukan generalisasi eksplisit. Disebut berbasis instans karena ia membangun hipotesis dari instans pelatihan (memori) itu sendiri. Kompleksitas komputasional $O(n)$ dari hipotesis dapat tumbuh ketika kita memiliki beberapa data (n). Ia dapat dengan cepat mengadaptasi modelnya ke data yang sebelumnya tidak terlihat. Instans baru disimpan atau dibuang berdasarkan kriteria yang ditetapkan sebelumnya.

Contoh pembelajaran berbasis instans meliputi algoritma K-nearest neighbor (K-NN), mesin kernel (support vector machine, PCA), dan jaringan fungsi basis radial (RBF).

Semua algoritma ini menyimpan contoh yang sudah diketahui dan menghitung jarak atau kesamaan antara contoh ini dan contoh pelatihan untuk membuat keputusan akhir. Algoritma pengurangan contoh dapat digunakan untuk mengatasi masalah kompleksitas memori dan masalah overfitting. Mari kita bahas fungsi basis radial (RBF) secara terperinci.

11.4.1 Fungsi basis radial

Jaringan fungsi basis radial (RBF) biasanya memiliki tiga lapisan: satu lapisan masukan, satu lapisan tersembunyi dengan fungsi aktivasi RBF non-linier, dan satu lapisan keluaran linier (Lihat [Ara. 11.4](#)).



GAMBAR 11.4 Fungsi Dasar Radial

Dalam diagram di atas, vektor input (x) digunakan sebagai input untuk semua fungsi basis radial, masing-masing dengan parameter yang berbeda. Lapisan input (X) hanyalah lapisan fan-out, dan tidak ada pemrosesan yang terjadi di sini. Lapisan kedua (tersembunyi) menjalankan fungsi basis radial, yang merupakan pemetaan non-linier dari ruang input (vektor X) ke ruang dimensi orde yang lebih tinggi. Output dari jaringan (Y) adalah kombinasi linear dari output dari fungsi basis radial. Jika klasifikasi pola diperlukan (dalam Y), maka fungsi hard-limiter atau sigmoid dapat ditempatkan pada neuron output untuk memberikan nilai output 0/1.

Bagian yang khas dari jaringan fungsi basis radial (RFFN) adalah prosedur yang diterapkan dalam lapisan tersembunyi. Idennya adalah bahwa pola dalam ruang masukan membentuk kluster. Di luar area ini

(area pengelompokan, area fungsi RFB), nilainya turun drastis. Fungsi Gaussian adalah fungsi basis radial yang paling umum digunakan. Dalam jaringan RBF, r adalah jarak dari pusat kluster.

Ruang (jarak) yang dihitung dari pusat kluster biasanya adalah jarak Euclidean. Untuk setiap neuron yang merupakan bagian dari lapisan tersembunyi, bobot mewakili koordinat pusat kluster. Oleh karena itu, ketika neuron tersebut menerima pola masukan, X , jaraknya ditemukan menggunakan persamaan berikut:

$$r_j = \sqrt{\sum_{i=1}^n (x_i - w_{ij})^2}$$

Variabel sigma, σ , menunjukkan lebar atau jari-jari bentuk lonceng dan harus ditentukan dengan perhitungan. Ketika jarak dari pusat Gaussian mencapai σ , output turun dari 1 menjadi 0,6.

$$(hidden_{unit})\phi_j = \exp\left(-\frac{\sum_{i=1}^n (x_i - w_{ij})^2}{2\sigma^2}\right)$$

Output $y(t)$ adalah jumlah tertimbang dari output lapisan tersembunyi, yang diberikan oleh

$$y(t) = \sum_{i=1}^n w_i \phi(\|u(t) - c_i\|),$$

Di mana

$u(t)$ adalah input $\phi(\cdot)$ adalah fungsi basis radial non linier yang sembarangan $\|\cdot\|$ menunjukkan norma yang biasanya diasumsikan Euclidean c_i adalah pusat fungsi basis radial yang diketahui, w_i adalah bobot fungsi tersebut.

Dalam fungsi radial, respons menurun (atau meningkat) secara monoton terhadap jarak dari titik pusat dan bersifat simetris radial. Pusat, skala jarak, dan bentuk pasti fungsi radial merupakan pertimbangan yang

diperlukan dari model yang ditentukan. Fungsi radial yang paling umum digunakan adalah filter radial Gaussian, yang dalam kasus input skalar adalah.

$$h(x) = \exp\left(-\frac{(x - c)^2}{\beta^2}\right)$$

Parameternya adalah pusat c dan radius β (lebar), menggambarkan RBF Gaussian dengan pusat $c = 0$ dan radius $\beta = 1$. RBF Gaussian menurun secara monoton seiring jarak dari pusat.

11.4.2 Pro dan kontra metode pembelajaran berbasis instans

Keuntungan:Metode pembelajaran berbasis instans (IBL) sangat cocok untuk permasalahan yang fungsi targetnya sangat rumit, tetapi dapat juga didefinisikan oleh sekelompok perkiraan lokal yang tidak terlalu rumit.

Kerugian I: Biaya klasifikasi kasus baru bisa tinggi (sebagian besar perhitungan dilakukan pada tahap ini).

Kerugian II:Banyak pendekatan IBL biasanya mempelajari semua karakteristik kejadian yang mengarah ke masalah terkait dimensionalitas.

11.5 RINGKASAN

Pembelajaran representasi paling banyak digunakan dalam pengenalan kata, ucapan, pemrosesan sinyal, musik, dan identifikasi gambar. Misalnya, sebuah kata dapat memiliki makna berdasarkan konteksnya.

- Analisis komponen independen, atau ICA) mirip dengan analisis komponen utama (PCA), dengan pengecualian bahwa komponen-komponennya independen dan tidak berkorelasi.
- Autoencoder termasuk dalam keluarga jaringan neural dan mirip dengan PCA (Principal Component Analysis). Autoencoder lebih fleksibel daripada PCA. Pembelajaran aktif adalah jenis pembelajaran semi-supervised di mana algoritma pembelajaran dapat secara interaktif mengajukan pertanyaan kepada pengguna untuk memperoleh keluaran yang diinginkan pada titik data baru.
- Pengambilan sampel ketidakpastian: Dalam metode ini, algoritma pembelajaran aktif pertama-tama mencoba memberi label titik-titik di mana model saat ini paling tidak spesifik (yang berarti banyak kebingungan) pada keluaran yang benar.
- Dalam pembelajaran berbasis kejadian (pembelajaran berbasis memori), algoritma membandingkan kejadian masalah baru dengan kejadian yang sudah terlihat dalam pelatihan, yang telah disimpan dalam memori untuk referensi daripada melakukan generalisasi eksplisit.
- Contoh pembelajaran berbasis instans meliputi algoritma K-nearest neighbor (K-NN), mesin Kernel (Support Vector Machine, PCA), dan jaringan Radial Basis Function (jaringan RBF).
- Jaringan fungsi basis radial (RBF) biasanya memiliki tiga lapisan: satu lapisan masukan, satu lapisan tersembunyi dengan fungsi aktivasi RBF non-linier, dan satu lapisan keluaran linier.

C SOAL PILIHAN GANDA (SOAL 1 NILAI)

1. Nama lain dari pembelajaran representasi adalah ____
 1. Pembelajaran fitur
 2. Giat belajar
 3. Pembelajaran berbasis instans
 4. Pembelajaran secara berkelompok
2. Dalam pembelajaran representasi, ketika penyebab yang tidak diketahui (H) digabungkan, ia juga dapat menghasilkan data (V), yang disebut sebagai ____
 1. Pengakuan
 2. Generasi
 3. Perwakilan
 4. Yg mengkombinasikan
3. Ketika penyebab (H) menjelaskan data (V) yang kita amati, maka disebut sebagai
Bahasa Indonesia: ____
 1. Pengakuan
 2. Generasi
 3. Perwakilan
 4. Yg mengkombinasikan
4. Ketika penyebab yang tidak diketahui (H) digabungkan, maka dapat juga menghasilkan data (V), disebut sebagai ____
 1. Pengakuan
 2. Generasi
 3. Perwakilan
 4. Yg mengkombinasikan
5. Analisis komponen independen mirip dengan

1. Analisis ketergantungan
2. Analisis Sub Komponen
3. Analisis data
4. Analisis komponen utama
6. Dalam metode ini, algoritma pembelajaran aktif pertama-tama mencoba memberi label pada titik-titik di mana model saat ini paling tidak spesifik (karena ini berarti banyak kebingungan) pada keluaran yang benar.
 1. Perubahan model yang diharapkan
 2. Pertanyaan oleh komite
 3. Pengambilan sampel ketidakpastian
 4. Pengurangan kesalahan yang diharapkan

BAB 12 ALGORITMA PEMBELAJARAN ATURAN ASOSIASI

Santi Prayudani,S.Kom.,M.Kom.

A.Tujuan Pembelajaran

Pembelajaran aturan asosiasi adalah metode yang mengekstraksi aturan yang paling baik menjelaskan hubungan yang diamati antara variabel dalam data. Aturan ini dapat menemukan asosiasi yang penting dan berguna secara komersial dalam kumpulan data multidimensi besar yang dapat dimanfaatkan oleh suatu organisasi. Algoritma pembelajaran aturan asosiasi yang paling populer adalah algoritma Apriori dan proses Eclat.

12.1 Algoritma Apriori

Apriori dirancang untuk berfungsi pada basis data besar yang berisi berbagai jenis transaksi (misalnya, koleksi produk yang dibeli oleh pelanggan, atau detail situs web yang sering dikunjungi oleh pelanggan). Algoritma Apriori menggunakan metode 'bottom-up', di mana subset berulang diperluas satu item pada satu waktu (langkah ini dikenal sebagai pembuatan kandidat, dan kelompok kandidat diuji terhadap data). Algoritma Apriori adalah algoritma yang kuat untuk penambangan itemset secara berkala untuk aturan asosiasi boolean. Lihat [Bab 9](#) berjudul

'pembelajaran tanpa pengawasan' untuk memahami lebih lanjut tentang algoritma ini.

12.2 Algoritma Eclat

ECLAT adalah singkatan dari 'Equivalence Class Clustering and bottomup Lattice Traversal'. Algoritma Eclat adalah kumpulan lain dari pembangkitan frequent itemset yang mirip dengan algoritma Apriori. Tiga pendekatan traversal seperti pendekatan 'Top-down', 'Bottom-up', dan Hybrid didukung. ID transaksi (daftar TID) disimpan di sini. Ini mewakili data dalam format vertikal.

Langkah 1: Dapatkan ID Transaksi: tidlist untuk setiap item (pemindaian DB).

Langkah 2: ID Transaksi (tidlist) {a} adalah daftar transaksi yang mencakup {a}.

Langkah 3: Potong tidlist {a} dengan tidlist semua item lainnya, sehingga menghasilkan tidlist {a,b}, {a,c}, {a,d}, ... = {a}-basis data bersyarat (jika {a} dihilangkan).

Langkah 4: Ulangi dari 1 pada {a}-database bersyarat 5. Ulangi untuk semua item lainnya.

12.3 ALGORITMA PEMBELAJARAN ENSEMBLE

Ensemble berarti kolaborasi/gabungan/kelompok. Metode ensemble adalah model yang berisi banyak model yang lebih lemah yang dilatih secara otonom dan yang perkiraannya digabungkan secara perkiraan untuk membuat model prediksi keseluruhan. Diperlukan upaya lebih besar untuk mempelajari jenis-jenis pembelajar yang lemah dan berbagai cara untuk menggabungkannya.

Algoritma pembelajaran ensemble yang paling populer adalah:

- Agregasi Bootstrap (bagging)
- Meningkatkan
- AdaBoost
- Generalisasi Bertumpuk (Pencampuran)
- Mesin Pendorong Gradien (GBM)
- Pohon Regresi yang Didorong
- Gradien (GBRT) Hutan Acak

12.3.1 Agregasi bootstrap (Bagging)

Agregasi Bootstrap (bagging) bekerja menggunakan prinsip metode pengambilan sampel Bootstrap. Diberikan set data pelatihan D yang berisi m contoh, metode penggambaran bootstrap mengambil sampel contoh pelatihan D_i , dengan memilih m contoh secara acak dan seragam dengan penggantian. Metode ini terdiri dari dua fase yaitu fase Pelatihan dan Fase Klasifikasi.

Tahap Pelatihan:

1. Inisialisasi parameter
2. $D = \{P\}$
3. H = jumlah klasifikasi
4. Untuk $k = 1$ sampai h
5. Ambil sampel bootstrap S_k dari set pelatihan S
6. Membangun pengklasifikasi D_k menggunakan S_k sebagai set pelatihan
7. $D = D \cup D_i$
8. Kembali D

Tahap Klasifikasi:

1. Jalankan $D_1, D_2, \dots, D_k$ pada input x
2. Kelas dengan jumlah suara terbanyak dipilih sebagai label untuk x .

Original Sample	1	2	3	4	5	6	7	8
------------------------	----------	----------	----------	----------	----------	----------	----------	----------

Bootstrap Sample 1	1	1	2	8	3	4	5	3
Bootstrap Sample 2	1	4	5	7	4	5	1	2
Bootstrap Sample 3	5	2	1	2	1	8	4	2
Bootstrap Sample 4	7	4	2	8	5	6	6	6

Dalam contoh di atas, sampel asli memiliki delapan titik data. Semua sampel Bootstrap juga memiliki delapan titik data. Dalam sampel bootstrap yang sama, titik data diulang karena pemilihan dengan penggantian.

12.3.2 Meningkatkan

Sama seperti bagging, boosting adalah teknik lain yang berbasis pada ensemble. Boosting adalah teknik berulang. Teknik ini mengurangi kesalahan bias. Jika sebuah observasi diklasifikasikan secara tidak tepat, maka teknik ini akan meningkatkan bobot observasi tersebut. Dalam jenis ensemble ini, model pembelajaran yang lebih lemah dilatih pada data yang diambil sampelnya kembali, dan hasilnya digabungkan menggunakan pendekatan pemungutan suara berbobot berdasarkan kinerja berbagai model. Boosting adaptif atau AdaBoost adalah varian khusus dari algoritma boosting. Teknik ini didasarkan pada gagasan untuk menghasilkan pembelajar yang lemah dan belajar secara perlahan.

12.3.3 Mesin penguat gradien (GBM)

Seperti yang telah kita ketahui, boosting adalah algoritma pembelajaran mesin, yang meningkatkan pembelajar yang lemah menjadi pembelajar yang kuat. Kita mungkin telah mengetahui bahwa seorang pembelajar memperkirakan fungsi target dari data pelatihan. Gradient boosting adalah boosting dengan Gradient.

Gradien: Pertimbangkan L sebagai fungsi dari variabel ke- i , variabel $N - 1$ lainnya ditetapkan pada titik saat ini, dengan menghitung turunan L pada titik tersebut (L dapat dibedakan), kita memiliki – jika turunannya positif/negatif – penurunan/kenaikan nilai variabel ke- i untuk membuat kerugian lebih kecil (*). Menerapkan perhitungan di atas untuk semua $i = 1 \dots N$, kita akan mendapatkan nilai turunan N yang membentuk vektor, yang disebut gradien fungsi variabel N pada titik saat ini.

12.4.7 ALGORITMA REGULASI

Ini adalah perluasan yang dibuat untuk metode lain (biasanya metode regresi) yang memberi sanksi pada model berdasarkan kompleksitasnya, dengan mengutamakan model yang lebih sederhana yang juga lebih baik dalam melakukan generalisasi. Algoritme regularisasi telah dicantumkan secara terpisah di sini karena algoritme tersebut terkenal, berpengaruh, dan umumnya merupakan modifikasi sederhana yang dibuat pada metode lain.

Algoritma regularisasi yang paling populer adalah

- Regresi Punggungan.
- Operator Penyusutan dan Pemilihan Absolut Terkecil (LASSO).
- Jaring Elastis.
- Regresi Sudut Terkecil (LARS)

Merujuk **Bab 8** berjudul “Supervised Learning: Regression” untuk regresi Ridge dan metode LASSO.

Jaring Elastis

Ketika kita bekerja dengan kumpulan data berdimensi tinggi dengan sejumlah besar variabel independen, korelasi (hubungan) di antara variabel-variabel tersebut sering kali dapat mengakibatkan multikolinearitas. Variabel-variabel berkorelasi yang benar-benar terkait ini terkadang dapat membentuk kelompok atau kluster yang disebut jaring elastis variabel berkorelasi. Kita ingin menyertakan kelompok lengkap dalam pemilihan model meskipun hanya satu variabel yang dipilih.

12.5 RINGKASAN

Nama lain untuk pembelajaran representasi adalah pembelajaran fitur.

- Pembelajaran aturan asosiasi adalah metode yang mengekstrak aturan yang paling baik menjelaskan hubungan yang diamati antara variabel dalam data. Aturan ini dapat menemukan asosiasi penting dan berguna secara komersial dalam kumpulan data multidimensi besar yang dapat dimanfaatkan oleh suatu organisasi.
- Apriori dirancang untuk berfungsi pada basis data besar yang berisi berbagai jenis transaksi (misalnya, kumpulan produk yang dibeli pelanggan, atau detail situs web yang sering dikunjungi pelanggan).
- ECLAT merupakan singkatan dari “Equivalence Class Clustering and bottom-up Lattice Traversal.” Algoritma Eclat merupakan kumpulan frequent itemset generation yang serupa dengan algoritma Apriori. Tiga pendekatan traversal

seperti pendekatan “Topdown,” “Bottom-up” dan Hybrid didukung.

- Ensemble berarti kolaborasi/gabungan/kelompok. Metode ensemble adalah model yang berisi banyak model yang lebih lemah yang dilatih secara otonom dan perkiraannya digabungkan secara kira-kira untuk membuat model prediksi keseluruhan.

5. Pertanyaan oleh komite

6. Pengambilan sampel ketidakpastian

7. Pengurangan kesalahan yang diharapkan

7. Manakah dari berikut ini yang bukan merupakan jenis algoritma pembelajaran Ensemble?

1. Meningkatkan

2. AdaBoost

3. GBM

4. Jaring Elastis

SOAL JAWABAN SINGKAT (SOAL 5 NILAI)

1. Tulis catatan tentang Elastic Net
2. Sebutkan berbagai jenis algoritma regularisasi
3. Apa itu Gradient?
4. Apa itu Agregasi Bootstrap (Bagging)?
5. Sebutkan berbagai jenis algoritma pembelajaran Ensemble

SOAL JAWABAN PANJANG (SOAL 10 NILAI)

1. Bahas berbagai Algoritma Pembelajaran Aturan Asosiasi secara terperinci.
2. Apa itu Algoritma Pembelajaran Ensemble? Bahas berbagai jenisnya.

DAFTAR PUSTAKA

- Badieah, B., Gernowo, R., & Surarso, B. (2016). Metode Jaringan Syaraf Tiruan Untuk Prediksi Performa Mahasiswa Pada Pembelajaran Berbasis Problem Based Learning (PBL). *JURNAL SISTEM INFORMASI BISNIS*, 6(1), 46. <https://doi.org/10.21456/vol6iss1pp46-58>
- Bhaumik, A. (2018). From AI to Robotics. In *From AI to Robotics*. <https://doi.org/10.1201/9781315372549>
- Eni. (1967). Machine Learning (ets.). *Angewandte Chemie International Edition*, 6(11), 951–952., *Mi*, 5–24.
- Mubarokh, M. F., Nasir, M., & Komalasari, D. (2020). Jaringan Syaraf Tiruan Untuk Memprediksi Penjualan Pakaian Menggunakan Algoritma Backpropagation. In *Journal of Computer and Information Systems Ampera* (Vol. 1, Issue 1). <https://journal-computing.org/index.php/journal-cisa/index>
- Nasir, J. (2024). Kecerdasan Buatan - (Aplikasi Kecerdasan Buatan). In *Mengenal Teknologi Informasi*. <http://dymand-informatika.blogspot.co.id/2012/04/kecerdasan-buatan-aplikasi-kecerdasan.html>
- Rahmadani, F., & Pardede, A. M. (2021). JARINGAN SYARAF TIRUAN PREDIKSI JUMLAH PENGIRIMAN BARANG MENGGUNAKAN METODE BACKPROPAGATION (STUDI KASUS: KANTOR POS BINJAI). *Jurnal Teknik Informatika Kaputama (JTIK)*, 5(1).
- Shidiq, F. (2021). Penerapan Metode K-Nearest Neighbor (KNN) Untuk Menentukan Ikan Cupang Dengan Ekstraksi Fitur Ciri Bentuk Dan Canny. *Innovation in Research of Informatics (INNOVATICS)*, 3(2), 39–46. <https://doi.org/10.37058/innovatics.v3i2.3093>
- Suahati, A. F., Nurrahman, A. A., & Rukmana, O. (2022). Penggunaan Jaringan Syaraf Tiruan – Backpropagation dalam Memprediksi Jumlah Mahasiswa Baru. *Jurnal Media Teknik Dan Sistem Industri*, 6(1), 21. <https://doi.org/10.35194/jmtsiv6i1.1589>
- Wang, H., Czerminski, R., & Jamieson, A. C. (2021). Neural Networks and Deep Learning. *The Machine Age of Customer Insight*, 91–101.

- <https://doi.org/10.1108/978-1-83909-694-520211010>
- Wijayakusuma, I. G. N. L., & Emik Sapitri, N. K. (2020). Penerapan Jaringan Syaraf Tiruan Dalam Pembentukan Model Peramalan Angka Melek Huruf di Kabupaten Karangasem. *Jurnal Matematika*, 10(1), 11. <https://doi.org/10.24843/jmat.2020.v10.i01.p119>
- Zein, A., Pohan, Z. R. H., Idris, M. N., Ramli, Anwar, Paisal, J., Wira, J., Putra, G., Grace, Y., benardi, Permana, N., & Wijayanti, F. (2023). Putra, Jan Wira Gotama. (2020). Pengenalan Pembelajaran Mesin dan Deep Learning. *Jurnal Studi Alquran Dan Tafsir*, 4(1), 29–38. <https://jurnal.pranataindonesia.ac.id/index.php/jik/article/download/96/49>
- Achmad, A. D., Zainuddin, Z., Toding, J., & Kalau, R. (2016). Sistem keamanan perumahan berbasis mikrokontroler arduino uno. *Jurnal Ilmiah Techno Entrepreneur Acta*, 1(1), 1–8.
- Achyansyah, M. N. (2022). Kajian Analisis Kritis Norman Fairclough Dalam Pemberitaan Project Multatuli “Wadon Wadas Menjaga Alam Untuk Anak-Cucu.” *Jurnal Ilmiah Widya Sosiopolitika*, 4(2), 85. <https://doi.org/10.24843/jiwsp.2022.v04.i02.p02>
- Bahrudin, M. A., Niswatin, R. K., & Wahyuniar, L. S. (2021). *Sistem Pendukung Keputusan Penentuan Ekstrakurikuler Siswa SMK Al- Asy ' ariyah Prambon Dengan Metode K-Nearst Neighbor (KNN)*. 185–192.
- Bhaumik, A. (2018). From AI to Robotics. In *From AI to Robotics*. <https://doi.org/10.1201/9781315372549>
- Darmawan, A. S., Informatika, T., K-nn, A., Kepegawaian, S., & Mengajar, T. (2017). *Penentuan metode klasifikasi menggunakan algoritma knn untuk penerbitan surat keputusan sertifikasi guru*.
- Ferraz, A., Soares, F., & Carvalho, V. (2013). A Prototype for Blood Typing Based on Image Processing. *SENSORDEVICES 2013, The Fourth International Conference on Sensor Device Technologies and Applications, c*, 139–144.

- Ghalib, M. R., Bhatnagar, S., Jayapoorani, S., & Pande, U. (2014). *Artificial Neural Network based Detection of Renal Tumors using CT Scan Image Processing*. 6(1), 28–35.
- Iqbal. (2017). *Penerapan Metode Fuzzy Tahani Pada Sistem Pendukung Keputusan Penerima Beasiswa*. 9, 36–39.
- Irfan, M., Alam, C. N., & Tresna, D. (2019). Implementation of Fuzzy Mamdani Logic Method for Student Drop Out Status Analytics. *Journal of Physics: Conference Series*, 1363(1), 0–10. <https://doi.org/10.1088/1742-6596/1363/1/012056>
- Kazaryan, D. E., & Savinkov, A. V. (2017). Grammatical Evolution for Neural Network Optimization in the Control System Synthesis Problem. *Procedia Computer Science*, 103(October 2016), 14–19. <https://doi.org/10.1016/j.procs.2017.01.002>
- Mbagho, A., O. Meo, M., & Rinduh Iriane, G. (2023). Sistem Pakar Diagnosa Hama Penyakit Tanaman Tomat Menggunakan Metode Forward Chaining. *Jurnal Sains Dan Komputer*, 7(01), 25–30. <https://doi.org/10.61179/jurnalinfact.v7i01.383>
- Nasir, J. (2024). Kecerdasan Buatan - (Aplikasi Kecerdasan Buatan). In *Mengenal Teknologi Informasi*. <http://dymand-informatika.blogspot.co.id/2012/04/kecerdasan-buatan-aplikasi-kecerdasan.html>
- Nhita, F., Adiwijaya, Wisesty, U. N., & Ummah, I. (2015). Planting calendar forecasting system using evolving neural network. *Far East Journal of Electronics and Communications*, 14(2), 81–92. <https://doi.org/10.17654/FJECJun2015-081-092>
- Nidhi. (2015). *Image Processing and Object Detection*. 1(9), 396–399.
- Noorian, F., Silva, A. M. De, & Leong, P. H. W. (2015). *Grammatical Evolution : A Tutorial using gramEvol*. 1–16.
- O'Neill, M., Ryan, C., & Nicolau, M. (2001). Grammar Defined Introns: An Investigation into Grammars, Introns, and Bias in Grammatical Evolution. *GECCO '01: Proceedings of the Genetic and Evolutionary Computation Conference (GECCO-2001)*, 97–103.

- Passarella, R., Sutarno, & Ahmad Rezqy, F. F. (2014). Implementation of image segmentation using RGB color detection on virtual reality robot as spy tool. *International Conference on Electrical Engineering, Computer Science and Informatics (EECSI)*, 1(August), 374–379. <https://doi.org/10.11591/eecsi.1.400>
- Patel, V. G., State, G., & State, G. (2018). *Human face detection and tracking*. 9(4), 187–195.
- Perdana Sari, Y. (2024). *Komunikasi Data dan Jaringan*. 1–23.
- Pohlheim, H. (2006). Evolutionary Algorithms: Overview, Methods and Operators. *Population (English Edition)*, 8(December), 95. http://www.geatbx.com/download/GEATbx_Intro_Algorithmen_v38.pdf
- Putri, A. D., & Suhendra, D. (2016). Sistem Pakar Untuk Mendeteksi Kerusakan Air Conditioner Menggunakan Metode Forward Chaining Berbasis Web. *Jurnal Inovtek Polbeng*, 1(2), 148–160. <https://doi.org/10.1145/2533670.2533675>
- Shekhawat, R. S., Sain, A., & Bhardwaj, G. (2016). *Automatic Intelligence Car Robot*. 2(10), 504–508.
- Singh, C., Singh, S., & Baheti, P. (2014). Human Face Recognition and Face Detection using Skin Colour Model. *International Journal of Current Engineering and Techonology*, 4(4), 2503–2505.
- Sinta, T., Nugroho, J., Linawati, L., & Mahatma, T. (2019). *International Journal of Active Learning Analysis of Lecturers Competency Performance Evaluation using Fuzzy Modeling*. 4(2), 99–113.
- Sutojo, Mulyanto, E., & Suhartono, V. (2011). *KECERDASAN BUATAN*.
- Swetha, C. S. (2020). *Intruder detection security system*. 1170–1174.
- T, A. J., Yanosma, D., & Anggriani, K. (2017). Implementasi Metode K-Nearest Neighbor (Knn) Dan Simple Additive Weighting (Saw) Dalam Pengambilan Keputusan Seleksi Penerimaan Anggota Paskibraka. *Pseudocode*, 3(2), 98–112. <https://doi.org/10.33369/pseudocode.3.2.98-112>

- Wang, J., Qin, Q., Zhao, J., Ye, X., Feng, X., Qin, X., & Yang, X. (2015). Knowledge-based detection and assessment of damaged roads using post-disaster high-resolution remote sensing image. *Remote Sensing*, 7(4), 4948–4967. <https://doi.org/10.3390/rs70404948>
- Xinjie, Y., & Mitsuo, G. (2010). Introduction to Evolutionary Algorithms. In *Springer-Verlag* London. <https://doi.org/10.1017/CBO9781107415324.004>
- Yovita, L. V., Wibowo, T. A., Irawati, I. D., Santoso, I. H., Astuti, S., & Ramadha, A. A. (2023). Jaringan Komunikasi Data dan Perkembangannya. In *CV Widina Media Utama*.

PENGANTAR PEMBELAJARAN MACHINE LEARNING

Buku ini berisi pemahaman menyeluruh tentang konsep pembelajaran mesin. Tidak hanya mahasiswa, tetapi juga profesional perangkat lunak akan menemukan berbagai teknik dengan pembahasan yang memadai dalam buku ini yang memenuhi kebutuhan lingkungan profesional. Manajer teknis akan memperoleh wawasan tentang penerapan pembelajaran mesin ke dalam keseluruhan proses rekayasa perangkat lunak. Mahasiswa, pengembang, dan manajer teknis dengan latar belakang dasar ilmu komputer akan merasa materi dalam buku ini mudah dibaca. Setiap bab dimulai dengan paragraf pengantar, yang memberikan gambaran umum bab tersebut beserta tabel cakupan bab yang mencantumkan topik-topik yang dibahas dalam bab tersebut. Contoh pertanyaan di akhir bab membantu siswa mempersiapkan diri untuk ujian. Poin-poin pembahasan dan Poin-poin untuk direnungkan yang diberikan di dalam bab-bab membantu memperjelas dan memahami bab-bab tersebut dengan mudah dan juga mengeksplorasi kemampuan berpikir siswa dan profesional. Ringkasan diberikan di akhir setiap bab untuk tinjauan singkat topik-topik tersebut. Di seluruh buku ini, Anda akan melihat banyak latihan dan pertanyaan diskusi. Jangan lewatkan latihan-latihan ini – latihan-latihan ini penting untuk memahami konsep-konsep machine learning secara menyeluruh. Buku ini dimulai dengan pengantar tentang Pembelajaran Mesin yang menjadi landasan teori untuk bab-bab selanjutnya. Pemodelan, Rekayasa fitur, dan probabilitas dasar dibahas sebagai bab-bab sebelum memasuki dunia pembelajaran mesin yang membantu memahami konsep pembelajaran mesin dengan mudah di lain waktu.



Penerbit
Gita Lentera

Office1: Perm. Permata hijau regency blok F/1 kelurahan Pisang
kecamatan Pauh kota Padang, Sumatera Barat
Office2: Jl Weling no120 Gejayan, Yogyakarta
Cp. Admin: +62823-8699-7194
git4lenter4@gmail.com www.gitalentera.com



IKAPI
IKATAN PENERBIT INDONESIA

Anggota IKAPI
No. 042/SBA/2023